

中国科学技术大学

University of Science and Technology of China

博士学位论文



论文题目

基于结构和稀疏特性的车道线

检测算法研究

作者姓名

刘彬辉

学科专业

控制科学与工程

导师姓名

凌强 教授

完成时间

二〇二四年十月

中国科学技术大学 博士学位论文



基于结构和稀疏特性的车道线 检测算法研究

作者姓名： 刘彬辉

学科专业： 控制科学与工程

导师姓名： 凌强 教授

完成时间： 二〇二四年十月二十八日

University of Science and Technology of China
A dissertation for doctor's degree



Research on Lane Detection based on Structure and Sparsity Characteristics

Author: Binhui Liu

Speciality: Control Science and Engineering

Supervisor: Prof. Qiang Ling

Finished time: October 28, 2024

摘 要

近年来,随着全球汽车保有量的持续增加,交通事故导致的伤亡人数也在不断上升,每年有超过一百万人丧生,两千万人受伤。发展自动驾驶技术是减少交通事故、提升道路安全的有效途径。车道线检测,作为自动驾驶系统中的关键技术之一,为车辆提供了基础的导航信息。然而,受到车道线内在特性以及外部环境因素的影响,复杂环境下的车道线检测仍然是一个极具挑战性的任务。一方面,车道线具有形状和朝向多样、结构细长空间跨度大、像素稀疏车道纹理不明显的特点,使得车道线比常规目标的识别难度更大。另一方面,恶劣天气、极端光照、交通干扰和标线异常等复杂外部因素,使得有限的车道线视觉线索更加难以捕捉,进一步增加了车道线检测任务的难度。

现有的研究工作大多依赖不稳定的视觉线索实现车道线检测,存在车道线结构表示不够灵活、车道线结构预测不够可靠以及计算效率不高的问题,难以满足实际驾驶场景中的应用需求。本文对上述三个问题展开深入研究,并从车道线自身的结构和稀疏特性出发,提出了一系列针对性的解决方案。本文的主要工作和创新点如下:

1) 针对现有线性锚形状固定、难以适应不同形状和朝向车道线的问题,提出了一种基于超锚的车道线检测方法 HANet,以提升车道线结构表示的灵活性。该方法根据输入图片动态生成一组具有行列混合表示的超锚,这些超锚在形状灵活性和可靠程度上优于传统的密集线性锚,能够更准确地拟合各种形状和朝向的车道线。此外,现有的全尺寸特征增强方法存在容易向车道线特征中引入背景噪声、效率低下的问题, HANet 提出了多种车道位置敏感的特征增强方法,包括自适应感受野的车道线描述子构建和基于注意力机制的特征信息流构建。前者通过收集行内的邻域线索,扩充车道描述子的信息丰富度,后者利用注意力机制在车道内和车道间实现高效的跨区域信息传递。实验结果表明, HANet 通过建立灵活高效的车道线结构表示与信息传递机制,提升了对弯道、水平车道以及其他困难车道样本的检测准确率。

2) 针对复杂环境下车道线检测容易出现锯齿、断裂等不可靠结构的问题,提出了一种基于多车道片段的车道线检测方法 LaneSegNet,以提高车道线结构预测的鲁棒性。该方法提出了一种渐进式的车道线检测流程:首先提取显著线索区域的可靠参考点,然后基于相对偏移预测,关联参考点周围的车道点构建局部车道片段,最后利用多个车道片段重构完整车道线。LaneSegNet 将车道点表示为具有多层级和非对称结构的图节点。它通过局部和全局图增强模块分别捕捉车道片段内和参考点之间的多层级拓扑结构。另外,图节点间的非对称权重设计增

强了模型的推理能力。例如，被遮挡的车道点难以直接定位，可以依赖其他可靠的车道点位置进行推理，反之则不成立。此外，该方法还通过学习车道点间的相对偏移，强化了模型对车道点相对空间位置的理解。实验结果表明，LaneSegNet 利用车道线平滑连续的结构知识，增强了在复杂环境下车道线检测的结构鲁棒性。

3) 针对稀疏车道线在 Transformer 架构中感知困难和计算冗余大的问题，提出了一种基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer。该方法首先提出了一种稀疏的车道感知查询，其具有明确的物理位置，并能够动态更新，从而展现出比密集线锚和高维查询更精确的车道线定位能力。另外，注意力机制的计算复杂度正比于序列长度的平方，而车道线像素在图像中较为稀疏，带来了大量背景计算冗余。例如，在 CULane 数据集中车道像素占比仅为 3.6%，导致车道线与背景的计算比接近 1: 700。为了降低计算冗余，Sparse LaneFormer 提出了车道标记选择器和线性可形变采样器，用于在车道标记之间建立稀疏交互。车道标记选择器在编码器中有选择性地更新稀疏车道标记，而线性可形变采样器则在解码器中沿车道感知查询位置，准确地采样稀疏车道特征。Sparse LaneFormer 专注于最具信息量的稀疏车道标记，仅利用图像中 10% 的像素进行计算，实现了 80% 的计算开销降低和近 5 倍速度提升。在性能上，Sparse LaneFormer 不仅超越了现有基于密集设计的车道线检测方法，还成为首个性能超越卷积网络架构的端到端车道线检测方法，从而验证了稀疏设计在车道线检测任务中的可行性和有效性。

关键词：车道线检测；结构建模；稀疏表征；超锚；图神经网络；端到端检测

ABSTRACT

In recent years, with the continuous increase in the global number of vehicles, the number of casualties caused by traffic accidents has been rising, with over one million people dying and twenty million injured each year. The development of autonomous driving technology is an effective way to reduce traffic accidents and enhance road safety. Lane detection, as one of the key technologies in autonomous driving systems, provides vehicles with fundamental navigation information. However, lane detection in complex environments remains an extremely challenging task due to the inherent characteristics of the lanes and the influence of external environmental factors. On one hand, lanes have diverse shapes and orientations, slender structures with large spatial spans, and sparse pixel distribution with inconspicuous lane textures, making the identification of lanes more difficult than that of conventional targets. On the other hand, adverse weather conditions, extreme lighting, traffic interference, and abnormal markings make the limited visual cues of the lanes even more difficult to capture, further increasing the difficulty of the lane detection task.

Existing research work largely relies on unstable visual clues for lane detection, which has issues such as inflexible lane structure representation, unreliable lane structure prediction, and low computational efficiency, making it difficult to meet the application requirements in real driving scenarios. This dissertation conducts in-depth research on the aforementioned three issues and proposes a series of targeted solutions from the perspective of the structure and sparsity characteristics of the lanes themselves. The main work and innovations of this dissertation are summarized as follows:

1) To tackle the problem that existing line anchor shapes are fixed and unable to adapt to lanes of various shapes and orientations, this dissertation proposes a hyper-anchor-based lane detection method, named HANet, to enhance the flexibility of lane structure representation. This method dynamically generates a set of hyper-anchors with a mixed representation of rows and columns based on the input image. These hyper-anchors are superior to traditional dense line anchors in terms of shape flexibility and reliability, and can more accurately fit lanes of various shapes and orientations. Moreover, existing full-size feature enhancement methods tend to introduce background noise into lane features and are inefficient. HANet introduces various lane position-sensitive feature enhancement methods, including the construction of adaptive receptive field lane descriptors and the construction of feature information flow based on atten-

tion mechanisms. The former enriches the information of lane descriptors by collecting neighborhood clues within rows, while the latter utilizes attention mechanisms to efficiently transfer information across regions within and between lanes. Experimental results demonstrate that HANet improves the detection accuracy for curved and horizontal lanes, as well as other challenging lane samples, by establishing a flexible and efficient lane structure representation and information transmission mechanism.

2) To address the issue of unreliable structures such as jaggies and breaks in lane detection under complex environments, this dissertation presents LaneSegNet, a lane detection method based on multiple lane segments, to enhance the robustness of lane structure modeling. This method introduces a progressive lane detection process. First, it extracts reliable reference points from salient clue areas. Then it predicts and associates lane points around the reference points to construct local lane segments based on relative offset prediction, and finally reconstructs the complete lane using multiple lane segments. LaneSegNet represents lane points as graph nodes with hierarchical and asymmetric structures. It captures the hierarchical topological structure within lane segments and between reference points through local and global graph enhancement modules, respectively. Additionally, the asymmetric weight design between graph nodes enhances the model's inferential capability. For instance, occluded lane points that are difficult to locate directly can be inferred based on the positions of other reliable lane points, but not vice versa. Furthermore, by learning the relative offsets between lane points, the model strengthens its understanding of the relative spatial positions of lane points. Experimental results show that LaneSegNet, by leveraging the smooth and continuous structural knowledge of lanes, enhances the structural robustness of lane detection in complex environments.

3) To address the difficulties in perception and the large computational redundancy caused by the sparse characteristics of lanes in Transformer architecture, this dissertation proposes a fully sparse end-to-end lane detection method, called Sparse LaneFormer. Sparse LaneFormer proposes a sparse lane-aware query that provides a clear physical location and demonstrates more precise lane localization capabilities than dense line anchors and high-dimensional queries. Furthermore, given that the computational complexity of the attention mechanism is proportional to the square of the sequence length and that lane pixels are sparse in images, this results in considerable computational redundancy concerning the background. For instance, in the CULane dataset, the proportion of lane pixels is as low as 3.6%, resulting in a computation ratio of lane to background close to 1:700. To mitigate this computational redundancy,

Sparse LaneFormer introduces a Lane Token Selector and a Linear Deformable Sampler to establish sparse interactions among lane tokens. The Lane Token Selector selectively updates sparse lane tokens within the encoder, while the Linear Deformable Sampler accurately samples sparse lane features along the positions of the lane-aware queries in the decoder. By focusing on the most informative sparse lane tokens and utilizing only 10% of the pixels in the image for computation, Sparse LaneFormer achieves an 80% reduction in computational cost and nearly a 5-fold increase in frame per second. In terms of performance, Sparse LaneFormer surpasses existing design-prior based lane detection methods and becomes the first end-to-end lane detection method to outperform CNN architectures, thereby fully validating the feasibility and effectiveness of the proposed sparse designs.

Key Words: Lane Detection; Structure Modeling; Sparse Representation; Hyper-Anchor; Graph Neural Network; End-to-End Detection;

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	4
1.3 研究难点.....	7
1.4 本文主要工作.....	9
1.5 本文组织架构.....	11
第 2 章 车道线检测研究基础	13
2.1 传统车道线检测方法.....	13
2.1.1 图像预处理.....	13
2.1.2 手工特征提取.....	14
2.1.3 曲线拟合后处理.....	14
2.2 基于深度学习的车道线检测方法	16
2.2.1 基于像素分割的车道线检测方法.....	16
2.2.2 基于锚点检测的车道线检测方法.....	18
2.2.3 基于曲线回归的车道线检测方法.....	19
2.2.4 基于点集搜索的车道线检测方法.....	20
2.3 车道线检测数据集与评价指标	22
2.3.1 CULane 数据集与评价指标	23
2.3.2 TuSimple 数据集与评价指标	25
第 3 章 基于超锚的车道线检测算法	27
3.1 问题描述与分析.....	27
3.2 方法概述.....	29
3.2.1 基于超锚的车道线表示.....	30
3.2.2 超锚生成模块.....	32
3.2.3 自适应车道线描述子构建.....	34
3.2.4 车道内和车道间特征增强.....	35
3.2.5 优化函数.....	36
3.3 实验结果与分析.....	37
3.3.1 实验设置.....	38
3.3.2 与现有方法对比.....	38
3.3.3 可视化结果分析.....	43
3.3.4 消融实验.....	44
3.4 本章小结.....	48
第 4 章 基于多车道片段的车道线检测算法	49

4.1 问题描述与分析.....	49
4.2 方法概述.....	51
4.2.1 参考点选择.....	52
4.2.2 图增强模块.....	53
4.2.3 车道片段构建.....	55
4.2.4 优化函数.....	57
4.3 实验结果与分析.....	58
4.3.1 实验设置.....	58
4.3.2 与现有方法的对比.....	58
4.3.3 消融实验.....	63
4.4 本章小结.....	67
第 5 章 基于全稀疏设计的端到端车道线检测算法	69
5.1 问题描述与分析.....	69
5.2 方法概述.....	73
5.2.1 整体网络结构.....	73
5.2.2 车道标记选择器.....	74
5.2.3 车道感知查询.....	76
5.2.4 线性可形变采样器.....	77
5.2.5 复杂度分析.....	78
5.2.6 优化函数.....	79
5.3 实验结果与分析.....	80
5.3.1 实验设置.....	80
5.3.2 与现有方法的对比.....	80
5.3.3 可视化结果分析.....	83
5.3.4 消融实验.....	85
5.4 本章小结.....	91
第 6 章 总结与展望	93
6.1 本文内容总结.....	93
6.2 未来研究展望.....	95
参考文献.....	97

插图清单

图 1.1	主流的自动驾驶系统架构示意图	3
图 1.2	本文主要研究工作	9
图 1.3	本文组织架构	11
图 2.1	CULane 数据集中多种场景数据样本	23
图 2.2	CULane 数据集中多种场景数据比例	24
图 2.3	TuSimple 数据集中的数据样本	25
图 3.1	无车道线视觉线索问题以及两种现有解决方案。(a) 车辆遮挡与特征模糊; (b) 垂直与倾斜线性锚; (c) 全尺寸特征图车道特征增强方法。 ·	28
图 3.2	基于超锚的车道线检测方法 (HANet) 的框架	30
图 3.3	超锚与线性锚的比较	31
图 3.4	混合行列超锚表示不同朝向车道线	32
图 3.5	车道内和车道间特征增强	36
图 3.6	在 CULane 数据集弯道等挑战场景下的相对性能提升	40
图 3.7	车道线微调过程可视化	43
图 3.8	拥堵、夜间场景下剔除低置信度的误检结果	44
图 3.9	HANet 的弯道检测结果	45
图 3.10	CULane 和 TuSimple 数据集中不同驾驶场景下的车道线检测结果。从左至右依次为原图、车道真值和预测结果。	46
图 4.1	现有车道线检测方法的在结构表征方面的局限性	50
图 4.2	基于多车道片段的车道线检测方法 (LaneSegNet) 的框架	52
图 4.3	车道点层级结构、全局和局部的非对称图拓扑以及图增强块结构 ·	53
图 4.4	车道片段与车道线重构流程	56
图 4.5	LaneSegNet 与现有两类方法的最佳表现对比	60
图 4.6	基于多参考点的车道线重构流程可视化	62
图 4.7	CULane 数据集车道线检测结果对比	63
图 4.8	参考点与车道片段的可视化	65
图 5.1	车道线与常见目标的稀疏性比较	70
图 5.2	密集设计与稀疏设计对比	71
图 5.3	基于全稀疏设计的端到端车道线检测方法 (Sparse LaneFormer) 的框架	

图 5.4	车道标记选择器框架	74
图 5.5	CULane 不同驾驶场景下的检测结果	84
图 5.6	不同尺度下的图像掩模预测	84
图 5.7	不同稀疏比例下的掩模预测	85
图 5.8	车道感知查询在解码器层之间的更新过程	86
图 5.9	车道感知查询命中频率的统计和收敛后空间分布可视化	87
图 5.10	可学习车道感知查询消融实验	88
图 5.11	网络模块和操作符运行时间分析	91

表 格 清 单

表 2.1	CULane 和 TuSimple 数据集的详细信息	22
表 3.1	CULane 数据集上的实验性能对比。	39
表 3.2	模型精确率与召回率偏好分析	41
表 3.3	TuSimple 数据集上的实验性能对比。	42
表 3.4	基于行列混合超锚的车道线表示	45
表 3.5	车道位置敏感的特征增强方法消融实验	46
表 3.6	损失函数权重因子消融实验	47
表 4.1	CULane 数据集上的实验性能对比	59
表 4.2	TuSimple 数据集上的实验性能对比	61
表 4.3	组件消融实验结果, 包括全局图增强模块、局部图增强模块以及调制偏移损失。	64
表 4.4	车道节点邻接设计消融实验	65
表 4.5	参考点选择策略与参考点数量的消融实验	66
表 4.6	置信度阈值和距离阈值消融实验	67
表 5.1	密集交互和稀疏交互的计算复杂度对比	79
表 5.2	CULane 数据集上的实验性能对比	81
表 5.3	TuSimple 数据集上的实验性能对比	83
表 5.4	稀疏组件的消融实验	87
表 5.5	多尺度特征和不同采样方法的消融实验	89
表 5.6	采样点数量 K 和图像特征保留比例 α 的消融实验	90

第1章 绪 论

1.1 研究背景和意义

近年来,我国汽车产业高速发展,取得了斐然的成绩。据《2023 年汽车工业经济运行报告》^[1]统计,2023 年中国汽车市场实现“三个全球第一”——中国汽车产销量分别达到了 3016.1 万辆和 3009.4 万辆,连续 15 年保持全球第一;中国新能源汽车产销分别为 958.7 万辆和 949.5 万辆,连续 9 年位居第一;中国汽车出口量达 491 万辆,首次超越日本成为全球第一。此外,据公安部统计,2023 年中国汽车保有量达 3.36 亿辆,成为世界上汽车存量最多的国家,汽车驾驶员达 4.86 亿人。这些数据显示中国汽车市场的持续增长和庞大的汽车用户基础。随着我国乃至全球汽车保有量的增加,道路交通事故发生率也随之上升。这一现象不仅严重威胁了人民的自身安全,还造成了巨大的经济损失。据世界卫生组织(World Health Organization, WHO)最新发布的《2023 年全球道路安全现状报告》^[2]显示,自 2010 年以来,全球道路交通事故造成每年约 119 万人丧生,2000 万至 5000 万人受到非致命伤害,其中许多人因此残疾。车祸已成为全球 5 至 29 岁儿童和年轻人死亡的主要原因之一。此外,道路交通事故还给个人、家庭以及整个国家带来巨额经济损失,约占大多数国家国内生产总值的 3%。

多项研究和实际测试数据表明,自动驾驶技术对减少交通事故、提升道路安全具有积极作用。自动驾驶汽车利用多传感器融合和车路协同技术,实现全方位的环境感知,有利于提前规避风险,降低事故发生率。另外,自动驾驶汽车具有智能决策系统和精确执行系统,严格遵守交通规则,避免人类驾驶中的疲劳驾驶、酒后驾驶等危险行为。2020 年,Waymo 发布的《Waymo 公共道路安全性能数据》^[3]白皮书显示,Waymo 无人车在约 981 万公里真实道路行驶过程中仅发生了 18 起碰撞或轻微接触事故。虽然仍有事故发生,但 Waymo 无人车整体碰撞事故率已经比较低了。值得关注的是,其中 8 起伤害程度较严重的碰撞事故中,其他道路交通参与者的不合规行为是导致事故发生的主要原因。《自然·通讯》杂志相关论文^[4]基于 2100 辆配备高级自动驾驶系统的车辆和 35133 辆人类驾驶车辆在 2016 年至 2022 年间的事故数据,对真实世界中自动驾驶汽车的安全性进行了全面分析。该研究表明,自动驾驶车辆在大多数场景下比人类驾驶车辆事故更少、更安全。例如,自动驾驶车辆在保持车道位置和根据车流调整自车位置方面表现更佳。例如,自动驾驶车辆的追尾和侧面碰撞事故风险分别降低至人类驾驶车辆的 45.7% 和 17.1%。

国外自动驾驶技术的研究最早可以追溯到 20 世纪 70 年代。1977 年,日本筑波工程研究实验室开发了被认为是现代意义上第一辆自动驾驶乘用车的原型,

这辆汽车能够以每小时 30 公里的速度跟随白色路标行驶。21 世纪初，美国国防部高级研究计划局（Defense Advanced Research Projects Agency, DARPA）通过举办三届 DARPA 挑战赛，不仅极大地推动了自动驾驶技术的发展，还孵化了包括 Waymo、Cruise、Aurora、Uber、Velodyne Lidar 等在内的一系列自动驾驶公司以及传感器企业，这些企业成为推动自动驾驶技术发展的中坚力量。2004 年举办的第一届 DARPA 挑战赛在美国莫哈维沙漠地区进行。尽管没有参赛车辆完成全部赛程，卡内基梅隆大学的“红之队”（Red Team）行驶了最远的距离。2005 年第二届比赛要求参赛车辆在 10 小时内完成 212 公里的赛程，斯坦福大学的“斯坦利”（Stanley）^[5] 团队赢得了冠军。这次比赛表明自动驾驶汽车能够基于人工识别系统成功通过沙漠赛道。2007 年 DARPA 挑战赛在城市环境中进行，要求参赛车辆在 6 小时内完成 96 公里赛程，并遵守所有交通规则。卡内基梅隆大学的车辆“Boss”赢得了比赛，这标志着自动驾驶汽车技术能够在城市环境中进行自主导航。其后的数年间，大型互联网公司以及汽车制造商如谷歌、特斯拉等竞相推动自动驾驶技术的商业化。2012 年，谷歌展示了其自动驾驶汽车的原型，并在加州的公共道路上开始了测试。2015 年 10 月，特斯拉推出了第一个商用的自动驾驶辅助系统 Autopilot。2023 年 11 月，特斯拉向其员工推出了全自动驾驶^[6]（Full Self-Driving, FSD）的 V12 版本，该版本具备全新的“端到端自动驾驶”功能，首次尝试使用神经网络进行车辆控制，包括控制转向、加速和制动。

相比于国外，我国开展自动驾驶技术研究的起步时间较晚，但发展迅速。1992 年，国防科技大学、哈尔滨工业大学和沈阳自动化研究所共同研发了中国第一辆自动驾驶测试样车 ATB-1，这标志着中国自动驾驶行业的起步。长安汽车在 2016 年成为中国首个实现长距离自动驾驶测试的汽车企业。自 2020 年起，搭载百度 Apollo 系统的萝卜快跑无人出租车陆续在包括北京、上海、武汉等城市的智能网联示范区投入运营，吸引了消费者的广泛关注。2023 年 12 月，长安汽车成功获得了 17 张高快速路的 L3 级自动驾驶道路测试牌照，并在高速公路上实现了 L3 级别自动驾驶系统的应用。除了高等院校、研究所和企业的努力，中国自动驾驶技术的快速发展也离不开国家政策的大力支持。2015 年以来，国家及地方政府适时出台一系列政策和规划，进一步推动了我国自动驾驶相关产业的健康快速发展。2015 年，《中国制造 2025》计划首次将智能网联汽车的发展提升至国家战略高度，明确了自动驾驶作为汽车产业未来转型升级的重要方向。2020 年 2 月，由国家发改委、工信部等 11 部委联合发布了《智能汽车创新发展战略》，旨在加快推进智能汽车创新发展，并要求各地结合实际制定相关政策措施。该文件强调了里程碑时间节点，明确了发展战略和主要任务，指出要从多个维度确保 2025 年实现 L2 级自动驾驶规模化生产，L3 级在特定环境下的市场化应用。2022 年 8 月，交通运输部发布了《自动驾驶汽车运输安全服务指南（试行）》，向社会公

开征求意见。该文件的推出旨在适应自动驾驶技术发展的趋势，鼓励和规范自动驾驶汽车在运输服务领域应用，加快了自动驾驶汽车的大规模商业化进程。这些政策不仅体现了我国对汽车智能化发展的坚定决心和战略规划，而且通过顶层设计和具体的实施措施，为中国汽车产业的智能化转型提供了强有力的支持和保障。现阶段，自动驾驶已逐渐成为我国展现国家创新能力、研发实力和产业配套水平的新名片，整体呈现出蓬勃发展的新态势。

自动驾驶系统经过近 50 年发展至今，其核心可以概述为三个部分：分别是感知（Perception），规划（Planning）和控制（Control）模块。按照业界的主流观点^[7]，这些模块间的交互以及其与车辆硬件、其他车辆的交互关系如图1.1所示。




图 1.1 主流的自动驾驶系统架构示意图

自动驾驶系统中的感知模块主要负责利用多种传感器从环境中收集大量信息，构建并理解周围驾驶场景。规划系统是无人驾驶车辆为达成特定目标而进行有目的性决策的过程，这个目标通常是指从出发地到达目的地，同时避免障碍物，并且不断优化驾驶轨迹和行为以保证乘客的安全舒适。规划层通常细分为任务规划、行为规划和动作规划三个层次。控制模块接收规划模块输出的目标动作，并负责精确控制执行器执行既定的行驶动作。

环境感知是自动驾驶系统的核心要素之一，对实现安全可靠的自动驾驶至关重要。感知模块通过对车辆周围的多种动态（如机动车、非机动车、行人等移

动对象)和静态目标(如车道线、交通灯、标志牌等道路元素)的准确识别,构架全面的驾驶场景,为自动驾驶系统下游的规划和控制提供判断依据。其中,车道线、交通灯、标志牌等道路元素主要用于重建静态的道路结构。

车道线是最主要的道路交通标志,具备标识道路边界,划分不同的可行驶区域和规定车道行驶方向等功能,为所有交通参与者的安全行驶提供了必要的引导信息。目前,车道线检测被广泛应用于车道保持^[8](Lane Keeping, LK)、车道偏离预警^[9](Lane Departure Warning, LDW)、盲点监控^[10](Blind Spot Monitoring, BSM)、自适应巡航控制^[11](Adaptive Cruise Control, ACC)、前向碰撞预警^[12](Forward Collision Warning, FCW)等智能辅助驾驶系统中。

然而,受到车道线自身的特性以及外部环境因素影响,复杂环境下的车道线检测仍然是一个极具挑战性的任务。一方面,车道线固有的结构和稀疏特性使得车道线比常规目标的识别难度更高,即车道线形状细长,存在弯折、合并和分叉等多种结构、面积狭小,像素占比稀疏。另一方面,在实际的驾驶场景下,可能存在包括恶劣天气、极端光照、交通干扰和标线异常在内的诸多不可控的外部因素。这导致原本就有限的车道线视觉线索更加容易变得视觉不可见,进一步增加了车道线检测任务的难度。因此,车道线检测作为自动驾驶系统中的关键感知任务之一,具有显著的实际应用价值和理论研究挑战性。在此背景下,国内外学者主要围绕车道线视觉特征对车道线检测技术开展了大量研究,并取得了一系列进展。

1.2 国内外研究现状

早期的车道线检测研究主要依赖于颜色、边缘等基础图像特征。虽然基于手工特征的传统车道线检测方法设计简单且检测速度快,但它们在复杂环境下的抗干扰能力和鲁棒性较差,难以满足自动驾驶系统对车道线检测的高精度要求。近年来,深度神经网络的发展和大规模数据集的应用为解决车道线检测问题提供了新的途径。根据车道线表示形式的不同,基于深度学习的车道线检测方法主要分为四类:基于像素分割的方法、基于锚点检测的方法、基于曲线回归的方法和基于点集搜索的方法。接下来,本节将简要介绍这四类方法的优势和局限性。

(1) 基于像素分割的车道线检测方法

基于像素分割的车道线检测方法,通过逐像素分割来识别车道线,随后利用聚类和曲线拟合等后处理方法来获取车道线的参数化表示。按照分割输出形式的不同,基于分割的车道线检测方法可以进一步分为基于语义分割和基于实例分割两类。基于语义分割的方法^[13-17],首先通过二值分割提取车道线的轮廓。随后,应用聚类算法对这些车道线进行分组,以区分不同的车道线实例。这些

方法的主要区别在于它们所使用的聚类算法。例如, VPGNet^[13]采用了一种基于密度的聚类算法。LaneNet^[14]通过判别性损失函数, 使得同一车道线的嵌入(Embedding)在特征空间内更紧密地聚集, 同时使不同车道簇中心的相互远离, 并基于欧式距离的聚类得到不同车道线实例。LaneAF^[15]引入了一种基于相邻车道点方向的聚类技术, 利用水平和垂直的仿射场来指导车道点的排列方向, 增强了聚类过程的可解释性。

基于实例分割的方法^[18-25]直接预测每个车道线实例的分割图, 并通过曲线拟合来确定车道线的精确几何形状。由于车道线标记通常呈现为细长的线状结构, 这与常规的分割对象有所区别。为了提高对此类特定形状目标的分割精度, 一些研究将车道线的这种细长特性融入到神经网络架构的设计之中。例如, SCNN^[18]和 RESA^[19]采用了一种逐切片的空间卷积策略, 以增强特征图行列间像素的信息交流。CenLaneNet^[20]提出了一种结合实例分割和车道线中心定位的自适应多车道线检测框架, 通过在损失函数中引入余弦相似度度量, 增强了模型对细长车道线特征的识别能力。此外, ConvLSTM^[21]利用连续帧的时序信息, 通过融合卷积神经网络和循环神经网络的混合模型, 进一步提升了车道线分割的精度。

尽管基于分割的车道线检测方法设计简单, 但其在进行密集像素级预测时所需的计算资源和推理时间不容忽视^[22]。为了提高模型的推理速度, 研究者们将多种技术应用于车道线检测任务, 包括知识蒸馏^[22-23]、轻量级分割网络^[26-27]以及高效网络算子^[24-25, 28]。

(2) 基于锚点检测的车道线检测方法

受到目标检测中矩形锚框设计的启发, 研究者们设计了一系列密集的线性锚作为结构参考, 并通过预测车道点相对于线性锚的偏移量来实现车道线检测。这些预定义的线性锚覆盖了图像的不同区域, 以适应不同分布的车道线, 便于网络提取车道线特征。这些方法精心设计了多种类型的线性锚用于车道线检测, 包括垂直线锚^[29-30]和倾斜线锚^[31-32]。LineCNN^[33]是首个将目标检测范式应用于车道线检测的研究, 它没有明确使用线性锚来采样车道线特征, 而是在图像边界搜索可能的车道线起点并生成相应的车道线预测。PointLaneNet^[29]和 CurveLanesNAS^[30]采用了垂直线锚技术, 将特征图的每个单元格与车道的实际标注进行匹配, 并计算车道点相对于线性锚的位置偏移。然而, 由于垂直线锚与车道线的真实分布差异较大, 这可能导致垂直锚与车道线的交并比(Intersection over Union, IoU)较低, 影响车道线的准确采样。

为了克服这一问题, 后续的研究工作^[31-32]设计了更符合车道线分布特点的斜线锚, 即起始于图像的左/右/下边界向图像内延伸的射线。LaneATT^[31]通过引入锚点池化策略, 对车道线进行采样, 并结合注意力机制, 有效地从采样数据中

提取关键信息。在现实世界中，多条平行车道线通常在图像的某一点汇聚，这一点称为消失点。基于这一视觉特征，SGNet^[32]提出了一种以消失点为中心的锚点生成机制，能够生成一组结构化的线性锚，从而实现了更加稳定和精确的车道线检测。尽管这些方法取得了成功，但预定义的线性锚形状和位置固定，难以适用于不同形状和朝向的车道线，这可能导致车道线特征的采样不准确。此外，逐点的锚采样方式可能无法充分捕获临近区域的车道线细节，因而倾向于产生更多的漏检。

(3) 基于曲线回归的车道线检测方法

基于曲线回归的车道线检测方法将车道线表示为参数化曲线，并通过端到端的网络架构直接回归相应的曲线参数。这种方法涵盖了多种曲线模型，包括多项式曲线^[34-40]和贝塞尔曲线^[41-42]。Bert 等人^[34]设计了一种可微分的最小二乘拟合模块来优化车道线曲线参数。与先分割后拟合的两步处理相比，这种端到端方法增强了模型拟合步骤的稳定性，提供了更好的性能和解释性。PolyLaneNet^[35]将车道线表示为多项式曲线，并使用全连接层直接回归多项式系数，实现了有竞争力的推理速度。为了应对车道线复杂形状的挑战，PRNet^[36]采用具有不同系数的分段多项式来表示车道线。LSTR^[37]采用了卷积神经网络（Convolutional Neural Networks, CNN）与 Transformer^[43]的融合架构，以捕获车道线的全局上下文信息，并直接回归车道线的参数。但是 LSTR 基于特定车辆摄像头参数设计的曲线公式过于复杂，导致了模型训练困难。为此，PGANet^[39]在 LSTR 的基础上进行了改进，引入了均值曲率损失函数，优化了三次曲线函数对实际道路曲线的拟合效果，从而显著提高了基于参数回归的车道线检测方法性能。

多项式曲线参数的微小预测误差，尤其是高阶项系数，可能导致车道线整体定位的显著偏差。为了解决这一问题，一些研究工作^[41-42]尝试使用更稳定和更容易优化的贝塞尔曲线实现车道线检测。BezierLaneNet^[41]通过预测贝塞尔曲线多个控制点，能够实现对车道线的精确表示。与传统方法仅对高得分提议（Proposal）应用稀疏监督不同，DHPM^[42]采用了一种密集监督策略，对所有提议进行监督，以提高车道线预测在结构拓扑和空间定位方面的精度。EigenLane^[40]提出了一种基于车道线特征向量的车道线表示方法。该方法首先构建一个包含数据集中所有训练样本的坐标表示矩阵，并通过计算该矩阵的最佳秩近似得到车道线的特征向量，作为车道线表示的一组基。

(4) 基于点集搜索的车道线检测方法

基于点集搜索的车道线检测方法^[44-48]因其快速的推理速度和简洁的车道线表示而受到广泛关注。这类方法将车道线视为图像中均匀分布的一系列车道点。一些研究^[44-46]采用逐行的回归或分类策略来定位车道点。例如，UFLD^[44]和 UFLDv2^[45]将车道线检测任务重新定义为序数分类问题，并利用全局特征学习

车道的稀疏坐标。它们首先将图像划分为均匀大小的网格，并在每行识别至多一个网格作为车道点，随后通过邻近行上车道点的位置约束实现了一个空间损失函数，显著提升了检测的准确性和速度。E2ELMD^[46]提出了一种端到端的车道线检测方法，直接通过逐行坐标回归预测车道点位置。为了进一步减少计算冗余，该方法还提出了一种水平缩减模块，通过水平缩减冗余特征信息提高算法的计算效率。为了提高车道线检测的准确性，LaneFormer^[48]利用同一输入图像中的行人、车辆等目标检测结果作为辅助信息，有效减少了车道线误报。多尺度特征图被认为有助于定位小目标^[49-51]，包括细小的车道线。然而，上述方法通常使用低分辨率的深层语义特征进行车道点定位，这可能导致大量的车道线误检和漏检。

另外，为了提升对岔道等具有复杂结构的车道线检测性能，一些方法引入了条件卷积^[52]和可形变卷积^[53-54]等机制。CondLaneNet^[55]提出了一种基于条件卷积的自顶向下车道线检测框架，通过递归实例模块处理复杂拓扑结构的车道线。RCLane^[56]提出了一种基于接力链的车道线检测方法，其通过解码传递图（transfer map）和一个距离图（distance map），逐步预测下一个车道点，直至恢复完整的车道线。FOLOLane^[57]和 FastDraw^[58]则利用卷积神经网络的局部感知特性，探索车道线的局部关联性。GANet^[59]基于可形变卷积实现了一个全局关联网络，直接回归车道关键点相对于车道起始点的位置偏移，提高了算法的效率和鲁棒性。FMLane^[60]和 ECPNet^[61]分别利用嵌入向量和结构校正模块来优化车道线的结构表示。尽管这些方法在提升车道线检测的准确性和效率方面做出了贡献，但仍需进一步探索车道点之间的空间相对关系，以应对复杂环境下的车道线检测挑战。

1.3 研究难点

车道线检测在复杂环境中是一项挑战性的工作。首先，车道线本身细长、分布广泛且面积小，导致其在图像中的像素占比低，难以识别。其次，实际驾驶中可能遇到的恶劣天气、强烈光照变化、交通拥堵和标线磨损等外部因素，这导致原本就有限的车道线视觉线索更加容易变得视觉不可见，进一步增加了车道线检测任务的难度。本文重点研究车道线检测技术中存在的以下研究难点：

（1）线性锚形状固定、结构表示不灵活、难以适应不同形状和朝向车道线

受到车辆遮挡和光照变化等因素影响，车道线视觉线索缺失在实际驾驶场景中十分普遍。这导致车道线的网络特征响应变得发散和模糊，增加了车道线定位的难度。现有方法通常引入人工设计的密集线性锚，并基于线性锚实现车道线的特征采样和增强。尽管线性锚能够提供车道线的整体结构参考，并在一定程度

上提高了算法在有限视觉线索下的车道线检测性能，但它们的结构和空间位置是固定的，导致其难以适应不同形状和朝向的车道线。首先，线性锚的固定结构限制了它们对弯道、水平朝向的车道等复杂车道线的结构表示能力。其次，大量的预设锚落在背景区域，或者与车道线真实位置的 IoU 较低，这导致其采样得到的车道线描述子往往包含大量不相关的背景特征，一定程度上限制了其定位车道线的能力。此外，基于这些不够准确的车道描述子进行车道线特征增强时，还容易引入背景噪声。因此，如何灵活地表示车道线结构，并实现对车道位置敏感的高效特征增强机制，仍是当前亟需解决的问题。

（2）复杂环境下车道线检测容易出现锯齿、断裂等不可靠结构

车道线是道路表面白色或黄色的细长标线，其在图像中通常呈现为具有较大空间跨度的曲线段。与车辆、行人等结构紧凑的交通目标相比，车道线具有显著不同的视觉纹理和结构特性。现有的车道线检测方法通常将车道线表示为一组有序点集，并主要依赖于视觉线索独立地定位每个车道点，然后通过自下而上的方式重建完整的车道线。这些方法在不同程度上忽视了车道线的结构信息，特别是车道点之间的位置相关性。因此，在复杂环境下可能会产生具有锯齿状、断裂等不可靠结构的车道线检测结果。这可能导致车辆的路径规划系统错误判断车道边界，从而规划出不安全的行驶路径，增加碰撞的风险。事实上，无论车道线本身是否视觉可见，它们在空间上应始终保持平滑连续的结构特性。因此，如何充分利用车道线的结构特性，提高复杂环境下车道线结构预测的鲁棒性，是一个值得进一步探索的问题。

（3）稀疏车道线在 Transformer 架构中感知困难和计算冗余大的问题

端到端检测范式利用 Transformer 强大的关系建模能力来捕捉图像中元素之间的关系，具有性能上限高、框架简洁、拓展性强等特点，在诸多自动驾驶感知任务中得到了广泛应用。然而，在 Transformer 的注意力机制中，所有查询（Query）与键（Key）之间进行密集的两两交互，导致其计算复杂度正比于序列长度的平方。然而，车道线区域狭小，像素非常稀疏，这会限制了基于 Transformer 的车道线检测算法的性能和计算效率。首先，查询通过与全图像素密集交互的方式从海量的背景信息中探查稀疏的车道线，感知难度非常大，尤其是注意力机制在初始化时几乎对所有像素赋予均匀的注意力权重。其次，车道线像素数量远少于背景像素。例如，在 CULane 数据集中车道线像素占比仅为 3.6%，车道线与背景的计算比接近 1:700，带来了巨大的计算和显存占用冗余。因此，车道线的显著稀疏特性在 Transformer 架构下会导致车道线感知困难和计算冗余大的问题。




图 1.2 本文主要研究工作

1.4 本文主要工作

本文的主要研究工作如图1.2所示。复杂的外部驾驶环境存在包括恶劣天气和极端光照在内的诸多不可控的外部因素。同时，车道线具有结构细长，空间分布跨度大、面积狭小，像素占比稀疏等的固有属性。这些内外部因素使得车道线检测任务面临着结构表示不够灵活、车道线结构扭曲变形以及稀疏车道线感知困难和计算冗余大的问题。本文对上述研究问题进行了系统性的分析和研究，并从车道线的结构和稀疏特性出发，提出了一系列可行的解决方案，在多种挑战驾驶场景中实现了良好的车道线检测性能。

具体来说，本文的主要工作和创新点可以总结如下：

1) 针对现有线性锚形状和位置固定、难以适应不同形状和朝向车道线的问题，提出了一种基于超锚（Hyper-Anchor）的车道线检测方法 HANet，以提升车

道线结构表示的灵活性。该方法根据输入图片动态生成一组具有行列混合表示的超锚，其相较于密集线性锚具有更灵活的结构和位置，能够更准确地拟合不同形状和朝向的车道线。此外，现有的全尺寸特征增强方式存在容易引入背景噪声、效率低下的问题，HANet 提出了多种车道位置敏感的特征增强方式，包括自适应感受野的车道线描述子构建和基于注意力机制的车道特征信息流构建。前者通过收集行内的邻域线索，扩充车道描述子的信息丰富度，后者在车道内和车道间实现高效的跨区域信息传递的同时，避免了背景噪声的引入。实验结果表明，HANet 通过建立灵活高效的车道线结构表示与信息传递机制，提升了对弯道、水平车道以及其他困难车道样本的检测准确率。

2) 针对复杂环境下车道线检测容易出现锯齿、断裂等不可靠结构的问题，提出了一种基于多车道片段的车道线检测方法 LaneSegNet，以提高车道线结构建模的鲁棒性。该方法提出了一种渐进式的检测流程：首先提取显著线索区域的可靠参考点，然后通过关联参考点周围的车道点构建局部车道片段，最后利用多车道片段重构完整车道线。LaneSegNet 将车道点表示为具有多层级和非对称结构的图节点。它通过局部和全局图增强模块分别捕捉车道片段内和参考点之间的多层级拓扑结构，学习局部紧凑连续、全局平滑的车道线结构特点。此外，图节点间的非对称权重设计增强了模型的推理能力。例如，被遮挡的车道点难以直接定位，可以依赖其他可靠的车道点位置进行推理，反之则不成立。另外，该方法通过学习车道点间的相对偏移，强化了模型对车道点相对空间位置的理解。实验结果表明，LaneSegNet 利用车道线平滑连续的结构知识，增强了在复杂环境下车道线检测的结构鲁棒性。

3) 针对稀疏车道线在 Transformer 架构中感知困难和计算冗余大的问题，提出了一种基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer，该方法实现了稀疏查询和稀疏交互。该方法首先提出了一种稀疏的车道感知查询，其具有明确的物理位置，并能够动态更新，从而展现出比密集线锚和高维查询更精确的车道线定位能力。为了降低计算冗余，Sparse LaneFormer 还提出了车道标记选择器和线性可形变采样器，分别在编码器和解码器中建立车道标记间的稀疏交互。车道标记选择器在编码器中有选择性地更新稀疏车道标记，而线性可形变采样器则在解码器中沿车道感知查询位置，准确地采样稀疏车道特征。Sparse LaneFormer 专注于最具信息量的稀疏车道标记，仅利用图像中 10% 的像素进行计算，较密集基准方法实现了 80% 的计算开销降低和近 5 倍速度提升。在性能上，Sparse LaneFormer 不仅超越了现有基于密集设计的车道线检测方法，还成为首个性能超越 CNN 架构的端到端车道线检测方法，从而验证了稀疏设计在车道线检测任务中的可行性和有效性。

本论文提出的三种车道线检测方法各有侧重点，其中 HANet 和 LaneSegNet

关注于提升车道线的结构建模能力。HANet 强调通过自适应的超锚生成与特征聚合提升车道线结构表示的灵活性,以适应实际场景中弯道、折线道、水平车道等情况。LaneSegNet 将车道线划分为多个更精细的车道片段,并利用相对偏移预测和图增强设计提升车道点集的空间相关性。该方法在兼具结构建模灵活性的同时,显著提升了算法对复杂环境的抗干扰能力。最后, Sparse LaneFormer 聚焦于利用稀疏设计提升端到端车道线检测方法的计算效率。该检测范式相较于前两种方法,具有无需后处理的简洁性,并展示出更高的性能上限。

1.5 本文组织架构




图 1.3 本文组织架构

本文结合车道线的结构和稀疏特性对车道线检测技术展开了研究,全文组织架构如图1.3所示,各章节内容的安排如下:

第一章为绪论部分,首先阐述了本文的研究背景与意义,然后对车道线检测技术的国内外研究现状进行概述,接着指出了复杂环境下车道线检测存在的研究难点,并引出了本文的主要工作与创新点,最后对本文各章节的内容安排进行了说明。

第二章为车道线检测研究基础，首先回顾了基于手工设计特征的传统车道线检测方法，然后介绍了基于深度学习的车道线检测方法，最后介绍了本文应用的车道线检测数据集，为后续章节的方法设计与实验评估奠定基础。

第三章针对线性锚形状固定、结构表示不灵活、难以适应不同形状和朝向车道线的问题，首先阐述了现有车道线结构表示和特征增强方法存在的不足。然后详细介绍了一种结构灵活的超锚及其自适应生成方法，以及多种车道位置敏感的高效特征增强方法。接下来讨论分析在两个数据集上的定性和定量实验结果，验证方法在多种复杂场景下的有效性和通用性，最后对本章内容进行总结。

第四章针对复杂环境下车道线预测容易出现锯齿、断裂等不可靠结构的问题，首先分析了车道线固有的结构特性，以及现有方法在车道线结构建模方面的局限性。然后介绍了一种从车道点到车道片段，再到完整车道线的渐进式车道线检测方法。随后介绍了如何构建具有多层级和非对称结构的车道点图，并在两个数据集上验证了方法的有效性和通用性。最后对实验结果进行讨论并总结本章内容。

第五章针对稀疏车道线在 Transformer 架构中感知困难和计算冗余大的问题，首先定量分析了车道线区别于常规目标的显著稀疏特性。然后总结了现有密集锚和注意力机制的密集交互机制存在的局限性，并介绍了一种具有全稀疏设计的端到端车道线检测方法。随后验证了各项稀疏设计对于提升车道线检测性能和计算效率的积极作用，最后对本章内容进行总结。

第六章是总结与展望，对本文的研究内容进行了总结概括，并对未来的研究工作展开展望。

第2章 车道线检测研究基础

早期的车道线检测研究依赖于颜色、边缘等基础图像特征。近年来,深度神经网络和大规模数据集的出现,为解决车道线检测问题提供了更多的可能。按照车道线的表示形式的不同,基于深度学习的车道线检测方法可以分为四类,包括基于像素分割的方法、基于锚点检测的方法、基于曲线回归的方法和基于点集搜索的方法。本章对车道线检测的相关研究基础进行介绍。

本章内容安排如下:2.1节介绍了基于手工设计特征的传统车道线检测方法;2.2节先介绍了四类基于深度学习的车道线检测方法以及它们的优缺点。最后2.3节介绍了本文应用的车道线检测数据集以及相应的评价指标,为后续章节的方法设计与实验评估奠定基础。

2.1 传统车道线检测方法

在大型车道线检测数据集出现之前,传统的车道线检测方法主要基于手工特征,如颜色特征^[62]和边缘特征^[63]等,并利用多种数字图像处理技术,如霍夫变换^[64]和卡尔曼滤波器^[65]实现车道线定位。传统车道线检测方法的常见流程包括图像预处理、手工特征提取、结果后处理三个步骤。首先,对输入图像进行预处理,包括图像去噪、颜色空间转换和感兴趣区域(Region of Interest, ROI)选取等;其次,进行图像特征提取,包括车道线的颜色、纹理、边缘、方向以及车道线与路面的对比度等特征;最后,通过曲线拟合来确定车道线的位置。本节将按照以上处理步骤,回顾传统的车道线检测方法。

2.1.1 图像预处理

预处理的目的是过滤掉图像中的干扰,以提升特征表示的质量。为消除由摄像机不稳定等因素造成的图像噪声,通常使用均值、中值和高斯滤波器进行图像平滑。李茂月等人^[66]对比了高斯滤波、中值滤波与双边滤波的效果,发现双边滤波算法不仅可以减少噪声而且可以有效地保留边缘特征。XU 等人^[67]先用中值滤波器进行图像滤波,再采用图像直方图对灰度图像进行增强,去除不必要的噪声的同时能够保留细节。由于RGB颜色空间对光线强度变化敏感,因而常将RGB图像转换到其他颜色空间来提高车道线的质量,如灰度转换和YCbCr色度空间转换。灰度转换是将彩色图像转换为单通道的灰度图像,即只保留图像的亮度信息。灰度图像处理起来更简单,计算量小,常用于减少计算复杂度。YCbCr是一种颜色编码系统,常用于数字图像和视频压缩。在这个空间中,Y代表亮度

信息，而 Cb 和 Cr 分别代表蓝色和红色的色度信息。转换到 YCbCr 空间可以分离亮度和颜色信息，有助于在图像处理中单独处理亮度和颜色。

由于车载前视图像通常包含天空、建筑物等与车道线检测无关的信息，只对感兴趣的车道线区域进行分析可以大大减少计算量，加快检测速度。钱基德等人^[68]简单地将图像下半部分固定大小的区域设置为感兴趣区域，并去除图像上半部分的无关信息。此外，由于相机成像为透视图，原本平行的车道线在透视图变成相交于一点，造成车道线相互平行的结构约束丢失。因此，常用逆透视变换将透视图变为鸟瞰图，以恢复车道线的平行分布。鱼兆伟等人^[69]提出了一种动态感兴趣区域选择方法，首先将采集到的道路图像转换为灰度图，然后使用 Canny 算子提取图像边缘，并利用 Hough 变换找到车道线的消失点，消失点以下的图像部分被定义为动态感兴趣区域。这个过程不仅减少了计算量，还提高了车道线检测的准确性和效率。

2.1.2 手工特征提取

传统的车道线检测方法根据车道线的边缘、颜色等特征，将图像的车道线与非车道线区域分离来实现车道线识别。车道线边缘特征提取方法有 Sobel 和 Canny 边缘检测算子等。其中，Sobel 算子具有计算简单、处理速度快、抗干扰能力显著等优势，得到了广泛应用。Sobel 算子是一阶离散型的差分算子，可以用于检测 ROI 内的横向梯度和纵向梯度， G_x 和 G_y 。图像中某点 (i, j) 的梯度幅值 $G(i, j)$ 和梯度方向 $\theta(i, j)$ 的计算公式分别如下

$$G(i, j) = \sqrt{G_x(i, j)^2 + G_y(i, j)^2}, \quad (2.1)$$

$$\theta(i, j) = \arctan \left(\frac{G_y(i, j)}{G_x(i, j)} \right). \quad (2.2)$$

Ozgunalp 等人^[70]提出了一种结合 Sobel 边缘检测器和对称局部阈值 (Symmetrical Local Threshold, SLT) 的方法，用于提高车道线特征提取的性能。它们协同工作，能够更稳健地提取车道线特征，在检测道路边界方面具有优势。虽然基于边缘特征的车道线检测技术简单，但它受光照变化、阴影、图像亮度的影响严重。此外，在某些情况下选择合适的阈值也较为困难。为实现更精确的检测，还需考虑车道线的其他特征。与使用固定阈值的方法不同，Parajuli 等人^[71]提出了一种利用灰度图像垂直梯度特征预测车道线的方法，对于光照变化和阴影具有较强的鲁棒性。

2.1.3 曲线拟合后处理

在基于特征初步检测到车道标记后，需要使用曲线拟合方法来细化结果。曲线拟合是利用已知数据点来估计未知函数的过程，其目标是获得最接近数据且

具有最小方差的近似结果，并不要求近似曲线完全经过所有数据点。拟合步骤通常需要基于车道线的先验结构知识来滤除或修正部分已提取的特征，如车道线宽度、车道线之间的距离、车道平行特性等。常用的拟合方法包括最小二乘法、霍夫变换^[72]和随机抽样一致性^[73] (RANSAC) 等，常用的车道线拟合模型为二阶或高阶多项式曲线。霍夫变换是一种用于检测具有特定形状物体的技术，通常将图像空间信息映射到参数空间，并在参数空间中得到检测图像的直线、椭圆等轮廓。最小二乘拟合方法通过最小化误差的平方和寻找数据的最佳函数匹配，接下来本节简要介绍该方法。

给定图像平面上的一组加权车道点，即三元组 $\{(x_i, y_i, w_i)\}$ ，最小二乘法通过最小化残差的平方和来寻找最佳拟合曲线，从而确保拟合多项式曲线尽可能地接近所有给定点。首先，根据 m 个车道点的横纵坐标分别构建矩阵 $X \in \mathbb{R}^{m \times n}$ ， $Y \in \mathbb{R}^{m \times 1}$ 以及 $n-1$ 次多项式曲线系数 $\beta \in \mathbb{R}^n$ ，其中

$$X = \begin{bmatrix} 1 & x_1 & \cdots & x_1^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_m & \cdots & x_m^{n-1} \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_n \end{bmatrix}. \quad (2.3)$$

车道线的多项式曲线参数 β 满足如下公式

$$X\beta = Y. \quad (2.4)$$

在大多数情况下，可用点的数量或者说方程式的数量，远多于未知曲线参数数量，即 $m > n$ 。在这种情况下，可以确定 β 的一个近似解，使得拟合曲线和实际数据之间具有最小的平方误差，其定义为

$$\beta = \arg \min \|Y - X\beta\|^2. \quad (2.5)$$

紧接着，方程(2.4)的解可以通过求 X 的伪逆获得

$$\beta = (X^T X)^{-1} X^T Y. \quad (2.6)$$

上述方程可以看作是权重矩阵为 1 的加权最小二次拟合。考虑给定的对角权重矩阵 $W \in \mathbb{R}^{m \times m}$ ，方程(2.4)两边同时进行加权，可以得到

$$WX\beta = WY. \quad (2.7)$$

上述方程则可以通过定义 $X' = WX$ 以及 $Y' = WY$ 进行简化。其中

$$W = \begin{bmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & w_m \end{bmatrix}. \quad (2.8)$$

最后,加权的最小二乘拟合问题可以通过公式(2.6)视为无加权最小二乘拟合问题求解。

2.2 基于深度学习的车道线检测方法

基于手工特征的传统车道线检测方法通常设计简单且检测速度快,但它们对光照变化和遮挡的抗干扰能力较差,难以满足智能驾驶系统对车道线检测的高精度要求。深度神经网络和大规模数据集的发展极大地扩展了解决车道线检测问题的可能性。

根据车道线的表示形式,现有的基于深度学习的车道线检测方法主要分为以下四类:基于像素分割的方法、基于锚点检测的方法、基于曲线回归的方法和基于点集搜索的方法。本节将对这四类车道线检测方法进行详细的介绍,并比较和讨论这些方法的优缺点。本节首先介绍基于深度学习的车道线检测的理论基础和实验方法,包括本文使用的车道线检测数据集。

2.2.1 基于像素分割的车道线检测方法

基于分割的车道线检测方法的发展与分割网络结构的进步密不可分。全卷积网络^[75](Fully Convolutional Network, FCN)和 U-Net^[76]在车道线检测领域得到了广泛应用。FCN^[75]使用 1×1 卷积层来替换传统分割网络中的全连接层,并通过跳跃连接融合浅层与深层特征。FCN 还利用转置卷积进行上采样,使得输出预测图和输入图具有相同的大小,实现对每个像素的语义分割。为了解决 FCN 中上采样过程中可能遇到的信息丢失问题, U-Net^[76]通过跳跃连接将编码器中的高分辨率特征图与解码器中的上采样特征图相融合,逐步恢复目标结构的细节和空间维度。全卷积网络和 U-Net 等对称式的分割网络结构在许多基于分割的车道线检测工作^[14,16,77]中得到了应用。

早期的车道线检测方法通过逐像素的语义分割或实例分割,并配合聚类或曲线拟合等后处理实现车道线检测。基于语义分割的方法^[13-17]首先通过二值分割获取车道线的掩模,然后利用聚类算法将相应的车道线嵌入聚类为不同的车道实例。这些方法的核心差异在于它们所使用的聚类技术。例如, VPGNet^[13]采用基于密度的聚类方法,结合鸟瞰图下的平行结构约束和前视图中消失点的指导,实现车道点的有效聚类。LaneNet^[14]则利用距离判别损失来促使同一车道线的嵌入在特征空间中更接近,同时确保不同车道的簇中心相互远离。LaneAF^[15]则提出了一种基于车道点方向的聚类方法,通过水平和垂直仿射场来指示相邻区域内车道点的方向,提升了聚类方法的可解释性。PINet^[16]通过堆叠沙漏网络^[78]计算偏移图,对车道点的位置进行微调,并聚类相应的车道嵌入。沙漏网络在训练

过程中可以采用中间监督的方法,即在每个沙漏模块后都生成预测并计算损失。这种方法有助于提高网络训练的收敛速度和性能。HBNet^[17]利用全局语义信息和空间上下文来提高车道线检测的速度和准确性,通过混合分支网络提取四种不同感受野和空间上下文的特征图,以编码更丰富的车道线特征。

与此相对的是,基于实例分割的方法^[18-25]直接预测每个车道实例的概率图,并通过曲线拟合方法得到车道线的参数化表示。与普通目标不同,车道线具有独特的细长形状。为了针对性的提升车道线分割性能,一些方法将车道线独特的细长结构属性整合到神经网络设计中。SCNN^[18]和 RESA^[19]尝试使用逐切片的空间卷积来实现特征图内行和列像素之间的消息传递机制,RESA 因其灵活的步长和并行计算能力而更加高效。改进后的分割模型对一些空间跨度大的目标,如细长的车道线和电线杆等,在分割性能上获得了提升。CenLaneNet^[20]提出了一种基于实例分割的自适应多车道线检测方法,该方法结合了实例分割和车道中心估计,实现了鲁棒且高效的车道实例提取。此外,CenLaneNet 在目标函数中引入了余弦相似度度量,从而能够提取更具区分性的前景特征。ConvLSTM^[21]通过使用驾驶场景的连续多帧,并提出一种结合卷积神经网络和循环神经网络(Recurrent Neural Network, RNN)的混合深度架构,利用时序信息进一步提升车道线分割性能。

基于分割的车道线检测方法简单直接,但密集的像素级预测在计算和推理时间上的成本相对较高。例如,SAD^[22]指出,SCNN^[18]的空间消息传递机制占用了其总前馈时间的35%。为了提升模型的推理速度并保持可比性能,研究者们采用了知识蒸馏技术^[22-23]、轻量级分割网络^[26-27]和高效计算设计^[24-25,28]。SAD^[22]和 IntRA-KD^[23]利用知识蒸馏技术,以轻量级分割网络^[26-27]实现与教师模型相当的分割性能。SAD^[22]提出了一种自注意力蒸馏方法,允许轻量级分割模型从其深度学习上下文特征并获得显著的性能提升。IntRA-KD^[23]将图像的每个区域表示为图中的节点,并将场景结构的知识从容量较大的教师网络转移到小型学生模型,以促进其训练。HWLane^[25]基于行列多头自注意力机制,将注意力限制在各自的行和列内,并通过交叉特征高效地传递行列间的信息,显著扩大了车道线周围感知范围。FlipNet^[24]通过层次化特征翻转融合模块和双层注意力增强机制来聚合全局内容,有效地突出了车道结构特征并提升了算法效率。MLP-lane^[28]使用改进的线性层替换标准卷积层,并应用混合扩张卷积来更好地捕获多尺度车道特征,显著降低了模型参数量和计算量。

尽管这些方法在提升算法效率方面取得了一定的成果,但分割任务中的密集像素级预测及其后续的聚类 and 曲线拟合后处理仍然不可避免地引入了相当大的时间成本。本文主要探索基于点集表示的车道线检测方法,以实现更快的推理速度和更高的检测精度。

2.2.2 基于锚点检测的车道线检测方法

在经典目标检测器中,尤其是基于区域的卷积神经网络^[79](Region-Based Convolutional Neural Networks, R-CNN)及其衍生模型^[80-84],锚点(Anchor)机制被广泛应用于预测目标位置和尺寸。锚点通常是一个预定义的矩形框,由中心点坐标、宽度和高度所确定。在图像中,这些预定义的锚点以不同的区域、比例和形状覆盖,以适应不同大小和方向的目标对象,使网络能够学习到目标的真实边界框。矩形锚框的设计和使用经历了从手动选择到自动生成,再到自适应调整的演变过程。R-CNN^[79]引入了选择性搜索算法来生成约2000个左右的候选区域作为锚点,然后使用CNN提取特征并进行分类和边界框回归。由于R-CNN搜索候选区域的方法效率较低, Fast R-CNN^[85]通过卷积网络生成特征图,并直接裁剪区域获得推荐区域的特征图,提升了算法效率。Faster R-CNN^[80]基于全卷积网络实现了一个区域建议网络(Region Proposal Network, RPN),其能够自动生成候选区域(即锚点),实现了更快的推理速度。YOLO^[86](You Only Look Once)模型将锚点的概念与网格单元结合,每个网格单元预测多个边界框和类别概率,实现了快速的目标检测。

在车道线检测领域,受到目标检测中矩形锚框设计的启发,研究者设计了一系列密集的线性锚作为结构参考。基于锚点检测的车道线检测方法通过线性锚和车道点相对于线性锚的偏移量来表示车道线,从而提高了检测的准确性和效率。这些方法精心设计了多种类型的锚点用于车道线检测,包括垂直线锚^[29-30]和倾斜线锚^[31-33]。PointLaneNet^[29]和 CurveLanes-NAS^[30]等方法,采用了垂直线锚,通过将特征图的每个网格与邻近的车道真实标注匹配,并回归车道点相对于垂直线锚点的偏移量。随后应用非极大值抑制(Non-Maximum Suppression, NMS)来抑制冗余的检测结果,以提高检测的准确率。CurveLanes-NAS^[30]则通过神经架构搜索(Neural Architecture Search, NAS)找到合适的主干网络,在资源约束下实现模型检测准确率和计算效率之间的最佳平衡。然而, PointLaneNet^[29]和 CurveLanes-NAS^[30]使用的密集垂直线锚与真实车道线的分布模式不能很好的对齐,导致了锚与车道线平均交并比小,车道特征采样不准确的问题。

为了解决这一问题,后续的研究工作^[31-33,87]设计了更加符合车道线的分布特点的斜线锚,即起始于图像的左/右/下边界向图像内延伸的射线。这些方法通过更精细的锚点设计,提高了车道线的检测性能。LineCNN^[33]是首个将目标检测范式应用于车道线检测的工作,通过简单地在特征图的三个边界上的网格应用 1×1 卷积来生成车道线预测,而没有考虑车道线的全局特征。LaneATT^[31]则提出了基于锚的池化车道线采样方式,并尝试利用注意力机制对采样得到的车道线描述子进行特征增强。通常情况下,现实世界中多条相互平行的前向车道线会

汇集在图像坐标系中的一点,称之为消失点。利用这样的结构约束,SGNet^[32]提出了基于消失点引导的锚生成机制,通过分割学习消失点并生成结构化锚点,提供了更稳定的锚组空间分布模式。CLRNet^[87]受到 Sparse RCNN^[88]和 Cascade RCNN^[89]的启发,用可学习的车道线提议替换了线锚点,并在多尺度特征上迭代细化车道线预测。ADNet^[90]重新审视了基于锚点的车道检测方法的局限性,这些方法通常使用起始于图像边缘的固定锚点,忽视了它们的多样性和质量。ADNet提出了一种基于热图的锚生成策略。这种分解策略消除了对锚点起始点的限制,使得算法能够适应不同数据集中的各种车道类型。为了提高锚点的质量,该方法为特征金字塔网络(FPN)引入了大核注意力(LKA),这显著增加了感受野。这对于捕获通常贯穿整个图像的车道线所必需的充足上下文至关重要。此外,ADNet还提出了一种通用车道 IoU (GLIoU) 损失,这显著提高了 ADNet 在复杂场景下的性能。

得益于线锚提供的结构参考,基于锚点检测的方法^[29-33]即便在车道线不可见时,也能实现卓越的车道线检测性能。但这类方法也存在一些局限性。例如,预定义线性锚的形状和位置固定,难以适应多变的车道线朝向和形状,导致车道线特征的采样不准确。此外,逐像素的锚点采样策略可能无法充分捕获临近区域的车道线细节,因而倾向于产生更多的漏检,即较低的召回率。为了克服这些局限性,本文进一步探索了更灵活、更鲁棒的车道线表示机制,以及更高效的车道线特征增强方法。

2.2.3 基于曲线回归的车道线检测方法

基于曲线回归的车道线检测方法将车道线表示为参数化曲线,并通过端到端的方式直接回归曲线参数。常用于建模车道线的曲线模型包括多项式曲线^[34-40]和贝塞尔曲线^[41-42]。

Bert 等人^[34]设计了一种可微分的最小二乘拟合模块来优化车道线曲率参数。与传统的两步车道线检测流程相比,该方法允许网络在训练过程中隐式学习生成的特征,以防止模型拟合步骤中的不稳定性,提供了更好的性能和解释性。PolyLaneNet^[35]将车道线表示为多项式曲线,并使用全连接层直接预测这些多项式的系数,实现了有竞争力的推理速度。为了应对车道形状的复杂性,PRNet^[36]采用具有不同系数的分段多项式来表示不同的车道段。PRNet 通过三个分支,即多项式回归、初始化分类和高度回归,协同工作来预测动态数量的车道线。

多层卷积网络堆叠后,其有效感受野仍可能有限^[91]。为了捕捉车道线的长距离依赖,LSTR^[37]和 AtrousFormer^[38]采用卷积网络和 Transformer^[43]的混合网络结构来捕获车道线的上下文,并遵循 DETR^[92]的端到端检测范式完成了车道线参数的回归。LSTR 利用道路结构和相机姿态来构建车道形状模型,并通过自

注意力机制捕捉车道线的细长的结构。然而,注意力模块的计算复杂度与输入大小的平方成正比,这增加了车道线检测的整体计算冗余,尤其是在车道线像素在图像中是十分稀疏的。因此,LSTR等模型^[37,48],只能将少量自注意力层应用于低分辨率的特征图。此外,LSTR基于特定车辆摄像头的内外参数设计了复杂的曲线公式,但其曲线公式过于复杂和抽象,导致模型难以训练。为了解决这一问题,PGANet^[39]在LSTR的基础上进行了改进,并引入了均值曲率损失,改善三次曲线函数对实际道路曲线的拟合度,从而提高了算法在复杂数据集上的准确性。

由于多项式曲线参数的微小预测误差,尤其是高阶项系数,可能导致车道线整体定位的显著偏差。为了缓解多项式曲线参数的优化难题,BézierLaneNet^[41]提出将车道线建模为更稳定、自由度更高的贝塞尔曲线,并通过预测多个曲线控制点来表示车道线。此外,该方法还提出了基于可形变卷积^[53]的特征翻转融合模块,用于利用驾驶场景中车道的对称属性。与仅对高得分提议应用稀疏监督不同,DHPM^[42]密集地监督所有提议,以在拓扑和空间精度方面生成高质量的车道线预测。EigenLane^[40]提出了一种基于车道线特征向量的车道线表示方法。该方法首先构建一个包含数据集中所有训练样本的坐标表示矩阵,并通过计算该矩阵的最佳秩近似得到车道线的特征向量,作为车道线表示的一组基。DBNet^[93]引入了NURBS曲线建模车道线,并引入了三个关键模块解决遮挡情况下的车道线检测问题。首先,局部动态交互模块自适应地利用局部几何信息。其次,曲线拟合增强模块用于增强车道实例两端的特征。最后,全局关联共享模块用于捕获车道的全局特征。

2.2.4 基于点集搜索的车道线检测方法

基于点集搜索的车道线检测方法^[44-48]将车道线表示为图像中等间隔行上的一组车道点。由于车道线长度一般小于图片高度,这些方法通常还使用额外的行向指示器用来表示该行是否存在车道点。一些方法^[44-46]通过逐行的分类或回归来定位车道点。UFLD^[44]和UFLDv2^[45]将车道线检测任务重新定义为一个序数分类问题,利用全局特征来学习车道线的稀疏坐标。UFLD首先将图像划分为大小相同的网格,并在每一行上最多将一个网格分类为车道点,显著提升了车道线检测的准确性和速度。实际上,在前视驾驶图像中,当前车道和侧边车道表现出不同的空间方向偏好。为了确保每种类型的车道都能用足够数量的采样点和较小位置误差来表示,UFLDv2^[45]提出了一种混合锚点系统,并采用序数分类损失函数优化车道线的全局特征学习。KPMFF^[47]提出了一种基于关键点回归和多尺度特征融合的全局车道线检测策略。该方法首先通过回归策略在图像的每个网格中生成关键点序列来定位车道线,然后引入多尺度特征融合模块来合

并不同尺度的特征图。此外, KPMFF^[47]还提出了一种基于规则的快速后处理方法, 在保持竞争性准确性的同时, 显著提高了处理速度。E2E^[46]通过逐行分类直接预测车道点, 避免了像素级密集预测任务所需的复杂后处理步骤, 最终车道线位置可以通过测试时的 $\arg\max$ 操作直接获得。该方法还提出了一种新颖的水平缩减模块, 通过缩减水平方向冗余信息减少了计算量。车道线与其他交通对象之间存在隐含关系, 例如车辆和行人。例如, 车辆在车道内行驶, 而行人则通常被限制在人行横道区域, 很少出现在车道内。为了利用目标间的潜在位置约束, LaneFormer^[48]将同一输入图像的目标检测结果作为车道线检测的辅助信息, 并利用行人检测结果有效地减少人行横道场景中的车道线误报。

上述方法大多使用低分辨率的深层语义特征进行车道点定位, 同时实现了较快的推理速度。然而, 低分辨率的深层语义特征通常缺乏空间信息^[94], 这可能导致车道线定位不准确, 进而造成大量车道线误检和漏检。多尺度特征图被认为有助于定位小目标^[49-51], 包括细小的车道。此外, 基于点集表示的车道线检测方法^[44-47]通过逐行的回归或分类单独定位每个车道点, 而没有考虑它们之间的空间关系。因此, 在视觉线索不足的复杂环境下, 车道线结构的预测不可靠问题变得尤为突出。缺乏结构约束是导致这些方法出现车道线误检和漏检的另一个关键因素。

为了解决以上问题, 一些方法运用条件卷积^[52]和可形变卷积^[53-54]等机制, 增强模型对结构化车道线的检测能力。CondLaneNet^[55]提出了一种基于条件卷积的自顶向下车道线检测框架。该框架首先检测车道实例, 然后动态预测每个实例的几何形状。为了区分不同的车道线实例, 引入了条件卷积和递归实例模块来识别和连接具有复杂拓扑结构的车道线, 例如密集车道线和分叉车道线。RCLane^[56]提出了一种基于接力链的车道线检测方法。该方法通过预测分割图来区分前景和背景区域, 并针对每个前景区域内的像素点, 通过前向分支和后向分支来恢复完整的车道。每个分支解码一个传递图和距离图, 以产生移动到下一个点的方向, 可以动态预测岔道上的车道点。实际上, 充分利用目标的结构约束和分布模式已经在多个领域显示出其重要性, 包括地图构建^[95-98]和人体关键点检测^[99-102]。受此启发, FOLOLane^[57]提出了一种基于局部结构建模的车道线检测方法, 通过自底向上的方式实现车道线结构的重建。具体来说, 该方法使用两个预测头来构建车道线, 第一个头预测关键点的位置, 第二个头在局部范围内细化关键点的位置并关联同一车道线上的关键点。此外, 该方法还提出了一种面向效率的解码算法, 将局部信息整合到车道线的全局结构中, 且在不牺牲性能的情况下显著提高了运行效率。类似的, FastDraw^[58]通过预测当前车道点与其两个垂直相邻点之间的局部偏移来解决这个问题。然而, FastDraw 需要从单一参考点出发, 基于局部偏移量逐步向外扩展, 以重建完整的车道线。这不仅效率较低,

还容易在定位远端车道点时积累定位误差。为了解决这一问题, GANet^[59]提出了一种全新的车道线检测方法, 即全局关联网络 (Global Association Network), 该网络直接将每个关键点回归到其所在车道线的起始点。此外, GANet 采用可形变卷积^[53]预测关键点到对应车道起始点的偏移量, 全局地实现关键点与其所属车道线的关联。这样做不仅提高了效率, 而且对累积的单点误差更加鲁棒。FMLane^[60]利用嵌入向量确定图像中局部高响应车道点的位置, 进行车道线结构重建。它避免了对整个图像中每个像素进行分类的需要, 从而实现了更快的推理速度。ECPNet^[61]引入了一种新颖的结构校正模块, 基于车道方向的动态调整车道线的表示形式。尽管该方法一定程度提升了对车道线结构表示的灵活性, 但没有深入探索车道点之间的空间位置关系。Lane2Seq^[103]提出了一种新颖的基于序列生成的车道检测框架。它通过将车道检测视为序列生成任务, 统一了各种车道检测格式。这与以前依赖于特定任务设计的头部网络和相应损失函数的车道检测方法不同。Lane2Seq 仅采用了一个简单的基于 Transformer 的编码器-解码器架构和简单的交叉熵损失。此外, 该方法提出了一种新的基于强化学习的多格式模型调整方法, 以将特定任务的知识整合到 Lane2Seq 中。实验结果表明, 这样一个简单的序列生成范式不仅统一了车道检测, 而且在基准测试中也取得了有竞争力的性能。例如, 在 Tusimple 和 LLAMAS 数据集上, Lane2Seq 分别获得了 97.95% 和 97.42% 的 F1 分数。

点集表示形式下的车道线检测任务本质上是预测一个具有特定拓扑结构的点集。由于车道线本身具有高度的结构先验, 本文尝试在网络设计和优化函数方面引入这些结构先验, 以提高模型在复杂环境下的车道线检测准确性和鲁棒性。

2.3 车道线检测数据集与评价指标

数据集在深度学习领域中起着至关重要的作用。在训练阶段, 数据集为模型优化提供必要的原始材料, 帮助模型学习特征和模式。而在测试阶段, 验证集和测试集用于评估模型的准确性、泛化能力和鲁棒性。本节将介绍在车道线检测领域具有重大影响力的两个公开数据集: CULane^[18]和 TuSimple^[74], 它们也是本研究所使用的数据集。表2.1提供了这两个数据集的详细信息。

表 2.1 CULane 和 TuSimple 数据集的详细信息

数据集	帧数	训练集	验证集	测试集	分辨率	场景类型数	车道数
CULane ^[18]	133235	88880	9675	34680	590×1640	高速与城镇	≤4
TuSimple ^[74]	6408	3268	358	2782	720×1280	高速	≤5




图 2.1 CULane 数据集中多种场景数据样本

2.3.1 CULane 数据集与评价指标

CULane 数据集^[18]由香港中文大学发布，是一个规模庞大且具有挑战性的车道线检测数据集，目前已成为该领域中最广泛使用的数据集之一。该数据集通过在六辆不同车辆上安装摄像头收集，涵盖了北京市的多种道路场景，包括城市道路、乡村道路以及高速公路等。这些车辆由不同驾驶员驾驶，确保了数据的多样性和真实性。

在超过 55 小时的驾驶视频记录中，CULane 数据集共提取和标注了 133,235 帧图像，分辨率为 1640×590 像素。这些图像被划分为三个部分：训练集包含 88,880 张图像，验证集包含 9,675 张图像，而测试集则包含 34,680 张图像。根据场景难度，测试集进一步细分为“正常”类别和 8 个挑战性子类别，包括“拥堵”、“眩光”、“阴影”、“无线”、“箭头”、“弯道”、“十字路口”以及“夜间”，分别代表了不同的检测难度和环境条件。CULane 数据集通过对不同难度级别场景的分类，为车道线检测算法的研究和开发提供了丰富的资源和挑战。CULane 数据集各个场景类型的数据样例和数据占比分别如图 2.1 和图 2.2 所示。

CULane 数据集^[18]为每张图像提供了一个对应的文本标注文件，详细记录了车道线的关键点坐标。车道线的标注通过三次样条曲线手动完成，即使在车道标记不可见的情况下，也会依据场景上下文进行标注，确保了数据的准确性和完整性。该数据集重点关注车辆左右两侧距离最近的四条车道线的检测，这些车道线在实际交通场景中最为常见，也是车道线检测算法研究的重点。对于




图 2.2 CULane 数据集中多种场景数据比例

其他位置的车道线，数据集没有进行标注。此外，CULane 数据集的标注格式遵循一定的规则：每两个数值代表一个车道点坐标 (x, y) ，采用纵向等间隔的标注策略，主要标注图像的下半部分，即车道线通常出现的区域。对于训练集和验证集，CULane 数据集还提供了车道线语义分割信息，为算法的训练和验证提供了额外的上下文。

在评估过程中，车道线预测和真值的宽度被设定为 30 像素。如果预测的车道线与真实标注的车道线之间的交并比超过 0.5，那么该预测就被认为是正确的，即被分类为真阳性 (True Positive, TP)。IoU 是一种衡量预测结果与真实情况相似度的方法，其值介于 0 到 1 之间，值越大表示预测结果越准确。CULane 数据集将 F1 度量作为主要的评价指标。F1 度量是一种综合考虑了精确率 (Precision) 和召回率 (Recall) 的指标，它能够更准确地评估车道线检测算法的性能，确保算法在精确率和召回率之间取得平衡。F1 度量的计算公式如下

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2.9)$$

精确率 (Precision) 和召回率 (Recall) 的计算公式分别为

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (2.10)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2.11)$$

其中 TP 代表真阳性的数量，FP 代表假阳性 (False Positive) 的数量，即错误地将非车道线预测为车道线的情况，FN 代表假阴性 (False Negative) 的数量，即算法未能检测到的车道线。

2.3.2 TuSimple 数据集与评价指标

TuSimple 车道线检测数据集^[74]由美国图森未来 (TuSimple) 公司于 2018 年 6 月发布。如图 2.3 所示, TuSimple 数据集采集于晴朗天气下的美国高速公路, 车道线清晰度较高。车道线的标注采用点标注方式, 拍摄角度与汽车行驶方向接近, 使得车道线检测任务相对于 CULane 数据集来说难度较低。TuSimple 数据集包含 6,408 个视频序列, 每个序列由一秒钟内连续收集的 20 帧图像组成, 但仅第 20 帧进行了车道线真值标注, 图像分辨率为 1280×720 像素。数据集总共包含 3,626 张训练图像和 2,782 张测试图像。在数据集标注方面, TuSimple 对每张图像上的当前车道和两侧车道都进行了序列化的真值标注。车道线数目不固定, 最少为 2 条, 最多可达 5 条以上, 虚线被标注为连续的实线, 但双实线、白线、黄线等类别信息未在标注中体现。




图 2.3 TuSimple 数据集中的数据样本

TuSimple 数据集的官方评估指标是准确率 (Accuracy), 专注于衡量算法在车道点定位精度上的表现。准确率的计算方法是求所有图像中正确预测点数的平均比率来实现的。具体计算公式如下

$$\text{Accuracy} = \sum_{\text{clip}} \frac{C_{\text{clip}}}{S_{\text{clip}}}, \quad (2.12)$$

其中 C_{clip} 表示预测正确的车道点数量, S_{clip} 表示该图像中真实存在的车道点的总数。通过对所有图像片段的正确预测点数进行累加并求平均, 可以得到整个数据集的平均准确率。如果预测的车道点与真实标注的车道点之间的距离在 20 像素以内, 则该预测点被认为是正确的。使用准确率作为评估指标, TuSimple 数据集能够为算法在车道点定位方面的性能提供量化的评价。

第3章 基于超锚的车道线检测算法

为了解决现有线性锚形状和位置固定、难以适应多变的车道线形状和朝向的问题,本章提出了一种基于超锚(Hyper-Anchor)的车道线检测方法 HANet,以提升车道线结构表示的灵活性。该方法根据输入图片动态生成一组具有行列混合表示的超锚,其相较于预设的密集线性锚具有形状灵活、置信度高的特点,能够更准确地拟合不同形状和朝向的车道线。此外,现有的全尺寸特征增强方式存在容易引入背景噪声、效率低下的问题, HANet 提出了多种车道位置敏感的特征增强方法,包括具有自适应感受野的车道线描述子构建和基于注意力机制的车道特征信息流构建。前者通过收集行内的邻域线索,扩充车道描述子的信息丰富度,后者在车道内和车道间实现了高效的跨区域信息传递,避免引入背景噪声。实验结果表明, HANet 通过建立灵活高效的车道线结构表示与信息传递机制,显著提高了对弯道、水平车道以及其他困难车道样本的检测准确率,相较于基准模型实现了更高的检测召回率和精确率。

本章内容安排如下:3.1节首先分析了线性锚的应用背景以及其在车道线结构表示和特征增强方面的局限性,并提出了针对性的改进策略;3.2节详细介绍了基于超锚的车道线检测方法 HANet,包括超锚的生成、自适应车道描述子的构建以及车道内和车道间特征增强方法;3.3节在两个车道线数据集上验证 HANet 以及各组件的性能,并与其他方法进行定性和定量的比较以展示其优越性;3.4节对本章内容进行总结。

3.1 问题描述与分析

车道线在图像中通常呈现为白色或黄色的细长线条,展现出相对独特的视觉纹理。在光照充足且道路条件良好的情况下,车道线的检测任务通常较为直接。然而,在实际的驾驶环境中,车道线视觉线索的缺失非常普遍,导致算法难以准确识别车道线。事实上,车道线的自身特性和外部环境因素共同导致了车道视觉线索缺失问题。一方面,由于车道线细小狭长,其视觉线索在空间上相对分散。另一方面,恶劣的天气条件、极端的光照变化、交通干扰以及标线异常等外部因素,都可能进一步削弱车道线的纹理细节,使其在视觉上变得更加难以辨认,从而增加了车道线检测的难度。

图3.1直观地展示了无车道视觉线索问题以及两种现有的解决方案。如图3.1(a)所示,在车道线视觉线索缺失的场景下,深度神经网络提取的车道线特征表示可能出现模糊、扭曲等降质现象。这种现象是导致现有车道线检测方法在利用




图 3.1 无车道线视觉线索问题以及两种现有解决方案。(a) 车辆遮挡与特征模糊；(b) 垂直与倾斜线性锚；(c) 全尺寸特征图车道特征增强方法。

有限的视觉线索识别车道线位置和结构时面临困难，性能显著下降的直接原因。

实际上，无论车道线是否在视觉上可辨识，车道线在空间上应始终保持连续性。基于这一重要观察，研究人员提出了两种特征增强策略来解决在缺乏视觉线索时的车道线识别难题。一种策略是引入参考直线，即所谓的线性锚，用于车道线的特征采样和增强；另一种策略是通过空间消息传递机制来进一步增强车道线特征。然而，由于线性锚方法和全尺寸车道特征增强方法都采用了固定的结构设计，它们难以灵活适应实际场景中多变的车道线形状和朝向。如图 3.1 (b) 所示，线性锚方法^[29-31,33]将车道线视作从图像边界延伸出的射线，并引入两种人工设计的密集线性锚，包括垂直线锚^[29-30]和倾斜线锚^[31,33]，作为车道线结构的参考。其中，灰色网格表示线性锚的候选区域。每个中心点（红点）都与一组线性锚相关联。接着，通过预定义的线性锚逐点采样提取车道线的特征描述子。最终，通过回归车道点与线性锚之间的偏移量来实现车道线的检测。

由于线性锚提供了车道线的整体结构参考，这些方法在面对不同道路条件导致的部分车道线不可见时，仍能够保持稳定的检测性能，从而实现优秀的车道线识别效果。然而，线性锚固定的形状和位置也带来了相应的问题。首先，线性锚的固定结构限制了其对弯道、水平朝向车道等复杂车道线的建模能力。另外，

许多预设锚常常落在背景区域,或者与车道线真实位置的 IoU 较低,这导致采样得到的车道线描述子往往包含大量不相关的背景特征,难以有效的实现车道线定位和特征增强。此外,大量的线性锚还可能导致正负样本的极端不平衡,以及非最大值抑制(Non-Maximum Suppression, NMS)等复杂启发式设计,这需要投入大量的人力成本。

如图3.1(c)所示,为了弥补线性锚在车道线特征增强方面的缺陷,另一类方法,如 SCNN^[18]和 RESA^[19],采用了空间消息传递机制,并将其应用于全尺寸特征图。这些方法通过执行逐切片的空间卷积来补充原始的通道卷积。尽管这种全尺寸特征增强方式能够覆盖到车道线区域,但它可能会向车道特征中引入不相关的背景噪声,从而降低原有车道线的特征表示质量。此外,逐切片的空间卷积具有较高的计算复杂度,导致网络推理时间较长,难以满足实时运行的需求。总结来说,线性锚和全尺寸特征增强方式都采用了单一的结构模式,难以根据车道线的不同形状和空间分布进行自适应的动态调整。

针对线性锚在结构表示和车道特征增强方面的局限性,本章提出了一种基于超锚的车道线检测方法,即 HANet。超锚是一种动态生成的参考结构,它不再局限于直线形态,具有更灵活的形状和更高的置信度,能够更贴近实际车道的多样性和复杂性。针对现有的全尺寸特征增强方式存在容易引入背景噪声、效率低下的问题, HANet 还实现了多种车道位置敏感的特征增强方法,包括自适应车道线描述子构建和基于注意力机制的车道内及车道间特征增强。通过将超锚与车道位置敏感特征增强技术整合在一个统一的框架中, HANet 有效地提升了对弯道、水平车道以及其他视觉不可见车道线等多种困难样本的检测性能。此外, HANet 通过高效的超锚生成和车道位置敏感特征增强,实现了具有竞争力的检测速度。

3.2 方法概述

本节介绍了一种基于超锚的车道线检测方法 HANet,以解决现有方法在车道线结构表示和特征增强的局限性。HANet 的整体架构如图3.2所示。对于输入图像,首先利用一个轻量级网络生成基于行和列位置预期的超锚。在图中,行超锚和列超锚分别用橙色和青色点表示,以4个超锚为例进行展示。然后构建具有自适应感受野的车道线描述子。基于车道线描述子实现车道内和车道间特征聚合,并通过预测偏移和置信度获得完整的车道表示。

接下来的部分首先介绍基于超锚的车道线表示方法,这是构建 HANet 框架的基础,然后详细描述了 HANet 的每个组件,包括基于超锚的车道线表示、超锚生成、自适应车道线描述子构建和车道级特征增强方法。




图 3.2 基于超锚的车道线检测方法 (HANet) 的框架

3.2.1 基于超锚的车道线表示

现有的基于锚的车道线检测方法通常采用行锚 (row anchor) 和线性锚 (line anchor) 的车道线表示形式。本节首先简要介绍基于行锚和线性锚的车道线表示方法。然后再给出基于超锚的车道线表示方法, 并分析基于超锚的车道线表示的优点。

车道线通常由等间隔行上的一组车道点表示。对于给定的输入 $I \in \mathbb{R}^{H_I \times W_I \times 3}$, 行锚表示 $Y = \{y_i\}_{i=0}^{N_{row}-1}$, 其中 $y_i = i \cdot \frac{H_I}{N_{row}-1}$ ($i = 0, 1, \dots, N_{row}-1$), N_{row} 表示行锚的数量。车道点在行锚上的对应水平坐标表示为 x_i , 以及逐行的车道点存在指示符表示为 e_i 。对于一个车道实例, X 和 E 分别构造为 $X = \{x_i\}_{i=0}^{N_{row}-1}$ 和 $E = \{e_i\}_{i=0}^{N_{row}-1}$ 。常见的基于行锚的车道线表示^[44-45]可以表示为

$$\Psi_{Lane}^{row} = \{(x_i, y_i, e_i) \in (X, Y, E), i = 0, 1, \dots, N_{row} - 1\}. \quad (3.1)$$

基于线性锚的车道线表示首先引入满足以下约束条件下的密集线性锚

$$k_1 x + k_2 y + k_3 = 0, k_1 \neq 0 \text{ or } k_2 \neq 0. \quad (3.2)$$

然后计算车道点与线性锚之间的偏移量为

$$\begin{cases} \Delta X = \{\Delta x_i\}_{i=0}^{N_{row}-1} = \{x_i - x_i^{anc}\}_{i=0}^{N_{row}-1}, \\ x_i^{anc} = \frac{-k_3 - k_2 y_i}{k_1}. \end{cases} \quad (3.3)$$

此外, 还需要车道线长度 len 和置信度 $conf$ 来获得完整的车道线表示

$$\Psi_{Lane}^{line} = \{(\Delta x_i, y_i, len, conf, i = 0, 1, \dots, N_{row} - 1)\}. \quad (3.4)$$




图 3.3 超锚与线性锚的比较

图3.3对所提出的超锚与标准线性锚进行了直观的对比。超锚是一组紧密排列且能良好适应车道线形状的点构成的集合，它可以看作是线性锚的扩展。橙色和青色网格代表当前和侧边车道线，橙色和青色圆点分别表示行超锚和列超锚。超锚具有两个显著的优势：首先，其置信度较传统线性锚更高；其次，其形状更为灵活。如图3.3（a）所示，密集分布的线性锚多位于背景区域，与车道真值的IoU相对较低。传统线性锚的严格遵循公式(3.2)，这可能限制其对具有复杂结构车道线的描述能力。相比之下，超锚能够根据输入自适应地匹配任意形状，因为它们是通过计算网络输出的逐行位置期望值生成的，并在训练过程中针对车道线的真值进行了优化。因此，超锚不仅能够获取高质量的车道线描述子，还能在此基础上进一步实现车道线特征的高效增强。

利用图3.3中的超锚，即一组动态参考点，一种新的车道线表示可以写作

$$\begin{cases} \Psi_{Lane}^{hyper} = \{(\Delta x_i, y_i), st, end, conf, i = 0, 1, \dots, N_{row} - 1\}, \\ \Delta x_i = x_i - x_i^{hanc}, \\ x_i^{hanc} = \Phi(I, \theta), \end{cases} \quad (3.5)$$

其中 st 和 end 表示车道线起始点和车道线结束点的行锚的索引， $conf$ 表示车道线预测的置信度， $\Phi(\cdot)$ 表示超锚生成模块， I 为输入图像， θ 为模型参数。

如图3.4所示，考虑到当前车道和两侧车道存在不同的朝向特点，侧边车道更接近水平方向，只能用少数的行点表示，存在结构表示不精确的问题。因此，对于不同朝向的车道线，应采用不同的行和列车道表示方法。具体来说，行锚更适合垂直线条，因为垂直线条在垂直方向上有很大的变化，可以用足够多的车道点来精确描述。同样，列锚适用于更接近水平朝向的侧边车道线。因此，本章将基于行的超锚表示推广到列超锚，并采用了行列混合锚的车道表示，比使用单一

的行锚或列锚更有效。基于行列混合超锚的车道线表示可以表示为

$$\begin{cases} \Psi_{Lane}^{row} = \{(\Delta x_i, y_i), st, end, conf, i = 0, \dots, N_{row} - 1\}, \\ \Psi_{Lane}^{col} = \{(x_j, \Delta y_j), st, end, conf, j = 0, \dots, N_{col} - 1\}, \end{cases} \quad (3.6)$$

其中 N_{row} 和 N_{col} 分别表示行和列超锚的长度。




图 3.4 混合行列超锚表示不同朝向车道线

3.2.2 超锚生成模块

理想的超锚生成策略应确保生成的锚结构紧凑、定位准确且形状灵活。同时，考虑到实时应用的需求，锚的生成过程应高效且快速。本节受 Faster R-CNN^[80] 中参数共享思想的启发，提出了一种端到端的超锚生成模块。该模块仅通过几个简单的全连接层实现，能够满足上述所有要求。如图3.2所示，输入图像首先通过轻量级网络生成基于行和列位置期望的超锚。随后，构建具有自适应感受野的车道线描述子，并对其进行车道内和车道间的特征增强。最后，基于这些描述子预测偏移量和置信度，从而得到完整的车道线表示。为简化说明，图中以4个超锚为例，其中行超锚和列超锚分别以橙色和青色点表示。

具体而言，首先使用主干网络从输入图像中提取深层语义特征 F_b 。实验中采用 ResNet^[104] 作为主干网络，但其他通用主干网络如 DLA^[105] 和 Swin-Transformer^[106] 同样适用。在上分支中，对 F_b 进行 1×1 卷积操作以减少特征通道数，从而提高计算效率。之后，将特征展开并通过全连接层处理，最终重构得到 F_{gbl} 。 F_{gbl} 的通道数 C_{gbl} 由当前车道和侧边车道的数量决定，即

$C_{gbl} = N_{ego} + N_{side}$ 。 F_{gbl} 被分为四组，分别用于计算行超锚和列超锚，以及确定车道线的起始和结束位置。在图3.2中，侧边的灰色网格指示了车道线的开始和结束位置。

算法3.1详细介绍了行超锚的计算过程。同理，可以推导出列超锚的计算方法。行超锚和列超锚分别由等间隔行和列上的车道参考点组成，记为 P ，其中参考点是通过计算网络输出的逐行位置期望得到的。除了超锚 P ，还可以获得得分图 S ，用于后续车道线描述子的构造。 P 和 S 包含 K 个不同的元素，表示 K 个可能的车道线位置，这增强了车道线检测方法在复杂环境下的鲁棒性。然而，预设计的超锚数量典型为 36 个，远少于常见的线性锚数量，例如，在现有工作^[31]中，线性锚的数量通常超过 1000 个。为了使网络可以学习到车道线准确的起始和结束位置，本节还定义一个分类损失 L_{st_end} ，其表达式如下

$$L_{st_end} = \sum_{i=1}^{N_{ego}} [L_{CE}(st_i^r, G_i^{st-r}) + L_{CE}(end_i^r, G_i^{end-r})] + \sum_{m=1}^{N_{side}} [L_{CE}(st_m^c, G_m^{st-c}) + L_{CE}(end_m^c, G_m^{end-c})], \quad (3.7)$$

其中上标 r 和 c 分别用于索引行和列超锚， st_i^r ， end_i^r ， G_i^{st-r} 和 G_i^{end-r} 分别表示第 i 个当前车道线的起始位置和结束位置的预测值和真值。 st_m^c ， end_m^c ， G_m^{st-c} 和 G_m^{end-c} 遵循类似的命名规则。 $L_{CE}(\cdot, \cdot)$ 是用于非平衡样本分类任务的焦点损失函数^[107] (Focal Loss)，其表达式为

$$L_{CE}(p_t, y) = \begin{cases} -(1 - p_t)^{\gamma} \log(p_t) & \text{当 } y = 1, \\ -(p_t)^{\gamma} \log(1 - p_t) & \text{否则.} \end{cases} \quad (3.8)$$

其中 p_t 为预测概率， y 为目标的地面真值。

此外，对于超锚图 M_0 和超锚 P_0 应用分类损失 L_{anc} 和回归损失 L_{exp} 来学习超锚的位置

$$L_{anc} = \frac{1}{N_1} \sum_{i=1}^{N_{ego}} \sum_{j=st_i^r}^{end_i^r} L_{CE}(M_{i_ (j,:)}^r, G_{i,j}^{anc-r}) + \frac{1}{N_2} \sum_{m=1}^{N_{side}} \sum_{n=st_m^c}^{end_m^c} L_{CE}(M_{m_ (:,n)}^c, G_{m,n}^{anc-c}), \quad (3.9)$$

其中 N_1 和 N_2 用于归一化， $M_{i_ (j,:)}^r$ 用作预测第 i 个当前车道线的 j 行锚位置， $M_{m_ (:,n)}^c$ 用作预测第 m 个侧边车道线的第 n 列锚位置。 $G_{i,j}^{anc-r}$ 和 $G_{m,n}^{anc-c}$ 是相应车道线的位置真值。

回归损失 L_{exp} 计算公式为

$$L_{exp} = \frac{1}{N_1} \sum_{i=1}^{N_{ego}} \sum_{j=st_i^r}^{end_i^r} L_1(P_{0_ (i,j)}^r, G_{i,j}^{exp-r}) + \frac{1}{N_2} \sum_{m=1}^{N_{side}} \sum_{n=st_m^c}^{end_m^c} L_1(P_{0_ (m,n)}^c, G_{m,n}^{exp-c}), \quad (3.10)$$

其中 $L_1(\cdot)$ 是平滑的一阶绝对值损失。需要注意的是, $G_{i,j}^{exp_r}$ 和 $G_{m,n}^{exp_c}$ 是车道点的位置真值, 这些真值不必是整数。损失函数(3.9)和(3.10)仅当车道真值存在时计算。需要说明的是, 在上述计算超锚位置的过程中, 我们假设每条水平线或垂直线与一个车道实例仅相交一次。在面对复杂的弯道时, 同一条车道线可能在一行或一列上有多个点。对于多交点情况, 我们优先考虑保留底部交点, 即靠近下端和侧边界的车道点。底部优先策略虽然使得重建的车道线可能略短于实际车道, 但主要部分仍然保持了完整性, 这在我们的研究中被验证是可以接受的。

3.2.3 自适应车道线描述子构建

在线性锚方法中, 通过逐点采样得到的车道线描述子具有固定的感受野。这种固定的感受野在车道线清晰的情况下通常表现良好, 但在车道线线索模糊或环境复杂的场景中, 它可能不足以捕捉足够的上下文信息来准确地定位车道线。为了解决这一问题, 如图3.2所示, HANet 使用得分图 S 来构建一组具有自适应感受野的车道线描述子, 从而有效地利用周边线索, 提高车道线相对于超锚的准确偏移。实际上, 考虑响应分布信息的方法^[108]被证明有利于提升关键点的定位性能, 并被广泛使用。

在图3.2的下分支中, HANet 首先对低分辨率特征图 F_b 应用一个 1×1 卷积, 并将其通道数减少到 C_{fea} 。此外, 在特征金字塔网络 (FPN)^[49]的侧向连接中, 也应用了一个 1×1 卷积来生成 $F_{loc} \in \mathbb{R}^{H \times W \times C_{fea}}$, 得到尺寸为输入图像的 $1/8$ 的下采样特征。此外, 我们还通过将可学习的位置嵌入 (Positional Embedding, PE)

算法 3.1 行超锚生成

- 1 输入: 行超锚图 $M \in \mathbb{R}^{N_{row} \times N_{col}}$,
- 2 每条车道的超锚数量, $K \in \mathbb{R}$ 。
- 3 开始:
 - 1: 得分图 $S_0 = \text{row_softmax}(M)$;
 - 2: 行超锚 $P_0 = \{(i, p_{i,j}^0)\}_{i=0}^{N_{row}-1}$ 且 $p_{i,j}^0 = \sum_{j=0}^{N_{col}-1} s_{i,j}^0 \cdot (j + 0.5)$ 。
 $p_{i,j}^0$ 表示第 i_{th} 行上的锚点位置, $s_{i,j}^0 \in S_0$;
 - 3: 令 $k = 1$;
 - 4: 当 $k \leq K$ 执行:
 - 5: 获取行超锚图 M_k 和得分图 S_k $M_k = \text{row_topk_mask}(M)$,
 $S_k = \text{row_softmax}(M_k)$;
 - 6: 行超锚 $P_k = \{(i, p_{i,j}^k)\}_{i=0}^{N_{row}-1}$ 且 $p_{i,j}^k = \sum_{j=0}^{N_{col}-1} s_{i,j}^k \cdot (j + 0.5)$, 其中 $s_{i,j}^k \in S_k$;
 - 7: $k++$;
 - 8: 返回步骤 4

结束

输出: 得分图 $S = \{S_k\}_{k=0}^K$, $S_k \in \mathbb{R}^{N_{row} \times N_{col}}$,
 行超锚 $P = \{P_k\}_{k=0}^K$, $P_k \in \mathbb{R}^{N_{row} \times 2}$ 。

函数定义:

*row_softmax($\cdot$) 执行逐行的 softmax 操作。

*row_topk_mask($\cdot$) 保留每行最大的 k 个元素, 并将其他元素设置为负无穷, 负无穷将在 softmax 函数中被转换为 0。

逐像素加和到 F_{loc} 中, 为模型提供显式的位置信息。注意, F_{loc} 的尺寸与前面提到的得分图 S 相同, 从而在 S 和 F_{loc} 之间形成了一个一对一映射。随后, 车道描述子集合 D 可以表示为 $\{D_k\}_{k=0}^K$, 单个车道线描述子 D_k 可以通过公式(3.11)得到

$$D_k = \varphi(S_k, F_{loc} + PE), \quad (3.11)$$

其中 $D_k \in \mathbb{R}^{N_{anc} \times C_{fea}}$, S_k 是得分图 S 中的一个元素, PE 是可学习的位置嵌入, 函数 $\varphi(\cdot)$ 沿行或列方向执行逐元素的乘法和求和操作。具体来说, 为了获取自车道线 (ego lane) 的描述子, $\varphi(\cdot)$ 沿着行方向执行求和操作, 从而得到行车道线描述子 $D_i^{row} \in \mathbb{R}^{N_{row} \times C_{fea}}$ 。类似地, 两侧车道线描述子 $D_j^{col} \in \mathbb{R}^{N_{col} \times C_{fea}}$ 通过沿着列方向的求和来获得。这里 N_{row} 和 N_{col} 分别代表行超锚和列超锚的长度。

尽管车道线描述子中汇集了多行或多列位置的特征, 但这与基于局部特征预测偏移的设计原则并不矛盾。超锚的位置通过焦点损失函数进行优化, 目的是在关键区域增强车道线网格的响应, 而在其他区域则保持较弱的响应。因此, 理想的得分图 S 应呈现出尖锐的分布特征。这种情况下, 车道线描述子的特征主要受到具有强烈响应的点的影响, 正如公式 (3.11) 所描述的那样。然而, 在一些挑战性的场景中, 可能会观察到车道线位置的响应分布不够理想, 这些分布可能表现为平滑的形状或具有多个峰值, 从而使得车道线的表示变得模糊不清。在这种情况下, 响应分布的区分度降低, 意味着车道线的位置不确定性增加。通过公式 (3.11) 构建的车道线描述子, 能够搜索邻近区域以寻找更多的线索, 而不是仅仅依赖于单一的采样点。这种方法通过收集相邻区域的局部信息, 有助于提高车道线位置的准确性。综上, 无论是在常规还是具有挑战性的场景中, 车道线描述子都能够获得适当的感受野。

3.2.4 车道内和车道间特征增强

本节将阐述如何通过引入注意力机制来强化单个车道线内的特征表示, 以及不同车道线实例之间的相互关系。图 3.5 展示了基于注意力机制的车道线内和车道线间特征增强的过程。

车道内的特征增强在每个车道线描述子内部进行, 目的是深入挖掘单个车道线的特征相似性。为了便于理解, 图中仅展示了两个车道线描述子, 即 D_1 和 D_2 。根据公式 (3.11) 计算得到的车道线描述子首先被转换为序列形式。由于实际的车道线长度通常短于图片的长度或宽度, 所以车道描述子内的车道线部分在图中用青色和橙色表示, 背景区域则用灰色表示。车道内部特征的增强主要在青色和橙色的矩形区域内进行, 这一过程可以通过合适的掩码注意力机制高效实现。为了捕捉不同车道实例之间的全局分布模式, 本节还提出了车道间特征增




图 3.5 车道内和车道间特征增强

强的方法，如图 3.5 (b) 所示，该方法在不同车道实例间计算注意力。车道内和车道间特征增强方法忽略了背景特征，这样做既能提高计算效率，又能避免将背景噪声引入到车道线描述子中。如果未检测到车道线，则使用一种特殊的矩阵——单位矩阵，作为车道内增强的注意力图，以保持车道特征不变。单位矩阵在数学上代表一个所有对角线元素为 1，其余元素为 0 的方阵，如图中白色对角线所示。类似地，如果有效车道线段的数量少于两个，则在车道间增强中应用单位矩阵。如图 3.2 所示，这两个模块的输出分别是表局部和全局车道描述子，并被记为 $D_{loc} \in \mathbb{R}^{N_{anc} \times N_{lane}}$ 和 $D_{gbl} \in \mathbb{R}^{N_{anc} \times N_{lane}}$ 。值得注意的是， D_{loc} 由特定车道线的局部细节组成，用于预测准确的偏移量，而 D_{gbl} 则额外嵌入了其他车道线实例的信息，用于确定车道线的置信度。预测的偏移量有助于在具有挑战性的场景（如极端光照和遮挡）中获得更准确的车道线位置。考虑到全局上下文，从 D_{gbl} 获得的车道线置信度有助于减少误报，这一点在后续实验中得到了验证。如图 3.1 (c) 所示，与先前的全尺寸特征增强方法^[18-19]相比，本节提出的车道特征增强方法专注于车道线区域，提高了特征增强的针对性和效率。

3.2.5 优化函数

为了构建基于超锚的完整车道线表示，回归头根据局部车道线描述子 D_{loc} 来预测车道点相对于超锚的偏移量，如公式 (3.6) 所示。同时，分类头基于全局车道线描述子 D_{gbl} 来评估车道线预测的可靠性，这些描述子融合了车道线的局部和全局分布信息。回归头和分类头均通过全连接层实现，确保了模型的灵活性和表达能力。对于每个车道线描述子，回归头输出一个偏移向量 $O \in \mathbb{R}^{N_{anc} \times 1}$ ，其中 N_{anc} 可以是 N_{row} 或 N_{col} 。分类头则产生一个置信度值 $Q \in \mathbb{R}^1$ ，表示该车道线预测的可信程度。预测的偏移和置信度分别通过平滑 L1 损失和二元交叉熵

(Binary Cross-Entropy, BCE) 损失进行优化。

偏移分支的损失函数 L_{oft} 定义如下

$$L_{oft} = \frac{1}{N_1} \sum_{i=1}^{N_{ego}} \sum_{j=st_i^r}^{end_i^r} L_1(O_{i,j}^r, G_{i,j}^{oft-r}) + \frac{1}{N_2} \sum_{m=1}^{N_{side}} \sum_{n=st_m^c}^{end_m^c} L_1(O_{m,n}^c, G_{m,n}^{oft-c}), \quad (3.12)$$

其中 $L_1(\cdot)$ 是平滑 L1 损失, $O_{i,j}^r$ 和 $G_{i,j}^{oft-r}$ 分别是第 i 个自车道线的第 j 行的偏移预测和偏移真值。类似地, $O_{m,n}^c$ 和 $G_{m,n}^{oft-c}$ 是与第 n 个侧车道线的第 m 列相关的偏移预测和真值。

置信度预测分支的损失函数 L_{conf} 定义为

$$L_{conf} = \sum_{i=1}^{N_{ego}} L_{BCE}(Q_i^r, G_i^{conf-r}) + \sum_{m=1}^{N_{side}} L_{BCE}(Q_m^c, G_m^{conf-c}), \quad (3.13)$$

其中 $L_{BCE}(\cdot)$ 是二元交叉熵损失, G_i^{conf-r} 和 G_m^{conf-c} 是车道线置信度的二元标注。当相应的车道线预测被确定为正样本时, G_i^{conf-r} 和 G_m^{conf-c} 被设置为 1, 否则为 0。

本节还提出了一种动态的正样本选择策略, 以适应基于超锚点的车道线表示方法。这一策略根据网络预测结果动态调整正样本的选择标准。对于每个预测的车道线, 首先根据预测的起始和结束位置确定其有效长度。随后, 通过计算预测车道线与真实车道线之间的 IoU, 来定义正样本。通过考虑车道线预测的长度来计算有效的 IoU, 这有助于准确评估预测的置信度并减少误报。预测的车道线长度在一定程度上反映了预测的可靠性。当预测车道线与真实车道线之间的 IoU 超过一个经验确定的阈值时, 该车道线预测被认定为正样本。此外, 在它们落在邻近区域并同时满足 IoU 阈值的情况下, 多个超锚可以被分配给一个真实值。为了消除潜在的重复预测, 采用了非极大值抑制技术通过选择性地保留最佳预测来减少冗余。车道线预测的置信度在运行时根据多种因素动态生成, 这些因素包括车道线的存在性、有效长度和几何结构。

最终的训练损失函数如下

$$L = L_{anc} + \alpha L_{st_end} + \beta L_{exp} + \gamma L_{oft} + \eta L_{conf}, \quad (3.14)$$

其中 α 、 β 、 γ 和 η 是权重系数。

3.3 实验结果与分析

本节首先描述了实验设置, 接着在两个主要的车道线检测数据集 CULane^[18] 和 TuSimple^[74] 上展示了 HANet 的定量和定性实验结果, 在最后一小节中, 验证了车道敏感特征增强方法的有效性。

3.3.1 实验设置

在实验中, CULane 和 TuSimple 数据集的图像大小调整为 288×800 像素, 与本方法密切相关的方法 UFLD^[44]、UFLDv2^[45]、LATT^[31]保持一致。后续实验中, 我们均采用相同的输入分辨率 288×800 像素和硬件设备测试 FPS。基于经验和实验结果, 行锚的长度 N_{row} 设定为 36, 列锚的长度 N_{col} 设定为 100。同时, 自车道线 N_{ego} 和侧车道线的数量 N_{side} 均被设定为 2。特征通道数 C_{fea} 设为 64。训练过程采用了 Adam 优化器, 其参数 β_1 设为 0.9, β_2 设为 0.999。分别在 CULane 数据集上训练了 30 个周期, 在 TuSimple 数据集上训练了 60 个周期, 批量大小为 32。初始学习率设定为 5×10^{-4} , 后续采用余弦衰减策略调整学习率。损失函数公式 (3.14) 中的权重 α 、 β 、 γ 和 η 分别被设定为 1、1、0.2 和 0.5。为了避免训练初期大的偏移损失, 前两个训练周期采用了预热策略, 逐渐增加模型的学习率。正样本的选择时 IoU 阈值设为 0.4。所有的训练实验都是在 4 张 RTX 2080Ti GPU 上完成的。在测试阶段, 通过非极大值抑制过滤掉 IoU 大于 0.1 的重复预测。锚统计频率也被用作基于锚的车道线检测的标准过程。模型的帧率 (FPS) 由单个 RTX 2080Ti GPU 测试得到。对于自车道线, 设定了 10 个行超锚; 对于侧车道线, 设定了 6 个列超锚。

3.3.2 与现有方法对比

1. CULane 数据集实验结果

在表 3.1 中, 基于超锚的方法 HANet 与 CULane 数据集上的一些最先进的方法进行了比较。为了公平比较, UFLD^[44]、UFLDv2^[45]、LATT^[31]以及 HANet 均采用相同的输入分辨率 288×800 像素和硬件设备测试 FPS, 相应的结果用 * 标记。额外标注了每个类别的数据比例。评估指标是 F1 分数, IoU 阈值为 0.5。对于“路口”类别, 仅显示误报。

基于曲线的方法^[37,41]以端到端的方式回归曲线参数, 但优化曲线参数的学习过程较为困难, 导致 LSTR^[37]和 BézierLaneNet^[41]的性能略低于其他方法。在基于分割的车道线检测方法中, 密集的像素级预测和全尺寸图像上的特征增强不可避免地带来较高的时间成本。如表 3.1 所示, HANet (ResNet-18) 在速度上大约是 RESA (ResNet-50)^[19]的 5 倍, 同时达到了相同的 F1 分数。尽管 IntRA-KD^[23]利用知识蒸馏的方法实现了较快的处理速度, 但其性能与 HANet 相比仍有明显差距。此外, SAD^[22]与最近基于分割的方法^[16-17,20]相比, HANet 也同样在性能和速度方面取得了显著的提升。

HANet 与基于行锚^[44-48]和基于线性锚^[29-31]的车道线检测方法具有紧密联系。因此, 表 3.1 中将这两类方法同时列在基于锚的检测方法中, 方便更直观地对比和分析。为了公平比较, 这些方法根据主干网络大小被分为两组, 并且用粗

表 3.1 CULane 数据集上的实验性能对比。

方法	Total	FPS	正常 27.7%	拥堵 23.4%	眩光 1.4%	阴影 2.7%	无线 11.7%	箭头 2.6%	弯道 1.2%	路口 9.0%	夜间 20.3%
基于曲线的方法											
LSTR(ResNet-18) ^[37]	68.7	-	86.8	67.3	56.6	59.8	40.1	78.7	56.6	1166	59.9
LSTR(ResNet-34) ^[37]	72.5	-	89.7	69.8	64.3	68.2	45.3	85.0	64.1	1247	66.7
BézierLaneNet(ResNet-18) ^[41]	73.7	-	90.2	71.6	62.5	70.9	45.3	84.1	59.0	996	68.7
基于分割的方法											
SCNN ^[18]	71.6	8	90.6	69.7	58.5	66.9	43.4	84.1	64.4	1990	66.1
RESA(ResNet-34) ^[19]	74.5	45	91.9	72.4	66.5	72.0	46.3	88.1	68.6	1896	69.8
RESA(ResNet-50) ^[19]	75.3	36	92.1	73.1	69.2	72.8	47.7	88.3	70.3	1503	69.9
SAD(ENet) ^[22]	70.8	75	90.1	68.8	60.2	65.9	41.6	84.0	65.7	1998	66.0
FastDraw ^[58]	-	90	85.9	63.6	57.0	59.9	40.6	79.4	65.2	7013	57.8
PINet(4H) ^[16]	74.4	33	90.3	72.3	66.3	68.4	49.8	83.7	65.7	2052	66.3
HBNet ^[17]	73.1	40	91.9	71.6	64.7	66.7	46.8	85.3	65.1	2306	66.7
CenLaneNet ^[20]	74.8	81	90.1	73.7	66.0	73.9	48.6	85.8	66.5	1359	68.0
IntRA-KD ^[23]	72.4	100	-	-	-	-	-	-	-	-	-
基于锚的方法											
UFLD(ResNet-18) ^[44]	68.4	362*	87.7	66.0	58.4	62.8	40.2	81.0	57.9	1743	62.1
UFLDv2(ResNet-18) ^[45]	73.3	220*	90.8	71.8	60.0	70.2	45.7	85.3	66.1	1898	68.4
Laneformer(ResNet-18) ^[48]	71.7	-	88.6	69.0	64.1	65.0	45.0	81.6	60.5	25	64.8
CurveLanes-NAS-S ^[30]	71.4	-	88.3	68.6	63.2	68.0	47.9	82.5	66.0	2817	66.2
LATT(ResNet-18) ^[31]	75.1	206*	91.1	73.0	65.7	70.9	48.4	85.5	63.4	1170	69.0
HANet(ResNet-18)	75.3	181*	91.0	74.3	66.3	73.9	48.4	85.3	66.4	1639	70.4
E2E(ResNet-34) ^[46]	71.5	-	90.4	69.9	61.5	68.1	45.0	83.7	69.8	2077	63.2
KP-MFF(ResNet-50) ^[47]	69.0	417	87.2	67.1	63.7	66.1	44.7	81.5	65.5	3306	62.0
UFLD(ResNet-34) ^[44]	72.3	197*	90.7	70.2	59.5	69.3	44.4	85.7	69.5	2037	66.7
UFLDv2(ResNet-34) ^[45]	74.5	147*	91.9	73.4	61.7	70.8	47.8	87.5	69.6	2154	69.5
Laneformer(ResNet-34) ^[48]	74.7	-	90.7	72.3	67.1	71.6	47.4	85.1	65.9	26	67.8
PointLane(ResNet-101) ^[29]	70.2	-	88.0	68.1	61.5	63.3	44.0	80.9	65.2	1640	63.2
CurveLanes-NAS-M ^[30]	73.5	-	90.2	70.5	65.9	69.3	48.8	85.7	67.5	2359	68.2
LATT(ResNet-34) ^[31]	76.7	140*	92.1	75.0	66.5	78.2	49.4	88.4	67.7	1330	70.7
HANet(ResNet-34)	76.4	131*	91.7	75.6	67.4	76.4	49.5	86.2	68.1	1547	71.1

体标记了两组实验中的最佳成绩。

如表 3.1 所示,在“正常”场景下,大多数基于深度神经网络的方法达到了超过 90% 的 F1 分数。然而,在其他具有挑战性的场景中,车道线检测的准确性出现明显下降。可以看出,轻量级 HANet (ResNet-18) 在“拥堵”、“眩光”、“阴影”、“无线”和“夜间”场景中实现了最先进的性能,这表明 HANet 可以有效解决无视觉线索的问题。在第二组实验比较中, HANet (ResNet-34) 在具有挑战性的场景中也观察到了类似的性能提升,进一步验证了该方法的鲁棒性。

为了实现快速的车道线检测速度,包括 UFLD^[44]、UFLDv2^[45]、Laneformer^[48]和 KP-MFF^[47]在内的基于行锚的方法使用低分辨率的特征图来定位车道线,但没有充分探索车道线的空间和纹理线索。因此,在“夜间”、“眩光”

等具有挑战性的场景中，这些方法难以准确检测车道线。例如，KP-MFF^[47]在TensorRT加速下可以达到417 FPS的速度，但这是在一定程度上牺牲检测精度的前提下实现的。相比之下，HANet利用车道敏感的特征增强，有利于在困难情况下探索车道线的空间和纹理线索。因此，在检测精度和速度的整体性能上，两种HANet模型都显著优于先前的方法。具体来说，轻量级HANet在F1分数上超过了UFLD 6.9%和UFLDv2 2.0%。值得注意的是，在车道线不明显的“拥堵”、“眩光”、“阴影”、“雨天”和“夜间”场景中，性能提升远大于“正常”场景。这样的性能提升表明，HANet能有效识别在缺乏视觉线索的困难场景中的车道线样本。

相较于基于线性锚的车道线检测方法^[29-31]，HANet同时在车道结构表示和车道特征增强两方面做出了改进。因此，HANet在检测性能上优于基于线性锚的方法^[29-31]。PointLane^[29]和CurveLanes-NAS^[30]使用垂直线性锚点，这导致车道点与锚点之间的平均偏移量较大。轻量级HANet（ResNet-18）的性能在检测准确性方面分别超过了CurveLanes-NAS的简化版3.9%和PointLane（ResNet-101）5.1%，这一结果验证了超锚相较于线性锚的优越性。LATT^[31]采用了更为精确的倾斜线性锚，这是其相较于其他方法的显著改进。在“正常”类别的车道线检测中，由于车道线通常是直线形态且特征明显，易于检测，LATT利用其对车道线直线结构的特性和逐点采样的优势，表现略优于HANet。在更具挑战性的场景中，定位困难的车道线样本需要更多的局部细节，此时HANet提出的多种车道敏感增强明显优于LATT的逐点采样方式。此外，尽管HANet在网络运行速度上与LATT^[31]相当，但实际应用中由于LATT需要NMS后处理更多数量的线性锚，HANet可能会展现出更快的总体速度。

为了更详尽地分析HANet在各个挑战场景中的性能优势，图3.6以CurveLanes-NAS和LATT方法为对比基线，展示了HANet在弯道等子场景中的性能提升。




图 3.6 在 CULane 数据集弯道等挑战场景下的相对性能提升

基于线性锚的方法^[29-31]依赖于具有固定直线结构的锚点，这限制了它们对真实车道线形状的适应性。相比之下，提出的超锚方法以灵活的形状为特点，更

贴近真实的弯曲车道线。因此, HANet 在“弯道”类别的准确性上高于基于线性锚的方法^[30-31], 如图 3.6所示。尽管 CurveLanes-NAS^[30] 是利用神经架构搜索技术专门设计用于检测弯道的模型, 但 HANet (ResNet-34) 在曲线车道线检测方面仍然展现出优于 CurveLanes-NAS-M 的性能。此外, HANet (ResNet-18) 和 HANet (ResNet-34) 相较于 LATT^[31] 相应模型, 在弯道上的检测性能分别提升了 3.0% 和 0.4%。需要说明的是, 包括 UFLDv2 在内的基于行锚的方法, 以及基于分割的方法, 由于在预测期间不施加任何结构性约束, 也可以有效地表示曲线。另外, 在其他挑战性场景中, 车道线可能因为极端光照条件而几乎不可见, 导致车道线的预测位置和形状可能不准确。HANet 提出的车道敏感特征增强方法有助于根据车道线形状微调车道线位置并减少误报。因此, HANet 在“拥堵”、“眩光”和“夜间”场景中的表现要明显优于其他所有方法。

2. 模型特性分析

除了在 CULane 测试集各子场景上的对比, 本节还基于车道线检测精确率 (Precision) 和召回率 (Recall) 上分析了 HANet 的模型识别偏好。参与比较的方法为与 HANet 密切相关且源代码公开的两种典型方法: 基于行锚的 UFLD^[44] 和基于线性锚的 LATT^[31]。表 3.2 报告了使用各方法官方代码所获得的精确率和召回率。

表 3.2 模型精确率与召回率偏好分析

方法	F1(%)	Precision (%)	Recall(%)
UFLD (ResNet-18)	69.7 ¹	70.2	69.3
LATT (ResNet-18)	75.1	82.5	68.9
HANet (ResNet-18)	75.3	77.4	73.2

¹ 通过官方源码复现得到的实验结果略好于表格3.1提供的原论文数据。

结果显示, 这三种方法在车道线检测特性上存在明显的差异。UFLD^[44] 在精确率上与其他方法相比存在显著差距, 这主要是因为其基于低分辨率的深层语义特征来预测车道线, 导致在复杂场景中难以准确定位细小的车道线。此外, 由于缺乏整体结构的参考, UFLD 容易产生大量的误报和较低的精确率。而 LATT^[31] 虽然在精确率上表现出优势, 但在召回率上存在不足, 这主要是因为其使用的线性锚和点采样策略未能充分捕捉车道线的局部细节。线性锚为车道线的描述提供了整体结构的参考, 但大多数预定义的线性锚与真实车道线的 IoU 值较低。同时, LATT 的逐点采样策略在获取车道线描述子时, 由于缺乏足够的车道线线索, 容易被误判为负样本, 从而导致漏报增多, 召回率降低。

HANet 在 UFLD^[44] 的基础上实现了显著的性能提升, 并在精确率和召回率之间取得了更好的平衡。一方面, HANet 基于超锚的车道线描述子是从局部特

征 F_{loc} 中提取的, 具有自适应的感受野, 能够更准确地推断车道线的位置。同时, 从自适应车道线描述子中学习到的基于有效 IoU 的置信度有助于排除不准确的预测。另一方面, HANet 利用深层全局特征生成的超锚比传统的线性锚更精确。通过同时利用局部和全局特征, HANet 能够减少漏报并提高车道线检测的性能。

3. TuSimple 数据集实验结果

表3.3展示了不同方法在 TuSimple 数据集上的准确率 (Accuracy)、F1 得分以及每秒帧数 (FPS)。为了保证比较的公正性, HANet 方法与两种速度最快的方法 UFLD^[44]和 LATT^[31]均在相同设置下进行测试, 相应的帧率结果以星号 (*) 标记。HANet (ResNet-34) 的 F1 分数达到了 97.01%, 是表格中所有方法中最高的。在 F1 分数、误检率 (FP)、漏检率 (FN) 和 FPS 几项指标中, HANet 实现了与最先进方法相近的性能。HANet (ResNet-34) 在考虑多项指标时, 综合表现出色。尤其是在 F1 分数和帧率方面, 这表明 HANet 是一个在保持高检测精度的同时, 还能实现快速处理的车道检测方法。

由于 TuSimple 数据集的样本数量较少, 且大多数样本是在高速公路上和良好可见条件下收集的, 这导致大多数方法的准确率相差无几。准确率排名前两名的方法, SAD^[22]和 SCNN^[18], 都采用了基于像素分割的范式, 并且 SCNN^[18]是利用额外的数据集进行训练的。HANet (ResNet-18) 和 HANet (ResNet-34) 的准确性分别为 95.63% 和 95.66%, 达到了与基于锚点的其他方法相当的性能水平,

表 3.3 TuSimple 数据集上的实验性能对比。

方法	Accuracy(%)	F1(%)	FP(%)	FN(%)	FPS
SCNN ^[18]	96.53	95.97	6.17	1.80	8
SAD(ENet) ^[22]	96.64	95.92	6.02	2.05	75
FastDraw ^[58]	94.90	94.59	6.10	4.70	-
E2E(ResNet-18) ^[46]	96.04	96.40	3.11	4.09	-
E2E(ResNet-34) ^[46]	96.22	96.58	3.08	3.76	-
PolyLaneNet ^[29]	93.36	90.62	9.42	9.33	115
LSTR ^[37]	96.18	96.85	2.91	3.38	-
KP-MFF ^[47]	94.64	94.69	5.69	4.93	417
UFLD(ResNet-18) ^[44]	95.82	96.05	3.06	4.82	362*
UFLD(ResNet-34) ^[44]	95.81	96.13	3.06	4.66	197*
LATT(ResNet-18) ^[31]	95.57	96.71	3.56	3.01	206*
LATT(ResNet-34) ^[31]	95.63	96.77	3.53	2.92	140*
HANet(ResNet-18)	95.63	96.78	3.31	3.13	181*
HANet(ResNet-34)	95.66	97.01	3.15	2.86	131*

但在 FP、FN 上要明显低于同类型的 UFLD^[44] 和 LATT^[31] 方法。值得注意的是, HANet 模型是从头开始训练的, 没有使用额外的训练数据集。

3.3.3 可视化结果分析

本节通过对检测结果的可视化, 更直观地展示 HANet 在车道线定位微调、不可靠车道预测过滤以及弯道结构表示三个方面的优势。

基于超锚的车道点位置微调过程如图 3.7 所示。左图为车道真值, 右图为 HANet 方法的预测结果, 其中黄点表示超锚位置, 绿点表示微调后的最终预测结果。可以观察到, 车道线可见部分的定位通常是准确的。然而, 对于车道线的远端, 定位则更为困难。在 HANet 框架下, 预测的偏移可以对车道点的位置进行适当调整, 以提高定位的准确性。此外, 在被遮挡的区域和没有车道标记的区域, 偏移预测同样表现出良好的性能。尽管这些区域缺乏局部纹理特征, HANet 仍然能够利用车道内部增强机制, 在这些无视觉线索的区域重建出合理的全局车道线结构。超锚是从低分辨率的深层特征中提取的, 偏移分支可以作为对粗糙超锚的补充, 以获得更精确的车道线位置。




图 3.7 车道线微调过程可视化

图 3.8 展示了 HANet 如何剔除低置信度的误检结果, 左图为车道真值, 右图为预测结果。置信度较低的红色车道预测会被剔除, 可以有效减少误检。HANet 基于有效的 IoU 来定义车道线的置信度, 能够学习车道线的潜在可靠结构, 有助于区分高置信度的车道线和背景区域的响应特征。具体来说, 可靠的车道线应表




图 3.8 拥堵、夜间场景下剔除低置信度的误检结果

现出平滑且连续的特性。图中前两行所示，由于结构不可靠，一些车道线预测的置信度较低。图 3.8 的最后一行中，尽管车道线预测的结构看似合理，但在车道级特征增强的帮助下，它们仍然被正确地识别为误报。UFLD^[44]由于缺少对车道线置信度的评估机制，可能难以识别并排除这些误报。

HANet 的弯道检测结果如图 3.9 所示。超锚是根据图片动态生成的，其形状不再是固定的直线，从而使得检测结果可以很好的拟合弯曲的车道线。

HANet 在 CULane 和 TuSimple 数据集一些典型场景下的检测结果如图 3.10 所示。前三行分别展示了 CULane 数据集中“拥堵”、“夜晚”和“眩光”条件下的车道线检测样本，其余结果来自于 TuSimple 数据集。在图 3.10 的第二行和第三行中，即使在面对极强或极弱的照明条件时，HANet 依然展现出了良好的车道线定位能力，这证明了 HANet 在不同环境条件下的具有良好的鲁棒性和适应性。

3.3.4 消融实验

本节通过消融实验验证行列混合超锚表示和车道敏感特征增强方法的有效性。所有实验都是在 CULane 上使用 HANet (ResNet-18) 进行的参数在不同实验中都尽可能保持一致。




图 3.9 HANet 的弯道检测结果

1. 行列混合超锚表示

本节分别验证了三种车道表示形式下的算法性能，实验结果如表3.4所示。实验结果表明，基于混合超锚的车道表示相较于单一行锚和列锚带来了显著的性能提升，验证了行超锚和列超锚分别适用于不同朝向的车道线。由于 CULane 数据集中自车道线数量要多于侧边车道，因此基于行超锚的车道线表示要优于列超锚的车道线表示。

表 3.4 基于行列混合超锚的车道线表示

车道表示	F1(%)	Precision(%)	Recall(%)
行超锚表示	70.7	70.2	71.2
列超锚表示	61.6	63.2	60.1
混合超锚表示	75.3	77.4	73.2

2. 车道敏感特征增强方法

本章提出的车道敏感特征增强方法包括自适应车道线描述子构建和基于注意力的车道内和车道间特征增强。本节通过消融研究来验证车道敏感的特征增强技术的有效性，实验结果如表3.5所示。

实验首先定义了一个基线方法，该基线方法按照与 HANet 相同的流程生成超锚，但在车道线描述子的构建和特征增强方面有所不同。基线方法采用了逐点采样策略来构建车道线描述子，而没有考虑整行的概率分布，并且没有应用其他




图 3.10 CULane 和 TuSimple 数据集中不同驾驶场景下的车道线检测结果。从左至右依次为原图、车道真值和预测结果。

表 3.5 车道位置敏感的特征增强方法消融实验

基线方法	自适应描述子	车道内增强	车道间增强	F1(%)	FPS
✓				73.4	198
✓	✓			74.1(+0.7)	189
✓	✓	✓		75.1(+1.7)	184
✓	✓		✓	74.4(+1.0)	186
✓	✓	✓	✓	75.3(+1.9)	181

车道特征增强技术。随后，实验逐步将基线方法与所提出的各个增强组件相结合，以逐一展示每个组件的效果。

表3.5结果显示，基线方法通过使用超锚替代了传统的线性锚，在 F1 分数上达到了 73.4%，这验证了使用超锚进行车道线检测的可行性。而且，由于超锚是从输入图像动态生成的，因此在计算上几乎没有增加额外的负担。通过消融研究，可以清晰地看到，随着自适应车道线描述子构建和基于注意力的特征增强组

表 3.6 损失函数权重因子消融实验

α	β	γ	η	F1(%)
1	1	1	1	74.3
1.2	1	1	1	73.9
1.1	1	1	1	74.3
0.9	1	1	1	74.2
0.7	1	1	1	73.8
1	1.2	1	1	74.1
1	1.1	1	1	74.0
1	0.9	1	1	74.1
1	0.7	1	1	74.0
1	1	0.9	1	74.6
1	1	0.6	1	75.0
1	1	0.3	1	75.0
1	1	0.2	1	75.1
1	1	0.2	0.9	74.6
1	1	0.2	0.7	75.2
1	1	0.2	0.5	75.3
1	1	0.2	0.4	75.0

件的逐一加入，模型的性能得到了明显提升，且对算法的速度影响较小。这同时验证了各个组件的有效性和较高的计算效率。

通过自适应采样构建的车道线描述子，能够有效提高算法的 F1 得分。与传统的逐点采样方法相比，自适应车道线描述子通过整合邻近行和列的局部信息，创建了一个能够捕捉车道线细节的描述子。这种描述子在车道线位置不确定的情况下，能够提供更广阔的感受野，从而有助于更准确地定位车道线。

车道内部特征增强的应用带来了明显的性能提升。一方面，它提高了相对于超锚点的偏移预测的准确性，同时有利于真阳性（TPs）的增加和假阳性（FPs）的减少，如图 3.8 所示。另一方面，用于预测车道线置信度的全局车道线描述子 D_{gbl} 是通过车道间增强和车道内部增强共同生成的，如图 3.2 所示。即使仅使用车道内部增强， D_{gbl} 也能够捕捉到车道线的基本形状，这有利于预测车道线的置信度。因此，车道内部增强对于提高偏移预测的准确性和车道线置信度的预测都是有益的，从而带来了整体性能的显著提升。

表 3.5 的第五行旨在通过引入车道间特征增强，探究车道线的全局分布模式。例如，同一条车道上的车道线应始终共存，它们在空间上的分布呈现出一定的对称性，并且通常汇聚于同一消失点。然而，实验结果表明，尽管车道间的全局结构模式提供了有关车道线共存和对称性的信息，但这种信息在直接提升局部车道点定位精度方面的效果并不如车道内部信息流显著。因此，如何更有效地利用全局车道线结构信息，仍需在未来的研究中进一步探索。

3. 损失函数各权重因子消融实验

在本章提出的总损失函数公式(3.14)包含了多项子任务，包括超锚位置的回归任务、车道起始点分类任务、偏移回归任务以及车道实例的置信度判断任务。由于不同的任务难度与重要性不同，这里我们对损失函数的权重系数进行消融实验，相应的实验结果如表格3.6所示。由于大多数车道线的起始范围较为接近并且实例级别的车道线分布模式总是平滑和连续的，因此车道起始点分类任务与车道置信度预测较为简单，相应的损失函数权重因子 α 和 η 对于模型性能的影响较小。其中，偏移预测与车道线的定位直接相关，因此该任务对应的权重因子 γ 对于所提算法的性能影响较大。最终，可以确认损失函数公式 (3.14) 中的最佳权重设置 α 、 β 、 γ 和 η 分别为 1、1、0.2 和 0.5。

3.4 本章小结

本章探讨了一种新的车道线检测技术，称为超锚网络 (HANet)，旨在解决传统线性锚点在处理车道线朝向和形态多样性方面的局限性。该技术通过动态创建一组具有行列混合特征的超锚点，提高了对车道线形状和方向的适应性，从而更精确地捕捉不同形状和方向的车道线。此外，针对现有特征增强方法可能引入的背景干扰和低效率问题，HANet 引入了几种车道位置敏感的特征增强策略，包括自适应的感受野构建和基于注意力机制的特征信息流构建。这些策略不仅增强了车道描述子的信息量，还在车道内部和车道之间实现了有效的信息交互。通过大量的实验验证，HANet 通过构建灵活高效的车道线表示和信息传递机制，显著提高了对复杂车道线，如弯道、水平车道等的检测能力，并保持了良好的处理速度。

第4章 基于多车道片段的车道线检测算法

本文第三章提出的基于超锚的车道线检测方法有效提升了车道线结构表示的灵活性，并且通过预测车道线实例级别的置信度来滤除结构不可靠的检测结果。尽管如此，该方法仍缺乏对车道线结构的建模机制，无法直接提升车道线结构预测的准确性。事实上，现有的车道线检测方法通常将车道线表示为有序点集，并主要依赖视觉线索来独立地定位每个车道点。这些方法在不同程度上忽视了车道点之间的空间位置相关性。因此，在复杂环境下可能会产生具有锯齿状、断裂等不可靠结构的车道线检测结果。

针对复杂环境下车道线检测容易出现锯齿、断裂等不可靠结构的问题，本章提出了一种基于多车道片段的车道线检测方法 LaneSegNet，以提高车道线结构建模的鲁棒性。该方法提出了一种渐进式的检测流程：首先从显著线索区域中提取可靠参考点，然后通过关联参考点周围的车道点构建局部车道片段，最后利用多车道片段重构完整车道线。车道线作为一种具有高度结构先验的对象，其结构特性可以辅助网络在复杂环境下识别车道线，尤其是提高车道线结构建模的可靠性。为此，LaneSegNet 创新性地将车道点表示为具有多层级和非对称结构的图节点。它一方面通过局部和全局图增强模块分别捕捉车道片段内和参考点之间的多层级拓扑结构，学习局部紧凑连续、全局平滑的车道线特点。另一方面，车道节点间非对称的权重设计，可以提升模型的推理能力。例如，被遮挡的车道点难以直接定位，可以依赖其他可靠的车道点位置进行推理，反之则不成立。为了进一步强化模型对车道点相对空间位置的理解，LaneSegNet 不再直接回归每个车道点的绝对位置，而是通过学习车道点间的相对偏移。广泛的实验结果表明，通过构建层级的车道拓扑结构能够有效提升复杂环境下车道线预测结果的结构可靠性。

本章内容安排如下：4.1节分析了现有车道线检测方法在车道线结构建模方面存在的不足和针对性的改进策略；4.2节详细阐述基于多车道片段的车道线检测方法 LaneSegNet 以及完整的车道线重构流程；4.3节在两个车道线数据集上对提出的方法以及各组件进行验证和分析，并与其他方法进行比较；4.4节对本章内容进行总结。

4.1 问题描述与分析

车道线通常表现为道路表面的白色或黄色线条，具有独特的视觉线索。另外，与汽车、行人等结构较为紧凑的交通目标不同，车道线往往从图像的边缘开

始, 延伸至图像的广阔区域。因此, 车道线在结构特性上与其他交通目标有显著区别, 其通常可以视为满足连续性和平滑性结构约束的曲线段。车道线检测任务本质上是预测一个具有特定拓扑结构的点集, 充分利用车道线的结构特性对于提高算法在复杂环境下的鲁棒性至关重要。然而, 当前的车道线检测方法大多侧重于利用有限的视觉线索来识别和定位车道线, 而忽略了车道线本身的结构信息。

如图4.1所示, 现有车道线检测方法在车道线结构建模方面存在一定的局限性。图中绿色线表示车道线真值, 红色线或红色点表示不可靠的车道线预测结果。如图4.1(a)所示, 许多检测方法将车道线表示为不同类型的参数曲线, 如多项式曲线^[14-16,18-19,22-23,34-37]和贝塞尔曲线^[41-42], 并通过最小二乘拟合^[14-16,18-19,22-23,34-35]或端到端回归^[36-37,41]的方式获得曲线参数。尽管这些参数曲线可以平滑地表示整体车道线结构, 但参数曲线的结构描述粒度较粗糙, 难以精细调控局部结构。一方面, 基于曲线的车道线检测方法通常依赖于全局特征图的统计信息来回归曲线参数, 这种方式可能难以捕捉到局部车道的细微变化, 从而导致局部车道定位不准确。另一方面, 通过网络准确地回归曲线参数十分困难^[41], 高阶曲线系数的微小回归误差也可能导致局部车道定位出现显著偏差。




图 4.1 现有车道线检测方法的在结构表征方面的局限性

如图4.1(b)所示, 一些基于点集搜索的车道线检测方法^[30,33,44-45,48]将车道线表示为均匀间隔行上的一组车道点, 并以自下而上的方式构建车道线。尽管这些方法取得了一定的成功, 但他们通常忽视了车道点之间的结构相关性, 导

致车道线形状被部分异常车道点（红色点）所扭曲。例如，遮挡区域中车道点预测可能与邻近车道点位置有显著偏差。为了解决这一问题，如图4.1（c）所示，FastDraw^[58]通过预测相邻车道点之间的局部偏移来增强局部车道线结构建模能力。然而，该方法从单个参考点逐步向外扩展，以逐步重建完整的车道线，容易在定位远端车道点时累积较大误差的问题。另外，其在结构建模的空间尺度上较为单一。

针对现有方法在车道线结构建模方面的局限性，本章提出了一种基于多个车道片段重构完整车道线的方法，称为 LaneSegNet，如图4.1（d）所示。考虑到车道线的细长结构，LaneSegNet 将一条车道线划分为多个车道片段，并用一组具有层级结构的图节点表示车道线。一方面，在每个车道片段内，构建参考点（橙色点）和车道点（蓝色点）之间的局部紧凑结构。另一方面，通过构建空间相距更远的参考点之间的相对位置关系，以学习车道线全局的分布模式。具体而言，LaneSegNet 首先识别局部最大响应区域，从中提取出具有显著车道纹理特征的多个车道参考点。这些参考点作为整体车道结构的初步表示，有助于在各个区域中探索全局车道线索。接着，LaneSegNet 根据车道点间的相对位置偏移预测，将每个参考点与可靠的邻近车道点联系起来，构建出对应的局部车道片段。为了捕捉车道结构特征，LaneSegNet 还采用了全局和局部图增强模块，分别作用于参考点以及车道片段内的车道点。考虑到车道线可能会受到遮挡、光照条件变化等因素的影响，如果模型只关注标志点的绝对位置，可能无法准确处理这些复杂情况。对此，本章还引入了车道点相对偏移的学习任务，可以帮助模型在部分车道点被遮挡时，通过其他可见车道点的关系来推断被遮挡点的位置。基于以上设计，该方法能够有效缓解复杂环境下车道线预测结构不可靠的问题。

4.2 方法概述

本节详细介绍基于多车道片段的车道线检测方法 LaneSegNet，其通过利用车道点之间的空间位置约束，提高车道线检测在复杂环境下的结构鲁棒性。LaneSegNet 的整体网络架构如图4.2所示。LaneSegNet 主要由四个关键部分组成，包括一个 ResNet 主干网络、车道点选择模块、图增强模块以及车道片段构建模块。输入图像通过具有特征金字塔结构的主干网络进行前向传播以提取 8 倍下采样尺寸的图像特征。随后，基于聚合后的图像特征预测一个置信度图 $\hat{Y}$ ，并通过最大值池化从中获取具有局部最大响应的一组参考点。在图增强模块中，车道节点的特征根据网络预测得到的非对称拓扑结构进行交互，学习多尺度下的车道线结构特点。最后，一个描述车道点间相对位置偏移的图 $\hat{O}$ 被预测得到，并用于重建车道片段和完整的车道线。




图 4.2 基于多车道片段的车道线检测方法 (LaneSegNet) 的框架

4.2.1 参考点选择

如图4.2所示，输入图像 $I \in R^{H_I \times W_I \times 3}$ 首先通过 ResNet 主干网络^[104]提取多尺度特征，随后特征金字塔网络^[49] (Feature Pyramid Network, FPN) 对这些多尺度特征进行聚合，得到的输出特征 F 尺寸为 $\frac{H_I}{r} \times \frac{W_I}{r} \times C$ ，其中 r 代表输出的步长。置信度预测头基于 FPN 的输出特征图，生成置信度图 $\hat{Y} \in R^{+\frac{H_I}{r} \times \frac{W_I}{r} \times K}$ ，该图指示每个位置是否为车道点，其中 K 代表车道实例的数量。在理想情况下，具有显著车道线索的区域在置信度图中应获得较高的分数，而车道不可见的区域则分数较低。

为了充分利用不同区域的车道线索，需要从多个显著区域中选择一组参考点，并在这些参考点的邻近区域重建局部车道片段。一种简单有效的参考点筛选策略是在置信度图上选择响应最强的 N 个点作为参考点。然而，这种策略可能会导致多个参考点过度集中于一个小区内，无法全面反映车道的整体结构。为了优化参考点的选择并关注车道线不同区域的线索，采用核大小为 $K_{ref} \times K_{ref}$ 的局部最大值池化算子来过滤参考点。通过调整最大池化核的大小，可以相应地调整参考点的间隔和车道片段的全局分布，确保参考点的空间分布能够反映全局车道结构。

为了确定车道置信度图的真值，LaneSegNet 将非标准化的高斯核应用于车道点位置真值，在所需的尺度上生成相应的置信度图真值。当某个像素位置上同时出现多个高斯响应，保留逐元素的最大值作为该位置的真值。由于车道像素与背景像素之间存在的显著不平衡，采用焦点损失^[107] (Focal Loss) 来调节置信度回归任务的学习，以解决类别不平衡问题。置信度损失函数如下所示

$$\mathcal{L}_{\text{conf}} = \frac{1}{N} \sum_{xy}^N L_{CE}(\hat{Y}, G_{\text{conf}}), \quad (4.1)$$

其中 $L_{CE}(\cdot)$ 表示 Focal Loss, $\hat{Y}$ 和 G_{conf} 分别表示置信度预测值和真值, N 是特征图的特征数量, 即 $N = \frac{H_I}{r} \times \frac{W_I}{r}$ 。

4.2.2 图增强模块

尽管众多车道线检测方法已经展现出不错的性能,但对车道点之间高阶结构关系的挖掘仍有待加强。考虑到车道线的细长结构,本方法将车道线表示为一组具有层级结构的图节点,并通过图增强模块(Graph Enhancement Module, GEM)捕捉车道线的全局平滑性和局部紧凑性。

如图4.2所示,图增强模块用于构建车道节点在多个尺度下的图结构。图增强模块由全局和局部图增强块(Graph Enhancement Block, GEB)组成,分别负责建立参考点间的全局拓扑结构和车道片段内的局部拓扑结构。在具体实施过程中,首先从主干网络输出的特征图 F 中提取与车道节点及参考点相对应的节点特征。接着,GEB预测并聚合车道节点的拓扑关系。完整的图通常由节点集合、邻接矩阵和权重矩阵共同定义,这些矩阵定义了节点间的邻接关系和相关性。然而,车道点之间的邻接关系和权重矩阵的尚未明确定义。因此,确定每个图中的车道节点及其拓扑结构,包括邻接矩阵和权重矩阵,是一个重要任务。

如图4.3所示,本章提出了车道点层级结构、非对称图拓扑以及图增强块的网络结构。如图4.3(a)所示,本方法提出了一种车道节点的分层结构和一种自下而上的车道结构建模流程。车道线由一组等行间距的车道点表示,那些具有高置信度的点被选为参考点,并根据参考点位置将车道线划分为若干片段。




图4.3 车道点层级结构、全局和局部的非对称图拓扑以及图增强块结构

为了更有效地利用车道点之间的结构关系, LaneSegNet 利用图增强块构建了参考点间和车道片段内车道点的非对称图拓扑结构,如图4.3(b)所示。为了捕获全局结构关系,建立了远距离参考点间的全局车道拓扑图。为了学习局部车道连续紧凑的结构特点,在车道片段内,实现了参考点与其临近车道点的交互。图增强块的具体结构如图4.3(c)所示,由两个 GraphConv-LN-ReLU 残差块组成。

图节点间的权重矩阵应根据不同的驾驶场景动态调整,以表征车道节点间的相关性。在面临遮挡和极端光照等复杂驾驶场景时,一些难以直接定位的车道点,可以通过其他视觉可见且位置可靠的车道点进行推理。这些用于推理的车道点在不同场景中可能分布在不同空间位置,因此权重矩阵中的相关权重应当根据当前输入自适应生成,以适应多变的驾驶环境。分层的图结构和自适应权重学习赋予了 LaneSegNet 更强的结构推理能力,有效提升了检测困难车道样本的性能。

对于任意车道节点对 (v_i, v_j) , 权重矩阵中的对应元素表示为 a_{ij} , 其可以由节点对特征自适应地生成。具体来说,我们首先将两个节点的对应特征 h_i 和 h_j 进行线性映射后并串接 (concat), 随后利用另一个可学习的映射层计算得到标量权重值。通过这种方式, LaneSegNet 能够根据不同的驾驶场景和输入自适应地调整图节点间的权重,从而建立节点间的非对称依赖关系。这种非对称的权重计算设计提升了图结构的多样性,有助于减少噪声节点的影响,同时增强了可靠关键点的信息权重。节点权重的生成过程可以通过以下公式描述

$$a_{ij} = \Phi(\text{concat}(Wh_i, Wh_j)), \quad (4.2)$$

其中 h_i 和 h_j 分别代表两个车道节点的特征,而 W 是一个可学习的投影矩阵,即线性网络层。 $\Phi(\cdot)$ 是一个可学习的映射函数,它将向量映射为标量,通常通过全连接网络实现。

两个节点特征经过线性层映射后的特征被拼接,并使用 Φ 映射到一个标量。归一化的注意力权重 α_{ij} 的计算公式如下

$$\alpha_{ij} = \frac{\exp(a_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(a_{ik})}, \quad (4.3)$$

其中 $\mathcal{N}_i$ 表示第 i 个节点的邻接节点集合。需要指出的是,注意力权重 α_{ij} 和 α_{ji} 之间存在非对称性,这种非对称性主要有两个原因:首先,节点特征在经过线性映射和拼接后的顺序差异;其次,在权重归一化过程中,每个节点对邻接节点的依赖程度不同。具体来说, α_{ij} 是相对于节点 i 的所有邻接节点进行归一化的,而 α_{ji} 则是相对于节点 j 的所有邻接节点进行归一化。

进一步地,本节提出的图增强块由两个 GraphConv-LN-ReLU 模块通过残差连接构成。GEB 接收输入为车道节点特征 $H^s \in \mathbb{R}^{L \times C}$ 和归一化的权重矩阵 $A^s \in \mathbb{R}^{L \times L}$, 并输出更新后的节点特征 $H^{s+1} \in \mathbb{R}^{L \times C}$ 。在这里, L 表示节点的数量, s 表示层索引, C 表示输入节点特征的维度。车道节点特征 H^s 输入至图增强块后更新遵循以下规则,

$$H^{s+1} = \sigma(A^s H^s W^s) + H^s, \quad (4.4)$$

$$H^{s+2} = \sigma(A^{s+1} H^{s+1} W^{s+1}) + H^{s+1}, \quad (4.5)$$

其中 $\sigma(\cdot)$ 表示 LN-ReLU 操作, 更新后的车道节点特征和初始输入特征 F 以残差结构相加获得输出特征图 F' 。

4.2.3 车道片段构建

LaneSegNet 的目标是预测一组车道线 $L = \{l_1, l_2, \dots, l_K\}$, 其中 K 是车道线实例的总数。一条车道线由一组位于等行间距的车道点表示, 这些车道点被定义为

$$\begin{cases} l_k = \{(x_i^k, y_i)\}_{i=1}^{N_k}, \\ y_i = i \cdot \Delta y, i = 1, \dots, N_k, \end{cases} \quad (4.6)$$

其中 Δy 是预先给定的两个相邻车道点之间的垂直行间距, x_i^k 表示第 k 条车道线在第 y_i 行的车道点的水平坐标, N_k 是一条车道线的最大采样点数。LaneSegNet 通过预测车道点之间的相对偏移来重建车道片段。

在图增强模块中, 车道节点特征在特征图 F' 中得到了更新。随后, 偏移预测头采用更新后的特征图 F' 作为输入, 进而更准确地预测车道点之间的相对偏移图 $\hat{O} \in \mathbb{R}^{\frac{H_l}{r} \times \frac{W_l}{r} \times N_k}$, N_k 表示单条车道线允许的最大车道点数。车道点的垂直坐标是根据公式 (4.6) 定义为固定值。如果确定了第 k 条车道在第 i 行的参考点 (x_i^k, y_i) , 那么该参考点与其他所有车道点之间的水平偏移值就可以从偏移图 $\hat{O}$ 的第 i 个通道中获得。通过将相邻车道点与准确的偏移预测相联系, 可以在参考点周围构建出车道片段。此外, 通过学习相对偏移预测, 可以增强对车道点空间相对位置的理解, 从而更好地理解和预测在遮挡、极端光照等困难情况下的车道线结构。

车道片段与车道线的构建过程如图 4.4 所示。首先, 根据图 4.4 (a) 中的车道线置信度图, 通过局部最大池化操作和置信度阈值从中获得一组具有局部最大置信度的车道点, 这些点在图 4.4 (b) 中被标记为参考点。如图 4.4 (c) 和 (d) 所示, 黑色参考点将车道线划分为多个部分。在任意两个相邻参考点确定的区间内, 可以构建相应的车道片段。如果车道点的预测偏移量落在参考点附近的矩形区域内, 则可以将其关联为该车道片段的一部分。通过加权求和方法平滑连接多个车道片段, 可以重构出完整的车道线。这一过程不仅确保了车道线的连续性和完整性, 而且提高了检测的准确性。每个车道片段都与一个可靠的参考点相关联, 有助于识别车道线的起始和结束位置, 并在复杂道路环境中保持车道结构的稳定性。

在车道片段的构建过程中, (x_r, y_r) 表示参考点的坐标, 这些参考点在图 4.4 (c) 和 (d) 中以黑色点标出。参考点 (x_r, y_r) 上方和下方的临近参考点分别用




图 4.4 车道片段与车道线重构流程

$(x_r^{\uparrow}, y_r^{\uparrow})$ 和 $(x_r^{\downarrow}, y_r^{\downarrow})$ 表示。基于这些参考点，可以确定对应车道片段的上界 B_{up} 和下界 B_{bot} ，它们的定义分别为 $B_{up} = \max(y_r^{\uparrow}, y_1)$ 和 $B_{bot} = \min(y_r^{\downarrow}, y_{N_k})$ 。其中 y_1 和 y_{N_k} 分别代表车道线的起始和结束行位置，根据公式 (4.6) 确定。以参考点 (x_r, y_r) 为中心，定义了一个宽度为 δ 的矩形区域，该区域的左界 B_{ll} 和右界 B_{rl} 分别定义为 $B_{ll} = \max(x_r - \delta, 0)$ 和 $B_{rl} = \min(x_r + \delta, \frac{W_I}{r})$ 。对于车道线上的任意车道点 (x_i, y_i) ，如果它与参考点 (x_r, y_r) 间的相对位置偏移预测满足条件 (4.7)，则该车道点与参考点成功关联，并成为车道片段的一部分。该约束条件可以写作

$$\begin{cases} B_{up} < y_i < B_{bot}, \\ B_{ll} < x_i + \hat{O}_r(x_i, y_i) < B_{rl}, \end{cases} \quad (4.7)$$

其中 $\hat{O}_r$ 是与参考点 (x_r, y_r) 对应的相对偏移图预测， $\hat{O}_r(:, :)$ 用于索引车道点位置的相对偏移预测值。

如图 4.4 (c) 和 (d) 所示，相对水平偏移预测准确的车道点（绿色点）成功与相应的车道片段关联，而水平偏移预测不准确的车道点（红色点）则被弃置。值得注意的是，所有车道片段可以同时构建，大大提高了车道线检测的效率，避免了采取效率较低的迭代构建方式^[58]。一条完整的车道线可以通过多个车道片段来表示为

$$l_k = \{S_1 \cup S_2 \cup \dots \cup S_{N_{seg}}\}, \quad (4.8)$$

其中 S_i 表示第 i 个车道片段， N_{seg} 表示构成第 k 条整条车道线的车道片段总数。每个车道片段都是基于参考点的相对偏移预测值来确定的，并且所有这些片段共同构成了完整的车道线。

在车道线的构建过程中，两个相邻的车道片段可能会存在部分区域的重叠。在这些重叠区域，车道点的最终位置通过计算不同车道片段中相应车道点的加权平均值来确定。具体来说，假设 (x_{S_1}, y) 和 (x_{S_2}, y) 是位于同一行但分属于两个不同车道片段 S_1 和 S_2 的车道点的车道点。在这一行上，车道点的最终位置通过以下加权平均公式计算得到

$$(x, y) = \frac{y - y_1}{y_2 - y_1} \times (x_{S_1}, y) + \frac{y_2 - y}{y_2 - y_1} \times (x_{S_2}, y), \quad (4.9)$$

其中 y_1, y_2 分别表示两个相邻参考点的纵坐标。权重的计算基于车道点与相邻参考点 y_1 和 y_2 的相对垂直位置。通过这种方式，可以确保车道片段重叠区域内，

车道线的平滑性和连续性得到保持。此外,通过明确预测所有车道点相对于参考点的水平偏移,有助于建立车道线的全局结构关系,提高车道线检测的鲁棒性。

4.2.4 优化函数

多参考点在所提方法中扮演着核心角色,它们是构建局部车道片段和全局车道线的基础。参考点附近通常具有更丰富的车道线纹理,因此这些位置的车道点应该具有较高的置信度和准确的相对偏移预测。为了确保置信度预测图和相对偏移预测图之间的一致性,本节设计了一种置信度调制的偏移损失函数,使得高置信度区域的相对偏移预测得到更多的关注。偏移预测损失函数设计如下

$$\mathcal{L}_{\text{oft}} = \frac{1}{NN_k} \sum_i^{N_k} \sum_{xy}^N \hat{Y}_{xy} L_1(\hat{O}_i, G_{\text{oft}}^i), \quad (4.10)$$

其中 $L_1(\cdot)$ 表示平滑 L1 损失函数,用于衡量预测值与真实值之间的差异。 $\hat{Y}$ 表示模型输出的车道线置信度预测图,而 $\hat{Y}_{xy}$ 则特指图像中点 (x, y) 处的置信度预测值。 $\hat{O}_i$ 和 G_{oft}^i 分别代表预测值和真值,它们描述了车道点的偏移量。在模型训练阶段,车道点的相对偏移量真值 G_{oft} 被映射到相应的空间尺度,且不必要是整数值。结合置信度图,调制后的偏移损失函数主要受到置信度高的点的影响,从而显著提升了车道点定位和置信度的一致性。

进一步地,本节考虑了输出步长 r 对偏移预测图的影响。由于输出步长的存在,偏移图中的每个点实际上对应于原始输入空间中的 $r \times r$ 大小的区域。较大的输出步长可能导致在将预测结果映射回原始图像尺寸时产生误差,进而影响车道点位置的准确性。为了补偿这种映射误差,本节引入了一个额外的映射误差学习任务,并定义了如下损失函数

$$\mathcal{L}_{\text{qua}} = \frac{1}{N} \sum_{xy}^N L_1(\hat{E}, G_{\text{qua}}), \quad (4.11)$$

其中 $\hat{E}$ 表示车道点位置的预测值,而 G_{qua} 为真实值。在输出步长为 r 的情况下,每个车道点 (x, y_k) 对应的映射误差真值定义为 $G_{\text{qua}}(\lfloor \frac{x}{r} \rfloor, k) = \frac{x}{r} - \lfloor \frac{x}{r} \rfloor$ 。为了简化模型结构,图 4.2 并未展示映射误差预测头。

模型最终的训练损失由以下公式给出

$$\mathcal{L} = \mathcal{L}_{\text{conf}} + \alpha \mathcal{L}_{\text{oft}} + \beta \mathcal{L}_{\text{qua}}, \quad (4.12)$$

其中 α 和 β 是用于平衡不同损失项贡献的权重系数。

4.3 实验结果与分析

本节首先详细介绍了实验设置，然后深入讨论了所提方法在两个关键的车道线检测数据集上的表现，并通过定量和定性结果来证明其优越性。最后，通过消融实验进一步验证了各个组件的有效性。

4.3.1 实验设置

在本节实验中，选用了 ResNet-18 和 ResNet-34 作为主干网络。在模型训练和测试阶段，CULane 和 TuSimple 的图像被调整大小为 320×800 像素，并由主干网络进行 32 倍的下采样。输出步长 r 设置为 8。训练过程中应用了常见的数据增强技术，包括随机缩放、裁剪、水平翻转和随机旋转。车道线实例数量 K 被设置为 4。在特征金字塔和图增强模块中，特征维度 C 被设置为 64。此外，根据数据集中车道线空间分布的差异，分别在 CULane 和 TuSimple 中经验性地将车道点数量 N_k 设置为 20 和 30。最大池化核大小 K_{ref} 被设置为 7。训练采用了 Adam^[109] 优化器，参数 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ ，分别在 CULane 上训练 50 个周期和在 TuSimple 上训练 100 个周期，批量大小为 32。初始学习率为 1×10^{-3} ，并采用余弦衰减学习率策略。总损失函数 (4.12) 中的权重系数 α 和 β 分别被设置为 0.5 和 1.0。由于车道点集的相对偏移较大且参与预测的点数量较多，因此我们对两个任务的权重进行了适度调小，一定程度上可以避免网络受到个别噪声的干扰。为确保训练过程的稳定性，在开始时使用学习率预热防止出现较大的偏移损失。所有训练实验均使用 4 张 RTX 3090 GPU 完成。测试阶段的 FPS 在单个 RTX 3090 GPU，批量大小为 1 的情况下进行测量。参考车道点的置信度阈值设置为 0.4，将车道点与参考点关联得到车道片段的距离阈值 δ 设置为 1.5。

4.3.2 与现有方法的对比

1. CULane 数据集实验结果

表 4.1 展示了 LaneSegNet 在 CULane 数据集上的比较结果，其中 LaneSegNet (ResNet-34) 以 78.2% 的总 F1 得分达到了最先进的检测性能。在包括“正常”、“拥堵”、“眩光”、“无线”、“箭头”、“弯道”和“夜间”等复杂的场景中，LaneSegNet 同样展现出了最高的 F1 分数，证明了其在多种复杂环境下的鲁棒性。

基于曲线的车道线检测方法在曲线参数优化和细节结构描述上存在局限，这限制了他们在局部车道线定位上的准确性。所提出的检测方法 LaneSegNet 在准确性和处理速度上均优于这些基于曲线的方法。例如，LaneSegNet (ResNet-18) 和 LaneSegNet (ResNet-34) 的性能分别比 FlipNet^[24] 的对应版本高出 2.8% 和 2.1%。尽管 CenLaneNet^[20] 在基于曲线的方法中取得了最高的总 F1 分数，但 LaneSegNet (ResNet-34) 不仅在总 F1 分数上超出 1.4%，而且在速度上是 Cen-

表 4.1 CULane 数据集上的实验性能对比

方法	Total F1(%)	FPS	正常 27.7%	拥堵 23.4%	眩光 1.4%	阴影 2.7%	无线 11.7%	箭头 2.6%	弯道 1.2%	路口 9.0%	夜间 20.3%
基于曲线的方法											
PINet(4H) ^[16]	74.4	-	90.3	72.3	66.3	68.4	49.8	83.7	65.7	2052	66.3
SCNN ^[18]	71.6	8	90.6	69.7	58.5	66.9	43.4	84.1	64.4	1990	66.1
RESA(ResNet-34) ^[19]	74.5	45	91.9	72.4	66.5	72.0	46.3	88.1	68.6	1896	69.8
RESA(ResNet-50) ^[19]	75.3	36	92.1	73.1	69.2	72.8	47.7	88.3	70.3	1503	69.9
SAD(ENet) ^[22]	70.8	75	90.1	68.8	60.2	65.9	41.6	84.0	65.7	1998	66.0
IntRA-KD ^[23]	72.4	100	-	-	-	-	-	-	-	-	-
FlipNet(ResNet-18) ^[24]	75.0	-	92.4	72.6	65.1	74.3	47.2	88.6	67.9	1432	69.8
FlipNet(ResNet-34) ^[24]	76.1	-	92.8	74.0	69.9	76.0	47.7	88.9	68.9	1381	71.0
PGA-Net(ResNet-18) ^[39]	69.9	-	87.8	70.0	62.1	67.6	46.7	80.9	58.0	1700	59.0
PGA-Net(ResNet-18) ^[39]	74.7	-	91.2	73.9	64.4	77.6	50.5	87.0	63.9	1725	67.3
DHPM(ResNet-18) ^[42]	74.6	-	90.6	73.3	63.5	65.5	45.1	84.8	60.2	701	68.9
DHPM(ResNet-34) ^[42]	76.2	-	91.5	74.2	68.1	74.9	48.3	87.4	60.4	872	71.5
HWLane(VGG16) ^[25]	76.9	70	93.0	75.2	68.4	78.5	51.0	89.4	70.2	1703	72.1
BézierLaneNet(ResNet-18) ^[41]	73.7	-	90.2	71.6	62.5	70.9	45.3	84.1	59.0	996	68.7
BézierLaneNet(ResNet-34) ^[41]	75.6	-	91.6	73.2	69.2	76.7	48.0	87.2	62.5	888	69.9
Fast-HBNet(ResNet-18) ^[17]	73.1	40	91.9	71.6	64.7	66.7	46.8	85.3	65.1	2306	66.7
CenLaneNet ^[20]	74.8	81	90.1	73.7	66.0	73.9	48.6	85.8	66.5	1359	68.0
基于点的方法											
PointLane(ResNet-101) ^[29]	70.2	-	88.0	68.1	61.5	63.3	44.0	80.9	65.2	1640	63.2
E2E(ResNet-18) ^[46]	70.8	-	90.0	69.7	60.2	62.5	43.2	83.2	70.3	2296	63.3
E2E(ResNet-34) ^[46]	71.5	-	90.4	69.9	61.5	68.1	45.0	83.7	69.8	2077	63.2
Laneformer(ResNet-18) ^[48]	71.7	-	88.6	69.0	64.1	65.0	45.0	81.6	60.5	25	64.8
Laneformer(ResNet-34) ^[48]	74.7	-	90.7	72.3	69.1	71.6	47.4	85.1	65.9	26	67.8
FastDraw ^[58]	-	90	85.9	63.6	57.0	59.9	40.6	79.4	65.2	7013	57.8
UFLD(ResNet-18) ^[44]	68.4	323	87.7	66.0	58.4	62.8	40.2	81.0	57.9	1743	62.1
UFLD(ResNet-34) ^[44]	72.3	175	90.7	70.2	59.5	69.3	44.4	85.7	69.5	2037	66.7
UFLDv2(ResNet-18) ^[45]	74.7	330	91.7	73.0	64.6	74.7	47.2	87.6	68.7	1998	70.2
UFLDv2(ResNet-34) ^[45]	75.9	165	92.5	74.9	65.7	75.3	49.0	88.5	70.2	1864	70.6
KPMFF(ResNet-18) ^[47]	69.0	417	87.2	67.1	63.7	66.1	44.7	81.5	65.5	3306	62.0
CurveLanes-NAS-S ^[30]	71.4	-	88.3	68.6	63.2	68.0	47.9	82.5	66.0	2817	66.2
CurveLanes-NAS-M ^[30]	73.5	-	90.2	70.5	65.9	69.3	48.8	85.7	67.5	2359	68.2
LATT(ResNet-18) ^[31]	75.1	250	91.1	73.0	65.7	70.9	48.4	85.5	63.4	1170	69.0
LATT(ResNet-34) ^[31]	76.7	171	92.1	75.0	66.5	78.2	49.4	88.4	67.7	1330	70.7
ECPNet(ResNet-18) ^[61]	75.8	275	91.7	73.6	65.6	72.8	46.3	88.8	68.7	1896	69.9
FML(ResNet-34) ^[60]	72.6	181	91.1	70.5	57.7	69.6	44.6	86.0	69.8	2045	67.0
LaneSegNet(ResNet-18)	77.8	169	92.8	76.6	71.1	77.5	52.1	88.9	72.3	1334	71.7
LaneSegNet(ResNet-34)	78.2	141	93.1	77.4	71.4	77.7	51.7	89.6	73.2	1527	73.4

LaneNet 的两倍。一些车道线检测方法采用像素级分割和曲线后处理的方式，这一过程相当耗时。尽管 IntRA-KD^[23] 和 SAD^[22] 通过知识蒸馏技术，以轻量的分割网络实现了较快的处理速度，但 LaneSegNet 在速度上仍然显著超越了这些方法。这一优势主要归功于 LaneSegNet 所采用的高效的稀疏图构建技术。

基于点表示的车道线检测方法^[30-31,44-45] 常常忽略了车道点集之间的结构相关性。与此形成鲜明对比的是，LaneSegNet 在车道点之间构建了一种多层次的、非对称的拓扑结构，这使得模型能够更准确地捕捉到车道点间的依赖关系。尽管

LaneSegNet 和 UFLDV2^[45] 都采用了轻量级模型设计, 但 LaneSegNet 通过引入车道点之间的结构相关性, 在总 F1 得分上相较于 UFLDV2 (ResNet-18) 和 UFLDV2 (ResNet-34) 分别提升了 1.9% 和 2.3%, 并且在检测速度上也显示出了明显的优势。FastDraw^[58] 虽然尝试建立车道点之间的结构关系, 但它只考虑了相邻三个车道像素间的相对偏移。这种方法仅关注了有限区域内的像素级结构关系, 难以全面捕捉车道线的整体结构, 并且在定位远端车道点时容易累积误差。与之相比, LaneSegNet 通过图增强模块和相对偏移预测自适应地构建了不同尺度下的分层级车道线拓扑结构。此外, LaneSegNet 还能够并行构建多个车道片段, 避免了 FastDraw 中使用的迭代车道点索引过程。得益于这些设计, LaneSegNet 在所有场景类别中的表现均优于 FastDraw^[58] 方法。

如表4.1所示, 在天气和道路条件理想的“正常”场景类别中, 大多数车道线检测方法都能实现超过 90% 的 F1 分数。然而, 不同方法之间的性能差异主要体现在它们在复杂场景中检测车道线的能力上。为了展示 LaneSegNet 的显著优势, 本节将其与 CULane 中所有挑战性场景中表现最佳的基于曲线和基于点的方法进行了比较分析, 结果如图4.5所示。




图 4.5 LaneSegNet 与现有两类方法的最佳表现对比

在这里, “最佳表现”指的是在特定场景下, 某一类型方法目前达到的最高 F1 得分。例如, 在“拥堵”场景中, Curve_SOTA 代表了基于曲线的方法所实现的最佳性能。从图中可以看出, 与“正常”场景相比, 在“拥堵”、“眩光”、“箭头”和“夜间”等具有挑战性的场景中, LaneSegNet 的性能提升尤为显著。LaneSegNet 通过将车道线划分为不同的车道片段, 提供了比原有基于曲线的方法更为精细的车道线表示。此外, 与基于点的方法相比, 额外的图增强模块和相对偏移预测构建了车道点之间的结构关系。因此, 即使在复杂环境下, LaneSegNet 也能有效地检测出车道线样本, 构建稳定可靠的车道线结构。此外, LaneSegNet 的性能提升在“弯道”类别中最为显著, 这凸显了分层车道线结构构建方案在处理具有复

表 4.2 TuSimple 数据集上的实验性能对比

方法	Accuracy(%)	F1(%)	FPS
基于曲线的方法			
PINet(4H) ^[16]	96.62	97.10	-
SCNN ^[18]	96.53	95.97	8
SAD(ENet) ^[22]	96.64	95.92	75
BézierLaneNet(ResNet-18) ^[41]	95.41	95.04	-
BézierLaneNet(ResNet-34) ^[41]	95.65	95.49	-
DHPM(ResNet-18) ^[42]	95.61	95.59	-
DHPM(ResNet-34) ^[42]	96.87	95.79	-
CenLaneNet ^[20]	96.48	97.20	-
基于点的方法			
KPMFF(ResNet-18) ^[47]	94.64	94.69	417
E2E(ResNet-18) ^[46]	96.04	96.39	-
E2E(ResNet-34) ^[46]	96.22	96.57	-
FastDraw ^[58]	94.90	94.59	-
CurveLanes-NAS-S ^[30]	95.97	-	-
CurveLanes-NAS-M ^[30]	96.21	-	-
UFLD(ResNet-18) ^[44]	95.82	87.87	323
UFLD(ResNet-34) ^[44]	95.81	87.91	175
UFLDv2(ResNet-18) ^[45]	95.84	87.90	330
UFLDv2(ResNet-34) ^[45]	95.73	88.08	165
LATT(ResNet-18) ^[31]	95.57	96.71	250
LATT(ResNet-34) ^[31]	95.63	96.77	171
LaneSegNet(ResNet-18)	96.42	97.22	169
LaneSegNet(ResNet-34)	96.55	97.37	141

杂结构的车道线方面的潜力。

2. TuSimple 数据集实验结果

在 TuSimple 数据集的实验中，共对比了十一种车道线检测方法，涵盖了 SCNN^[18]、SAD^[22]、BézierLaneNet^[41]、CenLaneNet^[20]、PINet^[16]、E2E^[46]、FastDraw^[58]、CurveLanes-NAS^[30]、UFLD^[44]、UFLDv2^[45]以及 LATT^[31]。表4.2给出了这些方法的车道点预测准确率（Accuracy）、F1 分数和每秒帧数（FPS）。

在 TuSimple^[74]数据集上，LaneSegNet（ResNet-34）实现了 97.37% 的当前最佳 F1 分数，以及 96.55% 的具有竞争力的车道点预测准确率，与最先进方法的

表现相当。准确率反映了单个车道点位置的精准程度，而 F1 分数则综合评估了整个车道线的识别可靠性。SAD^[22]通过采用实例分割技术处理车道线检测问题，达到了 96.64% 的最优准确率。在能见度良好的条件下，SAD 能够生成精确的像素级车道线表示，并有效定位车道点。然而，这类采用像素级表示的车道线检测方法^[16,18-20,22]在复杂驾驶场景中可能会遇到显著的性能下降，如表4.1所示。相比之下，LaneSegNet 通过充分利用车道点之间的相对结构关系，实现了更高的 F1 分数，展现出更强的实例级定位能力。

值得注意的是，TuSimple 数据集中的大多数车道线样本都是在良好能见度条件下的高速公路上收集的，这使得它们相对容易识别。因此，在这个数据集上，大多数方法的性能趋于饱和，都达到了超过 95% 的准确率和 F1 分数。在这种情况下，具有强大结构建模能力的 LaneSegNet 可能仅带来微弱的性能提升。这种现象可能暗示了模型在 TuSimple 的有限车道线样本上存在过拟合的风险。

3. 定性实验结果

最大池化策略下参考点的分布情况如图4.6所示。为了更清晰的可视化效果，多个车道的置信度图被合并展示。观察结果表明，所选取的参考点位于车道的显著区域，并且能够反映出车道线的整体结构。




图 4.6 基于多参考点的车道线重构流程可视化

为了验证 LaneSegNet 的有效性，图4.7对比了 UFLD^[44]和 UFLDv2^[45]在复杂场景下的检测结果，包括“拥堵”、“夜间”、“阴影”、“眩光”和“无线”等场景。可以看到，在复杂环境中，如极端照明条件和遮挡情况下，车道线标记可能部分或完全不可见。在这些情况下，UFLD 和 UFLDv2 预测的车道结构存在明显的锯齿和断裂结构。相比之下，LaneSegNet 利用车道点之间的结构关系，在挑战性场景实现比基线方法更为鲁棒的结构预测。

车道线作为一种具有高度结构先验的对象，在复杂环境下的识别中，其结构信息对于提高车道线结构建模的可靠性至关重要。UFLD^[44]和 UFLDv2^[45]作为两种经典的车道线检测方法，尽管在网络架构上较为简单且有效，但在检测过程中并未充分利用车道点之间的结构知识。这两种方法独立地确定每个车道点的位置，通过逐行计算网络响应的位置期望。然而，当异常车道点出现时，可能会对车道线结构的准确性产生负面影响。与 UFLD 和 UFLDv2 相比，LaneSegNet



图 4.7 CULane 数据集车道线检测结果对比

虽然在网络架构上保持了简洁性，但它通过引入图增强模块和相对偏移预测，为模型提供了一种强大的机制，用以理解和建模车道点之间的相互关系，从而在多种复杂场景下都能实现鲁棒的车道线检测。

4.3.3 消融实验

本节将详细展示 LaneSegNet 中关键组件和设置的有效性。为了确保实验结果的可比性，所有消融实验均在 CULane 数据集上，基于 LaneSegNet (ResNet-34) 上进行。在所有实验中，各项参数尽可能保持一致。

1. 关键组件

表 4.3 总结了全局图增强块 (GGEB)、局部图增强块 (LGEB) 和调制偏移损失的消融实验结果, 以评估它们在车道线检测中的作用。我们选取了 CULane 数据集中除“正常”类别的部分困难样本, 用以计算绝对位置误差。FPS 基于 RTX 3090 GPU, 输入图像尺寸为 320×800 像素测试得到。

表 4.3 组件消融实验结果, 包括全局图增强模块、局部图增强模块以及调制偏移损失。

基线模型	GGEB	LGEB	调制损失	像素误差	F1(%)	FPS
✓				10.3	76.3	150
✓	✓			9.3	76.6	148
✓		✓		7.6	77.4	144
✓	✓	✓		7.0	77.7	141
✓	✓	✓	✓	5.4	78.2	141

基线模型采用了多车道片段表示方法, 并通过预测每个车道片段内车道点之间的相对偏移来实现车道线的重构。这种方法有效地保持了车道线的结构连续性, 并实现了 76.3% 的 F1 分数, 凸显了多车道片段表示方法的优势。进一步地, 全局图增强块和局部图增强块的引入细化了车道线的分层结构, 有助于减少车道点位置误差。具体来说, 当 GGEB 和 LGEB 联合使用时, 车道点的绝对像素误差降低到了 7.6 个像素。另外, 单独使用 LGEB 相比于 GGEB 能够达到更高的 F1 分数和更小的位置误差, 这可能是因为局部车道线结构相对更稳定, 更易于模型学习。此外, 由公式(4.10)定义的调制偏移损失在提高参考点质量方面发挥了重要作用, 通过保持置信度图和相对偏移图之间的一致性, 进一步将绝对像素误差降至 5.4 个像素。

由于车道片段的参考点和车道点的稀疏性, GGEB 和 LGEB 作用于车道点构成的稀疏图, 计算成本相对较低, 对算法的运行速度影响较小。如公式(4.4)所示, 每个图增强块的计算成本主要由矩阵乘法决定, 即 $O(AHW)$ 。调制偏移训练损失仅在模型训练阶段应用, 不影响模型的推理速度。消融实验的结果表明, GGEB、LGEB 以及调制偏移损失在车道线检测中起到了关键作用。它们不仅提高了模型的准确性, 还保持了模型的高效性。

2. 车道节点邻接设计

车道节点邻接设计的消融实验结果如表4.4所示。本节对参考点之间以及每个车道片段内的连通设计进行了探索, 尤其是全局图增强块和局部图增强块中的邻接矩阵。车道节点的邻接矩阵是车道线检测算法设计中的关键因素, 它直接影响到节点之间信息聚合的空间范围。本节对比了两种不同的连通设计: 一种是基于欧几里得距离的 K-最近邻 (K-nearest neighbors) 方法, 另一种是自适应全




图 4.8 参考点与车道片段的可视化

连通设计。全连通意味着任意两个车道节点都被视为互相可达的节点，但他们彼此间的依赖权重可能不同，详细的解释见 §4.2.2 节。通过非对称权重的学习设计，模型能够自适应地识别不同节点的重要性。因此，全连通设计能够在整个邻接空间提取丰富的结构信息，从而增强车道线检测的鲁棒性。

表 4.4 车道节点邻接设计消融实验

邻接节点数量	1	2	3	4	所有节点
F1(%)	75.3	76.3	77.1	77.6	78.2

3. 参考点选取策略

如表4.5所示，本节对比分析了两种不同的参考点选择策略。第一种策略通过最大池化操作提取参考点，其数量会随着最大池化核尺寸的变化而变化。第二种策略是在置信度图全局范围内挑选置信度最高的 Top-K 个点作为参考点。这两种策略提取得到的参考点在空间分布上展现出不同的特点。具体来说，当采用较小的池化核时，所选择的参考点数量会增加。但参考点数量的增加并不总能提升性能，因为使用较小池化核可能会错误地将一些置信度不高的局部点识别为参考点。实验结果表明，使用 7×7 池化核时，车道线检测性能最佳，平均每条车道线大约有 3.3 个参考点。而当使用与置信度图尺寸相匹配的 40×100 池化核时，参考点数量减少至 1 个。在这种情况下，召回率出现了明显的下降，而精确率（Precision）则略有提高。召回率（Recall）的降低意味着在检测过程中，有更多的车道线样本被遗漏。因此，在采用较少参考点的策略下，检测困难的车道线样本变得更加具有挑战性，尤其是在重建远端车道点时，单一的参考点可能导致较大的定位误差。

此外，多参考点策略能够关联更多的车道点，增强了方法的鲁棒性。这一点在图4.8的可视化结果得以验证。图中红色点表示参考点，青色点表示预测车道

表 4.5 参考点选择策略与参考点数量的消融实验

策略	核尺寸	参考点数量	F1(%)	Precision(%)	Recall(%)
最大池化	3×3	6.7	77.4	79.6	75.3
	5×5	4.4	77.6	79.8	75.5
	7×7	3.3	78.2	81.1	75.6
	9×9	2.1	77.5	81.5	73.8
	40×100	1	76.8	82.1	72.0
Top-K	-	7	77.2	81.3	73.4
	-	5	77.0	81.4	73.1
	-	3	76.9	81.9	72.3
	40×100	1	76.8	82.1	72.0

点，深蓝色点代表真实标注的车道点。可视化结果表明，多个参考点在车道线的可靠区域内均匀分布，为车道线提供了大致的轮廓。特别地，在那些远离参考点的红色方框区域，多参考点策略相较于单参考点策略，能够实现更小的位置误差。这一优势归功于局部尺度上的车道线片段构建，这使得能够更精确地捕捉到车道线的细节。进一步的研究发现，在参考点数量相似的情况下，最大池化策略相较于 Top-K 策略具有更好的表现。原因在于，尽管两种策略得到的参考点数量相近，但在响应值和空间分布上存在显著差异。最大池化操作确保了相邻参考点之间的距离至少为池化核的尺寸，避免了参考点的过度集中。相比之下，响应值最高的 Top-K 点可能仅集中在局部区域，无法全面反映车道线的整体结构。因此，如表4.5所示，随着参考点数量的增加，性能的提升往往是微弱的。另一方面，通过最大池化策略得到的参考点可能并非置信度图中响应最强的点，这为模型提供了探索置信度相对较低区域的可能性。

4. 超参数消融实验

LaneSegNet 设计中涉及两个重要的超参数，即选取参考点使用的置信度阈值和关联车道点使用的距离阈值。这两个超参数的消融实验结果如表4.6所示。

实验结果表明，LaneSegNet 对这两个超参数都表现出良好的鲁棒性。在一定范围内提高置信度阈值可以增加所选参考车道点的可靠性。但如果置信度阈值设置得过高，少量的参考点可能无法提供车道的整体结构，从而导致性能下降。此外，距离阈值用于将相邻车道点与局部区域内的车道片段关联起来。由于车道点与参考车道点彼此接近，它们之间的水平偏移可以被准确预测。因此，我

表 4.6 置信度阈值和距离阈值消融实验

置信度阈值	0.30	0.35	0.40	0.45	0.50
F1(%)	77.4	77.6	78.2	77.6	77.3
距离阈值	1.0	1.5	2.0	2.5	3.0
F1(%)	77.8	78.2	77.8	77.3	77.2

们的方法对距离阈值的设置表现出一定的鲁棒性。

4.4 本章小结

车道线作为一种具有高度结构先验的对象，充分利用其结构模式有利于识别复杂环境下车道线，尤其是提高车道线结构预测的稳定性。本章提出了一种基于多车道片段的车道线检测方法，名为 LaneSegNet。LaneSegNet 首先识别出车道的关键点，并基于这些点构建出车道的局部片段，然后通过这些片段来重建完整的车道线。该方法将车道点视为图的节点，这些节点具有多层次和非对称的拓扑关系。通过图增强技术，LaneSegNet 能够捕捉到车道片段内部以及与其他关键点之间的复杂拓扑结构，从而学习到车道线的局部紧凑性和整体平滑性。此外，LaneSegNet 还通过引入非对称权重的节点连接，增强了模型对车道线结构的推理能力。它还通过分析车道点之间的相对位移，提高了对车道点空间关系的识别精度。实验证明，LaneSegNet 通过利用车道线的连续性和平滑性，显著提升了在复杂环境中车道线检测的鲁棒性。

第5章 基于全稀疏设计的端到端车道线检测算法

本文的第三章和第四章分别探讨了如何提升车道线结构表示的灵活性和鲁棒性。事实上，车道线不仅具有独特的结构特性，还表现出显著的稀疏性，即车道线像素在整个图像中所占比例极小。现有的车道线检测方法通常依赖于一些密集设计，比如密集锚点或基于密集交互的注意力机制，这与车道线的稀疏特性并不相符。基于锚点的方法^[31-32]利用密集的线性锚来提取车道线特征，但需要非极大值抑制等后处理步骤，因此不是完全端到端的。另一些方法^[37,48,110]基于 DETR 范式^[92]利用稀疏查询实现端到端的车道线检测，但它们在注意力模块中仍利用了图像标记（Token）之间的密集交互。这不仅增加了从背景信息中提取稀疏车道线特征的难度，而且导致了显著的背景计算冗余。

针对稀疏车道线在 Transformer^[43]架构中感知困难和计算冗余大的问题，本章提出了一种基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer，同时实现了稀疏查询和稀疏交互。具体而言，本章提出了一种车道线感知查询（Lane Aware Query, LAQ），它具有明确的车道线位置信息。LAQ 作为可学习的稀疏车道查询，能够比传统的线性锚和常规高维查询更精确地预测车道线位置。为了减少计算冗余，本章还引入了车道标记选择器（Lane Token Selector, LTS）和线性可形变采样器（Linear Deformable Sampler, LDS），分在在编码器和解码器中构建车道标记间的稀疏交互。LTS 能够在编码器阶段有选择性地更新稀疏车道标记，而 LDS 则在解码器阶段通过沿 LAQ 自适应采样车道线特征，从多尺度特征图中提取出具有区分度的车道线表示。专注于最具信息量的稀疏车道标记，Sparse LaneFormer 仅利用 10% 的图像像素，实现计算开销降低 80%，FPS 提升近 5 倍，成为首个性能超越 CNN 架构的端到端车道线检测方法，从而验证了稀疏设计在车道线检测领域中的可行性和有效性。

本章内容安排如下：5.1节定量分析了车道线的显著稀疏特性，并讨论了现有车道线检测方法中的密集设计；5.2节详细介绍了基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer，包括车道感知查询、车道标记选择器和线性可形变采样器；5.3节在两个车道线数据集上验证了 Sparse LaneFormer 的性能，并通过消融实验验证了各项稀疏设计的有效性；5.4节对本章内容进行了总结。

5.1 问题描述与分析

如图5.1所示，与常见目标相比，车道线展现出非常显著的稀疏性。以广泛使用的车道线检测数据集 CULane^[18]和目标检测数据集 COCO^[111]为例，图5.1定

性和定量地展示了这两个数据集中目标标注的差异。尽管 COCO 数据集中存在大量小目标，其中大约 41% 的目标面积小于 32^2 像素，但车道线在稀疏性上的表现更为突出。如图 5.1 (c) 所示，COCO 数据集中的前景目标占据了 30.1% 的图像像素，而每个目标的平均像素百分比为 4.1%。相比之下，CULane 数据集中的车道线仅占 3.6% 的像素，大约是 COCO 数据集中目标像素占比的八分之一。其中，面积的测量基于分割掩模中的像素数量。此外，每条车道线的平均像素百分比更低，仅为 1.1%，每张图像中车道线的平均数量约为 3.4 条。相比之下，COCO 数据集中的每张图像上平均目标数量为 7.4 个。车道线在前景区域的平均比例、单个目标区域大小以及每张图像中目标的平均数量等方面都展现出显著的稀疏性，这为车道线检测任务带来了独特的挑战。




图 5.1 车道线与常见目标的稀疏性比较

充分考虑车道线的稀疏特性对于提高车道线检测算法的性能和效率至关重要。然而，现有的车道线检测方法大多基于与车道线稀疏特性不匹配的密集设计，如图 5.2 所示。目前，最先进的车道线检测方法主要由基于密集锚点的方法主导，如图 5.2 (a) 所示。这些方法在图像上预定义了密集的线性锚，包括垂直线锚和倾斜线锚，并沿着这些锚点提取车道线特征，预测车道点相对于锚点的偏

移量。尽管这些方法在概念上直观易懂且性能卓越，但它们依赖于手工设计的组件，如锚点生成、基于规则的训练目标分配、非极大值抑制等，并不能实现完全端到端的检测。




图 5.2 密集设计与稀疏设计对比

2020 年, Carion 等人^[92]提出了 DETR (DEtection TRansformer) 将目标检测转化为一个集合预测问题, 消除了经典目标检测器中诸多手工设计的规则, 并构建了首个完全端到端的目标检测器。DETR 范式以其简洁性与优越性能, 在目标检测^[112-116]、目标跟踪^[117-118]、图像分割^[119-121]、姿态估计^[122-123]等领域得到了广泛应用。鉴于车道线检测与通用目标检测的诸多相似之处, 一些方法^[37,48,110]尝试将 DETR 模型应用于端到端车道线检测。然而, 如图 5.2 (c) 所示, DETR 的注意力机制中采用密集交互形式, 即任意两个查询 (Query) 与键 (Key) 都会交互。其中灰色和白色圆圈分别对应保留和移除的交互, 对角线上的深灰色圆圈表示自交互, 蓝色圆圈表示车道标记。这种密集交互机制不利于准确识别稀疏车道线以及提高算法的计算效率。

一方面, 密集交互形式下, 每个车道查询都需要与全部图像标记交互, 这使得从海量背景信息中有效提取稀疏车道特征变得十分困难。特别是 Transformer^[43]网络在初始化时, 注意力模块对特征图中的所有像素几乎都赋予了均

匀的注意力权重。让注意力权重学会从全尺度的特征图中定位到稀疏的有意义的目标位置上难度较大。因此,密集交互首先导致了车道线感知困难的问题。另一方面,Transformer 中的注意力计算复杂度与像素数量的平方成正比。考虑到 CULane 数据集^[18]中车道线前景像素比例仅为 3.6%,车道线像素与背景像素的计算比例接近 1:700,背景区域的计算带来巨大的计算资源浪费。此外,高分辨率的特征图有利于检测小目标,但密集交互形式下的二次计算复杂度限制了应用多尺度特征图以提升车道线识别准确率。因此,设计一个利用车道线稀疏特性的高效端到端车道线检测范式是一个亟待解决的问题。

尽管 DETR 中注意力机制擅长捕捉长程依赖关系,理论上有利于建模车道线的细长结构。然而,现有基于 Transformer 的端到端车道线检测方法大多简单地迁移了 DETR 模型,没有充分考虑车道线稀疏特性在端到端检测范式中带来的独特挑战,导致它们的性能未能超越现有的 CNN 车道线检测方法。例如, LSTR^[37]是首个采用 DETR 模型的车道线检测方法,沿用了原有的模型结构并基于稀疏查询回归车道线的多项式系数。此外,车道线与其他交通目标之间存在隐含关系,例如车辆通常在车道内行驶,而行人通常出现在人行横道区域。受到这种关系的启发, LaneFormer^[48]将同一输入图像的目标检测结果作为辅助信息用于车道线检测,有效减少了人行横道场景中的车道误检。然而,该方法同样没有对车道线的稀疏性做出针对性的改进。为了解决 DETR 框架中遇到的标签语义冲突问题, O2SFormer^[110]提出了一种新型的一对多标签分配策略,并引入了逐层软标签以动态调整不同解码器层的损失权重,以加速模型收敛速度。

为了解决在 Transformer 架构中稀疏车道线感知难和计算冗余大的问题,本章提出了一个基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer。全稀疏设计是指采用了稀疏查询,并在编码器和解码器中实现了查询与键的稀疏交互。具体来说, Sparse LaneFormer 专注于稀疏但信息量丰富的车道区域,并提出了一个具有明确车道线位置的可学习车道感知查询(LAQ),如图5.2(b)所示。这些可学习的 LAQ 作为稀疏查询,比密集锚点和普通高维查询产生了更准确的车道线位置。此外,提出了一个车道标记选择器(LTS)和一个线性可形变采样器(LDS),以在车道标记之间建立稀疏交互,如图5.2(d)所示。LTS 在编码器中有选择地更新稀疏车道标记, LDS 则在解码器阶段通过自适应采样技术,从全局特征图中提取具有判别性的车道线特征表示。因此, Sparse LaneFormer 在编码器和解码器中实现了车道标记的稀疏交互。 Sparse LaneFormer 首次在车道线检测领域验证了稀疏设计的可行性和有效性。特别地, Sparse LaneFormer 在仅使用 10% 的图像标记的情况下,实现计算开销降低 80%, FPS 提升近 5 倍,并在 CULane 和 TuSimple 数据集上超越了现有基于密集设计的方法,成为首个性能超越 CNN 架构的端到端车道线检测方法。

5.2 方法概述

本节介绍了一个名为 Sparse LaneFormer 的全稀疏端到端车道线检测方法，同时实现了稀疏查询和稀疏交互。Sparse LaneFormer 的框架如图5.3所示。本节首先介绍 Sparse LaneFormer 的整体框架，包括其关键稀疏组件：车道标记选择器、车道感知查询和线性可形变采样器。最后分析了方法的计算复杂度，并介绍了优化函数。




图 5.3 基于全稀疏设计的端到端车道线检测方法（Sparse LaneFormer）的框架

5.2.1 整体网络结构

Sparse LaneFormer 框架遵循 DETR^[92] 的设计，采用 Transformer 编码器和解码器结构进行车道线的检测任务。Sparse LaneFormer 主要由以下几部分组成：卷积主干网络、车道标记选择器、Transformer 编码器、Transformer 解码器，以及多个特定任务的预测头。卷积主干网络用于提取图像多尺度特征。车道标记选择器筛选多尺度特征中更具信息量的稀疏前景特征（图5.3中带有绿点的网格）进行后续的更新。Transformer 编码器旨在改善卷积主干网络输出的多尺度内容嵌入。它由多个编码器层堆叠而成，每层主要由自注意力层，可形变注意力层^[94]和前馈神经网络（Feed Forward Network, FFN）组成。相对应地，Transformer 解码器是由解码器层的堆叠而成，每层由自注意力层、线性可形变采样器和前馈层组成。最终，通过相应的预测头获取完整的车道线表示，包括置信度、车道长度、车道点的偏移和车道查询位置 (x, y, θ) 。

对于输入图像 $I \in \mathbb{R}^{3 \times H \times W}$ ，ResNet^[104] 主干网络首先提取多尺度的特征表示。主干网络中提取得到的三个尺度的特征被记为 $\{f_l\}_{l=1}^L$ ($L=3$)，其中 $f_l \in \mathbb{R}^{C_l \times H_l \times W_l}$ 。 $\{f_1, f_2, f_3\}$ 分别对应于原始图像大小的 1/8、1/16 和 1/32 尺度。车道标记选择器（参见 5.2.2 节）预测每个特征尺度下的二值车道线掩模，用于指示

一个像素是否与车道线相关。这些车道线掩模表示为 $\{m_l\}_{l=1}^L$ ，其中 m_l 的空间尺寸与 f_l 保持一致，而通道数为 1，即 $m_l \in \mathbb{R}^{H_l \times W_l}$ 。在编码器中，筛选得到的不同尺度下的少量车道标记（5.3 中带有绿点的网格）通过自注意力^[43]、可形变注意力^[94] 和前馈层，进行特征交互并得到更新。因此，属于前景的车道标记可以丰富多尺度语义和纹理信息。在解码器中，车道感知查询（参见 5.2.3 节）与线性可形变采样器（参见 5.2.4 节）协同工作，以提取稀疏车道线特征。线性可形变采样器沿着车道感知查询预测自适应采样位置，并从编码器更新后的多尺度特征中采样车道线特征。第 n 个解码器层的内容查询和车道感知查询分别表示为 C_q^n 和 L_q^n 。最终，基于最后一个解码器层的内容和位置查询的输出，特定于任务的预测头将预测出完整的车道线表示，包括置信度、车道线长度、车道点的偏移和车道查询位置 (x, y, θ) 。预测头在所有解码器层之间共享，可以实现对车道线预测的逐层优化和更新。

5.2.2 车道标记选择器

两阶段目标检测器^[79-80,85]所取得的优秀检测性能证明了目标的前景特征对于实现目标定位和分类至关重要。然而，自然图像通常包含了大量与主要目标无关的背景部分^[111,124-125]。这导致在端到端的检测系统中，背景数据占据了很大一部分^[126-129]。如前文所述，车载前视图像中也存在相当大的背景冗余。因此，设计一个专注于显著区域的高效端到端车道线检测器是必要且自然的。




图 5.4 车道标记选择器框架

本节提出了车道标记选择器（Lane Token Selector, LTS）用以筛选更具信息

量的车道特征,为建立稀疏车道特征之间的交互奠定了基础。LTS 通过选择预计会被解码器引用的标记,有效地进行车道线检测。如图 5.4 所示, LTS 首先将主干网络输出的多尺度特征集合 $\{f_l\}_{l=1}^L$ ($L=3$) 调整至所需尺寸并串接。随后,这些串接的特征经由 1×1 卷积网络生成二值车道掩模 m_l , 表示任意位置是车道标记的概率。对于任意空间尺度的车道掩模 m_l , 均由多尺度特征共同预测。与基于单尺度特征推断车道掩模的方法相比, 利用多尺度特征包含的多层级信息进行推理, 能够更好地适应驾驶场景的变化, 从而获得更加鲁棒和准确的车道掩模。随后 m_l 分别被用于提取相应特征层 f_l 中的车道标记, 并在编码器中进行更新。LTS 由 1×1 卷积网络组成, 其计算成本相对较低, 几乎可以忽略不计。尽管其结构很简单, 但我们对车道标记选择器的消融研究揭示了, 即使使用最小的标记保留率, 比如 10%, 其性能仍然令人满意, 且不会对模型的整体性能产生显著影响。接着, 基于二值车道掩模可以筛选得到少量车道标记。车道掩模 m_l 的计算方式如下

$$m_l = \text{Conv}(\text{Concat}(\text{Resize}(\{f_l\}_{l=1}^L))), \quad (5.1)$$

其中 m_l 表示与 f_l 对应的二值车道掩模, 主干网络输出的多尺度特征集合 $\{f_l\}_{l=1}^L$ 经过尺寸调整 (Resize) 以匹配相同的维度, 随后进行串接 (Concat) 以及卷积 (Conv) 操作生成车道掩模。具体地, m_l 和 f_l 的尺寸分别为 $\mathbb{R}^{H_l \times W_l}$ 和 $\mathbb{R}^{C_l \times H_l \times W_l}$ 。

m_l 的监督信号来自于车道掩模真值在特征图上的投影。对于特征图 f_l 上的每个标记 $t_l^{(i,j)}$, 其步长为 s_l , 这里 l 表示尺度级别的索引, (i,j) 表示特征图中的位置坐标, 则相应的原始图像中的坐标 (x,y) 定义为 $(\lfloor \frac{s_l}{2} \rfloor + i \cdot s_l, \lfloor \frac{s_l}{2} \rfloor + j \cdot s_l)$ 。相应的标签 $T_l^{(i,j)}$ 定义为

$$T_l^{(i,j)} = \begin{cases} 1 & \text{当 } (x,y) \in M_{Lane}, \\ 0 & \text{否则.} \end{cases} \quad (5.2)$$

其中 M_{Lane} 表示车道掩模真值, $M_{Lane} \in \mathbb{R}^{H \times W}$, $l \in 1, 2, 3$ 。 H 和 W 分别代表原始图像的高度和宽度。如果特征图 f_l 上的标记 $t_l^{(i,j)}$ 的位置映射位于车道掩模真值 M_{Lane} 内, 那么对应的标签 $T_l^{(i,j)}$ 被设置为 1, 否则标签为 0。

在训练阶段, 模型采用 Focal Loss^[107] 来优化车道掩模的学习过程, 能够有效解决类别不平衡问题。在测试阶段, 模型根据设定的图像标记保留比例 α 来选择具有最高概率的图像标记。这意味着只有最具信息量的标记被保留用于后续的处理。在编码器中, 只有所选的车道标记作为查询和键, 在自注意力模块和可变形注意力模块中交互与更新, 从而在编码器中可以构建稀疏交互。这种仅关注前景车道特征的稀疏交互的设计在充分发挥 Transformer 架构建立车道远程结构上优势的同时, 避免了计算冗余和背景噪声的干扰。实验观察到, 即使只有部分编码器标记被更新, 车道线检测的性能也几乎不受影响, 详细数据参见实验表

格5.6。此外，基于车道线标记选择器，Sparse LaneFormer 首次能够将多尺度特征引入到端到端车道线检测范式中。

5.2.3 车道感知查询

在解码器的交叉注意力机制中，查询通过与键的交互来定位图像特征图中的特定区域。这一过程涉及将这些特征通过计算得到的注意力权重加权聚合到每个目标实例对应的查询中，并用于目标的语义分类和位置预测。然而，车道线展示出显著的稀疏特性，这使得查询在定位和聚合车道线特征时，面临的挑战远大于常规的矩形目标。尽管如此，如何提升查询的感知能力以更好地应对这一挑战，在车道线检测领域中尚未得到充分的探索。在现有研究中，LSTR^[37] 和 LaneFormer^[48] 采用了原始的 DETR 中的高维目标查询，即 $Q \in \mathbb{R}^{N \times C}$ ，其中 N 表示查询数量， C 表示特征维度。但这种高维查询缺乏明确的物理意义，且难以直观地解释其关注的位置。

在基于 DETR^[92] 范式的目标检测器中，增强查询的定位能力是一个关键的研究问题。原始的 DETR 模型中，目标查询是一组可学习的高维嵌入，但这些嵌入缺乏明确的物理意义，使得预测它们将关注图像中的哪些区域变得困难。这种不确定性导致查询在定位感兴趣目标时面临挑战，因为它们不会自动专注于特定区域。为了解决这一问题，Anchor DETR^[82] 提出基于锚点构建目标查询，这在基于 CNN 的检测器中广泛使用。这种方法使得每个目标查询得以专注于锚点附近的区域。进一步地，Conditional DETR^[83] 将查询解耦为内容查询和空间查询，并引入了条件交叉注意力机制。具体来说，该方法利用目标参考点坐标和解码器嵌入映射得到条件空间查询，使其与键的位置编码处于相同的高维空间，从而增强空间查询与键的空间关联性，提升查询的定位能力与检测性能。Conditional DETR 在生成条件空间查询时，仅显式地考虑了目标中心点信息。DAB-DETR^[130] 进一步使用目标框的宽度和高度信息作为空间查询的一部分，提出了一种基于动态锚框的查询。这种方法直接在 Transformer 解码器中使用框坐标作为空间查询，使得查询的物理意义更加清晰。通过引入显式的空间信息，这些方法提高了查询与键的相似性，从而提升了检测性能。

本节受到上述工作^[82-83,130] 的查询设计启发，提出了一种新型的车道感知查询 (Lane Aware Query, LAQ)，它具有明确的车道位置信息。具体而言，每个车道感知查询被构建为一个三元组 (x_s, y_s, θ) ，其中 (x_s, y_s) 表示归一化的车道起始点坐标，而 θ 表示车道线的方向。一组车道感知查询可以记为 $L_q \in \mathbb{R}^{N \times 3}$ 。与传统的高维查询相比，LAQ 具有两方面的显著优势。首先，LAQ 具有比高维查询更明确的物理意义，有助于提高模型的解释性。其次，LAQ 能够在每个 Transformer 解码层中动态更新，这使得它能够更好地适应车道线的位置。因此，与固定位置

的预设锚^[29-33]相比, LAQ 能够提供更精确的位置参考。车道感知查询的更新方式可以用以下公式表示

$$\hat{l}_{n+1} = \text{sigmoid}(\text{FFN}(f)) + \hat{l}_n. \quad (5.3)$$

其中 $\hat{l}_n$ 是第 n 个解码器层的输入车道感知查询的归一化表示, 而 $\hat{l}_{n+1}$ 则是更新后的车道感知查询 (x_s, y_s, θ) , f 是解码器的嵌入表示, 前馈层可以根据解码器嵌入生成一个归一化的查询调整量。

尽管 O2SFormer^[110] 采用了类似的查询公式 (x_s, y_s, θ, o) , 其中额外的参数 o 表示车道点的偏移量, 但这些查询仍被编码为高维嵌入, 并与全局特征图进行密集的交互以聚合车道特征, 这与现有方法^[37,48]的处理方式相似。相比之下, 在 Sparse LaneFormer 中, LAQ 提供了直接的车道线位置参考, 并基于可形变注意力机制^[94]与小部分车道标记进行交互, 有效忽略了海量的背景信息, 从而能够高效准确地提取车道特征。

5.2.4 线性可形变采样器

在目标检测领域, 无论是经典的目标检测器^[80,86]还是基于 DETR 的端到端目标检测器^[130-131], 准确采样目标特征已被证明是至关重要的一环。这些方法通过 ROI 池化或目标查询在解码器的交叉注意力模块中提取目标特征。然而, 现有的基于 DETR 的车道线检测方法^[37,39,48,110]在交叉注意力模块中采用密集交互, 使得每个车道查询都与全局图像特征进行交互。在模型初始化阶段, 交叉注意力模块将注意力权重几乎均匀的分配给特征图中的所有像素, 使得查询难以集中于稀疏的车道位置。这可能是现有基于 DETR 范式的车道线检测方法^[37,39,48,110]性能受限的主要原因。

为了有效地从多尺度特征图中提取车道线特征, 本节提出了一种基于可形变注意力^[94]的线性可形变采样器 (Linear Deformable Sampler, LDS)。在 Deformable DETR^[94]中, 可形变注意力机制在相应的目标框内预测二维采样位置, 使得每个查询能够与稀疏的图像特征进行交互。然而, 车道线与常规目标在形状特征上存在差异, 车道线通常跨越较大的图像区域, 形状更接近线段而非二维目标框, 因此原始的二维采样策略并不适用于车道线的细长结构。针对这一问题, 本节提出了线性采样策略, 以更好地提取车道线特征。如图 5.3 所示, LDS 以车道感知查询 L_q 、更新后的内容查询 C'_q 和编码器输出 x 为输入, 利用车道感知查询提供的位置参考, 预测一维但非均匀的采样位置, 并从编码器输出中提取多尺度车道特征。

给定更新后的内容查询 $c'_q \in C'_q$, 车道感知查询 $l_q \in L_q$ 和编码器输出 x , 其

中 q 索引车道感知查询, 线性可形变采样器的计算过程可以表示为

$$LDS(c'_q, l_q, x) = \sum_{m=1}^M W_m \left[\sum_{k=1}^K A_{mqk} \cdot W'_m x(\Phi_K(c'_q, l_q)) \right], \quad (5.4)$$

其中 M 和 K 分别表示注意力头的数量和每个头中的采样位置数, m 表示特定的注意力头索引, k 表示采样点索引, $\Phi_K(\cdot)$ 负责生成沿输入查询的 K 个采样点, $x(\cdot)$ 表示对特征进行索引操作, W_m 和 W'_m 是投影层, A_{mqk} 是第 m 个注意力头中第 k 个采样点的预测注意力权重, 该权重通过对查询特征 c'_q 进行线性投影获得的。

特别地, 采样位置和权重是自适应预测的, 这使得 LDS 能够适应不同的车道线长度, 灵活的关注不同区域的车道线索, 从而提取更具判别性的车道线特征表示。当采样位置和权重被设置为均匀分布时, LDS 退化为平均池化采样, 这在基于锚的车道线检测方法^[29-33]中得到了广泛应用。

5.2.5 复杂度分析

注意力机制是 Transformer 模型的核心, 它通过计算查询 (Query, Q), 键 (Key, K) 和值 (Value, V) 之间的关联。标准注意力模块的密集计算可以表示为

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V. \quad (5.5)$$

标准自注意力通过 Q 和 K 之间的点积计算注意力权重, 并根据得到的注意力权重对 V 进行加权求和得到输出。其中 d_k 是 K 的通道维度, 分母中的缩放操作是为了避免点积的数值过大, 从而保证 softmax 函数的稳定性。

本章提出的稀疏模块, 即 LTS、LAQ 和 LDS, 在编码器和解码器中都采用了稀疏化的查询和键策略。这种设计不仅增强了对车道区域的注意力, 同时也提高了计算效率。编码器和解码器的计算成本主要由自注意力和交叉注意力/LDS 模块决定。

密集交互和稀疏交互的计算复杂度对比如表5.1所示。 H 和 W 分别是特征图的高度和宽度, N_q 表示解码器查询的数量, α 是 LTS 的保留比率, K 是采样点的数量。通过这种稀疏化策略, 模型能够更加高效地处理数据, 尤其是在处理具有显著稀疏特性的车道线检测任务。

在密集交互中, 主干网络输出的多尺度特征同时作为编码器自注意力模块中的查询和键。编码器自注意力的计算复杂度随着序列长度的增长而呈二次方增长, 而解码器的交叉注意力则表现为线性增长。由于解码器查询的数量 N_q 远小于多尺度特征的总和 $\sum_l H_l W_l$, 因此引入多尺度特征后, 编码器成为模型的主要计算瓶颈。在 Sparse LaneFormer 中, 车道标记被选作编码器中的查询和键。车

表 5.1 密集交互和稀疏交互的计算复杂度对比

	模块	# 查询	# 键	复杂度	多尺度输入复杂度
密集交互	Enc. Self-Attn	HW	HW	$O(H^2W^2C)$	$O((\sum_l H_l W_l)^2 C)$
	Dec. Cross-Attn	N_q	HW	$O(HW N_q C)$	$O(\sum_l H_l W_l N_q C)$
稀疏交互	Enc. Self-Attn	αHW	αHW	$O(\alpha^2 H^2 W^2 C)$	$O(\sum_l \alpha^2 H_l^2 W_l^2 C)$
	Dec. LDS	N_q	K	O_{LDS}	O_{LDS}

道标记的总数量是 αHW ，其中 α 是 LTS 中标记保留的比例。参考 Deformable DETR^[94] 的复杂度分析，LDS 的复杂度可以表示为

$$O_{LDS} = O(KC + 3MK + C + 5K)N_q C, \quad (5.6)$$

其中 K 和 M 分别代表采样点和注意力头的数量。

Sparse LaneFormer 同时采用稀疏查询和键，能够实现高效的计算性能。本章使用乘加累计操作数 (Multiply-Accumulate Operations, MACs) 评估计算量。如表 5.5 中的实验 3 所示，编码器的计算 (87.8 GMACs) 占总计算量 (111.3 GMACs) 的 78.9%，是解码器计算量的 6.7 倍。如表 5.6 所示，在典型的设置下， $\alpha = 0.1$ 且 $K = 16$ ，Sparse LaneFormer 的计算成本从 111.3 GMACs 大幅减少至 22.5 GMACs，降低了约 80%。

5.2.6 优化函数

在 Sparse LaneFormer 训练过程中，每条车道真值都通过匈牙利算法与预测车道进行匹配。匹配成本的计算考虑了预测置信度和位置两个因素，定义如下

$$C_{match} = w_{conf} C_{conf} + w_{pos} C_{xyo\theta}, \quad (5.7)$$

其中 C_{conf} 是基于 Focal Loss^[107] 计算的置信度成本，而 $C_{xyo\theta}$ 表示预测车道与真实车道之间位置的 L1 距离成本， o 表示车道点的偏移量。匈牙利算法通过最小化总匹配成本来寻找预测车道和真实车道之间的最优匹配。

在模型的训练阶段，总损失函数由多个部分组成，具体公式为

$$L_{total} = w_{conf} L_{conf} + w_{dis} L_{xy\theta l} + w_{seg} L_{seg} + w_{LIoU} L_{LIoU}, \quad (5.8)$$

其中 L_{conf} 是 Focal Loss^[107]， $L_{xy\theta l}$ 是衡量车道感知查询位置误差的 L1 损失， L_{seg} 是 LTS 模块的交叉熵损失， L_{LIoU} 是 Line-IoU 损失^[87]， w_{conf} 、 w_{pos} 、 w_{dis} 、 w_{seg} 和 w_{LIoU} 是各损失项的权重。正样本参与所有损失项的计算，而负样本则只对置信度损失有贡献。

5.3 实验结果与分析

本节首先描述实验设置，随后展示在两个主要的车道线检测数据集 CULane^[18] 和 TuSimple^[74] 上获得的结果，最后通过全面的消融研究证明了所提出稀疏设计的有效性。

5.3.1 实验设置

实验中采用了在 ImageNet 预训练的 ResNet^[104] 作为主干网络，以提取图像特征。CULane^[18] 和 TuSimple^[74] 数据集集中的所有输入图像大小都被调整至 320×800 像素。实验中应用了随机平移、旋转、缩放和水平翻转等数据增强方法，以提高模型的泛化能力。为了与 DETR^[92] 框架的标准设置保持一致，编码器和解码器的层数均设定为 $N = 6$ 。车道感知查询的数量 N_q 和特征维度 C 分别设定为 192 和 256，这与 O2SFormer^[110] 中的设置保持一致。对于可形变注意力和线性可变形采样器模块，注意力头数 M 和采样点数 K 分别设定为 8 和 16，这些配置是基于消融实验结果确定的。Sparse LaneFormer 在 CULane 数据集上训练了 30 个周期，在 TuSimple 数据集上训练了 70 个周期。训练过程使用了 AdamW^[132] 优化器，初始学习率设定为 $2e-4$ ，并采用了余弦衰减学习率策略。在第一个周期中实施了线性的学习率预热策略，确保模型的稳定启动。所有训练实验均在 4 个 RTX 3090 GPU 上完成。在公式(5.7)和公式(5.8)中，权重因子 w_{conf} 、 w_{pos} 、 w_{dis} 、 w_{seg} 和 w_{LIoU} 分别设定为 1、3、0.3、1 和 2，这与对比方法 O2SFormer^[110] 中的设置保持一致。

5.3.2 与现有方法的对比

1. CULane 数据集实验结果

表5.2展示了 Sparse LaneFormer 在使用不同比例图像标记下的性能表现。其中“*”表示结果引自 BézierLaneNet^[41]，“-”表示结果不可用。可以看到，在使用全部图像标记的时，Sparse LaneFormer (ResNet-34) 在 CULane 数据集上实现了 79.4% 的总 F1 分数，刷新了现有记录。值得注意的是，即使在标记比例 α 显著降低的情况下，Sparse LaneFormer 的性能略有下降，但总体上仍然保持在较高水平。例如，当标记比例仅为 10% 时，Sparse LaneFormer 总计算量减少了近 70%。但性能仅下降了 1.0% 至 1.2%，且仍然超越了所有基于密集设计的车道线检测方法。在实际应用中，通过选择适当的 α ，可以实现模型检测精度和计算效率之间的平衡。

在非端到端方法中，基于锚点的车道线检测方法通常优于基于分割的方法。例如，PointLaneNet^[29]、NAS^[30]、LaneATT^[31] 和 SGNet^[32] 等方法，它们通过设计线性锚来采样所有的车道位置。与此相对，Sparse LaneFormer 采用了可学

表 5.2 CULane 数据集上的实验性能对比

方法	Total	正常 27.7%	拥堵 23.4%	眩光 1.4%	阴影 2.7%	无线 11.7%	箭头 2.6%	弯道 1.2%	路口 9.0%	夜间 20.3%	MACs(G)
非端到端方法											
基于分割的方法											
SCNN ^[18]	71.6	90.6	69.7	58.5	66.9	43.4	84.1	64.4	1990	66.1	328.4
HBNet ^[17]	73.1	91.9	71.6	64.7	66.7	46.8	85.3	65.1	2306	66.7	-
PINet(4H) ^[16]	74.4	90.3	72.3	66.3	68.4	49.8	83.7	65.7	2052	66.3	-
RESA(ResNet-34) ^[19]	74.5	91.9	72.4	66.5	72.0	46.3	88.1	68.6	1896	69.8	41.0
RESA(ResNet-50) ^[19]	75.3	92.1	73.1	69.2	72.8	47.7	88.3	70.3	1503	69.9	43.0
CenLaneNet ^[20]	74.8	90.1	73.7	66.0	73.9	48.6	85.8	66.5	1359	68.0	-
KP-MFF(ResNet-50) ^[47]	69.0	87.2	67.1	63.7	66.1	44.7	81.5	65.5	3306	62.0	-
基于锚的方法											
PointLane(ResNet-101) ^[29]	70.2	88.0	68.1	61.5	63.3	44.0	80.9	65.2	1640	63.2	-
CurveLanes-NAS-S ^[30]	71.4	88.3	68.6	63.2	68.0	47.9	82.5	66.0	2817	66.2	9.0
CurveLanes-NAS-M ^[30]	73.5	90.2	70.5	65.9	69.3	48.8	85.7	67.5	2359	68.2	33.7
LATT(ResNet-18) ^[31]	75.1	91.1	73.0	65.7	70.9	48.4	85.5	63.4	1170	69.0	9.3
LATT(ResNet-34) ^[31]	76.7	92.1	75.0	66.5	78.2	49.4	88.4	67.7	1330	70.7	18.0
LATT(ResNet-122) ^[31]	77.0	91.7	76.2	69.5	76.3	50.5	86.3	64.1	1264	70.8	70.5
SGNet(ResNet-18) ^[32]	76.1	91.4	74.1	66.9	72.2	50.2	87.1	67.0	1164	70.7	-
SGNet(ResNet-34) ^[32]	77.3	92.1	75.4	67.8	74.3	50.9	88.0	69.7	1373	72.7	-
端到端方法											
PRNet(ResNet-18) ^[36]	74.8	90.8	72.3	64.2	70.6	47.6	85.2	67.2	1113	69.2	-
BézierLaneNet(ResNet-18) ^[41]	73.7	90.2	71.6	62.5	70.9	45.3	84.1	59.0	996	68.7	14.7
BézierLaneNet(ResNet-34) ^[41]	75.6	91.6	73.2	69.2	76.7	48.0	87.2	62.5	888	69.9	29.5
LSTR(ResNet-18)* ^[37]	68.7	86.8	67.3	56.6	59.8	40.1	78.7	56.6	1166	59.9	4.1
LSTR(ResNet-34)* ^[37]	72.5	89.7	69.8	64.3	68.2	45.3	85.0	64.1	1247	66.7	34.5
Laneformer(ResNet-18) ^[48]	71.7	88.6	69.0	64.1	65.0	45.0	81.6	60.5	25	64.8	13.8
Laneformer(ResNet-34) ^[48]	74.7	90.7	72.3	69.1	71.6	47.4	85.1	65.9	26	67.8	23.0
O2SFormer(ResNet-18) ^[110]	76.1	91.9	73.9	70.4	74.8	49.8	86.1	68.7	2361	70.7	15.2
O2SFormer(ResNet-34) ^[110]	77.0	92.5	75.3	70.9	77.7	51.0	87.6	68.1	2749	72.9	25.1
PGANet(ResNet-18) ^[39]	69.9	87.8	70.0	62.1	67.6	46.7	80.9	58.0	1700	59.0	6.7
PGANet(ResNet-34) ^[39]	74.7	91.2	73.9	64.4	77.6	50.5	87.0	63.9	1725	67.3	14.4
Ours(ResNet-18) ($\alpha = 1$)	79.1	93.5	77.2	73.8	80.8	54.2	90.2	69.3	2054	75.2	90.9
Ours(ResNet-34) ($\alpha = 1$)	79.4	93.6	77.7	73.3	81.0	54.1	90.2	70.7	1885	75.4	100.3
Ours(ResNet-18) ($\alpha = 0.3$)	78.7	93.1	77.0	72.4	80.1	52.5	90.1	70.1	1891	74.3	34.7
Ours(ResNet-34) ($\alpha = 0.3$)	79.0	93.4	77.0	73.7	80.6	54.1	90.0	69.6	1717	74.6	44.2
Ours(ResNet-18) ($\alpha = 0.1$)	77.9	92.5	76.4	72.0	72.3	52.1	88.5	69.3	1629	73.5	22.5
Ours(ResNet-34) ($\alpha = 0.1$)	78.4	92.9	76.6	71.5	74.1	52.4	89.0	69.6	1559	73.7	31.5

习的车道感知查询,这不仅允许查询学习车道的空间分布模式,还可以在解码器层间逐步更新查询位置,实现更精确的车道特征采样。因此, Sparse LaneFormer (ResNet-18) 和 Sparse LaneFormer (ResNet-34) 分别以 3.0% 和 2.1% 的优势超越了 SGNet^[32] 的相应模型。此外,轻量级 Sparse LaneFormer (ResNet-18) 在性能上分别超过了 LATT (ResNet-18)^[31] 4.0% 和 CurveLanes-NAS-S^[30] 7.7%, 这进

一步证明了车道感知查询的优越性。在标记保留比例 $\alpha = 0.3$ 的情况下, Sparse LaneFormer (ResNet-18) 使用与 CurveLanes-NAS-M^[30] 相当的总 MACs, 性能提高了 5.2%。相较于这些基于锚检测的方法, Sparse LaneFormer 的另一个显著优势是其完全端到端的特性, 它不包含任何手动设计的组件, 如锚点生成和 NMS。

关于端到端车道线检测方法, 先前的类似 DETR 的车道线检测方法^[37,39,48,110] 采用了密集交互, 并且与基于 CNN 的方法^[31-32] 相比性能较弱。考虑到车道线的稀疏性, Sparse LaneFormer 引入了车道感知查询和线性可形变采样器来有效地探查稀疏的车道特征。因此, Sparse LaneFormer 能够有效地识别具有挑战性的车道样本。如表 5.2 所示, 在车道线索通常是不可见的诸多挑战性的场景中表现出色, 例如“拥挤”、“夜晚”、“阴影”和“眩目”等场景中, Sparse LaneFormer 以明显的优势超越了先前的端到端车道线检测方法^[37,39,48,110]。这种改进凸显了稀疏设计的有效性。据目前所知, Sparse LaneFormer 在基于 DETR 范式的端到端车道线检测器中取得了最佳性能。值得注意的是, 额外交通目标检测结果^[48] 和复杂的标签分配策略^[110] 有望进一步提升算法性能。

2. TuSimple 数据集实验结果

表 5.3 展示了 Sparse LaneFormer 在 TuSimple 数据集^[74] 上的准确率 (Accuracy)、F1 分数、误检率 (FP) 和漏检率 (FN)。

由于 TuSimple 数据集的样本大多在高速公路上的良好可见条件下收集, 不同方法在该数据集上的表现已经趋于饱和, 准确率普遍超过 95.0%。尽管如此, Sparse LaneFormer (ResNet-18) 在该数据集上仍达到了最佳的准确率和 F1 分数, 分别为 96.69% 和 97.23%。Sparse LaneFormer 在 F1 分数方面的优越性主要归功于其在减少误检测和漏检测之间的有效平衡。具体来说, Sparse LaneFormer 展现出较低的误检和漏检, 这表明了其在维持高检测准确率的同时, 能够有效降低这两种错误类型。例如, 尽管 SCNN 在漏检测数量更少, 但 Sparse LaneFormer 在误检测的数量上明显更低。类似地, LSTR^[37] 虽然误检测较低, 但 Sparse LaneFormer 在减少漏检车道线方面略胜一筹。

值得注意的是, Sparse LaneFormer 在使用 ResNet-18 和 ResNet-34 时都表现出色, 这证明了模型对于不同主干网络的适应性。特别是, Sparse LaneFormer (ResNet-18) 在参数量较少的情况下, 仍然能够达到与 ResNet-34 版本相近或更好的性能, 这进一步证明了稀疏设计的有效性。

此外, Sparse LaneFormer 还展示了不同的标记保留比例 α 对模型检测性能的影响。从表中可以看出, 随着 α 的减小, 模型的计算成本显著降低, 但性能下降并不显著, 特别是当 $\alpha = 0.3$ 时, Sparse LaneFormer (ResNet-18) 仍然保持了 96.44% 的准确率和 97.18% 的 F1 分数, 同时显著减少了计算量。总体而言, 稀疏设计在场景较为简单的 TuSimple 数据集^[74] 和场景更复杂的 CULane 数据

表 5.3 TuSimple 数据集上的实验性能对比

方法	Accuracy(%)	F1(%)	FP(%)	FN(%)	MACs(G)
非端到端方法					
SCNN ^[18]	96.53	95.97	6.17	1.80	328.4
PINet(4H) ^[16]	96.62	97.10	3.08	2.72	-
CenLaneNet ^[20]	96.48	97.20	3.10	2.50	-
SAD(ENet) ^[22]	96.64	95.92	6.02	2.05	-
KP-MFF(Tiny ResNet-50) ^[47]	94.64	94.69	5.69	4.93	-
PointLaneNet ^[29]	96.34	95.07	4.67	5.18	-
CurveLanes-NAS-S ^[30]	95.97	-	-	-	9.0
CurveLanes-NAS-M ^[30]	96.21	-	-	-	33.7
LATT(ResNet-18) ^[31]	95.57	96.71	3.56	3.01	9.3
LATT(ResNet-34) ^[31]	95.63	96.77	3.53	2.92	18.0
SGNet ^[32]	95.87	-	-	-	-
端到端方法					
BézierLaneNet(ResNet-18) ^[41]	95.41	95.04	5.30	4.60	14.7
BézierLaneNet(ResNet-34) ^[41]	95.65	95.49	5.10	3.90	29.5
LSTR(ResNet-18) ^[37]	96.18	96.85	2.91	3.38	4.1
Laneformer(ResNet-18) ^[48]	96.54	96.63	4.35	2.36	-
Laneformer(ResNet-34) ^[48]	96.56	95.61	5.39	3.37	-
Ours(ResNet-18) ($\alpha = 1$)	96.69	97.23	3.03	2.51	90.9
Ours(ResNet-34) ($\alpha = 1$)	96.63	97.11	3.18	2.60	100.3
Ours(ResNet-18) ($\alpha = 0.3$)	96.44	97.18	3.05	2.59	34.7
Ours(ResNet-34) ($\alpha = 0.3$)	96.38	97.12	3.15	2.60	44.2
Ours(ResNet-18) ($\alpha = 0.1$)	96.58	97.17	3.04	2.61	22.5
Ours(ResNet-34) ($\alpha = 0.1$)	96.48	97.15	3.03	2.66	31.5

集^[18]上都取得了出色的表现。

5.3.3 可视化结果分析

图5.5展示了 Sparse LaneFormer 在 CULane 数据集中不同驾驶场景下的车道线检测结果。从左至右,依次展示了车道真值、车道线预测、LTS 选择的 30% 图像标记、解码器最后一层的车道感知查询位置,以及 LDS 预测的动态采样点。

可以看出, Sparse LaneFormer 能够在光照强烈或不足、遮挡等复杂场景下实现稳定可靠的车道线检测。所选择的 30% 图像标记有效覆盖了与车道直接相关




图 5.5 CULane 不同驾驶场景下的检测结果

的区域，确保了车道特征的准确提取。LAQ 和 LDS 的采样点与 LTS 提取的区域精确对齐，有助于高效提取车道特征。如图5.5第一行所示，LDS 预测的采样点集中在车道线索明显的区域，并能够很好的适应不同的车道线长度，从而获得更具辨识度的车道特征表示。这些结果验证了车道标记选择器、车道感知查询位置和线性可形变采样器这三个稀疏组件能够协同工作，以实现精确的车道特征探查。

为了直观地说明车道标记选择器的作用，本节在图5.6和图5.7中展示了 LTS 对同一组图片在三个不同尺度和不同稀疏比例下的掩模预测。高中低分辨率掩模分别对应了原图尺寸的 1/8、1/16 和 1/32。如图5.6所示，在多样化的场景中，LTS 利用多尺度特征预测图像掩模，并且在每个尺度下都能很好地适应前景区域。这意味着不同尺度下的稀疏前景特征都得到了合理关注，并在编码器中更新后，用于解码器中的车道线定位。




图 5.6 不同尺度下的图像掩模预测

图5.7展示了在 30%、20% 和 10% 的稀疏比例下，同一组图片的图像掩模。可以看到，随着稀疏比例的降低，保留的区域更加接近车道线前景，这表明尽管车道标记选择器结构设计简单，但其预测结果仍然相当准确。尽管这些图像是在不同稀疏比例下由同一模型训练得到的，LTS 的预测结果仍然显示出高度的准

确性和一致性。总的来说,这些可视化结果表明,LTS在减少图像标记、降低计算成本的同时,依然能够聚焦于最重要的视觉信息,这对于提高车道检测算法的效率和性能具有重要意义。




图 5.7 不同稀疏比例下的掩模预测

图5.8进一步展示了车道感知查询在解码器层之间的更新过程,不同层更新后的车道感知查询用不同的颜色标记。初始的查询位置可能不够精确,但随着解码器层的更新,车道感知查询位置迅速收敛至车道的实际位置。尽管模型采用了6个解码器层,但大多数车道感知查询位置在经过一次更新后就能实现相当准确的定位。因此,在图5.8中,部分更新后的车道感知查询位置可能会有重叠现象。这一过程不仅展示了 Sparse LaneFormer 在解码器层中对车道特征的逐步精细化处理,也体现了模型在车道线检测任务中的高效性和准确性。

5.3.4 消融实验

本节开展了一系列消融实验,旨在验证 Sparse LaneFormer 中各个稀疏组件的有效性。除非另有说明,所有消融实验都是在 CULane 数据集上进行,模型使用 ResNet-18 作为主干网络。

1. 稀疏组件消融实验

表5.4总结了各项稀疏设计对性能的影响,包括车道感知查询(LAQ),线性可形变采样器(LDS)、多尺度特征(MS)和车道标记选择器(LTS)。基线方法采用了高维查询和密集交互的注意力机制,得到的F1分数为70.1%。在实验2中,通过将基线方法中的高维查询替换为车道感知查询,实现了相对于基线4.2%的性能提升。这是因为车道感知查询采用与编码器特征相同的正弦位置编码方法,增强了查询与键在空间位置上的相关性,有助于通过解码器中的密集交互更有效地提取车道特征。此外,车道感知查询还在解码器中通过预测相对调整量 $\Delta(x, y, \theta)$,实现逐层优化。如实验3所示,引入线性可形变采样器使得F1分数进一步增加了2.9%,这一性能提升源于解码器中对车道特征的更准确提取。




图 5.8 车道感知查询在解码器层之间的更新过程

LDS 利用车道感知查询的位置信息，自适应地提取具有区分度的车道特征。

此外，多尺度特征能够提供额外的低级车道细节，有利于定位细小的车道线，因而带来了 1.9% 的额外性能提升。在计算效率方面，车道感知查询和线性可形变采样器对计算成本的影响相对较小，而多尺度特征的引入则显著增加了计算成本。由于车道线的固有稀疏性，在 Transformer 架构下引入了较大的计算冗余，特别是在编码器中。为了解决这一问题，车道标记选择器被用来识别稀疏但信息量丰富的车道标记，这在几乎不影响性能（仅下降 0.4%）的情况下实现了超过 60% 的计算成本降低。表 5.5 和表 5.6 提供了关于 LDS 和 LTS 的进一步分析和详细数据。值得注意的是，车道感知查询和线性可形变采样器可以同时提高精确率（Precision）和召回率（Recall），而多尺度特征主要通过提高召回率来提升性能，这表明低级特征中的纹理细节对于检测具有挑战性的车道样本是有帮助的。同时，保留的图像标记数量减少有利于降低误报，从而提高精确率。

2. 车道感知查询消融实验

图 5.9 详细展示了车道感知查询数量对模型性能的影响，提供了查询数量 $N = 192$ 时，查询收敛后的空间分布情况。

如图 5.9 (a) 所示，当查询数量在 15 到 192 之间变化时，模型的性能指标波动不大。尽管在 $N = 15$ 时模型表现略优，但为了确保比较的公平性，本章在报告实验结果时选择了 $N = 192$ ，与 O2SFormer^[110] 的设置保持一致。图 5.9 (b)

表 5.4 稀疏组件的消融实验

序号	基线方法	LAQ	LDS	MS	LTS	F1(%)	Precision(%)	Recall(%)	MACs(G)
1	✓					70.1	78.0	63.6	15.0
2	✓	✓				74.3	81.1	68.6	15.2
3	✓	✓	✓			77.2	84.2	71.2	14.4
4	✓	✓	✓	✓		79.1	84.1	74.6	90.9
5	✓	✓	✓	✓	✓	78.7	85.3	73.0	34.7




图 5.9 车道感知查询命中频率的统计和收敛后空间分布可视化

展示了车道感知查询命中次数的累积分布直方图。在这个直方图中，横轴代表查询的数量，纵轴表示车道命中的累计频率。实验中，车道感知查询的数量 N_q 被设定为 192。大约只有 20% 的查询（大约 38 个）在检测车道时达到了高命中率，这表明使用少量查询就能有效感知车道位置。这一结果与传统的基于预设锚点的方法，如 LATT^[31]，形成鲜明对比，后者通常需要超过 1000 个密集线性锚。由于采用了 1 对 1 的标签分配策略，许多查询的命中次数接近于 0。为了评估查询的收敛质量，图 5.9 (c) 和 (d) 可视化了学习到的车道感知查询的位置，包括命中率最高的前 10% 和 20% 的车道感知查询的位置。颜色越深表示相应查询的命中频率越高。可以看出，排名靠前的查询集中在车道线高频出现的位置上，包括了中间以及两侧的车道区域。感知查询的全局分布也证实了每个车道感知查询能够在相应的区域内有效地检测车道线。

另外，车道感知查询可以通过训练梯度不断更新初始位置，以及在推理阶段通过线性层预测实现解码器层间的位置更新。如图 5.10 所示，我们验证可学习




图 5.10 可学习车道感知查询消融实验

查询在模型中的作用及其对模型性能的影响。实验通过比较具有不同配置的模型在查询数量变化下的 F1 得分，分析了可学习查询、初始化更新和跨层更新对性能的具体贡献。实验结果表明，引入可学习查询的模型在 F1 得分上表现更佳，验证了初始化更新和跨层更新对优化模型性能的重要性。在模型训练过程中允许查询的初始化更新，可以动态调整初始查询位置以适应车道线的分布模式，从而能够有效提升模型的检测性能。层间查询的设计则保证了在推理阶段，有益于提升解码器层间递进式的车道线定位精度。

3. 线性可形变采样器消融实验

解码器中不同采样策略以及多尺度特征对性能的影响如表 5.5 所示。本章使用 C5、C4 和 C3 分别指代主干网络在下采样因子分别为 32、16 和 8 时获得的特征表示。为了确保采样策略分析的精确性并排除其他变量的影响，所有实验统一使用了车道感知查询。

本节共考察了三种采样方法，即密集采样、2D 采样和 1D (LDS) 采样。在密集采样中，所有查询与编码器生成的键之间建立了密集交互作用。与此同时，2D 和 1D (LDS) 采样方法根据可形变注意力^[94]对采样位置施加了不同程度的约束。在 2D 采样位置是没有约束的，可以是图像中的任何位置。而 1D 采样则沿着车道感知查询在编码器增强后的图像特征上进行。在这些实验中，2D 和 1D 策略中的采样点数量均设置为 16。采样点数量的影响稍后在表 5.6 中给出了分析。

在表 5.5 的实验 1 中，使用单尺度 C5 特征和密集采样，得到的 F1 分数为 74.3%，编码器和解码器的计算成本分别为 2.3 GMACs 和 2.9 GMACs。然而，引入多尺度特征 C4 和 C3 会导致性能下降，如实验 2 和实验 3 所示。这是因为随

表 5.5 多尺度特征和不同采样方法的消融实验

实验 序号	特征尺度			采样方法			F1(%)	模型	编码器	解码器
	C5	C4	C3	密集	2D	1D (LDS)		MACs(G)	MACs(G)	MACs(G)
1	✓			✓			74.3	15.2	2.3	2.9
2	✓	✓		✓			73.3	28.3	13.2	5.0
3	✓	✓	✓	✓			72.8	111.3	87.8	13.2
4	✓				✓		75.9	14.8	2.4	2.3
5	✓	✓			✓		74.3	26.6	13.5	2.9
6	✓	✓	✓		✓		73.4	90.9	75.9	4.6
7	✓					✓	77.2	14.8	2.4	2.3
8	✓	✓				✓	78.3	26.6	13.5	2.9
9	✓	✓	✓			✓	79.1	90.9	75.9	4.6

着标记数量的增加,从多尺度特征中有效提取稀疏车道线索变得更加困难。同时,多尺度特征的引入也显著增加了编码器的计算成本。为了有效提取车道特征并降低计算负担,实验中尝试了2D和1D(LDS)采样策略。尽管两种采样方法的计算成本相同,但1D(LDS)采样能够更精确地聚焦于车道线特征。实验4、5、6和实验7、8、9的结果显示,1D(LDS)采样在多尺度特征上持续获得显著的性能提升,分别提高了2.9%、5.0%和6.3%。这表明了LDS采样方法相比传统密集交互方式的优势。此外,当使用三个尺度的特征时,LDS采样机制相比密集采样在总计算成本上降低了45.8%,如实验3和实验8所示。

4. 稀疏交互消融实验

Sparse LaneFormer通过精细调控形变注意力机制中的采样点数量 K ,以及车道标记选择器中的保留比例 α ,实现车道标记间的稀疏交互。本节对采样点数量 K 以及标记保留比例 α 进行消融实验。

(1) 采样点数量

在车道线检测任务中,编码器和解码器通过预测一系列采样点来获取稀疏的键,这一过程对于提高模型的效率和性能至关重要。在“密集交互”基线模型中,采用了车道感知查询、三种多尺度特征以及密集交互的方式,这与表5.4中的实验3的设置相一致。然而,这种密集交互的方法在车道线检测任务上显示出了局限性,F1分数仅为72.8%。此外,编码器的计算成本高达87.8 GMACs,占到了总成本111.3 GMACs的78.8%,成为整个系统的计算瓶颈。

如表5.6所示,Sparse LaneFormer采用的稀疏设计,显著提高了性能和计算

效率。当采样点数量 $K = 16$ 时, 模型达到了最佳的 F1 分数 79.1%, 比基线模型提高了 6.3%, 同时将编码器的计算成本从 87.8 GMACs 降低到了 75.9 GMACs。有趣的是, 增加采样点数量会显著影响模型的推理速度, 却并不一定能带来性能上的提升。一方面, 过多的参考点可能会引入背景噪声, 影响模型对车道的准确检测。另一方面, 随着采样点数量的增加, 线性可形变采样器预测得到的采样点之间的距离变得更近, 权值差距也会减小。这可能会导致 LDS 退化成平均池化操作。相反, 当采样点数量较少时, LDS 能够更专注于显著的车道位置, 从而获得更独特的车道特征表示。如图 5.5 第一行所示, 稀疏采样点能够很好地适应车道标记长度。值得注意的是, 编码器的总体计算成本与采样点的数量并不是严格的正比关系。这是因为编码器和解码器层不仅包括注意力模块, 还包括额外的前馈网络, 这些都会对计算成本产生影响。

表 5.6 采样点数量 K 和图像特征保留比例 α 的消融实验

		F1(%)	编码器 MACs(G)	解码器 MACs(G)	模型 MACs(G)	FPS
采样点数量 K	密集交互	72.8	87.8	13.2	111.3 (100%)	8.6
	128	78.1	141.0	7.7	159.1 (143%)	16.6
	64	78.4	104.3	5.9	120.1 (108%)	22.9
	32	78.8	85.2	5.0	100.6 (90.4%)	27.0
	16	79.1	75.9	4.6	90.9 (81.7%)	29.6
	8	78.8	71.3	4.4	86.0 (77.3%)	31.7
标记保留比例 α ($K=16$)	1	79.1	75.9	4.6	90.9 (100%)	29.6
	0.5	78.8	33.7	4.6	48.6 (53.5%)	32.4
	0.4	78.7	26.5	4.6	41.5 (45.6%)	35.5
	0.3	78.7	19.7	4.6	34.7 (38.1%)	37.7
	0.2	78.2	13.4	4.6	28.4 (31.2%)	38.6
	0.1	77.9	7.5	4.6	22.5 (24.7%)	39.4

(2) 车道标记保留比例

表 5.6 展示了车道标记选择器中不同图像特征保留比例 α 对算法性能的影响。车道标记选择器筛选出前景车道标记, 作为编码器中稀疏的查询和键。

如表 5.6 所示, 当保留比例从 1 降至 0.3 时, 计算成本显著减少, 而性能下降并不明显。具体来说, 当 $\alpha = 0.3$ 时, 模型的 F1 分数能够达到 78.7%, 这验证了即使只更新少量的稀疏车道标记, 也足以实现令人满意的车道线检测性能。同时, 编码器的计算成本大幅降低了 74.0%, 从 75.9 GMACs 减少到 19.7 GMACs。即使在只有 10% 的车道标记的情况下, Sparse LaneFormer 在性能 (77.9% vs 72.8%)

和速度 (39.4 vs 8.6) 上都明显优于密集基线模型, 其计算成本仅为 20.2% (22.5 GMACs 对 111.3 GMACs), 实现了近 5 倍的速度提升以及近 80% 的计算成本降低。如图 5.5 所示, 所选的 30% 标记已经能够准确覆盖车道区域, 这些区域随后由线性可形变采样器 (LDS) 参考以产生最终的车道线预测。然而, 当保留比例降至 0.3 以下, 如 0.2 和 0.1 时, 准确筛选车道标记变得更加具有挑战性, 这导致 F1 分数出现了明显下降。尽管如此, 在 $\alpha = 0.1$ 的情况下, Sparse LaneFormer 的性能仍然优于现有的基于密集设计的方法。这表明 Sparse LaneFormer 在车道线检测任务中具有强大的鲁棒性和效率, 即使在极端的稀疏条件下也能保持较高的性能水平。

5. 网络运行时间分析

为了深入理解网络模型的运行效率, 图 5.11 提供了不同组件和操作符在神经网络计算中时间占比的评估和可视化分析。如图 5.11 (a) 所示, 解码器的运行时间占比最高, 达到了 51.1%, 在所有展示的组件中耗时最长。编码器紧随其后, 占据了 35.3% 的运行时间。主干网络和车道标记选择器的运行时间分别占据了 8.7% 和 4.8%。由此可见, 在基于 Transformer 架构的模型中, 编解码器的计算仍是构成模型计算瓶颈的主要部分。进一步地, 图 5.11 (b) 通过 Pytorch^[133] 框架的内置接口, 对底层操作符的运行时间占比进行了统计。结果显示, 线性计算、乘加操作符以及部分二值索引操作符的运行时间加起来占据了总运行时间的 60%。




图 5.11 网络模块和操作符运行时间分析

5.4 本章小结

本章节介绍了一种基于稀疏设计的端到端车道线检测方法, 该方法针对车道线稀疏性在传统 Transformer 模型中引起的感知困难和计算冗余, 提出了车道标记选择器、车道感知查询和线性可形变采样器。这些稀疏设计有效减少了算法计算冗余, 同时保持了极具竞争力的车道线检测性能。具体来说, 所提算法仅利用图像中大约 10% 的像素, 实现了计算成本的大幅度降低 (约 80%) 和处理速度的显著提升 (近 5 倍)。在性能方面, Sparse LaneFormer 不仅超越了现有的基

于密集设计的车道线检测方法，还实现了超越传统 CNN 架构的端到端车道线检测性能，证明了稀疏设计在车道线检测任务中的实用性和高效性。

第6章 总结与展望

近年来,随着全球汽车保有量的持续增长,交通事故导致的伤亡人数不断攀升,每年有超过一百万人丧生,两千万人受伤。发展自动驾驶技术是减少交通事故、提升道路安全的有效途径。车道线检测,作为自动驾驶系统中的关键技术之一,为车辆提供了基础的导航信息。然而,受到车道线内在特性以及外部环境因素的影响,复杂环境下的车道线检测仍然是一个极具挑战性的任务。一方面,车道线具有形状和朝向多样、结构细长空间跨度大、像素稀疏车道纹理不明显的特点,使得车道线比常规目标的识别难度更大。另一方面,恶劣天气、极端光照、交通干扰和标线异常等复杂外部因素,使得有限的车道线视觉线索更加难以捕捉,进一步增加了车道线检测任务的难度。

现有的研究工作大多依赖不稳定的视觉线索实现车道线检测,存在车道线结构表示不够灵活、车道线结构预测不够可靠以及计算效率不高的问题,难以满足实际驾驶场景中的应用需求。本文对上述三个问题展开深入研究,并从车道线自身的结构和稀疏特性出发,提出了一系列针对性的解决方案,并取得了一定的进展。

本章6.1节对全文的研究内容和创新点进行全面总结,6.2节针对本文研究中存在的一些不足之处,对未来的研究工作进行展望,希望能为相关领域的研究者提供新的思路 and 想法。

6.1 本文内容总结

为了提升复杂环境下的车道线检测算法性能,本文深入挖掘了车道线自身的结构和稀疏特性,分别从提升车道线结构表示的灵活性、提升车道线结构建模的鲁棒性以及提升端到端检测器对稀疏车道线的定位能力和计算效率,三个方面开展研究工作,并取得了一定的进展。本文提出的三种现对本文主要工作和创新点总结如下:

- 1) 针对现有线性锚形状固定、难以适应不同形状和朝向车道线的问题,提出了一种基于超锚的车道线检测方法 HANet,以提升车道线结构表示的灵活性。该方法根据输入图片动态生成一组具有行列混合表示的超锚,这些超锚在形状灵活性和置信度上优于传统的密集线性锚,能够更准确地拟合多种形状和朝向的车道线。此外,现有的全尺寸特征增强方式存在容易引入背景噪声、效率低的问题, HANet 提出了多种车道位置敏感的特征增强方式,包括自适应感受野的车道线描述子构建和基于注意力机制的特征信息流构建。前者通过收集行内的

邻域线索,扩充车道描述子的信息丰富度,后者利用注意力机制在车道内和车道间实现高效的跨区域信息传递。实验结果表明, HANet 通过建立灵活高效的车道线结构表示与信息传递机制,提升了对弯道和水平朝向车道线的检测性能。

2) 针对复杂环境下车道线检测容易出现锯齿、断裂等不可靠结构的问题,提出了一种基于多车道片段的车道线检测方法 LaneSegNet, 以提高车道线结构预测的鲁棒性。该方法提出了一种渐进式的检测流程: 首先提取显著线索区域的可靠参考点, 然后通过关联参考点周围的车道点构建局部车道片段, 最后利用多车道片段重构完整车道线。LaneSegNet 将车道点表示为具有多层级和非对称结构的图节点。它通过局部和全局图增强模块分别构建车道片段内和参考点之间的多层级拓扑结构。此外, 图节点间非对称的权重设计, 可以提升模型的推理能力。例如, 被遮挡的车道点难以直接定位, 可以依赖其他可靠的车道点位置进行推理, 反之则不成立。此外, 该方法通过学习车道点间的相对偏移, 强化了模型对车道点相对空间位置的理解。实验结果表明, LaneSegNet 利用车道线平滑连续的结构知识, 增强了复杂环境下车道线检测的结构鲁棒性。

3) 针对稀疏车道线在 Transformer 架构中感知困难和计算冗余大的问题, 提出了一种基于全稀疏设计的端到端车道线检测方法 Sparse LaneFormer, 同时实现了稀疏查询和稀疏交互。该方法首先提出了一种稀疏的车道感知查询, 其具有明确的物理位置, 并能够动态更新, 从而展现出比密集线锚和高维查询更精确的车道线定位能力。另外, 注意力机制的计算复杂度正比于序列长度的平方, 而车道线像素在图像中较为稀疏, 带来了大量背景计算冗余。例如, 在 CULane 数据集中车道像素占比仅为 3.6%, 导致车道线与背景的计算比接近 1: 700。为了降低计算冗余, Sparse LaneFormer 提出了车道标记选择器和线性可形变采样器, 用于在车道标记之间建立稀疏交互。车道标记选择器在编码器中有选择性地更新稀疏车道标记, 而线性可形变采样器则在解码器中沿车道感知查询位置, 准确地采样稀疏车道特征。Sparse LaneFormer 专注于最具信息量的稀疏车道标记, 仅利用图像中 10% 的像素进行计算, 实现了 80% 的计算开销降低和近 5 倍速度提升。在性能上, Sparse LaneFormer 超越了现有基于密集设计的车道线检测方法, 成为首个性能超越 CNN 架构的端到端车道线检测方法, 验证了稀疏设计在车道线检测任务中的可行性和有效性。

本论文提出的三种车道线检测方法各有侧重点, HANet 强调通过自适应的超锚生成与特征聚合提升车道线结构表示的灵活性, LaneSegNet 的设计则对车道线划分为多个更精细的车道片段, 并利用相对偏移预测和图增强设计提升车道线结构预测的鲁棒性, 而 Sparse LaneFormer 则关注利用稀疏设计提升端到端车道线检测方法的计算效率。前两种方法基于卷积神经网络设计, 具有尺寸小、运算速度快的优势, 每秒能处理约 100 帧图像, 因而在低算力、低成本的应用场

景中是较好的选择。HANet 能够较好地处理结构多样的车道线,例如弯道、水平方向车道。LaneSegNet 则在恶劣天气环境中能够更为准确地预测车道线结构,适合对于行驶路线精度要求较高的应用场景。第三种方法 Sparse LaneFormer 基于 Transformer 架构设计,相较于前两种方法具有性能上限高、可拓展性强和设计简洁等优势。然而,该方法的检测速度仅有每秒 30 帧,因而更适合部署在具有高算力芯片的智能驾驶平台上。在实际应用中,可以根据具体需求和目标场景,从提出的三种车道线检测方法中选择最合适的一种,或者考虑将这些方法进行有效融合。

6.2 未来研究展望

本文针对复杂环境下车道线检测任务面临的诸多问题,提出了有效的解决方案,并取得了积极的成果。然而,研究中也存在一些局限性和不足之处。在未来的研究工作中,以下几个方面值得深入探讨:

1) 时序信息融合。本文研究的车道线检测算法只考虑单帧图像中的车道线信息,而忽略了过往时序信息。车道线作为一种具有高度结构化的道路元素,其在不同时间帧中的表现具有高度的连续性。同时,复杂场景中的多种因素也呈现出动态变化的特性。这种变化可能由多种因素引起,包括但不限于车辆的移动、光线条件的变化、路面状况的差异等。通过对连续帧中车道线的位置信息进行分析,研究者可以捕捉到车道线的动态变化模式,并据此预测未来帧中车道线的位置和形状。未来的研究可以探索如何更有效地利用时域信息,例如通过递归神经网络(Recurrent Neural Network, RNN)或长短期记忆网络(Long Short-Term Memory, LSTM)来捕捉车道线的动态特性。这种时序信息的引入,不仅能够提高车道线检测的准确性,还能增强系统在面对环境变化时的稳定性。

2) 空间视角扩展。本文研究的车道线检测算法局限于在单一前视视角的图像中检测车道线。然而,对于自动驾驶系统而言,单一视角的图像信息不足以满足其对周围环境全面感知的需求。自动驾驶车辆通常以自车为中心建立坐标系,并在鸟瞰图的视角下构建周边的道路结构。因此,通过环视视角的图像输入构建鸟瞰图视角下完整的道路结构,对于自动驾驶车辆感知周围环境、做出决策具有重要意义。未来的研究可以着眼于如何利用环视视角的图像输入,在考虑相机和车辆的空间约束的基础上,构建鸟瞰图视角下精确的场景表示和道路结构。这不仅能够提供更为丰富和准确的道路信息,还能够极大地提升自动驾驶车辆对周围环境的感知和适应能力。

3) 交通语义理解。本文研究的车道线检测算法的主要目标在于提升车道线定位和结构等空间属性的检测精度。但事实上,车道线不仅仅是道路空间的划分

标志，它们还蕴含了丰富的交通语义信息。不同类型的车道线往往对应着不同的驾驶行为规范。例如，实线通常不允许车辆在此线两侧变换车道，虚线表示车道的界限较为宽松，允许车辆在安全的情况下变换车道。此外，车道线还指示了车辆的行驶方向。因此，对车道线的交通语义进行深入理解，不仅有助于自动驾驶车辆遵守交通规则，还能促进车辆与其他道路元素（如交通信号灯、道路文本、箭头标记、路侧标志牌等）之间的逻辑关系建立，从而提高驾驶场景的理解度，构建更为安全可靠的自动驾驶系统。

参考文献

- [1] 中国汽车工业协会. 2023 年汽车工业经济运行报告[EB/OL]. <http://lwzb.stats.gov.cn/pub/lwzb/bzt/202405/W020240527578179613545.pdf>.
- [2] ORGANIZATION W H. Global status report on road safety 2023[EB/OL]. <https://www.who.int/teams/social-determinants-of-health/safety-and-mobility/global-status-report-on-road-safety-2023>.
- [3] SCHWALL M, DANIEL T, VICTOR T, et al. Waymo public road safety performance data [A]. 2020. arXiv: 2011.00038.
- [4] ABDEL-ATY M, DING S. A matched case-control analysis of autonomous vs human-driven vehicle accidents[J]. Nature Communications, 2024, 15(1): 4931-4942.
- [5] THRUN S, MONTEMERLO M, DAHLKAMP H, et al. Stanley: The robot that won the darpa grand challenge[J]. Journal of field Robotics, 2006, 23(9): 661-692.
- [6] TALPES E, SARMA D D, VENKATARAMANAN G, et al. Compute solution for tesla's full self-driving computer[J]. IEEE Micro, 2020, 40(2): 25-35.
- [7] GRUYER D, MAGNIER V, HAMDI K, et al. Perception, information processing and modeling: Critical stages for autonomous driving applications[J]. Annual Reviews in Control, 2017, 44(1): 323-341.
- [8] SON Y S, KIM W, LEE S H, et al. Robust multirate control scheme with predictive virtual lanes for lane-keeping system of autonomous highway driving[J]. IEEE Transactions on Vehicular Technology, 2015, 64(8): 3378-3391.
- [9] WANG W, ZHAO D, HAN W, et al. A learning-based approach for lane departure warning systems with a personalized driver model[J]. IEEE Transactions on Vehicular Technology, 2018, 67(10): 9145-9157.
- [10] KIEFER R J, HANKEY J M. Lane change behavior with a side blind zone alert system[J]. Accident Analysis & Prevention, 2008, 40(2): 683-690.
- [11] TAJEDDIN S, EKHTIARI S, FAIEGHI M, et al. Ecological adaptive cruise control with optimal lane selection in connected vehicle environments[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(11): 4538-4549.
- [12] SONG W, YANG Y, FU M, et al. Lane detection and classification for forward collision warning system based on stereo vision[J]. IEEE Sensors Journal, 2018, 18(12): 5151-5163.
- [13] LEE S, KIM J, SHIN YOON J, et al. Vpgnet: Vanishing point guided network for lane and road marking detection and recognition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 1947-1955.

- [14] NEVEN D, DE BRABANDERE B, GEORGOULIS S, et al. Towards end-to-end lane detection: an instance segmentation approach[C]//Proceedings of the IEEE Intelligent Vehicles Symposium. 2018: 286-291.
- [15] ABUALSAUD H, LIU S, LU D B, et al. Laneaf: Robust multi-lane detection with affinity fields[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 7477-7484.
- [16] KO Y, LEE Y, AZAM S, et al. Key points estimation and point instance segmentation approach for lane detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(7): 8949-8958.
- [17] PANG G, ZHANG B, TENG Z, et al. Fast-hbnet: Hybrid branch network for fast lane detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 15673-15683.
- [18] PAN X, SHI J, LUO P, et al. Spatial as deep: Spatial cnn for traffic scene understanding[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018: 7276-7283.
- [19] ZHENG T, FANG H, ZHANG Y, et al. Resa: Recurrent feature-shift aggregator for lane detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021: 3547-3554.
- [20] SUN Y, LI J, XU X, et al. Adaptive multi-lane detection based on robust instance segmentation for intelligent vehicles[J]. IEEE Transactions on Intelligent Vehicles, 2023, 8(1): 888-899.
- [21] ZOU Q, JIANG H, DAI Q, et al. Robust lane detection from continuous driving scenes using deep neural networks[J]. IEEE Transactions on Vehicular Technology, 2020, 69(1): 41-54.
- [22] HOU Y, MA Z, LIU C, et al. Learning lightweight lane detection cnns by self attention distillation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1013-1021.
- [23] HOU Y, MA Z, LIU C, et al. Inter-region affinity distillation for road marking segmentation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 12486-12495.
- [24] WEN Y, YIN Y, RAN H. Flipnet: An attention-enhanced hierarchical feature flip fusion network for lane detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(8): 8741-8750.
- [25] ZHAO J, QIU Z, HU H, et al. Hwlane: Hw-transformer for lane detection[J/OL]. IEEE Transactions on Intelligent Transportation Systems, Early Access, 2024. DOI: 10.1109/TITS.2024.3386531.
- [26] PASZKE A, CHAURASIA A, KIM S, et al. Enet: A deep neural network architecture for real-time semantic segmentation[A]. 2016. arXiv: 1606.02147.
- [27] ROMERA E, ALVAREZ J M, BERGASA L M, et al. Erfnet: Efficient residual factorized

- convnet for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 19(1): 263-272.
- [28] YAO X, WANG Y, WU Y, et al. Mlp-based efficient convolutional neural network for lane detection[J]. IEEE Transactions on Vehicular Technology, 2023, 72(10): 12602-12614.
- [29] CHEN Z, LIU Q, LIAN C. Pointlanenet: Efficient end-to-end cnns for accurate real-time lane detection[C]//Proceedings of the IEEE Intelligent Vehicles Symposium. 2019: 2563-2568.
- [30] XU H, WANG S, CAI X, et al. Curvelane-nas: Unifying lane-sensitive architecture search and adaptive point blending[C]//Proceedings of the European Conference on Computer Vision. 2020: 689-704.
- [31] TABELINI L, BERRIEL R, PAIXAO T M, et al. Keep your eyes on the lane: Real-time attention-guided lane detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 294-302.
- [32] SU J, CHEN C, ZHANG K, et al. Structure guided lane detection[C]//Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence. 2021: 997-1003.
- [33] LI X, LI J, HU X, et al. Line-cnn: End-to-end traffic line detection with line proposal unit [J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(1): 248-258.
- [34] VAN GANSBEKE W, DE BRABANDERE B, NEVEN D, et al. End-to-end lane detection through differentiable least-squares fitting[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. 2019: 905-913.
- [35] TABELINI L, BERRIEL R, PAIXAO T M, et al. Polylanenet: Lane estimation via deep polynomial regression[C]//Proceedings of the International Conference on Pattern Recognition. 2021: 6150-6156.
- [36] WANG B, WANG Z, ZHANG Y. Polynomial regression network for variable-number lane detection[C]//Proceedings of the European Conference on Computer Vision. 2020: 719-734.
- [37] LIU R, YUAN Z, LIU T, et al. End-to-end lane shape prediction with transformers[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2021: 3694-3702.
- [38] YANG J, ZHANG L, LU H. Lane detection with versatile atrousformer and local semantic guidance[J]. Pattern Recognition, 2023, 133(1): 109053-109062.
- [39] LI Q, YU X, CHEN J, et al. Pga-net: Polynomial global attention network with mean curvature loss for lane detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(1): 417-429.
- [40] JIN D, PARK W, JEONG S G, et al. Eigenlanes: Data-driven lane descriptors for structurally diverse lanes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17142-17150.

- [41] FENG Z, GUO S, TAN X, et al. Rethinking efficient lane detection via curve modeling [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17062-17070.
- [42] WU Y, ZHAO L, LU J, et al. Dense hybrid proposal modulation for lane detection[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(11): 6845-6859.
- [43] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.
- [44] QIN Z, WANG H, LI X. Ultra fast structure-aware deep lane detection[C]//Proceedings of the European Conference on Computer Vision. 2020: 276-291.
- [45] QIN Z, ZHANG P, LI X. Ultra fast deep lane detection with hybrid anchor driven ordinal classification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 46(5): 2555-2568.
- [46] YOO S, LEE H S, MYEONG H, et al. End-to-end lane marker detection via row-wise classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 1006-1007.
- [47] ZHENG S, XIE Y, LI M, et al. A novel strategy for global lane detection based on key-point regression and multi-scale feature fusion[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 23244-23253.
- [48] HAN J, DENG X, CAI X, et al. Laneformer: Object-aware row-column transformers for lane detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022: 799-807.
- [49] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.
- [50] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//Proceedings of the European Conference on Computer Vision. 2016: 21-37.
- [51] GHIASI G, LIN T Y, LE Q V. Nas-fpn: Learning scalable feature pyramid architecture for object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7036-7045.
- [52] TIAN Z, SHEN C, CHEN H. Conditional convolutions for instance segmentation[C]//Proceedings of the European Conference on Computer Vision. 2020: 282-298.
- [53] DAI J, QI H, XIONG Y, et al. Deformable convolutional networks[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 764-773.
- [54] ZHU X, HU H, LIN S, et al. Deformable convnets v2: More deformable, better results [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.

- 2019: 9308-9316.
- [55] LIU L, CHEN X, ZHU S, et al. Condlanenet: a top-to-down lane detection framework based on conditional convolution[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3773-3782.
- [56] XU S, CAI X, ZHAO B, et al. Rclane: Relay chain prediction for lane detection[C]//Proceedings of the European Conference on Computer Vision. 2022: 461-477.
- [57] QU Z, JIN H, ZHOU Y, et al. Focus on local: Detecting lane marker from bottom up via key point[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 14122-14130.
- [58] PHILION J. Fastdraw: Addressing the long tail of lane detection by adapting a sequential prediction network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 11582-11591.
- [59] WANG J, MA Y, HUANG S, et al. A keypoint-based global association network for lane detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1392-1401.
- [60] ZHAN J, YANG Y, JIANG W, et al. Fast multi-lane detection based on cnn differentiation for adas/ad[J]. IEEE Transactions on Vehicular Technology, 2023, 72(12): 15290-15300.
- [61] ZHANG Y, ZHENG Y, WU C, et al. Enhanced curve perception in lane detection via adaptive guided techniques[J/OL]. IEEE Transactions on Vehicular Technology, Early Access, 2024. DOI: 10.1109/TVT.2024.3408162.
- [62] CHIU K Y, LIN S F. Lane detection using color-based segmentation[C]//Proceedings of the IEEE Intelligent Vehicles Symposium. 2005: 706-711.
- [63] LÓPEZ A, SERRAT J, CANERO C, et al. Robust lane markings detection and road geometry computation[J]. International Journal of Automotive Technology, 2010, 11(1): 395-407.
- [64] NAROTE S P, BHUJBAL P N, NAROTE A S, et al. A review of recent advances in lane detection and departure warning system[J]. Pattern Recognition, 2018, 73(1): 216-234.
- [65] FENG Y, LI J. Robust accurate lane detection and tracking for automated rubber-tired gantries in a container terminal[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(10): 11254-11264.
- [66] 李茂月, 吕虹毓, 王飞, 等. 基于机器视觉的智能车辆鲁棒车道线识别方法[J]. 中国机械工程, 2021, 32(02): 242-251.
- [67] XU H, LI H. Study on a robust approach of lane departure warning algorithm[C]//Proceedings of the International Conference on Signal Processing Systems. 2010: 201-204.
- [68] 钱基德, 陈斌, 钱基业, 等. 基于感兴趣区域模型的车道线快速检测算法[J]. 电子科技大学学报, 2018, 47(03): 356-361.

- [69] 鱼兆伟, 吴晓波, 沈林. 基于动态感兴趣区域的光照无关车道线检测算法[J]. 计算机工程, 2017, 43(2): 43-47.
- [70] OZGUNALP U. Combination of the symmetrical local threshold and the sobel edge detector for lane feature extraction[C]//Proceedings of the International Conference on Computational Intelligence and Communication Networks. 2017: 24-28.
- [71] PARAJULI A, CELENK M, RILEY H B, et al. Robust lane detection in shadows and low illumination conditions using local gradient features[J]. Open Journal of Applied Sciences, 2013, 3(1): 68-74.
- [72] BALLARD D H. Generalizing the hough transform to detect arbitrary shapes[J]. Pattern Recognition, 1981, 13(2): 111-122.
- [73] DERPANIS K G. Overview of the ransac algorithm[J]. Image Rochester NY, 2010, 4(1): 2-3.
- [74] TUSIMPLE. Tusimple benchmark[EB/OL]. <https://github.com/TuSimple/tusimple-benchmark/>, accessed November, 2021.
- [75] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
- [76] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Proceedings of the Medical Image Computing and Computer-Assisted Intervention. 2015: 234-241.
- [77] GHAFOORIAN M, NUGTEREN C, BAKA N, et al. El-gan: Embedding loss driven generative adversarial networks for lane detection[C]//Proceedings of the European Conference on Computer Vision Workshops. 2018: 256-272.
- [78] NEWELL A, YANG K, DENG J. Stacked hourglass networks for human pose estimation [C]//Proceedings of the European Conference on Computer Vision. 2016: 483-499.
- [79] GIRSHICK R, DONAHUE J, DARRELL T, et al. Region-based convolutional networks for accurate object detection and segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(1): 142-158.
- [80] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[C]//Advances in Neural Information Processing Systems. 2015: 91-99.
- [81] LAW H, DENG J. Cornernet: Detecting objects as paired keypoints[C]//Proceedings of the European Conference on Computer Vision. 2018: 734-750.
- [82] WANG Y, ZHANG X, YANG T, et al. Anchor detr: Query design for transformer-based detector[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022: 2567-

- 2575.
- [83] MENG D, CHEN X, FAN Z, et al. Conditional detr for fast training convergence[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3651-3660.
- [84] CHEN X, WEI F, ZENG G, et al. Conditional detr v2: Efficient detection transformer with box queries[A]. 2022. arXiv: 2207.08914.
- [85] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2015: 1440-1448.
- [86] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [87] ZHENG T, HUANG Y, LIU Y, et al. Clrnet: Cross layer refinement network for lane detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 898-907.
- [88] SUN P, ZHANG R, JIANG Y, et al. Sparse r-cnn: End-to-end object detection with learnable proposals[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 14454-14463.
- [89] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 6154-6162.
- [90] XIAO L, LI X, YANG S, et al. Adnet: Lane shape prediction via anchor decomposition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6404-6413.
- [91] LUO W, LI Y, URTASUN R, et al. Understanding the effective receptive field in deep convolutional neural networks[C]//Advances in Neural Information Processing Systems. 2016: 4898-4906.
- [92] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers [C]//Proceedings of the European Conference on Computer Vision. 2020: 213-229.
- [93] DAI X, XIE J, ZHANG G, et al. Dbnet: A curve-based dynamic association framework for lane detection, early access[J/OL]. IEEE Transactions on Intelligent Vehicles, 2024: 1-10. DOI: 10.1109/TIV.2024.3370213.
- [94] ZHU X, SU W, LU L, et al. Deformable detr: Deformable transformers for end-to-end object detection[C]//Proceedings of the International Conference on Learning Representations. 2021: 1-16.
- [95] LI Q, WANG Y, WANG Y, et al. Hdmapnet: An online hd map construction and evaluation

- framework[C]//Proceedings of the International Conference on Robotics and Automation. 2022: 4628-4634.
- [96] LIU Y, YUAN T, WANG Y, et al. Vectormapnet: End-to-end vectorized hd map learning [C]//International Conference on Machine Learning. 2023: 22352-22369.
- [97] LIAO B, CHEN S, WANG X, et al. Maptr: Structured modeling and learning for online vectorized hd map construction[C]//Proceedings of the International Conference on Learning Representations. 2023: 1-18.
- [98] LIU Z, ZHANG X, LIU G, et al. Leveraging enhanced queries of point sets for vectorized map construction[A]. 2024. arXiv: 2402.17430.
- [99] SUN X, SHANG J, LIANG S, et al. Compositional human pose regression[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 2602-2611.
- [100] CHU X, OUYANG W, LI H, et al. Structured feature learning for pose estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2016: 4715-4723.
- [101] TANG W, YU P, WU Y. Deeply learned compositional models for human pose estimation [C]//Proceedings of the European Conference on Computer Vision. 2018: 190-206.
- [102] TANG W, WU Y. Does learning specific features for related parts help human pose estimation?[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 1107-1116.
- [103] ZHOU K. Lane2seq: Towards unified lane detection via sequence generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16944-16953.
- [104] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [105] YU F, WANG D, SHELHAMER E, et al. Deep layer aggregation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 2403-2412.
- [106] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.
- [107] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 2980-2988.
- [108] ZHANG F, ZHU X, DAI H, et al. Distribution-aware coordinate representation for human pose estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pat-

- tern Recognition. 2020: 7093-7102.
- [109] KINGMA D P, BA J. Adam: a method for stochastic optimization[C]//Proceedings of the International Conference on Learning Representations. 2015: 1-15.
- [110] ZHOU K, ZHOU R. End-to-end lane detection with one-to-several transformer[A]. 2023. arXiv: 2305.00675.
- [111] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]//Proceedings of the European Conference on Computer Vision. 2014: 740-755.
- [112] LI F, ZENG A, LIU S, et al. Lite detr: An interleaved multi-scale encoder for efficient detr [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 18558-18567.
- [113] ZHAO Y, LV W, XU S, et al. Detsr beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16965-16974.
- [114] ZHAO C, SUN Y, WANG W, et al. Ms-detr: Efficient detr training with mixed supervision [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 17027-17036.
- [115] CHEN Q, SU X, ZHANG X, et al. Lw-detr: A transformer replacement to yolo for real-time detection[A]. 2024. arXiv: 2406.03459.
- [116] ZHANG D, WANG G, ZHU R, et al. Sparsead: Sparse query-centric paradigm for efficient end-to-end autonomous driving[A]. 2024. arXiv: 2404.06892.
- [117] MEINHARDT T, KIRILLOV A, LEAL-TAIXE L, et al. Trackformer: Multi-object tracking with transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 8844-8854.
- [118] ZHANG Y, SUN P, JIANG Y, et al. Bytetrack: Multi-object tracking by associating every detection box[C]//Proceedings of the European Conference on Computer Vision. 2022: 1-21.
- [119] CHENG B, MISRA I, SCHWING A G, et al. Masked-attention mask transformer for universal image segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1290-1299.
- [120] LI Z, WANG W, XIE E, et al. Panoptic segformer: Delving deeper into panoptic segmentation with transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1280-1289.
- [121] LI F, ZHANG H, XU H, et al. Mask dino: Towards a unified transformer-based framework for object detection and segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 3041-3050.
- [122] LIU H, CHEN Q, TAN Z, et al. Group pose: A simple baseline for end-to-end multi-person

- pose estimation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 15029-15038.
- [123] SHI D, WEI X, LI L, et al. End-to-end multi-person pose estimation with transformers [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11069-11078.
- [124] CAESAR H, BANKITI V, LANG A H, et al. nusenes: A multimodal dataset for autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11621-11631.
- [125] BEHLEY J, GARBADE M, MILIOTO A, et al. Semantickitti: A dataset for semantic scene of lidar sequences[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9297-9307.
- [126] ROH B, SHIN J, SHIN W, et al. Sparse detr: Efficient end-to-end object detection with learnable sparsity[C]//Proceedings of the International Conference on Learning Representations. 2022: 4361-4383.
- [127] ZHENG D, DONG W, HU H, et al. Less is more: Focus attention for efficient detr[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6674-6683.
- [128] TANG P, WANG Z, WANG G, et al. Sparseocc: Rethinking sparse latent representation for vision-based semantic occupancy prediction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15035-15044.
- [129] LIU H, TENG Y, LU T, et al. Sparsebev: High-performance sparse 3d object detection from multi-camera videos[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 18580-18590.
- [130] LIU S, LI F, ZHANG H, et al. DAB-DETR: Dynamic anchor boxes are better queries for DETR[C]//Proceedings of the International Conference on Learning Representations. 2022: 2541-2559.
- [131] ZHANG H, LI F, LIU S, et al. Dino: Detr with improved denoising anchor boxes for end-to-end object detection[C]//Proceedings of the International Conference on Learning Representations. 2022: 1-23.
- [132] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[C]//Proceedings of the International Conference on Learning Representations. 2019: 4061-4078.
- [133] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library[C]//Advances in Neural Information Processing Systems. 2019: 8024-8035.