

分类号: TP183

学校代码: 12715

UDC: 004.8

学 号: 2208540606022



西京学院
XI JING UNIVERSITY

专业学位硕士学位论文

Thesis for Master's Degree

基于深度学习的城市街景语义分割方法研究

学 院 :	<u>电子信息学院</u>
学 位 类 别 :	<u>电子信息</u>
领 域 :	<u>控制工程</u>
论 文 作 者 :	<u>陈文艺</u>
指 导 教 师 :	<u>苗宗成 张译中</u>
日 期 :	<u>2024 年 12 月</u>

西京学院研究生处

西京学院硕士学位论文

基于深度学习的城市街景语义分割方法研究

论 文 作 者：	陈文艺	学 生 类 别：	全日制
专业学位类别：	电子信息	领 域 名 称：	控制工程
校 内 导 师：	苗宗成	职 称：	教授
企 业 导 师：	张译中	职 称：	高级工程师

Thesis Submitted to
Xijing University
for
The Master Degree of
Electronic and Information Engineering

**Research on Deep Learning-based Semantic Segmentation
Method for Urban Street Scene**

by
Chen Wenyi

Supervisor: Prof. Miao Zongcheng
S.E. Zhang Yizhong

December 2024

摘 要

随着车载和监控摄像头设备的急速普及，从而产生了大量的城市街景图像。如何充分利用这些图像中的语义信息是推进自动驾驶和城市智能服务等应用的重要环节。然而，传统的语义分割方法主要依赖手工设计的特征，面对复杂的城市街景往往难以适应，导致分割精度受限，难以满足当前对高质量特征处理的需求。为此，本文提出了两种基于深度学习的城市街景语义分割方法，旨在提升城市街景图像的语义分割性能，以满足高效、精准且自动化的应用需求。本文的主要工作如下：

(1) 提出了基于高分辨率表示的城市街景语义分割网络 HRDLNet。具体为，将 DeepLabv3+ 网络应用于城市街景语义分割，针对现有语义分割网络在处理空间信息丢失等问题，设计引入一种新的主干网络 HRNetV2，通过高效融合高分辨率信息和多尺度特征，提升了语义分割性能。其次，针对网络对图像细节和全局上下文信息捕获能力不足等问题，优化 ASPP 模块，通过在空洞卷积金字塔池化中引入额外的空洞卷积，提高了对目标的识别和分割能力。随后，针对网络对空间和通道信息捕获不全等问题，引入了融合卷积块注意力和压缩激励网络的双注意力机制模块，通过动态调整特征权重，提高了图像分割的精度。最后，针对样本类别不均衡等问题，提出重构权重损失函数，增强了网络对困难样本的关注和分割精度。实验结果表明，与传统特征提取网络的原型网络相比，本研究提出的 HRDLNet 在收敛速度和精度方面均展现出一定的优势。

(2) 提出了基于多尺度信息整合的城市街景语义分割网络 HHMENet。具体为，通过对 HRDLNet 以及现有语义分割网络的研究，发现分割网络在应对更为复杂的多尺度全局信息时，仍然存在一定的局限性。表现为对不同尺度特征的捕捉和融合能力不足，导致在处理包含多尺度信息的复杂场景时，分割效果难以保持一致性和精确性。为此，本文设计了两种全新的注意力机制，专注于多尺度信息整合，以弥补上述不足。具体包括混合通道和空间信息注意力模块以及多尺度全局注意力模块。同时，本文根据双注意力机制的设计，对 ASPP 模块进行了相应的优化。实验结果显示，与当前主流的分割网络相比，本研究提出的 HHMENet 不仅在收敛速度上表现出更快的优势，同时在分割精度方面也取得了相应的提升。

关键词：自动驾驶；语义分割；高分辨率表示；ASPP；注意力机制

ABSTRACT

With the rapid popularization of in-vehicle and surveillance camera devices, this has resulted in a large number of urban street view images. How to fully utilize the semantic information in these images is an important part of advancing applications such as autonomous driving and urban intelligent services. However, traditional semantic segmentation methods mainly rely on hand-designed features, which are often difficult to adapt in the face of complex urban streetscapes, resulting in limited segmentation accuracy and difficulty in meeting the current demand for high-quality feature processing. For this reason, this thesis proposes two deep learning-based semantic segmentation methods for urban street scenes, aiming to improve the semantic segmentation performance of urban street scene images to meet the needs of efficient, accurate and automated applications. The main work of this thesis is as follows::

(1)HRDLNet, a semantic segmentation network for urban streetscape based on high-resolution representation, is proposed. specifically, DeepLabv3+ network is applied to semantic segmentation of urban streetscape, and a new backbone network HRNetV2 is designed and introduced to address the problems of the existing semantic segmentation network in dealing with the loss of spatial information, etc., which improves the performance of the semantic segmentation by efficiently fusing the high-resolution information and the multiscale features. The network is designed to improve semantic segmentation performance by efficiently fusing high-resolution information and multi-scale features. Secondly, to address the network's insufficient ability to capture image details and global context information, the ASPP module is optimized to improve the recognition and segmentation of targets by introducing additional null convolution in the null convolution pyramid pooling. Subsequently, for problems such as incomplete capture of spatial and channel information by the network, a dual-attention mechanism module incorporating convolutional block attention and compressive excitation network is introduced, which improves the accuracy of image segmentation by dynamically adjusting the feature weights. Finally, for problems such as sample category imbalance, the reconstructed weight loss function is proposed to enhance the network's attention to difficult samples and segmentation accuracy. The experimental results show that compared with the prototype network of traditional feature extraction network, the HRDLNet proposed in this study

demonstrates certain advantages in both convergence speed and accuracy.

(2)HHMENet, a semantic segmentation network for urban street scenes based on multi-scale information integration, is proposed. specifically, through the study of HRDLNet and existing semantic segmentation networks, it is found that the segmentation network still has certain limitations when dealing with more complex multi-scale global information. This is manifested in the insufficient ability to capture and fuse features of different scales, which leads to difficulties in maintaining consistency and accuracy of segmentation effects when dealing with complex scenes containing multi-scale information. For this reason, this paper designs two new attention mechanisms focusing on multi-scale information integration to compensate for the above deficiencies. Specifically, they include the mixed channel and spatial information attention module and the multi-scale global attention module. Meanwhile, this paper optimizes the ASPP module accordingly to the design of the dual attention mechanisms. The experimental results show that compared with the current mainstream segmentation network, the HHMENet proposed in this study not only exhibits faster convergence speed, but also achieves corresponding improvement in segmentation accuracy.

KEYWORDS: automatic driving; semantic segmentation; high-resolution representation; ASPP; attention mechanism

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 卷积神经网络研究现状.....	3
1.3 城市街景图像语义分割技术研究现状	4
1.3.1 传统的图像分割方法.....	5
1.3.2 传统方法与深度学习相结合的图像语义分割方法	6
1.3.3 基于深度学习的图像语义分割方法.....	7
1.4 本文研究内容.....	10
1.5 章节安排.....	12
第二章 城市街景图像语义分割方法的相关理论研究	13
2.1 卷积神经网络.....	13
2.2 经典的图像语义分割网络	18
2.2.1 SegNet 网络	18
2.2.2 U-Net 网络.....	19
2.2.3 DeepLab 系列网络	20
2.3 网络结构复杂度分析.....	23
2.3.1 时间复杂度.....	23
2.3.2 空间复杂度.....	24
2.4 迁移学习概述.....	24
2.5 注意力机制概述.....	26
2.6 本章小结.....	27
第三章 基于高分辨率表示的城市街景语义分割网络	29
3.1 基于高分辨率表示的城市街景语义分割网络	29
3.1.1 具有高分辨率表示的特征提取模块.....	30
3.1.2 多尺度特征提取增强模块.....	31
3.1.3 双注意力机制.....	32
3.1.4 损失函数优化.....	33
3.2 实验数据与实验平台.....	34
3.2.1 实验数据集.....	34
3.2.2 数据预处理.....	35
3.2.3 实验平台	37
3.3 图像语义分割评价指标.....	37
3.4 网络训练.....	39
3.5 实验一：不同损失函数对比结果分析	40

3.6 实验二：不同主干网络对比实验结果分析	42
3.7 实验三：模块消融实验结果分析	44
3.7.1 改进模块消融实验结果分析.....	44
3.7.2 不同 Atrous Rates 的 ASPP 消融实验结果分析	46
3.7.3 不同位置的 SE 与 CBAM 注意力机制消融实验结果分析	48
3.8 实验四：与先进分割方法性能对比实验结果分析	50
3.9 实验五：跨数据集性能验证对比实验结果分析	52
3.10 本章小结.....	55
第四章 基于多尺度信息整合的城市街景语义分割网络	57
4.1 基于多尺度信息整合的城市街景语义分割网络	57
4.1.1 混合通道和空间信息注意力模块.....	59
4.1.2 多尺度全局注意力模块.....	61
4.1.3 多尺度特征提取增强模块.....	64
4.2 实验数据与实验平台.....	65
4.2.1 实验数据集.....	65
4.2.2 数据预处理.....	65
4.2.3 实验平台	65
4.3 图像语义分割评价指标.....	66
4.4 实验一：不同主干网络对比实验结果分析	66
4.5 实验二：模块消融实验结果分析	67
4.5.1 改进模块消融实验结果分析.....	67
4.5.2 不同 Atrous Rates 的 ASPP 消融实验结果分析	69
4.6 实验三：与先进分割方法性能对比实验结果分析	71
4.7 实验四：跨数据集性能验证对比实验结果分析	73
4.8 本章小结.....	75
第五章 总结与展望	77
5.1 总结.....	77
5.2 展望.....	78
参考文献.....	81

插图索引

图 1.1	城市街景语义分割图	2
图 2.1	卷积神经网络结构图	13
图 2.2	步长为 1 的卷积计算过程	14
图 2.3	Sigmoid 激活函数图	15
图 2.4	Tanh 激活函数图	16
图 2.5	ReLU 激活函数图	17
图 2.6	步长为 2 的最大池化与平均池化	17
图 2.7	SegNet 网络结构图	19
图 2.8	U-Net 网络结构图	20
图 2.9	DeepLabv1 网络结构图	21
图 2.10	DeepLabv2 网络结构图	21
图 2.11	DeepLabv3 网络结构图	22
图 2.12	DeepLabv3+网络结构图	23
图 2.13	迁移学习过程	25
图 3.1	基于高分辨率表示的城市街景语义分割网络	30
图 3.2	HRNetV2 网络结构图	31
图 3.3	多尺度特征提取增强模块	32
图 3.4	Cityscapes 数据集示例	35
图 3.5	不同损失函数实验结果对比	41
图 3.6	不同损失函数的损失值比较	42
图 3.7	主干网络性能对比实验（括号中的内容，如‘ResNet50’代表主干网络）	44
图 3.8	改进模块消融实验对比	45

图 3.9	改进模块消融实验分割效果可视化	46
图 3.10	多尺度特征提取增强模块消融实验	47
图 3.11	记录不同位置的 SE 与 CBAM 注意力机制	48
图 3.12	与先进分割方法性能对比实验	51
图 3.13	跨数据集性能对比实验	54
图 4.1	基于多尺度信息整合的城市街景语义分割网络	58
图 4.2	混合通道和空间信息注意力网络结构	61
图 4.3	多尺度全局注意力网络结构	63
图 4.4	多尺度特征提取增强模块	64
图 4.5	主干网络性能对比实验（括号中的内容，如‘ResNet50’代表主干网络）	67
图 4.6	改进模块消融实验对比	69
图 4.7	多尺度特征提取增强模块消融实验	70
图 4.8	与先进分割方法性能对比实验	72
图 4.9	跨数据集性能对比实验	74

表格索引

表 3.1	实验环境	37
表 3.2	训练超参数设置	39
表 3.3	类别平衡后的各类别权重	40
表 3.4	不同损失函数实验结果对比	40
表 3.5	不同主干网络对比实验结果	43
表 3.6	改进模块消融实验结果对比	45
表 3.7	多尺度特征提取增强模块消融实验	47
表 3.8	不同位置的 SE 与 CBAM 注意力机制消融实验（在第一列中，如“1+2”，“+” 左边代表 CBAM 注意力机制，“+”右边代表 SE 注意力机制）	49
表 3.9	与先进分割网络的实验结果比较（第一列括号中的数字代表该网络所提出的 年份）	50
表 3.10	跨数据集性能验证实验结果对比	53
表 4.1	实验环境	65
表 4.2	不同主干网络对比实验结果	66
表 4.3	改进模块消融实验结果对比	68
表 4.4	多尺度特征提取增强模块消融实验	70
表 4.5	与先进分割网络的实验结果比较（第一列括号中的数字代表该网络所提出的 年份）	71
表 4.6	跨数据集性能验证实验结果对比	73

第一章 绪论


1.1 研究背景与意义

截至 2023 年底，中国的汽车拥有量达到了 4.35 亿辆。该趋势表明，虽然汽车在人们日常出行中的使用率日益增加，带来了便利，但也给自动驾驶技术的进步带来了前所未有的挑战。在自动驾驶技术的发展中，城市街景图像的语义分割显得尤为重要。这项技术能够精准帮助自动驾驶车辆快速响应识别并理解其周边环境，从而极大的提高驾驶的安全性和效率。随着全球汽车数量的急剧增加，尤其是在城市地区，街道环境变得越来越复杂多变。这种复杂性对图像语义分割技术提出了更高的要求，不仅需要提升其识别的准确度，还需要增强其在不同驾驶环境下的鲁棒性和适应性。因此，面对城市环境的日益复杂化，图像语义分割技术的持续创新和进步变得尤为关键。这种技术的进步能够确保自动驾驶系统在处理多样化和复杂场景时的有效性，从而保障自动驾驶汽车在城市街道上的安全与高效行驶。进一步深化对城市街景图像语义分割技术的研究，对于促进自动驾驶技术的广泛应用，保证道路交通的安全性，以及提高自动驾驶车辆的整体性能至关重要。因此，加强该领域的技术研发和创新，不仅推动了自动驾驶技术的发展，也是实现更安全、更高效交通系统的重要步骤。在该背景下，探索更先进的图像处理技术和网络，以应对复杂城市街景的需求，成为当前自动驾驶技术发展中的一个重要研究方向。

图像语义分割（Image Semantic Segmentation, ISS）^[1]作为计算机视觉领域的核心技术，旨在对图像中的每一个像素点进行精准分类，使得不同物体或区域能够被细致区分^[2]。ISS 通过深度学习和图像处理算法，将具有相同语义属性的像素点归并到同一类别中，从而生成精细化的图像分割结果。在城市街景中，ISS 技术是自动驾驶系统中不可缺少的重要组成部分。自动驾驶系统需要实时感知周围环境，以便做出正确的决策和规划行驶路径，而 ISS 技术正是实现该目标的关键手段之一。通过 ISS，自动驾驶系统能够准确识别出行人、车辆、道路标线以及建筑物等关键元素，从而为车辆提供精确的环境感知信息。例如，图 1.1 展示了从 RGB 彩色图片 A 到其分割图 B 的转换，后者是通过语义像素聚类实现的。在医疗行业，这种技术帮助医生识别影像中的器官和异常，从而促进定制化治疗方案，推动智能医疗发展。因此，持续改进图像分割技术对自动驾驶、智能医疗等领域的发展至关重要，并将对其他应用行业产生广泛影响。



(a) 实景图



(b) 分割效果图

图 1.1 城市街景语义分割图

本章详细探讨了图像语义分割技术在自动驾驶技术领域处理复杂城市街景中的关键作用。特别聚焦于如何有效分析和处理包括广泛对象类别及不同尺寸的城市街景图像，这不仅包括道路、车辆、建筑物、绿化带和行人等常见元素，还包括路灯、交通标志、小型非机动车辆以及视野中较远的车辆和行人等更细小的对象。这些元素的广泛多样性及其尺寸的变化，对图像语义分割技术的准确分割提出了挑战。本文的核心目标是深化对图像语义分割技术的研究和优化，增强其处理复杂场景的能力，以便为自动驾驶系统提供更高效、更安全的支持。通过这种技术突破，希望能够推动自动驾驶领域的发展，使自动驾驶车辆能够在复杂的城市环境中安全有效的工作。

传统的图像分割技术通常依赖于特征提取阶段，但这种方法往往无法达到理想的分割效果。近年来，随着深度学习的快速进步，研究人员借助全卷积网络（Fully Convolutional Networks, FCN），开发了多种端到端的深度学习语义分割网络。这些网络凭借其出色的学习和泛化能力，提升了分割的准确性，并且能够更深入地挖掘数据之间的潜在联系。尽管如此，深度学习方法在将图像从下采样转换回上采样的过程中，仍然会丢失重要的空间信息，这对于实现精确的像素级分割来说是一大挑战。此外，这些网络对计算资源的需求高，且具有较高的模型复杂度。如何在控制模型复杂度的同时提高分割精度，成为当前研究的关键。因此，使用深度学习技术对复杂城市街景进行语义分割已成为学术研究的一个热点领域。

1.2 卷积神经网络研究现状

卷积神经网络（Convolutional Neural Network, CNN）属于一种特殊类别的前馈神经网络，它们在处理图像、视频等具有网格结构的数据方面表现出了卓越的性能，尤其是在计算机视觉和图像处理领域。这种网络通过模拟生物视觉系统的工作原理，有效地识别和处理视觉信息。早在 1962 年，Hubel 和 Wiesel 的猫的视觉皮层研究中首次引入了感受野的概念，这一开创性发现奠定了 CNN 发展的理论基础，并为后续的技术革新提供了启发^[3]。到了 1998 年，LeCun 等人设计并实现了 LeNet-5^[4]，这是一个具有历史意义的卷积神经网络，其在图像分类领域，特别是在手写数字识别任务上展示了较为先进的性能。LeNet-5 的成功不仅证明了 CNN 架构在视觉任务中的有效性，还为未来深度学习应用的探索开辟了道路。然而，尽管 LeNet-5 取得了重大突破，其在训练过程中的时间消耗较大，并且由于网络结构相对较简单，在面对更复杂的数据集时，其性能有一定的局限性。此外，当时计算机硬件的性能限制，尤其是处理能力和存储能力的局限，成为了进一步推动卷积神经网络研究和应用发展的一大挑战。尽管如此，这些早期的努力和挑战为 CNN 的进步及其在各种复杂任务中的应用奠定了坚实的基础。

在 2012 年，深度学习领域经历了一次深刻的变革。AlexNet 的胜出不仅在 ImageNet 的视觉识别竞赛中领先，还通过利用卷积神经网络的方法，大幅度超越了之前依赖手工特征提取的技术，标志着深度学习的崛起及其在图像处理领域的巨大潜力^[5]。该成就重新激发了科研界对深度学习的关注。同时，得益于计算技术的飞速发展和数据量的爆炸式增长，深度学习技术迅速进化，很快成为图像识别和分类任务的主流选择。随着时间的推移，2013 年，由 LeCun 领衔的研究团队提出了 Dropconnect 算法，这种网络架构通过创新方法将分类任务的错误率进一步降低至

11%，展现了深度学习技术持续进步的趋势。而到了 2014 年，深度学习的应用和研究达到了新的高度。牛津大学的研究人员推出的 VGGNet，通过其深层的网络结构，为图像分类任务设定了新的准确度标准^[6]。同年，谷歌公司推出的 GoogleNet 引入了 Inception 架构，该架构通过结合不同尺寸的卷积核来提取图像特征，进一步展现了利用深度学习技术处理和理解图像内容的巨大潜力，对后续的研究和应用产生了深远影响。这一系列进步不仅推动了深度学习技术的快速发展，还为图像处理和识别任务提供了更加高效和精确的方法^[7]。

ResNet 网络架构由 He 及其团队提出，不仅推进了深度学习领域的界限，还引入了深度残差学习的概念，使网络能够通过增加层数来提高训练效率，而不会导致性能下降^[8]。实践证明，这种设计使得更深的网络结构能够实现更加出色的性能，使 ResNet 成为特征提取任务中广泛采用的先进技术之一。CNN^[9]的影响力远不止于图像识别领域的突破，其还在图像分割、目标检测等领域展现了其强大的能力。这种技术的核心在于其卓越的特征提取能力，能够自动学习并识别图像中的复杂模式和高级特征，而无需人工干预。该特性使得 CNN 成为众多应用领域的首选技术，不仅在医疗影像分析中发挥重要作用，帮助医生更准确地诊断疾病，还在自动驾驶技术中提供了可靠的视觉识别支持，并且在自然语言处理和计算机视觉任务中，如面部识别、情感分析等，展示了其强大的适用性和效果。这些应用的成功实践充分展示了 CNN 在处理和复杂数据方面的巨大潜力和价值。

1.3 城市街景图像语义分割技术研究现状

城市街景图像的分析已经逐渐成为图像处理领域中的研究热点，其中图像语义分割技术在解析和理解街道视角图像中扮演着关键角色。这项技术主要可以划分为三种类别，各有其特点和应用领域。第一类是基于图像固有特征的传统分割技术，这种方法主要依赖于图像的颜色、纹理、边缘等低层次特征，通过阈值分割、区域生长、聚类分析等经典算法实现区域划分。第二类技术是一种混合型方法，巧妙地将传统的图像处理方法与现代的深度学习技术结合起来，通过这种融合，既利用了传统技术的直观优势，又借助深度学习的强大学习能力来提高分割的准确性和效率。第三类是完全基于深度学习的图像语义分割技术，这类方法利用复杂的深度神经网络，对图像进行深层次的学习和分析，从而实现对图像中每个像素的精确标注和分割。这三种技术各具特色，传统方法强调计算效率和实现简便，适用于资源受限的场景；混合方法平衡了传统方法和深度学习的优势，适用于多样化的应用需求；而深度学习方法则以其卓越的性能和适应性，为复杂环境下的高精度语义分割提供了

强有力的解决方案。这些技术的进步为城市规划、交通监控、自动驾驶等领域的发展提供了重要支持，促进了智慧城市的建设和发展。这些技术的进步为城市规划、交通监控、自动驾驶等领域的发展提供了重要支持，促进了智慧城市的建设和发展。

1.3.1 传统的图像分割方法

传统图像分割方法中常见的技术包括基于阈值、边缘检测、聚类以及图论^[10]等。这些方法主要利用图像中的基本特征，如颜色、纹理等较为简单的低级特征来实现图像分割的目标。

基于阈值的图像分割方法通过设定阈值来将图像分为不同的区域。2004 年，Kwak 及其团队引入了一种革新的自适应阈值图像分割方法，该技术根据图像的特定特征自动调整阈值，从而更精确地保留目标对象的边界。该方法的实施步骤开始于应用矢量量化技术对原图进行简化处理，该步骤旨在降低处理复杂度的同时保留重要信息。接下来，通过评估图像的峰值信噪比来确定最佳的量化颜色数量，确保图像质量不会因简化而大幅损失。之后，从简化的图像中识别出初步的分割区域，进而在 CIE Lab 和 RGB 两种颜色空间内将这些初步区域合并成具有实际意义的语义单元。最终阶段，通过在 RGB 颜色空间内进一步验证，确保分割结果能够准确反映图像中独立的语义实体。通过系列实验验证，这种方法展示了其在图像分割质量上的明显优势^[11]。

基于边缘的图像分割方法旨在识别图像中的边界像素点，并通过连接这些边界点将图像分割成不同的区域。在 2021 年，Xiang 等研究者提出了一个创新的应用，该应用在鸟瞰图像分析中，通过结合多种边缘信息来支持语义同时定位与地图构建（Simultaneous Localization and Mapping, SLAM）操作。研究人员在停车场环境下进行的实验表明，与依靠传统点特征的方法相比，新策略在精确度和稳定性方面都有所提升，结果突出了边缘信息在提高语义 SLAM 性能中的重要作用和潜力。通过这种方式，该团队不仅推动了 SLAM 技术的进步，还为未来在复杂环境下的导航和地图构建提供了新的视角和方法^[12]。

基于聚类的图像分割方法通过分析图像特征组织像素点，基于特征矩阵中的相似性将像素聚集，并通过不断的迭代调整每个区域的特征直到收敛，从而实现图像的分割。在 2019 年，Subudhi 及其团队采纳了简单线性迭代聚类算法作为他们研究的出发点，成功生成了初步的图像分割图。为进一步提升初步分割图的质量，他们接着应用了基于密度的无噪声应用空间聚类算法。该方法通过对相近的超像素进行有效聚集，对初步分割图进行了精细化优化，从而得到了更为准确的最终分割图。进一步地，通过在最终分割图与按像素分类图之间执行多数投票机制，他们生成了

一个精度更高的最终分类图。这项研究不仅证明了聚类算法在图像分割任务中的强大效能，还提升了图像分割和分类的整体精确度，展示了聚类算法在图像处理领域内广泛的应用潜力^[13]。

图论在图像分割方法中的应用将图像视为一个加权无向图，其中每个节点代表一个像素点，节点之间的边代表像素点的相互关系，且这些边的权重映射了像素间的相似性。这种相似性通常根据像素点之间的空间距离及其灰度值的差异来衡量。2020年，Brito 及其团队依托相关理念，开发出了一种新颖的网络，该网络结合了 X 射线计算机断层扫描技术、计算语义概念以及先进的数字图像处理方法，专为油籽评估而设计。该网络不仅深入分析了目标对象像素与图像背景之间的复杂关系，还通过引入几何描述符进一步丰富和提高了从图像中提取的信息质量。经过一系列实验验证，该研究证实了该网络在挑选有助于提升生产效率和油籽品质的作物品种方面的有效性和应用潜力^[14]。

这四种传统的图像语义分割方法—基于阈值、边缘检测、聚类以及基于图论的技术，虽然在早期的图像处理领域中被广泛采用，却普遍面临着几个挑战。首先，这些方法在很大程度上依赖于手工提取的特征，这不仅增加了处理过程的复杂度，还限制了分割效果的优化空间。其次，由于这些算法计算密集，处理时间往往较长，这在需要快速处理大量数据的应用场景中尤为不利。此外，尽管这些方法能够将图像划分为不同的区域，但它们缺乏对特定目标的精确识别能力，在处理复杂场景时尤为明显。面对这些限制，研究者们积极寻求解决方案，努力将这些传统技术与计算机视觉领域的最新进展相融合。通过这种跨领域的融合，他们开发出了更加高效和精确的语义分割网络，特别是针对城市街景图像分析的需求。这些新一代的网络利用深度学习、特别是 CNN 的强大能力，提升了分割精度和目标识别率。这不仅为理解复杂的城市环境提供了强大的工具，也为自动驾驶技术的发展奠定了坚实的理论和技術基础，使车辆能够更准确地理解其周围的环境，从而做出更安全、更有效的决策。这些进步不仅展示了计算机视觉技术的巨大潜力，也为未来的技术革新开辟了新的路径。

1.3.2 传统方法与深度学习相结合的图像语义分割方法

这种进阶方法结合了三种关键策略：基于候选区域、利用概率图模型的分析以及应用分割掩膜的技术^[15]。Chen 及其研究团队引入了一项革新性的语义分割技术，该技术的独特之处在于其对基于区域的对象检测器的有效运用，从而实现了高精度的图像分割。该技术的核心在于，首先通过对象检测器对提出的各个区域进行准确的识别和分类，接着采用显著性检测技术对这些已分类的区域进行更为精细的分割

处理。该方法在 Pascal VOC 2012 验证数据集上进行了实验，证明其性能与传统的完全监督分割方法相媲美，显示出其在图像语义分割领域的巨大潜力和卓越性能。这种方法的成功不仅展示了多种策略结合的强大能力，也为未来图像处理技术的发展提供了新的方向^[16]。

分割掩膜的方法首先通过图像识别技术确定潜在的目标候选，然后将图像细分为包含这些候选目标的多个区块。随后，这种方法应用卷积神经网络对这些区块内的像素进行评估，以识别它们是否属于特定的目标类别。Van 团队推出了一项领先的创新，即基于掩膜区域的卷积神经网络三维语义分割技术。该技术特别强调了对三维图像颜色层面的理解，采用颜色编码区分不同的对象类别，从而在视觉上分割出图像中的各种对象。这种方法不仅提高了从复杂图像中识别和分割对象的效率，而且实验验证表明，结合三维数据和语义分割可以极大提升场景感知的可靠性。这种技术的成功实施为深度学习在三维空间的应用开辟了新途径，同时为未来的图像处理和场景理解技术提供了宝贵的参考^[17]。

概率图模型方法依赖于构建图形结构来分析图像，其中节点表示图像中的单个像素点，边则揭示像素之间的相互关系。Zheng 及其团队在这个领域取得突破，他们将传统的 RGB 三通道输入扩充为四通道，新增了一个先验概率图通道。该改进构成了一个基于 CNN 的先进前景分割网络，通过集成先验概率图，网络的前景与背景识别及分割准确度得到了提升。该方法不仅利用了颜色信息，还结合了像素间的相关性预测，为网络提供了更加丰富的输入信息。实验证明，该独到的方法大幅增强了网络的分割效果，展现了先验概率图在提升前景识别和分割性能中的巨大潜力。该研究不仅推动了图像分割技术的发展，也为未来的图像处理网络提供了新的思路和方法^[18]。

1.3.3 基于深度学习的图像语义分割方法

这种方法目前是图像处理领域内受研究者广泛欢迎的主流技术，其主要包括三个分支：基于 CNN、基于循环神经网络（Recurrent Neural Network, RNN）以及基于生成对抗网络（Generative Adversarial Network, GAN）的技术。

（1）基于循环神经网络

Isin 及其团队通过改进 ReNet 架构开发了 ReSeg 网络，该网络巧妙结合了 CNN 和 RNN 的优势。CNN 擅长提取图像的局部特征，而 RNN 则能够捕捉图像中长期依赖关系，两者的结合使得 ReSeg 网络既能精细捕捉图像细节，又能有效理解整个场景中的复杂关系，提升了图像分析的深度和准确性。ReSeg 网络展示了如何通过深度学习技术的融合创新，推动复杂图像处理任务的进步。尽管 ReSeg 网络在精度上

有所提升,但其复杂架构带来了高计算成本,尤其在处理高分辨率图像时,计算开销和训练时间大幅增加。此外,RNN的引入可能导致梯度消失问题,限制了其在长序列数据处理中的表现^[19]。

(2) 基于 GAN 的方法

Su 团队提出了一种无监督对抗性域适应网络,利用条件生成对抗网络来减少源域与目标域的差异,从而提升跨域语义分割的效率和准确性。然而,该方法依赖于对抗性训练,容易导致网络不稳定,尤其在处理复杂场景时,效果仍有待进一步提升^[20]。Xia 团队在 DeepLabv3 的基础上提出了改进网络,将 Pix2pix 整合为生成对抗框架,进一步提升了语义分割的精确度。该网络表现出显著的性能改进。然而,缺点在于对抗性训练增加了模型的不稳定性,且训练过程对计算资源需求较高,限制了其实际应用的效率和可扩展性^[21]。2021 年,Yang 团队将 U-net 与 GAN 相结合,创新性地提升了多维数据分割的性能。然而,该方法的缺点在于 GAN 的复杂性增加了模型的不稳定性,并且对计算资源的需求较高,限制了其在实际应用中的广泛部署^[22]。

(3) 基于卷积神经网络

FCN^[23]的概念首次由 Long 及其团队引入,FCN 的核心创新在于其全卷积架构允许端到端的像素级预测,并通过跳跃连接有效融合不同层次的特征。然而,其主要缺点包括空间分辨率降低,导致边界细节分割不理想,以及多尺度信息处理能力不足,在小物体和复杂场景下的表现欠佳,难以捕捉全局上下文信息。Li 的工作不仅在技术上优化了图像分割的性能,还为处理大规模图像数据提供了一种高效的方法,进一步推动了图像语义分割技术的发展^[24]。Yu 及其同事在传统卷积神经网络的基础上,引入了创新性的空洞卷积技术,通过在卷积核中插入空隙来扩大感受野,解决了特征提取中的分辨率下降问题^[25],该方法的缺点在于,当特征稀疏的时候容易造成上下文信息丢失,影响网络性能。梁格颖及其团队将空洞卷积成功应用于图像语义分割,解决了池化层引起的细节丢失问题。然而,该方法在处理稀疏特征时,空洞卷积容易导致上下文信息不连续,影响分割精度^[26]。

Ronneberger 及其团队推出了 U-Net 网络^[27],U-Net 是一种用于图像分割的网络,采用对称的编码器-解码器架构,通过跳跃连接有效保留细节信息。但是,也存在计算开销大,处理高分辨率图像时资源需求高,且在深层特征提取时可能丢失细节,影响复杂场景下的分割效果等问题。Li 团队对 U-Net 进行了改进,加入了深层卷积、残差连接和树形网络架构,提升了网络的效率和精度。然而,这些改进增加了网络的复杂性和计算开销,尤其在处理大规模数据时,对计算资源的需求更高,限制了其在资源有限环境中的应用^[28]。与此同时,Badrinarayanan 等人提出的 SegNet 网络

[29]通过去除 VGG-16 网络尾部的全连接层并将其作为编码器部分，为图像分割领域引入了新的视角。Dong 团队基于 SegNet 架构开发了一种专注于港口区域的像素级分割框架，专门用于高分辨率合成孔径雷达港口图像的精细分类。但是，该方法的计算复杂度较高，尤其在处理高分辨率图像时，训练和推理时间较长，限制了其在实际应用中的效率和广泛部署[30]。此外，Paszke 等人提出的 E-Net[31]通过设计不对称的编码器-解码器结构，有效减少了训练时间并加快了图像分割过程，大幅提升了处理速度。该网络在其轻量化设计在某些复杂场景下可能导致分割精度下降，特别是对细节处理的效果不如其他更复杂的网络。Chen 及其团队通过引入注意力机制开发了一个专门处理多尺度图像的网络。该网络通过卷积神经网络提取不同尺度的图像特征，并使用注意力机制智能分配权重，从而实现多尺度特征的高效融合。然而，缺点在于该方法计算复杂度高，尤其在处理高分辨率图像时，容易导致网络训练时间增加和资源消耗过大[32]。Zhao 团队的 PSPNet 通过金字塔池化层有效提取多尺度上下文信息。然而，该方法存在计算复杂度较高，尤其在处理高分辨率图像时，计算资源需求大，影响实际应用效率等问题[33]。Li 团队引入了基于通道注意力的局部多尺度模块，利用扩张卷积生成特征并对不同尺寸进行加权，精准定位交通标志的各种尺寸。然而，缺点在于该方法计算复杂度较高，尤其在处理大规模数据时，可能导致网络训练效率下降[34]。Xiong 团队推出了结合像素级注意力模块和双通道注意力融合模块的新网络，旨在自适应筛选重要低级特征并高效融合上下文信息。该方法的缺点在于该结构较为复杂，增加了训练和推理时的计算成本，影响了实际应用的效率[35]。Zhang 及其团队开发了双向特征注意力融合网络，结合光学遥感分支和高程特征分支。光学分支通过空间关系模块学习全局关系，而高程分支提升分类准确性。然而，缺点在于该网络结构较复杂，训练和推理阶段计算成本较高，限制了在大规模应用中的效率和可扩展性[36]。

在上述基础上，DeepLab 系列网络应运而生，通过引入空洞卷积、空间金字塔池化等技术，有效提升了多尺度特征融合的能力，并在处理复杂场景分割方面表现出色。其中，DeepLabv1[37]利用了空洞卷积来扩大感受野，避免通过池化层引起的分辨率下降问题，从而保留更多的空间信息。其还引入了全连接条件随机场（Conditional Random Field, CRF）进行后处理，以增强分割的边界精度。然而，DeepLabv1 的缺点在于下采样后的分辨率仍然较低，导致空间信息丢失，特别是在处理物体边界时表现不佳。DeepLabv2[38]在 DeepLabv1 的基础上引入了空洞空间金字塔池化（Atrous Spatial Pyramid Pooling, ASPP）[39][40][41]模块，用于更好地捕获多尺度信息。这一改进使得网络能够处理更加复杂的场景，并改善了全局和局部信息的整合。但 DeepLabv2 的缺点依然是边界恢复能力较弱，没有解码器结构来专门处

理边界信息，导致细节处理上仍存在不足。DeepLabv3 进一步优化了空洞卷积^{[42][43][44][45]}和 ASPP 模块，去除了 CRF，并直接依赖空洞卷积来捕捉更多的上下文信息。与此同时，DeepLabv3 的缺点在于尽管多尺度信息捕捉得到了改进，但仍然缺乏边界细节恢复的机制，导致在复杂场景下边界模糊。同时，计算成本较高，影响了实际应用中的效率。DeepLabv3+^[46]网络在语义分割领域通过引入编码器-解码器结构和空洞卷积来增强多尺度特征提取和边界恢复能力。该网络的优势在于通过捕获多尺度上下文信息，提升了图像分割的准确性，特别是在处理复杂边界时表现优异。然而，该网络仍然存在一些局限性，尤其是在空间信息丢失和误差累计方面，在处理高分辨率信息时，深层网络中的多次卷积和上采样过程容易导致误差逐渐累积，影响细节的分割精度。此外，虽然空洞卷积扩大了感受野，但在处理细微特征时，仍可能导致信息的缺失。这些问题限制了该网络在某些场景下的表现，并增加了计算开销。

综上所述，传统图像语义分割方法过于依赖特征提取阶段的精细设计，这限制了分割结果的优化空间。相比之下，基于深度学习的语义分割方法在学习复杂数据结构、挖掘数据内在联系和通用特性方面展现了一定的优势，提供了提升分割精度的新途径。然而，深度学习网络由于其复杂的架构，面临着计算复杂度高的问题。同时，空间信息丢失和误差累计问题随着多次卷积和上采样的进行而加剧，影响了对细节的分割精度。尽管对抗性训练提高了分割效果，但同时引入了网络的不稳定性，在复杂场景中的表现仍不够理想。此外，虽然一些网络通过创新设计提升了效率，但在处理复杂场景或大规模数据时，仍存在扩展性和应用效率的限制。为应对这些挑战，研究人员提出了多种创新策略并进行了实践，包括网络压缩技术、设计高分辨率网络结构、以及引入轻量级注意力机制等。这些方法不仅提升了网络的性能与实用性，也为算法的广泛应用和推广提供了一定的参考。

1.4 本文研究内容

本文旨在深入研究 DeepLab 系列中的 DeepLabv3+网络，并提出有效的优化方法，以实现复杂城市街景图像的准确、实时分割。首先，本文概述了卷积神经网络和城市街景图像语义分割技术的研究现状，分析了现有语义分割方法在空间信息丢失、误差累计和网络模型复杂度过高等方面的不足。针对这些问题，本文对 DeepLabv3+网络结构部分模块进行了优化和设计，从而有效提升了网络在城市街景图像语义分割中的精度。本文的研究内容如下：

（1）为解决上述问题，本文提出了基于高分辨率表示的城市街景语义分割网络

HRDLNet。具体内容为，将 DeepLabv3+ 的基础特征提取网络替换为 HRNetV2。HRNetV2 通过其独特的结构，高效整合了高分辨率图像信息与多尺度特征，极大地提升了对各种尺度目标的处理能力以及对高分辨率信息的处理效率。进一步，在 ASPP 模块中，引入了额外的 atrous 卷积层，大幅扩展了网络的感知范围，加强了对图像细节关系和全局背景信息的捕捉。此外，本文设计了一种轻量级双注意力机制模块，结合了卷积块注意力模块（Convolutional Block Attention Module, CBAM）和压缩激励网络（Squeeze-and-Excitation, SE）模块的优势，专注于精准捕捉图像的关键像素和通道信息。这些注意力机制通过动态调整网络焦点，极大提高了网络捕捉图像微观特征和丰富语义信息的能力。这项技术的应用增强了图像分割的准确性和细节表现，确保了网络在处理庞大数据集时的高效性和在细节上的高分辨率表示能力。最后，针对选定数据集中存在的类别不平衡问题，本文调整了交叉熵损失函数，引入重构权重概念，以优化网络对难以分割样本的处理能力。通过这些综合性的优化措施，本文提升了图像语义分割的整体性能，特别是在精确度和细节捕捉方面的表现。本文通过将 HRDLNet 应用于 Cityscapes 数据集和 PASCAL VOC 2012 Augmented 数据集，进行了全面的训练和测试，以验证提出策略的有效性。在 Cityscapes 数据集上，网络针对复杂城市街景图像进行了训练，旨在检验其对高分辨率信息细节及多变场景的处理能力。随后，在 PASCAL VOC 2012 Augmented 数据集上进行的跨数据集性能测试进一步探索了网络在不同类型图像上的分割能力。通过与当前先进的图像分割方法进行比较，实验结果展示了 HRDLNet 的优越性能。

（2）基于 HRDLNet 及现有语义分割网络，本文提出了基于多尺度信息整合的城市街景语义分割网络 HHMENet。具体内容为，在该网络中设计了两种全新的注意力机制，专注于多尺度信息整合，以弥补现有分割网络在处理多尺度信息时的不足。即混合通道和空间信息注意力模块以及多尺度全局注意力模块。同时，根据双注意力机制的设计，对多尺度特征提取增强模块进行了相应的优化。这些优化设计使该网络在特征提取阶段始终保持高分辨率表示，并通过更有效地整合高分辨率信息与全局多层次特征，提升了网络对不同尺度目标的处理能力以及对复杂样本的适应性。本文通过将 HHMENet 应用于 Cityscapes 数据集和 PASCAL VOC 2012 Augmented 数据集，进行了对应的训练和测试，以验证提出策略的有效性。通过与当前先进的图像分割方法进行比较，实验结果展示了本文所设计网络的优越性能。特别是在城市街景图像分割任务中，该网络不仅在多尺度全局信息的处理和整合上表现卓越，还在应对复杂场景的能力上展现了一定优势。

1.5 章节安排

本文主要分为 5 个章节，每章安排如下：

第一章 绪论。本章首先探讨了城市街景语义分割技术的研究背景及其重要性，强调了在自动驾驶、城市规划等领域对精确识别和理解街景元素的迫切需求。接着，重点分析了 CNN 技术的发展现状及其在城市街景图像语义分割任务中的应用进展，梳理了领域内的关键技术挑战及解决方案。最后，概述了本文的核心内容与章节安排，旨在提出应对现有挑战的创新解决策略，包括网络结构优化、效率提升及准确度改进等方面。

第二章 城市街景图像语义分割方法的相关理论研究。首先，解析了 CNN 的网络框架构成，包括其关键层次结构与工作原理。随后，详细介绍了该领域内几种标志性的语义分割网络，如 SegNet、U-Net 和 DeepLab 系列，着重分析了它们在图像分割任务中的应用及各自的创新点。此外，本章还涵盖了网络模型复杂度分析、迁移学习的应用及注意力机制的重要性，为理解网络性能优化提供相应的理论支持。

第三章 基于高分辨率表示的城市街景语义分割网络 HRDLNet。本章详述了对 DeepLabv3+ 网络进行的一系列优化策略，旨在提高其性能和效率。这包括使用高分辨率网络 HRNetV2 作为特征提取的主干网络，增强网络对多尺度特征的提取能力。此外，本文引入了轻量级双注意力机制，进一步精细化特征捕捉，并通过重新设计交叉熵损失函数，引入重构权重调节因子，优化网络对不同类别样本的处理策略。这些优化旨在提升网络的精确度和处理复杂城市街景图像的能力。在实现网络架构和评估实验结果方面，本章首先详细描述了使用的关键数据集 Cityscapes，包括数据预处理步骤和实验环境的配置细节。接着，介绍了评估网络性能的关键指标以及网络的训练过程。通过在上述数据集上进行的实验和比较分析，验证了本章所设计网络的有效性。

第四章 基于多尺度信息整合的城市街景语义分割网络 HHMNet。本章基于 HRDLNet 及当前主流分割网络，进行了一系列优化设计，旨在提高性能和效率。其中包括重新设计双注意力机制模块，具体为混合通道与空间信息注意力模块及多尺度全局注意力模块。此外，根据注意力机制的设计，对多尺度特征增强模块进行了相应优化。在网络实现和性能评估方面，本章通过在相关数据集上的训练，验证了所设计网络的有效性。实验结果表明，本章所设计的网络在处理复杂城市街景图像语义分割任务时，相较当前主流分割网络，具有更高的分割精度和模型效率。

第五章 总结了本文提出的两种网络在验证数据集上的性能表现，并提出了未来的研究方向，包括数据集设计、跨技术融合及复杂场景下的进一步优化。

第二章 城市街景图像语义分割方法的相关理论研究

真实城市街景的复杂多样性使得分割的准确率和精度成为一个巨大挑战，尤其在自动驾驶领域。近年来，卷积神经网络在城市街景图像分割中表现出了优异的性能。本章深入探讨了卷积神经网络的结构组成，并分析了经典语义分割网络的基本原理。通过研究网络复杂度、迁移学习和注意力机制，本章旨在为城市街景图像的精准分割提供坚实的理论基础。

2.1 卷积神经网络

CNN 是深度学习技术中的一项重要进步，特别是在处理视觉任务时表现出卓越性能。CNN 的设计理念有效应对了随着网络层次增加而带来的内存消耗和计算资源挑战。核心组成部分包括输入层、多个卷积层、激活函数层、池化层，以及最终的全连接层^[47]。如图 2.1 所示，CNN 的独特之处在于三大关键架构特点：局部感受野、权重共享和池化操作。局部感受野聚焦于输入数据的局部区域，提取特征，使网络能够捕捉图像的细微结构。权重共享机制减少了网络参数的数量，这不仅提升了计算效率，还有助于降低网络的复杂度和过拟合的风险。池化层的引入进一步减少了特征维度，同时保留了重要的特征信息，这有助于提升网络对图像变形和旋转的鲁棒性。这些结构特征的综合运用不仅限制了网络的参数规模，减轻了计算负担，还确保了 CNN 在处理大规模数据集时的高效性与稳定性，使其成为处理复杂视觉任务的强大工具。




图 2.1 卷积神经网络结构图

1.输入层：该网络的输入层设计能够适配不同类型的图像数据，包括灰度图和彩色图像。以灰度图为例，假定其尺寸为 $[1,32,32]$ ，其中1代表单通道灰度图，而 32×32 则是图像的高度和宽度。输入层的设计灵活性使其能够兼容单通道灰度图和三通道彩色图，确保图像数据被正确读取并传递给网络的后续层进行更深入的特征提取和分析。这种设计不仅提高了网络的应用范围，还增强了处理不同类型视觉信息的灵活性。

2.卷积层：卷积层在卷积神经网络中的作用是通过卷积操作提取输入图像或前一层特征图中的空间特征，输出为新的特征图。如图 2.1 所示，网络的第一个卷积层配置了 3 个卷积核，这些卷积核独立扫描输入图像，提取初级空间特征，生成了一个包含 3 个特征图的新特征矩阵。每个特征图的维度为 $[32,32]$ ，整个特征矩阵的维度为 $[3,32,32]$ 。接下来，第二个卷积层配置了 5 个卷积核，这些卷积核进一步在第一卷积层输出的特征图上执行卷积操作，以提取更复杂的特征。遵循与第一个卷积层相同的处理逻辑，第二卷积层处理后输出的特征矩阵维度为 $[5,32,32]$ ，即包含 5 个特征图，每个特征图的空间维度仍旧是 $[32,32]$ 。这种层层深入的特征提取机制使网络能够捕捉从简单到复杂的图像特征，为后续的图像分析和理解任务提供丰富的特征表示。如图 2.2 所示，卷积操作细节展现了卷积核如何在输入数据上滑动并执行元素乘加操作以生成特征图。




图 2.2 步长为 1 的卷积计算过程

在图 2.2 中，左边为输入图像矩阵，大小为 5×5 ，中间为卷积核，大小为 3×3 ，左边矩阵与卷积核进行运算，则右边特征图第一个计算为 $1 \times 1 + 1 \times 0 + 1 \times 1 + 0 \times 0 + 1 \times 1 + 1 \times 0 + 0 \times 1 + 0 \times 0 + 1 \times 1 = 4$ ，得出的计算结果即为输出图像特征矩阵左上角元素。按照这种计算方法，进行滑步计算，最后可以得到大小为 3×3 的一张特征图。

3.激活层：激活层是卷积神经网络中不可或缺的组成部分，其核心作用是通过激活函数对前一层的线性输出进行非线性转换。尽管在早期神经网络中，简单的线性

分类器可以处理某些任务，但现实世界中大多数数据集通常是线性不可分的，这限制了纯线性模型的应用范围和效果。因此，激活函数的引入，目的是引入非线性因素，使神经网络具备解决复杂问题的能力，提升了网络的学习、表达和泛化能力。常见的激活函数包括 Sigmoid、Tanh 和 ReLU，它们各有不同的数学特性和应用场景。激活函数的引入使网络能够学习更复杂的数据分布和特征表示，有效提升处理高维、非线性数据的能力。重要的是，激活层的应用不会改变特征图的维度，即特征图的宽度和高度在经过激活函数处理后保持不变，这保证了网络结构的连贯性和特征信息的完整传递。这种设计使卷积神经网络在保持数据结构不变的同时，增强了对复杂模式的识别和学习能力。下文将具体介绍这几种常用的激活函数：

（1）Sigmoid 激活函数：Sigmoid 函数^[48]是神经网络中使用频率极高的一种非线性激活函数，能够将输入的实数值映射到（0，1）区间，如公式（2.1）所示。该特性使 Sigmoid 函数特别适用于输出需要表示为概率的场景，比如在二分类问题中预测事件发生的概率。Sigmoid 函数的输出不仅平滑连续，还具有良好的可导性，为梯度下降及其他基于梯度的优化算法提供了便利，帮助它们在网络训练过程中更精细和平稳地调整网络参数。然而，Sigmoid 函数并非没有缺陷。其主要问题之一是在输入值绝对值较大时容易产生梯度消失现象，即梯度接近零的情况。这会导致在深层网络中，梯度信息在传递过程中迅速衰减，从而使得网络的权重更新变得非常缓慢，甚至停滞，进而影响训练效率和网络性能。尽管存在这些挑战，Sigmoid 函数因其简洁的数学特性和在特定应用场景下的有效性，仍然是理解神经网络运行机制和基本概念的重要工具之一，尤其是在网络输出需要解释为概率时。

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.1)$$

函数图像则如图 2.3 所示：




图 2.3 Sigmoid 激活函数图

（2）Tanh 激活函数：Tanh 函数^[49]（双曲正切函数）是深度学习中广泛使用的

一种激活函数，能够将输入映射到-1至1的输出范围。这种特性使 Tanh 函数在处理需要中心化数据的场景中尤为有用，因为它将数据的平均值自然调整接近零，从而加快神经网络的训练速度并提高网络的收敛性。由于这一输出范围的调整，Tanh 函数特别适合对输入值的正负性有明确区分要求的应用，比如在某些类型的序列数据处理中。作为一种非线性函数，Tanh 允许神经网络捕捉到输入数据中的复杂模式和关系，这是线性模型所无法实现的。尽管 Tanh 函数在输出范围上比 Sigmoid 函数更为优化（输出范围更广，负值区分能力更强），但它仍面临梯度消失问题，尤其是在处理极高或极低输入值的数据时。梯度消失会导致网络在这些极值区域的学习速度大幅下降，影响整体训练效率。尽管如此，Tanh 函数因其数据中心化优势和较广的输出范围，仍在许多深度学习模型中被广泛采用。具体表达式如下所示：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.2)$$

函数图像则如图 2.4 所示：




图 2.4 Tanh 激活函数图

（3）ReLU 激活函数：ReLU 激活函数在深度学习中极为常见，其简洁高效的特性使其成为多种神经网络架构的首选。ReLU 的数学表达形式简单直接，对于给定的输入 x ，输出是 x 与 0 之间的最大值。这意味着，如果输入 x 为正数，ReLU 函数将直接传递这个值；而如果输入是负数或零，则输出为 0。这种设计赋予了 ReLU 一个独特的特性：处理正数输入时，它表现出线性行为，使训练中的梯度传播顺畅；而对于负数输入，则将输出固定为 0，有效减少了网络的计算负担。ReLU 函数广泛应用，不仅因为其数学形式简洁，还因为它在实际应用中展现出多个显著优势：缓解深层网络中的梯度消失问题，提高网络收敛速度，并且由于其非饱和性质，ReLU 在

正区间内保持较大梯度，使网络在训练期间能够更快学习，提升整体学习效率。具体表达式如下所示：

$$f(x) = \max(0, x) \quad (2.3)$$

函数图像则如图 2.5 所示：




图 2.5 ReLu 激活函数图

4.池化层：在 CNN 架构中，池化层的主要目的是通过减小特征图的空间维度来降低计算复杂度，同时减少网络参数数量，从而提升运行效率。池化层通过下采样操作，对输入特征图的子区域进行汇总，保留关键特征信息，同时增强网络对输入数据中小幅位置偏移的鲁棒性。池化操作主要分为两种类型：最大池化和平均池化。最大池化选取特定区域内的最大值代表该区域，有效捕捉特征的显著性；平均池化则计算区域内所有值的平均数，提供更平滑的特征表示。这两种池化策略各有优势，最大池化因其能够突出强特征而被广泛应用，平均池化则因其能够减少网络对局部变化的敏感度而有其独到之处。引入池化层使 CNN 能够在不显著丢失特征信息的前提下，有效减轻过拟合风险，并增强网络对输入数据变化的适应能力和泛化性。该步骤在保持网络深度和复杂度的同时，为实现高效准确的图像识别与分类提供了保障。设定步长为 2，则两种池化过程如图 2.6 所示。




图 2.6 步长为 2 的最大池化与平均池化

5.全连接层：全连接层在 CNN 中起着关键作用，通过连接每个神经元与前一层所有神经元，有效整合了前几层提取的特征。这种结构使全连接层能够学习特征之间的复杂相互作用，增强网络的预测精度。通常位于 CNN 末端，全连接层将卷积层和池化层的局部特征转换为全局特征，为最终的分类或回归任务做准备。这一层是网络理解数据全貌并做出决策的基础。具体表达式如下所示：

$$y = Wx + b \quad (2.4)$$

其中： y 是全连接层的输出、 W 是权重举证、 x 是输入特征向量、 b 是偏置向量。

在该方程中，输入向量 x 通过与权重矩阵 W 相乘，并加上偏置向量 b ，来产生输出向量 y 。这个过程可以包含一个或多个神经元，其中，每个神经元都有自己的权重集和偏置值，负责产生最终的输出信号。在实践中，该步骤通常还会伴随一个激活函数，用于引入非线性，使得神经网络可以学习并模拟更复杂的函数或决策边界。

2.2 经典的图像语义分割网络

本节将详细介绍基于 CNN 的图像语义分割网络，主要探讨 SegNet、U-Net 以及 DeepLab 系列等经典网络。

2.2.1 SegNet 网络

SegNet 网络采用独特的编码器-解码器架构，有效处理了图像的细节恢复和分类。该网络通过深入分析输入图像，提取关键特征，并将其映射回原始图像尺寸，实现精确的像素级分类，从而在多个应用场景中实现高效的图像分割。如图 2.7 所示，为 SegNet 的网络结构，SegNet 的编码器部分基于经典的 VGG-16 网络，利用其深层卷积结构。编码器阶段涵盖了多个卷积层，每层后通常跟有 ReLU 激活函数，引入非线性处理，增强网络的表达能力。此外，最大池化层在该阶段发挥着关键作用，它们通过逐层降低图像的空间分辨率，使得网络能够在保留关键信息的同时减少计算量。这种压缩机制使得编码器不仅提取到图像的深层特征，而且还为后续的上采样和分类做好准备。在解码器部分，SegNet 利用编码器阶段的最大池化索引进行精确上采样，展现了其独到之处。该创新性的做法允许网络在放大特征图的同时，精准地恢复图像的空间细节，尤其是边缘和轮廓信息。与传统上采样方法相比，这种基于最大池化索引的策略在不增加额外参数的情况下保留了更多有用信息，提高了分割准确性。SegNet 网络的这种结构设计，不仅优化了图像分割的精度和效率，还降

低了网络的复杂度。这使得 SegNet 在需要处理大量数据的实际应用中，如自动驾驶车辆的道路检测、遥感图像分析以及医学图像处理等领域，都展现出了卓越的性能。其轻量级的设计和高效的运算能力，使得 SegNet 能够在有限的硬件资源下，快速地进行高精度的图像语义分割，满足了工业和科研领域对于高效图像处理算法的迫切需求。




图 2.7 SegNet 网络结构图^[29]

2.2.2 U-Net 网络

U-Net 网络通过精心设计的编码器-解码器框架和创新的跳跃连接，为城市街景分割等复杂图像处理任务提供了高效且精确的解决方案。

编码器作为 U-Net 的下降路径，采用多层卷积和池化操作，逐步提炼输入图像中的关键特征。每一层卷积都旨在捕获图像的局部细节，而随后的池化层则将这些特征压缩，同时增加其抽象层次。这种设计不仅减少了数据维度，还帮助网络学习从局部到整体的图像表示，为后续的图像重构提供丰富的语义信息。编码器的每一个操作都精心设计，以确保在提取深层特征的同时，尽可能保留原始图像的重要信息。解码器部分，或上升路径，通过逐级上采样和卷积操作，将编码阶段的压缩特征图逐渐扩展回原始图像尺寸。关键的跳跃连接在该过程中发挥至关重要的作用，将编码器捕获的高分辨率、丰富细节的特征图直接传递到解码器的对应层级。这不仅有效地弥补了上采样过程中可能丢失的空间信息，还提高了分割边缘的清晰度和精确度。此外，解码器中的卷积操作进一步细化了上采样后的特征图，确保了最终输出的图像分割结果既精确又连贯。跳跃连接是 U-Net 中的一大创新，通过直接连接编码器和解码器的对应层，使网络在恢复图像细节时能够有效利用更深层次的空间信息。这种设计理念不仅提升了网络在复杂场景下的分割性能，也极大地增强了网络对小物体和细节结构的识别能力。在城市街景分割的应用中，这意味着从路标到行人，从车辆到建筑物的细微部分，都能被准确地识别和分割，为进一步的场景理解和分析提供了坚实的基础，如图 2.8 所示，为 U-Net 的网络结构图。

综合来看，U-Net 凭借其创新的网络结构，在城市街景分割等复杂图像处理任务中表现出卓越的能力。其不仅能够处理图像中的细节信息，还能在有限训练样本条件下实现高效学习，这使 U-Net 在医学图像分析以外的多个领域，尤其在城市规划、自动驾驶技术开发和交通监控系统建设中，产生了重要影响。




图 2.8 U-Net 网络结构图

2.2.3 DeepLab 系列网络

为进行城市街景图像分割任务，本文采用了重新设计的 DeepLabv3+ 进行训练和测试。由于 DeepLabv3+ 是在其前三个版本基础上进一步发展的，本文首先对这三个版本进行详细的介绍。

DeepLabv1 是一种专为图像分割设计的深度学习网络，特别适用于处理复杂场景，如城市街景。如图 2.9 所示，DeepLabv1 的网络结构采用了空洞卷积技术，通过增加卷积核中的空间间隔来扩大感受野，使网络能够在不降低图像分辨率的前提下捕捉更广泛的上下文信息。为提高分割精度，网络末端还使用了 CRF，该步骤可以细化分割边缘，通过分析像素间的细节关系来细化分割边缘，优化输出。但 DeepLabv1 也存在一些缺点：首先，该网络的空间分辨率不足，由于网络中的下采样操作导致特征图的分辨率大幅下降，使得边界细节无法准确恢复。其次，边界恢复效果不理想，因为 DeepLabv1 缺乏解码器模块，无法专门处理高分辨率特征图的边界信息，导致分割结果特别是在复杂场景中的边界模糊。最后，小物体分割效果差，下采样过程中对小物体特征的丢失较多，导致小物体分割不够精确。




图 2.9 DeepLabv1 网络结构图^[37]

DeepLabv2 继续沿用了 DeepLabv1 的核心特性，并通过引入新的改进进一步增强了图像分割能力。如图 2.10 所示，其中最主要的改进是引入了多尺度处理和 ASPP 模块。ASPP 通过在不同扩张率下并行使用空洞卷积，有效捕捉多尺度的上下文信息，这对于理解图像中不同大小的物体至关重要。此外，CRF 仍然作为后处理步骤被保留，以进一步细化分割结果，尤其是在物体边缘区域。ASPP 模块的引入标志着 DeepLab 系列在图像分割问题处理上的重要进步，使网络更有效地理解广泛的视觉信息。尽管引入了空洞卷积和 ASPP 模块来捕捉多尺度信息，但由于缺乏细粒度的特征融合和解码器模块，网络仍在处理精细结构和小物体时丢失了部分空间信息。此外，DeepLabv2 在下采样过程中仍然存在特征分辨率降低的问题，导致部分细节在恢复时难以还原。尤其在高分辨率图像处理上，信息丢失的现象更加明显。




图 2.10 DeepLabv2 网络结构图^[38]

DeepLabv3 进一步优化了 DeepLab 系列网络的结构，特别是在空洞卷积和多尺度上下文捕捉方面。如图 2.11 所示，其关键创新之一是改进的 ASPP 模块，结合了不同扩张率的空间卷积和全局平均池化层，以捕获从局部到全局的上下文信息。该

设计增强了网络对图像不同区域和尺度的适应性和理解能力。DeepLabv3 继续采用预训练的 CNN，如 ResNet 和 Xception，作为骨干网络，以便从这些网络的深层和复杂特征中受益。这种选择进一步提升了网络的特征提取和表示能力。此外，DeepLabv3 专注于通过网络本身的结构优化来提高性能，而不是依赖于外部的后处理步骤，如 CRF。该方法简化了网络架构，同时保持了高效的分割性能，尤其在处理高分辨率输入图像时。DeepLabv3 虽然改进了多尺度信息处理，特别是通过增强的 ASPP 模块捕捉上下文信息，但仍存在一些缺点。首先，缺乏边界恢复机制，没有解码器模块来专门处理边界细节，导致在分割时边界模糊。其次，空间信息的丢失仍然存在，尤其在处理细小物体或复杂背景时，特征融合不足以完整保留局部信息。




图 2.11 DeepLabv3 网络结构图

DeepLabv3+的网络结构在 DeepLabv3 的基础上进行了改进，其具体网络结构如图 2.12 所示。Xception^{[50][51][52][53][54]}是一种基于深度可分离卷积的高效卷积神经网络，作为 DeepLabv3+网络的主干网络能够极大提升网络的计算效率。DeepLabv3+通过将 Xception 与空洞卷积结合，扩大了感受野，使得网络能够在不降低分辨率的情况下捕捉多尺度上下文信息。此外，DeepLabv3+还引入了 ASPP 模块^{[55][56][57]}，其通过不同空洞率的卷积层来获取全局和局部特征，并在解码器阶段结合低级特征，以实现更好的边界细节恢复。尽管 DeepLabv3+利用了 Xception 的高效特性，并通过多尺度特征提取提升了分割效果，但它仍然存在一些局限性。首先，空间信息丢失仍然是一个问题，尽管通过空洞卷积扩大了感受野，但在处理细小物体或复杂场景时，细节恢复仍不够理想。其次，网络的深层卷积操作和多次上采样容易导致误差累积，影响分割精度，特别是在高分辨率图像上表现明显。此外，DeepLabv3+的复杂架构和 Xception 主干的高计算成本增加了网络的计算开销，导致资源消耗较大，限制了其在需要高效处理的实际应用场景中的推广。




图 2.12 DeepLabv3+网络结构图^[46]

2.3 网络结构复杂度分析

模型复杂度通常包括时间复杂度和空间复杂度，分别反映网络的计算需求和参数规模。合适的复杂度对于网络的有效运作至关重要：过高的复杂度不仅增加过拟合风险，还可能导致计算资源浪费；而过低的复杂度则可能使网络无法充分学习，影响其性能。因此，在设计和训练网络时，平衡模型复杂度以实现优化效果和效率是一个重要的考虑因素。

2.3.1 时间复杂度

十亿次浮点运算（Giga Floating Point Operations per Second, GFLOPs）是一种衡量计算性能的指标，用于描述每秒可以执行的浮点运算次数（以十亿为单位）。GFLOPs 的计算公式依赖于具体的计算任务或算法。对于深度学习模型，尤其是 CNN，计算 GFLOPs 的一般公式可以表示为：

$$GFLOPs = \frac{2 \times N \times C_{in} \times H_{out} \times W_{out} \times K_h \times K_w}{10^9} \quad (2.5)$$

其中：N 是输出特征图的数量（即卷积层的输出通道数）、 C_{in} 是输入特征图的数量（即卷积层的输入通道数）、 H_{out} 和 W_{out} 分别是输出特征图的高度和宽度、 K_h 和 K_w 分别是卷积核的高度和宽度，乘以 2 是因为每个卷积操作涉及一次乘法和一次加法。

这个公式提供了一种估算 CNN 中单层卷积操作计算复杂度的方法。总的

GFLOPs 是将所有层的 GFLOPs 加起来得到的，提供了一个评估整个网络计算密集度的指标。需要注意的是，这个公式简化了一些实际计算中可能存在的因素，如填充和步长的影响，但其提供了一个大致的估计。在比较不同网络或计算系统的性能时，GFLOPs 是一个有用的指标，但其不包括内存访问、数据传输等可能影响实际性能的因素。

2.3.2 空间复杂度

空间复杂度是衡量算法或网络所需存储空间大小的一种度量，它反映了执行程序对存储资源的占用情况。在计算网络的空间复杂度时，主要关注的是随着输入数据量的增加，所需存储空间的变化趋势。这不仅包括程序中变量所占用的空间，也包括程序执行过程中临时占用的空间。对于深度学习模型来说，空间复杂度通常与网络的参数量直接相关。模型参数量是指网络中可学习参数的总数，包括权重和偏置等。因此，可以通过以下公式来估算一个深度学习模型的空间复杂度：

$$parameters = k^2 * C_{in} * C_{out} \quad (2.6)$$

式中 K 为卷积核尺寸， C_{in} 和 C_{out} 为输入、输出特征图的通道数。

在深度学习中，降低空间复杂度可以帮助网络减少内存占用，加快计算速度，这对于部署到内存受限的设备上尤为重要。有效控制空间复杂度，不仅可以提高网络的运行效率，还能使网络更容易被应用于不同的平台和场景。降低网络的空间复杂度有助于减少所需的存储空间，这意味着网络可以在更加紧凑的硬件条件下运行，同时还能降低能耗，这对于电池驱动的设备尤为重要。

2.4 迁移学习概述

当前语义分割领域中，部分数据集规模相对较小，这限制了网络的训练和学习效果。数据集的大小直接影响网络的学习效果，进而影响其性能表现。本节探讨了迁移学习^[58]作为一种策略，用以克服在数据集规模有限时网络训练所遇到的挑战。通过在预训练模型的基础上对新数据集进行进一步学习，迁移学习能够高效利用现有知识解决新任务，尤其是在标签样本稀少的场景中。这种方法减少了对大规模训练数据的需求，缩短了训练时间，并在有限数据环境中有效预防过拟合，增强了网络的准确度和鲁棒性。迁移学习过程如图 2.13 所示。




图 2.13 迁移学习过程

迁移学习，作为一种有效的学习策略，通过使用在原数据集上训练好的网络加速新任务的学习过程。根据目标数据集的大小及其与原数据集的相似度，存在四种不同的策略来提升学习效率和网络性能。

策略一：对于规模较小且与原数据集高度相似的目标数据集，一种有效的迁移学习策略是保留预训练模型中除最后一层外的所有层参数，仅重新训练输出层。这种方法考虑到在数据集规模有限的情况下，大量参数的重新训练易引发过拟合问题。由于目标数据集与原数据集在特征上高度相似，预训练模型已经捕获了绝大多数对新任务有用的特征信息，因此只需微调网络的最后一层以适应新任务需求，便可有效利用已有知识，减少训练资源消耗，同时保持网络性能。

策略二：面对庞大且与原数据集高度相似的目标数据集时，一种有效的迁移学习策略是使用在原数据集上预训练的模型，并对其所有层在目标数据集上进行全面训练。这种策略之所以可行，是因为较大的数据集为模型提供了充足的数据资源，这不仅避免了调整所有层参数时的过拟合，还确保了网络充分学习并适应新任务的特定特征。由于目标数据集与原数据集在特征上的高度一致，预训练模型已具备良好的基础特征表示，全面再训练进一步强化了这些特征的适应性，从而在提高网络性能的同时，加速了学习过程。

策略三：面对小规模且与原数据集相似度不高的目标数据集时，采用灵活的迁移学习策略尤为重要。在这种情况下，一种有效方法是保留预训练模型中除最后输出层外的所有层参数，仅对最后一层进行训练，或在保持网络初始几层参数不变的基础上训练后几层。此策略旨在利用预训练模型中的通用特征提取能力，同时避免了由于目标数据集规模较小而可能导致的过拟合问题。通过对后续层的微调，网络能够适应与原数据集在特征分布上显著不同的新任务。有选择性的参数调整帮助保持模型的泛化能力，同时优化新任务的特殊需求。

策略四：面对大规模且与原数据集相似度不高的目标数据集，采用的迁移学习

策略是对预训练模型进行全面重新训练，同时将预训练模型的参数作为起点。这种方法旨在最大限度地利用预训练模型作为知识基础，借助大量目标数据，确保网络充分学习并适应新的任务需求。这种全面训练策略不仅继承了预训练模型在处理类似问题上的能力，还通过针对性的训练，调整和优化网络以应对与原始任务差异较大的新场景，确保了网络在新任务中的性能和泛化能力。

2.5 注意力机制概述

注意力机制已成为深度学习研究的一个核心话题，受到人类处理信息时倾向于专注于感兴趣或关键区域的自然行为启发^[43]。例如，当快速浏览交通场景图像时，人们往往立即关注车辆、行人等显著对象，而忽略背景。在图像语义分割等计算机视觉任务中，注意力机制通过为关键特征分配更高权重，显著提升了网络对重要区域的识别能力，增强了场景解析。此外，注意力机制还能抑制不重要的信息，减少干扰，提升网络的细节刻画能力。这种仿人类视觉的优化手段不仅在语义分割中取得了突出效果，也为目标检测、图像分类等视觉任务提供了有效的改进。通过控制网络对图像各区域的关注，注意力机制帮助网络聚焦关键信息，提升处理效率和精确度，推动了视觉领域深度学习的进展。

根据其作用范围的差异，注意力机制可被分类为三种主要形式：空间域注意力、通道域注意力以及混合域注意力机制。

（1）空间域注意力机制专注于对图像空间维度的细致分析，识别并强调对任务至关重要的区域。该机制深入挖掘图像中每个位置的价值，使网络能够自主识别并优先处理信息丰富的关键区域。在网络训练过程中，空间域注意力赋予模型为不同区域分配权重的能力，从而在决策过程中提升这些区域的影响。通过动态调整和对空间信息的敏锐感知，网络的图像理解能力及在图像分割、目标检测等复杂任务中的表现得到了相应的提升，使网络在定位和识别重要元素和细节方面更为精确。

（2）通道域注意力机制专注于挖掘输入特征图中各个通道的关联性，动态评估并调整其重要性。通过调整通道权重，它突显重要特征，抑制不相关或贡献较少的信息，提升网络对图像内容的理解和判别能力。这种策略特别适用于处理复杂场景的分割或识别任务，有效提升网络的准确度和稳健性。通过细致调控通道特征的重要性，通道域注意力机制为深度学习模型提供了强有力的支持，优化了其在各种视觉任务中的表现。

（3）混合域注意力机制融合图像的空间位置信息和特征通道的相互关系，实现对视觉信息的综合分析。CBAM 是这种机制的典型应用之一，通过同时优化空间域

和通道域的注意力分配，它精准地强调了对网络性能贡献最大的图像特征。该策略不仅聚焦于图像特定空间位置的重要性，还综合比较各特征通道对图像内容表达的影响，实现对输入特征图的双重精细调整。这种方法使网络能够更有效地捕捉和理解复杂的图像结构与内容，极大提高了其在图像分类、目标检测和语义分割等视觉任务中的表现。引入混合域注意力机制使网络在多维度提升信息提取和处理能力，进而实现更深入全面的视觉数据理解。

2.6 本章小结

本章深入分析了 CNN 的理论及其在图像语义分割任务中的应用，特别是对网络结构进行了细致探讨。初步概述了数种经典的图像语义分割网络，包括 SegNet、U-Net 和 DeepLab 系列，并深入分析了这些网络的设计原则、结构特征及其实践表现。通过对这些关键网络的评估，本章旨在构建 CNN 在图像语义分割领域应用的理论框架和实践指导。

本章从空间复杂度和时间复杂度两个关键维度出发，细致分析了模型复杂度对语义分割任务的影响。探讨旨在揭示网络设计中的平衡，即如何在保证网络性能的同时优化运算效率和资源消耗。此外，本章涵盖了迁移学习的基础知识，包括其定义、应用价值及四种主要策略。最后，介绍了注意力机制，强调其在模拟人类视觉系统中的独特价值。通过引入注意力机制，网络能够更加聚焦于图像中的关键信息，进一步提升语义分割的准确性和效率。

综上所述，本章旨在提供一个全面的理论框架，不仅涵盖了网络结构的深入分析，还包括了对模型复杂度、迁移学习以及注意力机制等相关概念的讨论，为后续章节中的具体应用和深化研究奠定了一定的基础。

第三章 基于高分辨率表示的城市街景语义分割网络

面对城市街景图像的语义分割任务时，研究者常遇到物体种类多样性和空间分布复杂性等挑战。DeepLabv3+网络凭借高效的处理能力和出色的分割精度，已成为复杂城市街景分割任务的理想选择。基于第一章与第二章对卷积神经网络及相关理论的深入探讨，本章将专注于对 DeepLabv3+网络进行深入研究和优化设计。

本章的研究针对 DeepLabv3+网络的关键组成部分展开，以此提出了基于高分辨率表示的城市街景语义分割网络 HRDLNet，该网络的主要设计包括主干特征提取网络模块、多尺度特征提取增强模块和双注意力机制模块。通过设计这些核心技术，旨在进一步提升网络对城市街景中各类对象的识别和分割能力，特别是在处理种类繁多、空间分布复杂的场景。

3.1 基于高分辨率表示的城市街景语义分割网络

尽管 DeepLabv3+通过融合编码器-解码器架构与 ASPP 模块在语义分割领域取得了卓越的精度和细节捕捉能力，城市街景语义分割网络仍面临一些挑战。首先，输入图像在编码为低分辨率表征时会损失大量空间信息，导致后续恢复高分辨率时难以精确重现原图细节。其次，编解码过程中的误差累积可能导致恢复的图像与原始图像存在一定差异。此外，网络区分关键特征和目标区域的不足可能导致关键区域遗漏，反映出其在确定特征和区域重要性方面的局限性。最后，编解码过程中因尺度变化，网络在处理尺度差异显著的城市街景图像时可能遇到困难。这些问题共同制约了网络在复杂分割任务中的性能和准确性。

为应对现有语义分割网络的挑战，如空间信息丢失、误差累积、难以处理大尺度变化及关键区域识别不足，本章基于 DeepLabv3+提出了基于高分辨率表示的城市街景语义分割网络 HRDLNet，并进行了多项结构改进。这些改进旨在增强网络性能，特别是在维持空间信息、减少误差累积、适应尺度变化及加强关键区域识别和处理能力方面。首先，本文采用 HRNetV2 作为主干网络，该高分辨率特征提取网络有效结合高分辨率信息与多尺度特征，提升了网络处理不同尺度目标的能力。HRNetV2 的引入，确保了在特征提取过程中高分辨率信息的保持，从而有效地应对了空间信息丢失问题。此外，在 HRDLNet 的 ASPP 模块中整合新增的空洞卷积，扩展了感受野，增强了对图像细节及全局上下文的捕获能力，有效减少误差累积。此外，本章还融入了轻量化的 CBAM 和 SE 双重注意力机制，这种双重机制的设计，使网络能

够更为精确地关注关键像素和丰富的语义信息，在处理具有复杂背景和细节的视觉场景时，极大地提升了图像分割的精度和细腻度。综上所述，这些结构改进和技术创新为处理复杂度高、尺度变化大的视觉场景提供了新的解决方案，并在高分辨率保持和边缘精准识别方面展现一定的优势。基于高分辨率表示的城市街景语义分割网络如图 3.1 所示，图中详细的展示了 HRDLNet 的网络结构和模块集成信息。




图 3.1 基于高分辨率表示的城市街景语义分割网络

3.1.1 具有高分辨率表示的特征提取模块

本文提出了一种针对图像语义分割任务的高分辨率特征提取模块，创新性的引入 HRNetV2 作为主干网络。该网络针对图像分割任务中的两大挑战：高分辨率信息丢失和语义信息不足进行了相应的优化。传统卷积神经网络中，重复的下采样操作（如池化和步长大于 1 的卷积）导致高分辨率信息逐渐流失，影响了小目标的分割精度，并削弱了网络对大尺度目标语义结构的捕捉能力。HRNetV2 通过其独特设计，有效缓解了这些问题，为图像语义分割提供了精细的特征提取机制。

HRNetV2 采用了一种创新的多分支并行结构设计，有效地应对了传统卷积神经网络在图像分割任务中面临的高分辨率信息丢失问题。该网络在每个阶段包含高分辨率和低分辨率分支：高分辨率分支保留高分辨率特征，低分辨率分支通过下采样提取抽象语义特征。HRNetV2 特别设计了一套精巧的特征融合机制，在网络的各个阶段中，高分辨率特征图被上采样至与低分辨率分支相匹配的分辨率后进行融合，这种方法有效地促进了不同分辨率特征之间的信息流通和整合，加强了网络在维持高分辨率细节与捕捉粗糙语义信息之间的平衡。

HRNetV2 采用多阶段并行分支架构，逐阶段增强了多尺度特征表示能力，随着

深度增加，新增分支逐步加入，提升了特征提取效果。这种独特的多阶段并行分支策略，允许 HRNetV2 在维持高分辨率细节信息的同时，有效地融合全局语义信息，确保了网络在处理具有不同尺度的目标时能够实现优秀的性能表现。实验结果表明，HRNetV2 在众多公开数据集上相比其他分割网络展现出一定的优势，尤其在处理细小目标和高分辨率图像时表现出色。该网络的详细架构如图 3.2 所示。




图 3.2 HRNetV2 网络结构图

集成 HRNetV2 至 DeepLabv3+ 框架后，本研究实现了一定的性能提升。HRNetV2 的多分支并行结构优化了多尺度特征处理，使网络在保持高分辨率特征的同时，有效捕获丰富的语义信息。该架构的改进增强了对小目标和细节信息的分割能力，因 HRNetV2 不仅保留了细节特征，还能有效识别低分辨率下的全局信息。此外，HRNetV2 的多尺度特征处理能力极大提升了网络的泛化性，增强了其对不同类型和尺寸图像的适应性。因此，采用 HRNetV2 作为主干网络提升了整体性能，特别是在高分辨率信息和结构复杂的图像分割任务中，提供了更精准和细腻的结果。

3.1.2 多尺度特征提取增强模块

ASPP 结构在处理多尺度信息、特征融合及关键区域识别方面存在局限，可能影响网络在复杂场景下的语义分割性能。因此，对 ASPP 结构进行精细的优化，能够有效地解决这些问题，从而提升网络在复杂视觉环境中的语义分割性能。

在本文中，对 ASPP 模块进行了关键性的改进，设计了一种多尺度特征提取增强模块，通过在原有 atrous 卷积的基础上增加了三个额外的 atrous 卷积。该改进的主要优势是扩大了 ASPP 模块的感受野，使其在更广范围内捕获丰富的语义信息。这对于精确识别和分割不同尺度的目标至关重要，尤其是在处理具有多样化结构和尺度的复杂图像时。增加的这些额外 atrous 卷积增强了 ASPP 模块对多尺度特征的融合能力，通过不同扩张率的空洞卷积操作，ASPP 模块能够有效提取各尺度特征图中的关键信息。这些额外的 atrous 卷积扩展了特征图的尺度范围，使模块能够更全面地融合来自不同层次的特征信息，从而提升了网络对不同尺度目标的感知和识别能

力。此外，这种改进还提升了 ASPP 模块在细节和边缘信息捕获方面的能力，较小的膨胀率有助于模块更好地保留图像的细节和边缘特征，而较大的膨胀率则使网络能够捕捉到更广阔的语义信息。多层次的空洞卷积结构使 ASPP 模块能够同时捕获细节和全局语义信息，从而提升细节处理和边缘精细化的性能。通过这些改进，ASPP 模块能够有效地整合来自不同尺度的特征信息，提供更全面和精确的图像分割结果，尤其是在处理高分辨率和结构复杂的图像时。如图 3.3 所示，改进后的 ASPP 结构不仅在多尺度特征融合方面展现优势，还提升了细节和边缘精度。




图 3.3 多尺度特征提取增强模块

3.1.3 双注意力机制

在本章的研究框架内，深度集成的 CBAM^[59]和 SE^[60]双重注意力机制模块对提升网络在图像语义分割任务中的性能发挥了关键作用。首先，将 CBAM 注意力机制集成在 ASPP 模块的输入处，该策略使得网络在进入 ASPP 模块提取高级语义特征之前，能够全面优化输入特征图的空间和通道维度。具体而言，CBAM 注意力机制通过对空间和通道两个维度进行加权处理，提升了网络对关键特征的识别和强调能力。它不仅增强了对重要区域和特征的关注度，而且有效地抑制了背景噪声和无关信息。这为 ASPP 模块提供了更加精细和明确的特征图，优化了后续的特征融合与语义分割过程，提高了整体分割性能。随后，通过在网络的关键下采样阶段前集成 SE 注意力机制，本章进一步细化了网络的特征重标定流程。SE 模块通过学习通道间的依赖关系，自适应地调整各通道的特征权重。它能够增强网络对重要语义特征的响应，同时抑制对任务贡献较小的特征。这种通道级的重标定策略提高了网络在下采样前

的特征筛选和保留能力，尤其对于保持图像的细节和边缘信息至关重要。通过在下采样前引入 SE 注意力机制，确保了重要特征在下采样过程中得以强调和保留，减轻了下采样操作可能带来的信息丢失问题。这种处理方式有助于保留图像的细粒度细节，对复杂场景下的小目标和精细结构的识别具有重要意义。综上所述，CBAM 和 SE 注意力机制的结合应用，增强了网络在空间和通道维度上对关键特征的关注度。双重注意力策略提升了特征表示的质量，促进了网络对重要信息的捕获和利用，从而在语义分割任务中取得了更高的准确性和更优的性能表现。该改进对于复杂的城市街景图像处理，特别是在捕获细微特征和提高分割精度方面，具有一定的优势。

3.1.4 损失函数优化

在样本数据集构成中，类别间样本数量的不平衡现象经常对网络训练的效率及性能造成一定的影响。当某一类别的样本数量显著超过其他类别时，这种不平衡可能导致网络在训练阶段的信息偏差。此类偏差主要体现在两个方面：

首先，简单目标样本的过量存在使网络倾向于在这些高频样本上投入大量学习资源，导致网络更容易学习常见类别，而对低频类别的学习不足。低频类别在数据集中占比小，网络接收到的训练信号相对有限。类别不平衡直接影响训练效率，网络往往过度学习常见样本，忽略对泛化能力更为重要的罕见样本。其次，网络在高频简单样本的影响下，学习轨迹可能偏离既定目标。这是由于网络在学习过程中对这些占比过高的简单样本过度拟合，从而在遇到更多样化或复杂的样本集时性能表现不尽人意。在这种情形下，尽管网络在训练数据集上可能展现出较高的准确性，其在现实世界应用中的泛化能力却可能受到严重影响。这主要是因为网络未能充分学习到应对各类场景所需的广泛特征，特别是那些在训练集中较为罕见的场景。

综上，样本不平衡不仅降低训练效率，还削弱了网络的泛化能力。因此，在训练阶段引入过采样、欠采样或高级重平衡技术是优化网络性能的关键。这些方法有助于创建一个更加均衡的训练环境，从而提高网络的学习效率和泛化性能。

在目标检测数据集中，各类目标不仅种类繁多，而且同种目标的大小、形状和外观也存在极大的多样性。这种多样性在语义分割任务中尤其显著，其中常用的交叉熵损失函数在处理类别不平衡及识别难度较高的样本时，效果并不理想。为了解决该问题，本研究采用了重构权重损失函数作为改进策略。重构权重损失函数对传统的交叉熵损失函数进行了改进，通过引入一个调节因子来增加对少数类别和识别难度高的样本的关注，从而提高了网络对这些困难样本的识别精度并加速了网络收敛的过程。具体表达式为：

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t) \quad (3.1)$$

实际中，在式中增加了一个类别权重，具体表达式为：

$$FL(p_t) = -\alpha_t (1 - p_t)^\alpha \log(p_t) \quad (3.2)$$

在公式（3.2）中， $-\log(p_t)$ 是交叉熵损失函数， α 为类别间的权重参数， $(1 - p_t)^\gamma$ 为简单/困难样本调节因子， γ 为聚焦参数。当预测某类别准确率较高时，即 p_t 接近于1时， $(1 - p_t)^\gamma$ 的值接近于0；当某类别预测不准确时，即 p_t 接近于0时， $(1 - p_t)^\gamma$ 的值接近于1；本文设置 $\gamma = 2$ ， $\alpha = 0.25$ 。

3.2 实验数据与实验平台

3.2.1 实验数据集

Cityscapes 数据集被广泛应用于自动驾驶和城市场景分析等领域。该数据集涵盖了来自 50 个不同城市的街道场景，囊括了不同季节、天气条件和时段。具体来说，Cityscapes 提供了约 5000 张精细标注的图像，每个像素都被精确分类，覆盖包括道路、人行道、车辆、行人、建筑物等 30 种类别。此外，为增强网络的泛化能力，数据集还额外提供了超过 20000 张粗略标注的图像，以扩充训练集。Cityscapes 数据集的多样性体现在其涵盖市中心、郊区道路、住宅区等不同城市环境，提供了丰富且多变的视觉素材。为进一步考验网络在不同环境条件下的鲁棒性，数据集中还包含了在各种天气（如晴天、阴天、雨天）和光照条件（如白天、黄昏）下拍摄的图像。

Cityscapes 数据集在推动街道场景解析领域的研究中发挥了至关重要的作用，提供了大量高质量的标注数据，支持了多种视觉任务的研究与开发。它不仅作为衡量和比较不同视觉算法性能的标准化测试平台，还为研究人员提供了训练和验证其网络的可靠依据。此外，Cityscapes 数据集通过聚焦实际城市驾驶场景的复杂性和多样性，对自动驾驶系统的发展起到了关键推动作用，特别是在增强自动驾驶车辆的环境感知、提升系统安全性和可靠性等方面表现突出。图 3.4 展示了数据集中的部分示例，包括原始图像、精细分割图像和粗略分割图像，体现了其在提供详尽场景信息方面的能力。



图 3.4 Cityscapes 数据集示例

综上所述，Cityscapes 数据集通过其丰富的场景覆盖、详细的像素级标注和广泛的应用场景，为自动驾驶技术和城市场景解析领域的研究提供了宝贵的资源。

3.2.2 数据预处理

在深度学习项目的实施过程中，原始数据集的精细预处理是实现网络有效学习的前提条件。此预处理阶段是增强数据特征表征及提升网络性能的关键环节。以下列出了若干核心数据预处理步骤，它们共同构建了网络训练的坚实基础，并促进网络在面对未见数据时的泛化能力：

（1）数据审核与筛选：在深度学习实验开始之前，对数据集进行严格的审查与筛选是首要步骤。此环节旨在保障数据集的品质，排除可能引入网络偏见或导致错误解释的异常数据。例如，在本研究采用的数据集中，已经实施了该过程，确保了数据集的正确性和可用性。

（2）图像缩放处理：鉴于深度学习网络对输入数据尺寸的严格规定，图像尺寸调整成为预处理过程中不可或缺的一环。此步骤不仅保证了输入数据的尺寸一致性，同时也有助于降低计算资源的需求。通过将图像缩放至网络所需的特定输入维度，本步骤确保网络能以更高效率进行数据处理。

（3）数据归一化：数据归一化是一项关键的预处理操作，它通过将输入数据的

数值范围调整至一个标准化的区间（通常是 0 到 1 之间），有助于提升网络的收敛速度并增强网络的预测性能。归一化处理的方法多样，包括：

线性归一化：将数据线性映射到[0,1]区间内。是一种简单直接的方法。

标准差归一化：通过数据的标准差进行归一化，使得处理后的数据具有零均值和单位方差，适用于假定数据分布近似正态分布的场景。

Box-Cox 变换：这是一种使数据接近正态分布的方法，特别适用于对偏态分布的数据进行处理。

直方图均衡化：通过调整图像的对比度，使得图像的直方图分布更加均匀，这对图像处理任务尤其有效。

（4）图像增强：图像增强技术在深度学习数据预处理中扮演着关键角色，特别是在训练样本数量有限的背景下更显其重要性。尽管当代数据集的规模相较于过往已经有了显著的扩展，但数据的多样性与覆盖广度仍可能不足以培养出具有强大泛化能力的网络。因此，采用数据增强方法提升网络的鲁棒性、降低过拟合的风险以及增进网络对各类图像特性的泛化能力显得尤为重要。通过在现有数据集基础上执行一系列的变换操作，数据增强能够创造出在视觉或结构上具有差异性的新图像，该过程允许在无需手动增加额外数据标注的情况下，有效地扩大训练集的规模。这些操作包括但不限于：

随机翻转：通过水平或垂直翻转图像，可以增加样本的多样性，帮助网络学习到翻转不改变图像语义的特性。

随机裁剪：从原始图像中随机裁剪出小片段，这不仅可以增加数据量，还能迫使网络关注图像的局部特征，提高对细节的捕捉能力。

图像平移：通过对图像进行轻微的平移操作，可以模拟摄像头拍摄时的位置偏移，增强网络对图像位置变化的鲁棒性。

灰度变换：将彩色图像转换为灰度图像，可以迫使模型不依赖于颜色信息，强化对形状和纹理特征的学习。

这些操作均在公式 3.3 上实现：

$$y = Wx + b \quad (3.3)$$

通过这些精心设计的预处理步骤，不仅可以提升网络的训练效率，还能增强其在解决实际问题时的性能和泛化能力。这些预处理措施确保了数据的一致性和高质量，为深度学习模型的成功训练和部署奠定了坚实的基础。通过有效地处理数据中的噪声和异常值，网络能够更准确地学习数据的内在模式，从而在各种复杂场景下保持卓越的表现。

3.2.3 实验平台

在本研究中，实验软件采用的是 Pycharm，采用 Pytorch 深度学习框架进行算法实现。为保证实验能够顺利进行，对实验环境进行了调试，详细实验环境如表 3.1 所示。

表 3.1 实验环境

实验平台参数项	实验平台参数值
处理器（CPU）	Intel Xeon 8255C
显卡（GPU）	NVIDIA RTX 3090
显存（RAM）	24G
操作系统	Ubuntu20.04
GPU 加速器	CUDA 11.3
语言环境	Python 3.6
深度学习框架版本	Pytorch 1.11.0

3.3 图像语义分割评价指标

（1）平均交并比（Mean Intersection over Union，MIoU）是一种常用于评估图像分割任务性能的指标。其衡量了预测分割和真实分割之间的重叠程度。MIoU 的计算涉及到单个类别的交并比（Intersection over Union，IoU）的平均值，其中 IoU 是给定类别的预测分割和真实分割交集与它们并集的比例。对于每个类别，IoU 的计算公式是：

$$IoU = \frac{TP}{TP + FP + FN} \tag{3.4}$$

其中， TP 表示正确预测为该类别的像素数， FP 表示错误预测为该类别的像素数，而 FN 表示该类别的真实像素并未被预测出来。然后，MIoU 通过计算所有类别的 IoU 值的平均值来得出：

$$MIoU = \frac{1}{N} \sum_i^N IoU_i \tag{3.5}$$

这里的 N 是类别的总数， IoU_i 是第 i 个类别的 IoU 值。

MIoU 提供了一个直观的方式来理解网络在不同类别上的平均表现如何，尤其是在处理类别不平衡的数据集时。较高的 MIoU 值表明网络具有较好的分割性能，因

为其能够更准确地覆盖目标区域，同时减少误分类的情况。

(2) GFLOPs 是一个衡量计算性能的指标，广泛用于评估深度学习模型或任何计算密集型任务的硬件执行效率。GFLOPs 表示每秒可以执行多少十亿次浮点运算。这个指标尤其对于理解和比较不同硬件平台（如 CPU、GPU）或不同深度学习网络的计算需求 and 能力非常有用。在深度学习中，GFLOPs 常用于估计网络的复杂度和运行效率。计算网络的 GFLOPs 可以帮助开发者在网络设计阶段做出权衡，比如在网络精度和实时性（或运行时间）之间找到平衡点。计算 GFLOPs 的公式依赖于网络的具体操作，但一个常见的简化公式考虑的是卷积操作，因为它们在许多深度学习模型中占主导地位。对于卷积层，GFLOPs 可以近似计算为：

$$GFLOPs = \frac{2 \times K^2 \times C_{in} \times H_{out} \times W_{out} \times C_{out}}{10^9} \quad (3.6)$$

其中，K 是卷积核的尺寸（假设是正方形的）； C_{in} 是输入通道的数量； C_{out} 是输出通道的数量； H_{out} 和 W_{out} 分别是输出特征图的高度和宽度；乘以 2 是因为每个乘法操作涉及一个加法操作；最后除以 10^9 是将 FLOPs 转换为 GFLOPs。

需要注意的是，这个公式仅适用于卷积操作，并且在实际情况中，全连接层、激活函数、批量归一化等其他操作也会对总的 GFLOPs 有贡献，但卷积层通常是计算最密集的部分。通过计算网络的 GFLOPs，可以得到一个粗略的估计，了解网络运行一次前向传播需要执行多少计算操作，这有助于评估网络的复杂度和在特定硬件上的可行性。

(3) 参数量（Parameters, Params）指标通常用于衡量机器学习模型或神经网络的规模，它表示网络中的可训练参数总数。这些参数是网络在学习过程中需要调整的变量，包括权重和偏置。Params 的数量直接影响网络的学习能力和复杂性。一个网络的参数越多，理论上其表达能力越强，但同时也可能需要更多的数据来有效训练，且计算成本和存储需求也会增加。计算一个网络的 Params 非常直接，对于不同类型的层，计算方法略有不同：

1) 对于全连接层，参数数量为输入单元数乘以输出单元数加上输出单元数（用于偏置）。

2) 对于卷积层，参数数量为卷积核的尺寸乘以输入通道数乘以输出通道数加上输出通道数（用于偏置）。

具体计算公式可以根据层的类型和配置不同而变化，但一般来说，可以概括为：

$$Params = (ks \times ic \times oc) + oc \quad (3.7)$$

其中 ks 代表 Kernel size；in 代表 input channels；oc 代表 output channels。

例如，一个具有 3×3 卷积核，输入通道为 64，输出通道为 128，的卷积层 Params 计算如下：

$$Params = (3 \times 3 \times 64 \times 128) + 128 \tag{3.8}$$

总的来说，Params 提供了一个衡量模型复杂度的简单方法。网络的参数越多，通常意味着网络的学习能力越强，但也意味着需要更多的数据来避免过拟合，以及更高的计算和存储资源。

3.4 网络训练

1.迁移学习：迁移学习是一种先进的深度学习策略，使得网络能够将从一个任务中获得的知识迁移到另一个相关任务上。在数据资源有限的情况下，迁移学习尤为有效，因为它可以利用在大型数据集上预训练的网络来增强对新任务的学习效果。例如，一个在大规模图像数据集上训练过的深度学习网络能够识别一系列通用的视觉特征，这些特征可用于特定的图像识别任务，甚至在数据量较少时仍能提高性能。因此，迁移学习已成为解决数据稀缺和资源受限问题的重要方法，广泛应用于图像识别、自然语言处理等领域。

2.参数设置

在深度学习网络的设计与训练过程中，超参数的选择对于提升训练效率、达到性能上限、以及避免陷入局部最优解至关重要。恰当设置的超参数，如表 3.2 中所展示的，是确保深度学习模型顺利学习和泛化能力的关键因素。

表 3.2 训练超参数设置

参数名称	设置值
Learning Rate	0.01
Weight decay	1e-4
Momentum	0.9
优化算法	SGD

为了解决数据集中样本类别不平衡的问题，依据样本数量大小调整所有类别的 Loss 权值，防止数量少的样本的特征信息被忽视。本文选取数据集中出现频率最多的 19 个类别进行训练。若 c 为样本类别， α 是超参数，在实验过程中根据具体情况设置， p_c 为样本 c 的像素概率，则样本权重 W_c 计算公式为：

$$W_c = \frac{1}{\ln(\alpha + p_c)} \tag{3.9}$$

若 α 取值为 1.12，将其代入公式 3.9 则有表 3.3 所示的各类别权重。

表 3.3 类别平衡后的各类别权重

类别	权重	类别	权重	类别	权重
建筑物	3.6	交通灯	8.6	公共汽车	7.5
道路	2.7	地形	7.7	卡车	7.7
人行道	6.1	植被	4.3	火车	6.6
围栏	7.7	天空	6.8	自行车	8.4
墙壁	7.7	汽车	5.9	摩托车	8.5
杆	8.1	行人	8.0	-	-
交通标志	8.4	骑行者	8.6	-	-

3.5 实验一：不同损失函数对比结果分析

本文分别在优化网络中采用两种损失函数，依次为：（1）方案一：多分类交叉熵损失函数；（2）方案二：重构权重损失函数。


表 3.4 不同损失函数实验结果对比

方案	MIoU (%)	Overall Acc. (%)	Loss value	训练时长 (时)
方案 1	73.8	95.7	0.109	31.3
方案 2	75.1	95.6	0.074	35.6


根据表 3.4 中的数据分析可见，HRDLNet 采用重构权重损失函数替代传统交叉熵损失函数后，在 MIoU 这一关键性能指标上实现了约 1.3% 的提升。观察图 3.5 可以发现，应用方案 2（即使用重构权重损失函数）后，本章节所提出的网络在 MIoU 和 Overall Acc. 两个重要指标上表现得更加稳健和一致。这种稳定性表明，重构权重损失函数在网络训练中的关键作用。该损失函数通过更加精确的优化指导，减少了训练期间参数更新的波动和振荡，加快了网络的收敛速度，并提高了训练过程的稳定性。

在仅应用交叉熵损失函数时，网络在 MIoU 和 Overall Acc. 这两个关键性能指标上表现出较大的波动性，可能对网络训练的稳定性产生负面影响，进而削弱了网络的整体性能。特别是在图像分割等视觉处理任务中，由于类别间像素分布的不均衡，这种波动加剧了网络优化的难度。引入重构权重损失函数后，网络对关键但数量较少的类别的关注有所提升，确保这些稀缺类别在训练中得到有效识别和分割。该方法不仅增强了网络对不平衡数据的适应性，还在提升网络泛化能力和复杂场景中的

分割精度方面发挥了重要作用。通过该策略，训练过程更加稳定，波动和振荡现象得到有效控制。



(a) 不同损失函数对比实验 MIoU



(b) 不同损失函数对比实验 Overall Acc.

图 3.5 不同损失函数实验结果对比

如图 3.6 所示，HRDLNet 在使用交叉熵损失函数时展现出快速收敛的趋势，损失值从初始高位降至 0.109。而在采用重构权重损失函数对网络进行训练后，网络不仅保持了良好的收敛性，最终的损失值更是进一步降至 0.074。值得注意的是，采用重构权重损失函数的网络在训练过程中展现了更平稳的收敛趋势，表明了其在动态

训练中的稳定性。该表现突显了重构权重损失函数在梯度优化方面的优势，促进了网络整体性能提升。尽管交叉熵损失函数和重构权重损失函数均能加速网络收敛，但从最终结果来看，采用重构权重损失函数的网络表现更为出色。其通过精准捕捉与任务密切相关的特征，减少对背景噪声的依赖，提高了对目标边界的识别精度和细节捕捉能力。




图 3.6 不同损失函数的损失值比较

综合实验数据和观察结果，在本章设计的 HRDLNet 中引入重构权重损失函数使网络性能有了一定的提升。这种改进不仅在网络训练阶段体现出更稳健的表现，在整个训练周期内维持了稳定的 MIoU 和 Overall Acc.，而且在测试阶段也展现出解决类别不平衡问题的强大能力。该损失函数的设计优化了网络的学习过程，确保网络能够在各个类别上获得更均衡和优异的性能表现。它通过更精细地调整网络对不同类别的关注度，确保即便在样本数量不均衡的情况下，网络也能够有效地识别和分割出样本较少的类别，从而提升了图像分割的整体效果和准确性。

3.6 实验二：不同主干网络对比实验结果分析


本研究特别强调了所提出的高分辨率特征提取模块在提高特征提取效率和提高语义分割精度方面的优势。为了深入评估改进后的主干网络在处理复杂语义分割任务中的分割性能，本小节设计了一系列对比实验。这些实验选取了 ResNet50、ResNet101、MobileNet 和 Xception 等经典网络作为 DeepLabv3+ 框架的主干网络，对集成后的网络进行了系统、全面的训练和评估。实验旨在通过直接的性能比较，展

现本章所设计的网络在处理高度复杂的语义分割任务上的优势和独特之处。在这些实验中，重点比较了集成不同主干网络后的分割网络在 MIoU、Params、GFLOPs 等多个关键指标上的表现。此外，这些对比实验为评估不同主干网络在特征提取效率和精度方面的性能提供了相应的参考标准。通过该系列深入的比较分析，不仅验证了高分辨率特征提取模块的有效性，也充分凸显了 HRNetV2 在深度学习领域，特别是在高精度语义分割任务中的应用潜力和价值。


表 3.5 不同主干网络对比实验结果

网络	主干网络	MIoU (%)	Overall Acc.	Params (M)	GFLOPs	训练时长 (时)
DeepLabv3+	ResNet50	70.5	95.1	40.2	239.3	31.6
DeepLabv3+	ResNet101	74.2	95.5	59.2	317.3	34.2
DeepLabv3+	MobileNet	71.3	94.5	5.2	67.6	30.4
DeepLabv3+	Xception	66.1	93.8	37.5	212.0	36.7
DeepLabv3+	HRNetV2	75.1	95.6	33.9	115.2	35.6

在本节实验中，对 DeepLabv3+ 系列分割网络采用的多种主干网络，包括 ResNet50、ResNet101、MobileNet、Xception 以及本研究特别设计的 HRNetV2 进行了全面的性能比较。实验的核心目标是深入探讨这些网络在语义分割任务上的效能，其中特别关注它们在处理复杂图像分割任务时的精确度和效率。根据实验数据（如表 3.5 详细列出），HRNetV2 在 MIoU 指标上实现了 75.1% 的高分割性能，超越了其他分割网络。该分割精度得益于 HRNetV2 独有的高分辨率特征融合机制，该机制在多个尺度上综合了特征信息，使得网络能够精准捕捉到图像中的细节和上下文关系。这种能力在要求高精度和高分辨率输出的语义分割任务中尤为重要。为了直观展示不同主干网络在实验中的性能表现，图 3.7 中的可视化比较提供了训练过程中的数据变化。从图中可以清晰地看到，集成 HRNetV2 的分割网络在训练过程中展现了较高的分割精度和稳定性，与其他网络相比，其性能波动较小。这不仅凸显了 HRNetV2 在精确度和稳定性上的优势，也印证了将 HRNetV2 作为语义分割任务主干网络的合理性。通过实验可以看出，在处理高难度的语义分割任务时，选择合适的主干网络对于提高网络的整体表现至关重要。



(a) 不同主干网络对比实验 MIoU



(b) 不同主干网络对比实验 Overall Acc.

图 3.7 主干网络性能对比实验（括号中的内容，如‘ResNet50’代表主干网络）

3.7 实验三：模块消融实验结果分析


3.7.1 改进模块消融实验结果分析

为了综合评估本文提出的具有高分辨率表示的特征提取模块、多尺度特征提取增强模块以及双重注意力机制模块在增进网络性能方面的作用与效率，本节中设计了一系列的消融实验。首先对 DeepLabv3+网络的主干网络进行了关键的改进，形成了方案一的基础网络。随后，为了探究在此基础上引入新模块的效果和必要性，设计了方案二和方案三进行详细对比分析。具体而言，在方案二中，融入了多尺度特征融合模块。进一步地，在方案三中，引入了双重注意力机制模块。通过对比分析，


如图 3.8 所展示的结果，本文所提出的改进网络在 MIoU 和 Overall Acc.上均展现出了更加稳定和优异的性能。这不仅证明了网络在训练过程中参数优化的高效性，也减少了训练过程中可能出现的波动和不稳定现象。

表 3.6 改进模块消融实验结果对比

方案	MIoU (%)	Overall Acc.	训练时长 (时)
方案 1	72.1	95.3	34.9
方案 2	73.9	95.6	35.1
方案 3	75.1	95.6	35.6



(a) 改进模块消融实验 MIoU



(b) 改进模块消融实验 Overall Acc.

图 3.8 改进模块消融实验对比

在本小节研究中，所有三种实验设计均采用了经过改进的重构权重损失函数，以优化网络训练过程。这些方法在训练完成后，通过一系列指标评估了网络的语义分割性能，主要包括 MIoU、Overall Acc.以及网络训练所需的时间，具体实验数据详

见表 3.6 和图 3.8。通过对比方案一、方案二以及方案三的性能，可以明显看出，方案二中引入的多尺度特征提取增强模块以及方案三中加入的双注意力机制模块对提升网络的图像分割效果和整体性能都有着明显的提高。这些改进让网络更加深入地理解了图像的语义内容，实现了更为精确的语义分割效果。




图 3.9 改进模块消融实验分割效果可视化

如图 3.9 所示，在本小节中，对 DeepLabv3+网络及其在消融实验中的三个改进方案进行了详细的可视化对比，特别是在图中标注了若干在性能上有所提升的小物体实例，以便更直观地比较和观察。在原始的 DeepLabv3+网络中，一些小目标物体如交通标志和红绿灯的分割效果略有差异，这些场景中的部分细节信息往往容易遗失。相反，从方案一到方案三的逐渐改进中，可以观察到网络对这些细微之处的处理能力较强，特别是在小物体的识别和分割上表现更加精准。该系列改进主要得益于多尺度特征提取增强模块和双重注意力机制模块的引入，这两个模块有效的扩大了网络的感受野并增强了对图像细节的关注能力。


3.7.2 不同 Atrous Rates 的 ASPP 消融实验结果分析

为了进一步验证本文设计的多尺度特征提取增强模块在各类应用环境中的效能与适应性，本研究设计了一系列基于不同空洞率配置的消融实验。这一实验的目的在于剖析不同空洞率组合对网络整体性能所产生的影响，其目标是确保多尺度特征提取增强模块能够在广泛的应用场景下最大化其分割效果。通过对网络在各种空洞率设置下的性能差异进行细致比较与分析，本实验旨在全面评价该模块在增强网络处理复杂的多尺度特征以及丰富上下文信息方面的能力。


表 3.7 多尺度特征提取增强模块消融实验

Atrous Rates	MIoU (%)	Overall Acc. (%)	训练时长 (时)
6,12,18,24	72.2	95.3	35.1
6,12,18,24,30	71.7	95.2	35.2
6,12,18,24,30,36 (本章方法)	75.1	95.6	35.6
6,12,18,24,30,36,42	70.0	94.6	35.7

在本研究框架内，针对所提出的多尺度特征提取增强模块的性能优化进行了深入研究，特别是通过整合不同 atrous 卷积层策略，设计并实施了一系列精细的消融测试。这些测试涵盖了不同的 atrous 卷积配置，具体包括：“6,12,18,24”、“6,12,18,24,30”、“6,12,18,24,30,36”以及“6,12,18,24,30,36,42”。根据实验结果，如表 3.7 所示，随着 atrous 卷积层数量的增加，网络的性能表现出了先升后降的趋势，特别地，当配置为“6,12,18,24,30,36”时，网络性能达到峰值，MIoU 达到 75.1%。然而，过量采用 atrous 卷积可能会导致网络性能的降低，指出了在模块设计过程中需要寻求 atrous 卷积数量与网络性能之间的最佳平衡点。



(a) 多尺度特征提取增强模块消融实验 MIoU



(b) 多尺度特征提取增强模块消融实验 Overall Acc.

图 3.10 多尺度特征提取增强模块消融实验

图 3.10 清晰展示了, 当采用“6,12,18,24,30,36”该特定组合的 atrous 卷积时, 网络的性能表现达到了最佳, MIoU 值达到了 75.1%。该成果不仅在性能层面胜过了其他配置, 更重要的是, 其显示了该组合下网络在训练阶段的稳定性。这种稳定性暗示了网络对不同尺度特征的有效适应和学习能力, 而且避免了由于特征复杂度增加导致的性能波动问题。在对比分析中, 虽然其他 atrous 卷积组合同样提供了较好的分割性能, 证明了其在特定条件下的有效性, 但它们在达到高性能的同时, 训练过程中的波动性也更加显著。该对比强调了在设计网络时, 选择合适的 atrous 卷积配置对于优化网络性能和稳定性的重要性。通过精细调整 atrous 卷积层的组合, 能够更好地平衡网络的学习能力与其泛化性, 从而在语义分割任务中实现更高的准确率和稳健性。

3.7.3 不同位置的 SE 与 CBAM 注意力机制消融实验结果分析

本章节中设计了如图 3.11 的双重注意力机制模块, 其融合了 CBAM 和 SE 两种先进的注意力机制, 并将其精确地集成到 HRDLNet 结构的第“1”和第“5”的位置。为了更好的研究这两个特定位置的选取对网络整体性能的影响, 本小节设计了一系列消融实验。该实验采用控制变量法, 即在固定一个注意力机制位置的同时, 调整另一个的位置, 这样的实验设计能够精确评估每一种位置配置对网络分割精度的影响。通过这种系统的方法, 实现了对双重注意力机制模块选位优化效果的全面验证, 这些实验不仅证实了双重注意力机制模块的有效性, 而且进一步强化了设计选择, 展现了在深度学习模型中融合多种注意力机制以增强网络性能的潜力。




图 3.11 记录不同位置的 SE 与 CBAM 注意力机制

表 3.8 不同位置的 SE 与 CBAM 注意力机制消融实验（在第一列中，如“1+2”，“+”左边代表 CBAM 注意力机制，“+”右边代表 SE 注意力机制）

位置	MIoU (%)	Overall Acc.(%)	训练时长（时）
1+2	73.2	94.6	34.7
1+3	74.4	95.5	34.9
1+4	71.6	95.2	35.9
1+5（本章方法）	75.1	95.6	35.6
2+1	74.2	95.6	37.1
2+3	70.6	94.7	36.9
2+4	72.7	95.3	35.8
2+5	71.6	94.8	34.7
3+1	71.9	94.7	36.1
3+2	73.0	95.3	36.8
3+4	72.7	95.2	35.9
3+5	71.2	95.3	36.9
4+1	72.5	95.3	37.1
4+2	71.6	95.2	38.8
4+3	72.3	95.3	39.1
4+5	71.8	95.3	39.0
5+1	60.1	93.4	38.8
5+2	72.1	95.1	37.6
5+3	72.3	95.1	38.1
5+4	72.5	95.2	38.2

表 3.8 中的数据详细说明了将 CBAM 和 SE 注意力机制放置于 HRDLNet 中不同位置时，对网络分割性能的具体影响。在采用本研究提出的配置方案时，通过将 CBAM 和 SE 注意力机制引入指定位置，网络实现了最优的 MIoU 性能表现。这种效果背后原因在于，CBAM 通过融合空间与通道的注意力来增强特征表达力。特别是将 CBAM 置于“1”位置，能够在多尺度特征提取之前，帮助网络更有效地定位到图像中的关键区域，提升了输入特征的初步处理质量。同时，将 SE 注意力机制应用于“5”位置，进一步优化了通道权重的分配，确保在特征图尺寸缩减前，网络能够突出更富有信息的通道，保留关键特征信息。该双重注意力策略使得网络在关键的特征提取及下采样阶段对图像信息的处理更为细腻，不仅加强了对图像关键特征的识别能力，还优化了信息流动，提高了语义分割的准确度。

3.8 实验四：与先进分割方法性能对比实验结果分析


为了全面评估本章所设计的 HRDLNet 在图像语义分割任务上的效率与实用性，本研究设计了一系列比较实验，将改进网络与当前主流和最新的图像语义分割技术进行了细致对比。为确保实验结果的公正性和准确性，本小节采取了统一的训练策略和环境设置，保证所有比较的方法在相同条件下进行评估。这种方法的选择旨在排除外部变量的干扰，从而准确地揭示改进网络在性能和速度上相对于其他技术的优势和潜力。通过这种综合比较，不仅能够验证改进网络在提高分割准确性方面的有效性，同时也能够展示其在实时处理需求中的应用潜力，进一步证明了本章网络在图像语义分割领域的实用性。

表 3.9 与先进分割网络的实验结果比较（第一列括号中的数字代表该网络所提出的年份）


网络	MIoU (%)	Overall Acc. (%)	Params (M)	GFLOPs	训练时长 (时)
PSPNet (2017) ^[33]	61.6	93.6	49.0	194.4	38.1
FCN (2015) ^[23]	56.3	92.9	30.6	321.0	37.6
DANet (2019) ^[61]	63.3	94.1	47.5	205.5	37.3
DeepLabv3 (2018) ^[62]	61.2	93.9	42.1	180.9	36.1
DeepLabv3+ (2018) ^[46]	66.1	93.8	37.0	429.0	36.7
IkshanaNet (2022) ^[63]	54.8	95.7	4.0	413.3	34.2
SC-GAN (2021) ^[64]	55.9	95.5	66.2	126.0	30.1
CLADE (2021) ^[65]	58.5	95.5	67.9	75.5	29.7
INADE (2021) ^[66]	57.0	95.9	77.3	75.2	28.9
OASIS (2021) ^[67]	57.3	95.2	94.0	243.0	31.1
CCDM (2023) ^[68]	65.8	95.7	50.0	62.5	27.7
PIDNet (2023) ^[69]	80.6	-	34.4	194.7	31.8
BANet (2022) ^[70]	82.5	-	54.6	347.0	32.3
本章方法	75.1	95.6	33.9	115.2	35.6

在本研究节中，本章所提出的语义分割网络在综合对比分析中表现出一定的性能优势，具体网络性能如表 3.9 所示。该网络在 MIoU 这一关键性能指标上，相较于同表中其他现有方法表现出明显的性能提升。此外，通过图 3.12 提供的方法间可视化数据对比，可以观察到改进网络不仅在 MIoU 及 Overall Acc. 等关键评价指标上普遍超越其他主流与先进的语义分割网络，而且在整个训练过程中展示一定的稳定性。这种稳定性指标反映了网络在参数优化与更新过程中的稳健性，有效避免了训

训练阶段可能发生的剧烈波动。该特性有助于在预测过程中保持图像的高度细节信息，进而提升预测的准确性和综合性能。



(a) 与先进分割方法的比较 MIoU



(b) 与先进分割方法的比较 Overall Acc.

图 3.12 与先进分割方法性能对比实验

在本文中提出的改进策略融合了三个核心技术：高分辨率特征提取、多尺度特征增强，以及双注意力机制，实现了在减少网络参数的同时，提升性能的目标。通过采用 HRNetV2 作为主干网络，本策略利用其创新性的高分辨率并行子网架构，有效降低了由于连续的上下采样所导致的额外参数。这种架构优化了跨尺度特征的融合，不仅提升了特征提取的效率，而且增强了网络对图像细节的捕捉能力。此外，引入的 atrous 卷积在多尺度特征增强模块中，扩大了网络的感受野，允许在几乎不增加参数的情况下，有效处理不同尺度的特征。同时，设计的双重注意力机制通过优化参数配置，专注于图像的关键区域，从而进一步提升了网络的整体性能。这些创新的整合不仅极大地提高了网络在复杂图像分割任务中的处理速度和准确性，同

时也在维持较低的数量基础上，展现出了在高级图像分析任务中的出色性能和实用价值。本章所设计的网络，为实现高效且精确的图像分割提供了一种新颖有效的方法，其设计思想和实施方案在计算机视觉领域的高级应用中具有一定的学术意义和实践价值。

在本章提出的方法中，通过巧妙整合三个关键技术模块：高分辨率特征提取、多尺度特征增强，以及综合应用的双注意力机制，实现了在大幅降低计算成本的同时，提升图像处理能力的目标。特别地，方法中采纳的 HRNetV2 作为高分辨率特征提取的核心，通过其高效的并行子网结构，优化了特征的提取过程。该结构在维持特征高分辨率的同时，有效减少了由频繁的上下采样所带来的计算开销，该策略不仅降低了 GFLOPs，同时保障了数据特征的丰富性与准确性。进一步地，多尺度特征增强模块在 ASPP 架构的基础上，通过加入三种不同尺度的 atrous 卷积，极大地扩展了网络的感受野，允许其在几乎不增加计算负担的情况下，更加全面地捕获图像中的细节与语义信息。该优化不仅提升了图像分割的准确度，同时进一步降低了网络的 GFLOPs 需求。此外，双注意力机制模块的创新融合了 CBAM 和 SE 两种注意力策略，精细调整了网络对关键图像特征的识别与处理能力。这种优化在提高了特征提取的效率和精度的同时，避免了计算量的增加，对于进一步降低 GFLOPs 而言至关重要。通过这些技术模块的综合优势，本章节所提出的网络不仅在降低计算成本方面取得了显著成效，同时在保持低复杂度的基础上，提高了图像分割的性能。

3.9 实验五：跨数据集性能验证对比实验结果分析

尽管在 Cityscapes 数据集上的应用成果证明了本文所设计网络的出色性能，但为了全面评估其分割能力以及在与 DeepLabv3+ 网络系列的性能比较中所表现出的卓越图像分割能力，本研究特别设计了一系列的跨数据集性能验证对比实验。选取了广泛使用的 PASCAL VOC 2012 Augmented 数据集进行实验，这不仅是因为该数据集在图像分割领域的标准地位，更因为它提供了丰富多样的图像和场景，能够有效地测试网络对不同视觉信息的处理能力。通过该步骤，旨在深入探索本文网络在多样化数据来源下的适应性和鲁棒性，确保其不仅在城市街景图像分割任务中，也在更广泛的应用场景下展现出其实用性和可靠性。这种方法论上的考量，不仅强化了网络的实验验证过程，同时也为其在图像分割技术领域的进一步应用和发展提供了一定的基础。

表 3.10 跨数据集性能验证实验结果对比


网络	主干网络	MIoU (%)	Overall Acc. (%)	Params(M)	GFLOPs	训练时长 (时)
DeepLabv3+	ResNet50	76.3	94.7	40.2	59.8	35.1
DeepLabv3+	ResNet101	76.2	94.2	59.2	79.3	36.9
DeepLabv3+	MobileNet	70.2	92.9	5.2	17.0	29.8
DeepLabv3+	Xception	71.3	93.3	37.5	50.6	42.5
本章方法	HRNetV2	77.1	95.6	33.9	57.6	31.6

在本小节中主要专注于验证本文所设计的网络在 PASCAL VOC 2012 Augmented 数据集上的相关性能，以此来验证其在不同图像分割任务中的适用性和有效性。通过深入的实验分析，如表 3.10 和图 3.13 所示，本文所设计的网络在该数据集上实现了 77.1% 的 MIoU，该结果不仅印证了其优秀的分割精度，而且在 Params 和 GFLOPs 方面，同样展现了令人瞩目的性能。与当前领先的图像分割网络进行比较时，该网络在上述关键性能指标上的杰出成就，进一步证明了其在处理细腻的像素级语义分割任务方面的卓越能力。这些实验结果不仅彰显了改进网络在图像分割领域的强大竞争力，同时也突出了其在精确识别和处理各种图像中的复杂信息时的高效率和高精度。此外，该网络在保持较低参数量和计算负担的同时，仍能达到如此高的分割精度，这一点特别值得关注。其说明了网络设计中对效率和性能的平衡考量，不仅实现了计算资源的经济使用，也为在资源限制较为严格的应用环境中的部署提供了可能。


该网络之所以能在细腻捕捉物体边缘与类别信息上展现出色的性能，关键在于其设计理念中对高分辨率图像表示的持续维护。该网络通过在整个处理流程中保持图像的高分辨率，确保了对图像细节的精确捕获，从而大幅提升了物体边缘的识别精度和类别信息的判别能力。进一步地，其采用的注意力机制可以精准地聚焦于图像中的关键区域，该策略不仅增强了网络对于重要特征的识别能力，而且有效提高了分割的准确性和细致度。这种对高分辨率保持与关键信息聚焦的双重策略，赋予了该网络在处理复杂像素级分割任务时的一定优势，使其能够在众多分割网络中脱颖而出，提供更加准确和全面的分割结果。这些技术在需要高精度边缘识别和类别判定的场合，如自动驾驶、医疗影像分析等关键领域具有一定的实用价值，该网络的这些优势能够提升系统的性能和可靠性。因此，该网络的这些成就不仅体现了在图像分割领域的技术突破，同时也为未来在此技术领域及其应用前景提供了丰富的可能性和广阔的视野。

本文所设计的网络在轻量化方面的表现，体现了其在设计上的优势，即通过优

化参数量实现网络的高效性。拥有更少的参数量不仅意味着网络本身更为轻量级，也直接导致了对计算资源的需求降低。该特性使得该网络不只是在配备有高性能计算资源的环境中能够高效运行，更重要的是，它同样适合部署在计算能力受限的设备上，如移动设备和嵌入式系统。这种轻量级的设计在实际应用中具有极高的价值，尤其是在那些对处理速度和资源消耗有着严格要求的场景中，比如自动驾驶系统的实时物体识别，或是医疗设备中的即时图像分析等。此外，该网络在减少 GFLOPs 方面的优秀表现也凸显了其高效性。GFLOPs 作为评估网络运算复杂度的重要指标，其较低的数值标示着网络在执行任务时所需的计算资源和时间都大大减少。这种高效的计算性能在处理大型数据集或在需要快速处理和响应的应用场合中显得尤为重要，能够确保在不牺牲精度的前提下，实现快速且准确的图像分割。



(a) 跨数据集性能验证对比实验 MIoU



(b) 跨数据集性能验证对比实验 Overall Acc.

图 3.13 跨数据集性能对比实验

综上所述，该网络通过其轻量级设计和优化的计算复杂度，在实现卓越图像分割性能的同时，展现了一定的实用性与广泛的适用性。此网络架构在追求高效性的同时，未降低性能，反而在资源受限的环境下表现出独特的优势，凸显了其在实际应用中的潜在价值。

3.10 本章小结

在本章节中，深入分析并验证了 HRDLNet 在处理复杂的城市街道场景图像中的性能优势。首先对实验所采用的 Cityscapes 数据集进行了介绍以及其预处理步骤，确保了实验数据的质量和处理的统一性。此外，阐述了实验的配置环境、采用的网络评价指标以及网络训练和参数调整的策略。特别指出，通过在 ImageNet 数据集上应用迁移学习策略对网络进行预训练，本研究大幅度缩短了网络训练所需的时间。

进一步地，本章对于 HRDLNet 在 Cityscapes 数据集上的实验结果进行了详细的分析和讨论。在实验一中，通过对比传统的交叉熵损失函数和改进后的重构权重损失函数，研究揭示了后者在处理数据分配不均衡问题时，能够提高网络的 MIoU 及 Overall Acc.。实验二探讨了不同主干网络，包括 ResNet50、ResNet101、MobileNet、Xception 以及 HRNetV2 对网络性能的影响，发现使用 HRNetV2 作为主干网络时，网络展现出了最高的分割精度和最稳定的训练性能。在实验三中，通过对 HRDLNet 进行消融实验，本研究验证了高分辨率特征提取模块、多尺度特征提取增强模块以及双注意力机制模块对提升网络分割性能的影响。此外，针对不同 atrous rates 的 ASPP 模块进行的消融实验进一步强调了所设计 ASPP 配置在实现网络最佳性能中的关键作用。在实验四中，与现有的先进分割方法进行比较时，HRDLNet 不仅在分割精度上显示出明显的优势，而且在 Params 和 GFLOPs 上也表现出色。最后，实验五的跨数据集性能验证在 PASCAL VOC 2012 Augmented 数据集上进行，验证了 HRDLNet 在分割精度和模型效率方面相对于 DeepLabv3+采用其他主干网络时具有一定的优势。

第四章 基于多尺度信息整合的城市街景语义分割网络

在上一章设计的基于高分辨率表示的城市街景语义分割网络中，通过集成具有高分辨率表示的特征提取模块、多尺度特征提取增强模块、双注意力机制模块，以及对损失函数的优化，成功的在特征提取阶段保持了高分辨率表示，并有效地处理了不同尺度目标和复杂样本。然而，随着研究的深入发现，该分割网络在应对更为复杂和多样化的城市街景场景时，仍然存在一定的局限性。具体表现为，尽管该网络能够较好地融合多尺度特征，但在处理细节丰富和背景复杂的图像时，对于多尺度特征的提取仍有不足，这使得分割精度和鲁棒性仍有提升空间。

为此，本章提出了一个基于多尺度信息整合的城市街景语义分割网络 HHMENet，专注于多尺度信息整合，以弥补上述不足。该网络在前一章设计的基础上，重新设计了双注意力机制模块，具体包括混合通道和空间信息注意力模块以及多尺度全局注意力模块。同时，根据该注意力机制的设计，对多尺度特征增强模块进行了相应的优化。

通过这些设计优化，该网络在特征提取阶段始终保持高分辨率表示，并通过更有效地整合高分辨率信息与全局多层次特征，提升了网络对不同尺度目标的处理能力和对复杂样本的适应性。本章将详细介绍基于多尺度信息整合的城市街景语义分割网络的设计理念、关键模块，并验证其在城市街景语义分割任务中的应用与性能表现。通过对比实验和分析，本章将突出该网络在处理复杂场景时的优势，证明其在提升分割精度和鲁棒性方面的有效性。

4.1 基于多尺度信息整合的城市街景语义分割网络

在面对城市街景图像进行语义分割的任务时，研究者们常常遇到一系列挑战，尤其是由于街景中物体种类的多样性以及空间分布的复杂性。根据前文对基于高分辨率表示的城市街景语义分割网络的深入探讨，本章将专注于对 DeepLabv3+ 网络进行进一步的研究和设计，以解决现有方法中的若干问题并提升网络的性能。DeepLabv3 网络通过结合空洞卷积和编码器-解码器的结构，实现了更清晰的对象边界识别，并利用深度可分离卷积来提高计算效率。DeepLabv3+ 进一步改进了 DeepLabv3，添加了一个简洁而高效的解码器模块，从而提升了分割性能。这种改进不仅增强了网络对细节的捕获能力，还提升了整体的分割精度。然而，尽管现有研究在改进语义分割网络方面付出了巨大的努力，仍然存在一些难以有效解决的问题。

首先，现有网络在处理过程中会逐渐降低图像的分辨率，导致细节信息的丢失，难以保证精细的分割效果。其次，传统的分割网络往往在特征提取上存在局限，无法自适应地对全局和局部特征进行加权，导致重要信息的遗漏。再次，许多网络在固定尺度下提取特征，缺乏对不同尺度信息的综合利用，难以应对不同尺寸的目标和复杂的场景变化。最后，现有方法在多尺度信息的捕获上仍然存在不足，无法充分整合来自不同尺度的特征，导致分割结果的精确性不够理想。

本章在上述研究基础上，旨在进一步应对这些挑战。以此提出了基于多尺度信息整合的城市街景语义分割网络 HHMENet，依托于 DeepLabv3+网络，并引入了以下设计。本章设计了一种混合通道和空间注意力机制（Hybrid Channel Spatial Attention, HCSA），并将其集成到网络中，使得网络能够自适应地对不同特征进行加权。通道注意力机制通过对每一个通道进行加权，增强了图像中的重要特征；空间注意力机制则对不同空间位置的特征进行加权，使网络能够更好地关注重要的空间区域。这种结合有助于捕捉全局和局部特征，提升语义分割的性能。此外，本章还设计了一种多尺度全局注意力机制（Multi-Scale Global Attention, MSGA）。通过将 MSGA 集成到网络中，使得网络能够通过自适应平均池化提取全局上下文信息，利用多个不同膨胀率的卷积层提取多尺度特征，并结合全局上下文信息进行加权。最后，在 ASPP 模块中新增了 4 个 atrous 卷积。ASPP 模块通过使用不同膨胀率的卷积来捕捉多尺度信息，新增的 4 个 atrous 卷积进一步增强了这一能力，使网络能够捕捉更丰富的多尺度特征。HHMENet 的具体网络结构如图 4.1 所示。




图 4.1 基于多尺度信息整合的城市街景语义分割网络

本章的研究目标是通过以上针对性的设计，进一步提升 DeepLabv3+网络在城市街景图像分割任务中的性能，并为未来在类似复杂视觉场景下的语义分割研究提供有价值的参考和启示。在接下来的小节中，将详细说明这些设计和实验结果。

4.1.1 混合通道和空间信息注意力模块

在现有网络架构中，尽管其具备提取多层次特征信息的能力，但在通道和空间维度上缺乏足够的特征提取能力，这导致对关键特征的捕捉不够精确。这种不足可能会影响网络在语义分割任务中的表现，特别是在处理细节丰富和复杂场景时尤为明显。由于缺乏对不同通道间重要性和空间位置间显著特征的有效识别，进而影响整体的分割精度和效果。因此，提升通道和空间维度的特征提取能力对于提高 HHMENet 在语义分割任务中的表现至关重要。为了解决这些问题，本章提出了一种新的注意力机制，即混合通道和空间注意力机制。HCSA 通过同时关注通道和空间维度的信息，增强了特征表示的能力。具体而言，HCSA 包含两个主要部分：通道信息提取和空间信息提取。

在通道信息提取方面，HCSA 首先通过自适应平均池化操作来捕捉每个通道的全局信息。该步骤确保能够获得每个通道的全局特征，从而为后续的注意力计算提供基础。随后，经过一系列卷积和非线性激活操作生成通道注意力权重，通过这些权重，能够调整不同通道的特征强度。这意味着网络能够更好地识别并强调重要的特征通道，从而提高特征提取的精度和有效性。在空间信息提取方面，HCSA 通过卷积操作生成空间特征图，并通过 Sigmoid 激活函数生成空间注意力权重。这些权重用于在特征图的空间维度上选择性地关注重要位置，从而在空间上对关键区域进行重点处理。通过这种方式，HCSA 能够有效地提升对特征图中重要区域的关注度，使网络在细节处理和复杂场景中表现更为优异。具体公式如下所示：

(1) 通道注意力机制

1) 全局平均池化

$$F_{avg} = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W F(i, j) \quad (4.1)$$

其中， $F \in \mathbb{R}^{C \times H \times W}$ 为输出特征图， $F_{avg} \in \mathbb{R}^{C \times 1 \times 1}$ 为全局平均池化后的特征图。

2) 通道降维卷积和激活

$$F_{reduce} = ReLU(W_1 F_{avg}) \quad (4.2)$$

其中， $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ 为 1×1 卷积核， r 为缩放比。

3) 通道恢复卷积和激活

$$F_{restore} = \sigma(W_2 F_{reduce}) \quad (4.3)$$

其中, $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ 为 1×1 卷积核, σ 为 Sigmoid 激活函数。

4) 通道注意力

$$F_{CA} = F \odot F_{restore} \quad (4.4)$$

其中, $\odot$ 为逐元素相乘操作。

(2) 空间注意力机制

1) 空间卷积和激活

$$F_{conv} = W_s * F \quad (4.5)$$

其中, $W_s \in \mathbb{R}^{1 \times C \times k \times k}$ 为卷积核, k 为卷积核大小。

2) 空间注意力

$$F_{SA} = \sigma(F_{conv}) \quad (4.6)$$

(3) 最终特征表示

结合通道注意力和空间注意力机制, 最终融合后的特征表示为:

$$F_{HCSA} = F \odot F_{CA} \odot F_{SA} \quad (4.7)$$

具体来说, F_{CA} 和 F_{SA} 可以进一步展开表示为:

$$F_{CA} = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot F_{avg})) \quad (4.8)$$

$$F_{SA} = \sigma(W_s * F) \quad (4.9)$$

因此, 最终融合后的特征表示完整公式为:

$$F_{HCSA} = F \odot \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot F_{avg})) \odot \sigma(W_s * F) \quad (4.10)$$

综上所述, 通过这种双重信息提取机制, HCSA 有效地解决了当前网络在特征表示上的不足。通道信息提取增强了对不同特征通道的重要性捕捉, 而空间信息提取则提升了对特征图中重要区域的关注度。最终, HCSA 通过融合通道和空间有效信息, 生成了更细致、更精确的特征表示, 提升了网络在复杂视觉任务中的表现。该改进不仅提高了网络的准确性, 还在处理细节和复杂场景时展现出了更优异的性能。具体网络结构如图 4.2 所示。




图 4.2 混合通道和空间信息注意力网络结构

总结而言，HCSA 通过综合利用通道和空间维度的信息，解决了当前网络在特征提取方面的不足。它不仅增强了对不同特征通道和空间位置的有效识别，还提升了网络的整体分割精度和效果。随着该机制的引入，HHMENet 在语义分割任务中展现出了一定的性能提升，特别是在处理复杂场景和丰富细节时，表现突出。

4.1.2 多尺度全局注意力模块

在现有的语义分割网络中，尽管其具备提取多层次特征信息的能力，但在对多尺度信息的捕捉和全局上下文信息的整合方面仍存在不足。这种局限性导致了对关键特征捕捉的不够精确，尤其是在处理具有不同尺度特征和复杂背景的场景时，网络的表现显得不够理想。这些问题可能会影响网络在语义分割任务中的表现，特别是在处理细节丰富和复杂场景时更为明显。由于缺乏对不同尺度特征和全局上下文信息的有效识别和融合，整体的分割精度和效果受到了限制。

为了克服上述不足，本章提出了一种全新的多尺度全局注意力机制。MSGa 通过结合多尺度特征提取和全局上下文注意力，提升了网络的特征提取能力。具体来说，MSGa 的设计思想是利用全局和局部信息的互补性，以增强网络对多尺度特征和全局上下文的捕捉和整合能力，从而提高多尺度信息整合的高分辨率城市街景图像语义分割网络在复杂场景下的表现。具体公式如下所示：

（1）全局上下文注意力

1) 全局平均池化

$$F_{avg} = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W F(i, j) \quad (4.11)$$

其中, $F \in \mathbf{R}^{C \times H \times W}$ 为输入特征图, $F_{avg} \in \mathbf{R}^{C \times 1 \times 1}$ 为全局平均池化后的特征图。

2) 通道降维卷积和激活

$$F_{reduce} = ReLU(W_1 F_{avg}) \quad (4.12)$$

其中, $W_1 \in \mathbf{R}^{\frac{C}{r} \times C}$ 为 1×1 卷积核, r 为缩放比。

3) 通道恢复卷积核激活

$$F_{reduce} = \sigma(W_2 F_{reduce}) \quad (4.13)$$

其中, $W_2 \in \mathbf{R}^{C \times \frac{C}{r}}$ 为 1×1 卷积核, σ 为 Sigmoid 激活函数。

4) 全局上下文注意力

$$F_{global} = F \odot F_{restore} \quad (4.14)$$

其中, $\odot$ 为逐元素相乘操作。

(2) 多尺度特征提取

1) 多尺度特征提取

对每个尺度 S_i 进行卷积操作:

$$F_{scale_i} = Conv_{3 \times 3, dilation = s_i}(F) \quad (4.15)$$

其中, $F_{scale_i} \in \mathbf{R}^{C \times H \times W}$ 为调整后的特征图。

2) 特征拼接

$$F_{concat} = [F, F_{scale_1}, F_{scale_2}, \dots, F_{scale_n}] \quad (4.16)$$

其中, $F_{concat} \in \mathbf{R}^{C(n+1) \times H \times W}$ 为拼接后的特征图。

3) 通道调整卷积

$$F_{adjust} = Conv_{1 \times 1}(F_{concat}) \quad (4.17)$$

其中, $F_{adjust} \in \mathbf{R}^{C \times H \times W}$ 为调整后的特征图。

(3) 最终特征表示

结合全局上下文注意力和多尺度特征提取, 最终特征表示为:

$$F_{output} = F_{adjust} \odot F_{global} \quad (4.18)$$

首先, MSGA 通过全局平均池化操作来捕捉输入特征图的全局信息。全局平均池化能够有效地汇总整个特征图的信息, 生成一个全局特征向量。该步骤确保了整个特征图的信息被凝练到一个简洁的表示中, 便于后续的全局上下文注意力计算。接着, MSGA 基于全局特征向量, 通过一系列卷积和激活操作生成全局上下文注意力权重。这些权重反映了不同特征在全局上下文中的重要性, 应用于原始特征图上, 以增强其全局表示能力。这样, 网络能够更好地理解和捕捉全局上下文信息, 从而在处理复杂背景时表现得更加精准和有效。同时, MSGA 还利用了一系列具有不同膨胀率的卷积层来提取多尺度特征。不同膨胀率的卷积层能够在不同尺度上捕捉特征, 形成多个尺度的特征图。这些卷积层在不同的感受野上工作, 从而捕捉到不同尺度的空间信息。具体操作上, 这些卷积层会在不同的感受野上进行卷积操作, 以获取丰富的多尺度信息。然后, MSGA 将这些多尺度特征图与原始特征图拼接在一起, 形成一个包含丰富多尺度信息的特征图。为了有效整合这些信息, MSGA 通过一个 1×1 卷积层来调整拼接后的特征图的通道数, 生成融合了多尺度信息的特征表示。这个融合的特征表示不仅保留了原始特征图中的细节信息, 还通过多尺度特征提取机制增强了特征图在不同尺度上的表示能力。具体网络结构如图 4.3 所示。




图 4.3 多尺度全局注意力网络结构

综上所述, MSGA 不仅能够捕捉输入特征图的全局信息, 还通过多尺度特征提取机制, 增强特征图在不同尺度上的表示能力, 从而提升网络的整体性能。通过这种双重增强策略, MSGA 有效解决了当前网络在特征表示上的不足, 使 HHMENet 在语义分割任务中表现出更高的精度和更优异的性能, 特别是在处理细节丰富和复杂场景时。通过该改进, 该网络不仅在分割任务的准确性上得到了提升, 同时在复杂场景下的处理能力也表现得更加出色。

4.1.3 多尺度特征提取增强模块

在本章节中，尽管原始的 ASPP 模块通过多尺度的池化和膨胀卷积捕捉到了不同尺度的特征信息，但在处理复杂和多样化的场景时，仍然无法充分捕捉到所有尺度上的关键信息。这种不足导致网络在语义分割任务中的表现不够理想，尤其是在处理细节丰富和复杂背景的图片时，分割精度和鲁棒性受到影响。为了解决该问题，在本章节中针对所设计的双注意力机制模块重新设计了 ASPP 模块，具体是在 ASPP 模块中新增了 4 个 atrous 卷积层，这些卷积层具有不同的膨胀率，分别为 6,12,18,24,30,36,42，这些新增的卷积层能够在更广泛的感受野上捕捉到多样化的特征信息，从而更全面地表示输入图像中的各种尺度特征。改进后的 ASPP 模块包含全局平均池化、1x1 卷积、4 个新增的 atrous 卷积以及原有的 atrous 卷积。不同膨胀率的卷积层对输入特征图进行卷积操作后，将特征图拼接在一起，形成综合的多尺度特征表示，再通过 1x1 卷积进行通道调整，生成最终的特征表示。实验结果表明，通过引入这 4 个新增的 atrous 卷积层，改进后的 ASPP 模块增强了该分割网络对多尺度特征的捕捉能力，在语义分割任务中表现出更高的精度和鲁棒性，特别是在处理复杂场景时，分割效果得到了明显提升。这表明，新增的 atrous 卷积有效解决了原始 ASPP 模块在多尺度特征捕捉方面的不足，提升了 HHMENet 在复杂场景下的语义分割性能。具体网络结构如图 4.4 所示。




图 4.4 多尺度特征提取增强模块

4.2 实验数据与实验平台

4.2.1 实验数据集

在本章的数据集选取上，保持了与第三章一致的选择策略，以确保训练过程中的数据来源和条件具有一致性。具体而言，本章主要采用 Cityscapes 数据集来对所设计的网络进行训练和评估。这不仅有助于维持实验的可比性，还能够充分验证网络的实际表现和稳健性。通过使用相同的数据集，从而能够更加准确地评估新方法的改进效果。

4.2.2 数据预处理

在本章的数据预处理中，将采用与第三章一致的方法，以保证实验结果的连贯性和可比性。具体而言，数据预处理包括以下几个步骤：首先，对图像进行缩放处理，以统一尺寸并适配网络的输入要求；其次，进行数据归一化，以调整图像的像素值范围，从而提升网络的训练稳定性和收敛速度；最后，应用图像增强技术，如旋转、翻转和颜色调整等，以丰富数据的多样性，增强网络的泛化能力。通过采用与第三章相同的数据预处理方式，从而能够确保不同章节之间的数据处理流程保持一致，进而提高实验结果的可靠性和可比性。

4.2.3 实验平台

在本研究中，实验软件采用的是 Pycharm，采用 Pytorch 深度学习框架进行算法实现。为保证实验能够顺利进行，对实验环境进行了调试，详细实验环境如表 4.1 所示。

表 4.1 实验环境

实验平台参数项	实验平台参数值
处理器（CPU）	Intel Xeon 8255C
显卡（GPU）	NVIDIA RTX 3090
显存（RAM）	24G
操作系统	Ubuntu20.04
GPU 加速器	CUDA 11.3
语言环境	Python 3.6
深度学习框架版本	Pytorch 1.11.0

4.3 图像语义分割评价指标

本章所采用的语义分割评价指标与第三章保持一致，以确保评价过程的连贯性和结果的可比性。具体而言，本章选用了 MIoU、Overall Acc.、GFLOPs 以及 Params 这四项关键指标。为了保证分析的严谨性与科学性，这些指标的计算方法及其相关公式已在第三章中详细阐述。在此，沿用这些标准，以便在不同章节之间保持一致的评价指标，确保实验结果的可重复性和公平性。

4.4 实验一：不同主干网络对比实验结果分析


为了更好地验证本章中所设计的双注意力机制和多尺度特征提取增强模块与上一章节所设计的主干网络之间的兼容性，本节精心设计了一系列对比实验。这些实验旨在探讨不同主干网络与本章提出的模块在语义分割任务中的性能表现。具体而言，按照第三章节中所制定的实验逻辑，设计了多组对比实验。为了充分评估兼容性和性能表现，分别将主干网络替换为 ResNet50、ResNet101、MobileNet 和 Xception。通过这种主干网络的更换，本节构建了多个不同配置的分割网络，并对每个网络进行了系统的训练与评估。这些对比实验的设计不仅旨在展示各个主干网络与新模块的整合效果，还意在通过直接的性能比较，清晰地展示上一章节中所提出的主干网络与本章节中设计的双重注意力机制和改进 ASPP 模块之间的有效兼容性。

表 4.2 不同主干网络对比实验结果


网络	主干网络	MIoU (%)	Overall Acc.	Params (M)	GFLOPs	训练时间 (时)
DeepLabv3+	ResNet50	70.5	95.1	40.2	239.3	31.6
DeepLabv3+	ResNet101	74.2	95.5	59.2	317.3	34.2
DeepLabv3+	MobileNet	71.3	94.5	5.2	67.6	30.4
DeepLabv3+	Xception	66.1	93.8	37.5	212.0	36.7
DeepLabv3+	HRNetV2	76.8	95.9	32.7	107.8	34.9

在本次研究中，对集成于 DeepLabv3+ 框架下的多种主干网络进行了详尽的性能比对分析，涵盖了 ResNet50、ResNet101、MobileNet、Xception 及本文所集成的 HRNetV2。该对比研究的核心目的是探讨它们在执行语义分割任务时的具体效能，而详细的实验成果汇总于表 4.2 中。数据分析揭示，集成 HRNetV2 后的 DeepLabv3+ 实现了 76.8% 的 MIoU，该成绩彰显了其在该领域较为先进的分割性能。HRNetV2 较高的特征提取能力主要归功于其创新的高分辨率特征融合机制，该独特设计使网络

能够在多尺度上高效整合特征信息。这种跨尺度的特征融合能力极大地增强了网络捕获对象细微特征与全局上下文信息的能力。为了直观展示各主干网络的性能差异，在图 4.5 中加入了对比图表，直观地反映了整个训练阶段中各网络的 MIoU 变化趋势。从中可以清晰观察到，HHMENet 不仅保持了持续高位的 MIoU 水平，其性能稳定性亦表现突出，波动幅度相对较小。



(a) 主干网络对比实验 MIoU



(b) 主干网络对比实验 Overall Acc.

图 4.5 主干网络性能对比实验（括号中的内容，如 ‘ResNet50’ 代表主干网络）

4.5 实验二：模块消融实验结果分析

4.5.1 改进模块消融实验结果分析


为了全面验证上一章节所提出的具有高分辨率表示的特征提取模块，以及本章

节所提出的混合通道和空间信息注意力模块、多尺度全局注意力模块、多尺度特征提取增强模块在 HHMENet 中的作用和效果，本章节设计并执行了一系列消融实验。这些实验以原始的 DeepLabv3+作为基础对照网络，并通过逐步引入所设计的模块，分别构建了三组实验方案：DeepLabv3++具有高分辨率表示的特征提取模块、DeepLabv3++具有高分辨率表示的特征提取模块+HCSA 以及 DeepLabv3++具有高分辨率表示的特征提取模块+HCSA+MSGa。这种逐步集成本章节的模块设计，不仅便于精细评估各模块对网络性能的个体贡献，还利于验证它们增强分割准确度和应对复杂情景的能力，确保了其有效性和必要性。该策略性的实验流程加深了对各模块如何促进语义分割任务改进的认识，并为后续优化工作铺垫了有价值的参考基础。三种实验方案均在相同的实验环境中进行，训练后得到的语义分割性能指标包括 MIoU 和 Overall Acc.，详见表 4.3。本小节主要采用 MIoU 这一指标来展示各个类别的平均表现。具体而言，MIoU 通过计算每个类别的 IoU 并取其平均值，为每个类别提供了综合的性能评估。这种方法确保了评估的全面性，从而能够详细分析和比较网络在处理不同类别时的表现。


表 4.3 改进模块消融实验结果对比

方案	MIoU (%)	Overall Acc.	训练时长（时）
方案 1	76.4	95.9	34.6
方案 2	76.5	95.9	34.1
方案 3	76.8	95.9	34.9

相对于以 Xception 为主干网络的 DeepLabv3+网络，方案一对主干网络模块进行了改进，并以此作为基础网络，然后与方案二和方案三进行对比，以验证方案二和方案三中添加对应模块的必要性。在方案二中，引入了 HCSA。此改进不仅保留了原有的特征提取能力，还额外增强了网络对不同通道和空间信息的关注能力。通过该改进，网络能够获取更加丰富和多样的特征信息，从而有效提升了 MIoU 指标，改善了语义分割的效果。在方案三中，引入了 MSGa。该模块进一步增强了网络的性能，使其在处理不同尺度的特征时表现更加出色。引入这两种注意力机制使得网络在空间和通道两个维度上分配注意力资源更加合理，进一步提高了 MIoU 指标，表明网络的分割效果得到了一定的提升。从图 4.6 中可以看出，HHMENet 在 MIoU 和 Overall Acc.方面表现更加稳定，这表明网络在训练过程中能够更好地优化参数，避免了训练过程中的震荡和波动。



(a) 模块消融实验 MIoU



(b) 模块消融实验 Overall Acc.

图 4.6 改进模块消融实验对比


4.5.2 不同 Atrous Rates 的 ASPP 消融实验结果分析

为了更好的验证本章节设计的多尺度特征提取模块集成到 HHMENet 中的效能，本小节通过一系列消融实验对其进行全面分析。实验主要围绕不同 atrous rates 的配置变化展开，目的是深入探讨不同参数设置对网络性能的具体影响。这些实验不仅能够量化该模块在增强多尺度特征提取和捕获上下文信息方面的贡献，还能通过性能对比明确最佳的空洞率组合，揭示其在复杂场景下的表现。为了确保分析的全面性，实验设计中涵盖了多种空洞率配置，从而能够从多个维度评估该模块对分割精度的影响。通过对比不同参数下的网络表现，能够证明该模块在多尺度信息处理中


的重要性，尤其是在捕捉长距离依赖和细节信息之间的平衡上。此外，这些实验结果还将为后续网络设计提供依据，确保在保证分割网络高效性的同时，最大化分割性能的提升。

表 4.4 多尺度特征提取增强模块消融实验

Atrous Rates	MIoU (%)	Overall Acc. (%)	训练时长 (时)
6,12,18,24	75.9	95.9	34.1
6,12,18,24,30	75.6	95.8	34.5
6,12,18,24,30,36	76.6	95.9	34.6
6,12,18,24,30,36,42(本章方法)	76.8	95.9	34.9
6,12,18,24,30,36,42,48	76.4	95.9	35.2



(a) 多尺度特征提取增强模块消融实验 MIoU



(b) 多尺度特征提取增强模块消融实验 Overall Acc.

图 4.7 多尺度特征提取增强模块消融实验

在本小节的研究中，主要对不同 *atrous rates* 配置的 ASPP 模块进行了消融实验，以验证所设计的 ASPP 模块的有效性。实验结果如表 4.4 和图 4.7 所示。通过分析实验数据，可以看出，不同的空洞率配置对网络性能有着一定的影响。具体而言，在本章所设计的 ASPP 配置中，当空洞率设置为 6、12、18、24、30、36 和 42 时，网络的 MIoU 达到了 76.8%，Overall Acc. 为 95.9%。该结果表明，所设计的 ASPP 模块有效地增强了网络对多尺度特征的捕捉能力，提升了语义分割的精度和整体性能。然而，当进一步增加空洞率至 48 时，网络的 MIoU 略微下降至 76.4%。该现象表明，尽管增加更大的空洞率可以捕捉到更丰富的多尺度上下文信息，但过大的空洞率可能导致感受野过度重叠，或者引入过多的无关背景信息，反而对网络性能产生负面影响。因此，实验结果显示，在特定范围内适当增加空洞率更为有效。选择合适的空洞率配置，不仅可以充分利用多尺度特征，提高网络对不同尺度目标的辨识能力，还能避免由于过度扩大的感受野带来的性能下降。

4.6 实验三：与先进分割方法性能对比实验结果分析

为了全面评估本章节所设计的网络在图像语义分割任务中的效率与实用性，本小节设计了一系列对比实验，将该网络与当前主流及最新的图像语义分割技术进行了详细比较。为确保实验结果的公平性和准确性，本节统一采用了与第三章相同的训练策略和实验环境，确保所有比较方法在相同条件下进行评估。


表 4.5 与先进分割网络的实验结果比较（第一列括号中的数字代表该网络所提出的年份）

网络	MIoU (%)	Overall Acc. (%)	Params (M)	GFLOPs	训练时长 (时)
PSPNet (2017) ^[33]	61.6	93.6	49.0	194.4	38.1
FCN (2015) ^[23]	56.3	92.9	30.6	321.0	37.6
DANet (2019) ^[61]	63.3	94.1	47.5	205.5	37.3
DeepLabv3 (2018) ^[62]	61.2	93.9	42.1	180.9	36.1
DeepLabv3+ (2018) ^[46]	66.1	93.8	37.0	429.0	36.7
IkshanaNet (2022) ^[63]	54.8	95.7	4.0	413.3	34.2
SC-GAN (2021) ^[64]	55.9	95.5	66.2	126.0	30.1
CLADE (2021) ^[65]	58.5	95.5	67.9	75.5	29.7
INADE (2021) ^[66]	57.0	95.9	77.3	75.2	28.9
OASIS (2021) ^[67]	57.3	95.2	94.0	243.0	31.1
CCDM (2023) ^[68]	65.8	95.7	50.0	62.5	37.7


表 4.5 与先进分割网络的实验结果比较（第一列括号中的数字代表该网络所提出的年份）（续）

网络	MIoU (%)	Overall Acc. (%)	Params (M)	GFLOPs	训练时长 (时)
PIDNet (2023) ^[69]	80.6	-	34.4	194.7	31.8
BANet (2022) ^[70]	82.5	-	54.6	347.0	32.3
本章方法	76.8	95.9	32.7	107.8	34.9

在本小节的实验中，该网络的 MIoU 相较于表 4.5 中列出的其他现有方法实现了较高的分割精度。此外，通过图 4.8 中不同方法的可视化数据对比可以看出，改进后的网络不仅在 MIoU 和 Overall Acc. 等关键评价指标上普遍优于其他主流和先进的语义分割网络，而且在整个训练过程中表现出更高的稳定性。网络的稳定性体现在参数优化和更新过程中波动较小，有效避免了训练阶段的剧烈波动。该特性有助于在预测过程中保留图像的细节信息，从而提升预测的准确性和整体性能。



(a) 与先进分割方法性能对比实验 MIoU



(b) 与先进分割方法性能对比实验 Overall Acc.

图 4.8 与先进分割方法性能对比实验

在本小节中，在网络中引入了 HCSA 和 MSGA 双注意力模块，对语义分割网络进行了设计与改进。这两个模块分别从不同的维度对特征图的提取和处理进行了深度优化，增强了网络的表达能力和鲁棒性。具体而言，HCSA 模块通过结合通道注意力和空间注意力机制，细化了特征的选择与增强，确保了重要特征的有效利用；而 MSGA 模块则通过多尺度全局注意力的引入，进一步提升了网络在捕捉不同尺度下的全局信息的能力。

实验结果显示，通过引入这两个注意力机制，本章所设计的网络在语义分割任务中达到了 76.8% 的 MIoU 和 95.9% 的 Overall Acc.，同时保持了合理的 32.7M 参数量以及 107.8G 的计算复杂度。

4.7 实验四：跨数据集性能验证对比实验结果分析

尽管 Cityscapes 数据集上的实验结果充分证明了所提出改进网络在城市街景图像分割任务中的出色性能，为了更加全面地评估该网络的分割性能，并深入比较其与 DeepLabv3+ 系列网络在更广泛图像分割任务中的表现，本研究设计了跨数据集性能对比实验。这些实验的核心目标是测试 HHMENet 在不同数据集和多样化视觉场景中的表现，以验证其在更广泛应用中的适应性和鲁棒性。为此，本小节选择了在 PASCAL VOC 2012 Augmented 数据集进行测试。通过在该数据集对网络进行实验，不仅可以深入分析改进后的网络在应对多样化数据集时的适应性，还可以评估它在处理多种物体类别、复杂场景、多种物体形态和不同姿态等挑战时的表现。此外，通过将实验结果与 DeepLabv3+ 系列网络的性能进行对比，可以更清晰地揭示改进网络在跨数据集性能验证中的优势或不足。这种对比分析有助于进一步探讨改进网络在不同任务和数据集之间的分割能力，评估它在城市街景图像分割之外，能否在其他具有挑战性的场景中保持良好的表现。


表 4.6 跨数据集性能验证实验结果对比

网络	主干网络	MIoU (%)	Overall Acc. (%)	Params(M)	GFLOPs	训练时长 (时)
DeepLabv3+	ResNet50	76.3	94.7	40.2	59.8	35.1
DeepLabv3+	ResNet101	76.2	94.2	59.2	79.3	36.9
DeepLabv3+	MobileNet	70.2	92.9	5.2	17.0	29.8
DeepLabv3+	Xception	71.3	93.3	37.5	50.6	42.5
本章方法	HRNetV2	75.8	94.4	31.7	59.8	30.7


在本小节中，重点验证了 HHMENet 在 PASCAL VOC 2012 Augmented 数据集上

的分割性能，以评估其在不同图像分割任务中的适用性和有效性。通过深入实验分析，如表 4.6 和图 4.9 所示，HHMENet 在该数据集上实现了 75.8% 的 MIoU，与当前领先的图像分割网络相比，本章所提出的网络在这些关键指标上的出色表现，进一步验证了其在细致的像素级语义分割任务中的能力。HHMENet 在保持较低参数量和计算开销的同时，仍能实现如此高的分割精度。这表明网络在设计中有效平衡了效率与性能，不仅节省了计算资源，还为在资源受限环境中的应用部署提供了可能性。

HCSA 和 MSGA 模块的设计不仅提升了网络对细节信息和全局特征的处理能力，还通过多尺度特征的有效融合，进一步增强了网络在不同复杂场景中的适应性。这些模块从通道、空间和尺度等多个维度入手，对特征图进行了优化，确保网络能够更精准地捕捉并利用图像中的关键信息。此外，HCSA 模块通过聚焦重要特征，减少了不相关信息的干扰，提升了细节处理的精度，而 MSGA 模块则通过多尺度融合，增强了网络对全局信息的综合分析能力。



(a) 跨数据集性能验证对比实验 MIoU



(b) 跨数据集性能验证对比实验 Overall Acc.

图 4.9 跨数据集性能对比实验

4.8 本章小结

在本章中，提出了基于多尺度信息整合的城市街景语义分割网络 HHMENet，旨在解决当前语义分割任务中多尺度信息整合不充分等问题。该网络通过集成混合通道空间注意力机制、多尺度全局注意力机制、以及扩展的空洞空间金字塔池化模块，在特征提取和语义分割精度方面取得了一定的提升。

首先，在 HHMENet 中本章设计了混合通道空间注意力机制模块，该模块通过自适应地调整不同通道和空间位置的特征权重，进一步增强了网络对关键特征的提取能力，使其在处理复杂场景时表现得更加准确和稳定。此外，HHMENet 还引入了多尺度全局注意力机制模块，该模块通过全局平均池化提取上下文信息，并利用不同膨胀率的卷积层提取多尺度特征，使得网络能够更好地处理具有不同尺度的目标物体，提升了网络的泛化能力。为了进一步强化对多尺度信息的捕捉，该网络在多尺度特征提取增强模块中同时增加了额外的空洞卷积层，形成了扩展的多尺度特征提取增强模块。该模块扩展了网络的感受野，确保了在更广泛的尺度范围内捕捉到丰富的上下文信息，从而提升了网络的整体分割性能。

在 Cityscapes 和 PASCAL VOC 2012 Augmented 数据集上的实验结果表明，基于多尺度信息整合的城市街景语义分割网络在多个关键性能指标上均超越了现有的主流分割网络。在 Cityscapes 数据集中，该网络展示了极高的分割精度和鲁棒性，验证了其在处理复杂城市街景图像时的优越性。而在 PASCAL VOC 2012 Augmented 数据集的跨数据集性能验证实验中，其同样表现出色，达到了较高的 MIoU 和 Overall Acc.，同时保持了较低的 GFLOPs 和 Params。这些实验结果表明，该网络不仅在精度上占据优势，同时在计算资源的利用上也表现出较高的效率。

第五章 总结与展望

5.1 总结

随着深度学习技术的持续进步和发展,其在自动驾驶技术等多个应用场景中的应用日益增多,尤其在提高自动驾驶系统的视觉识别能力方面发挥了关键作用。为确保自动驾驶车辆的安全行驶,图像语义分割技术,作为计算机视觉技术的一个重要分支,对于为自动驾驶系统提供精确的视觉信息至关重要。该技术使得自动驾驶车辆能够有效地解析和预测其所处复杂城市环境中的各种信息,进而确定安全可靠的行驶路线。然而,自动驾驶在城市环境中面临的挑战尤为复杂,要求车辆必须能够实时接收并准确处理相关视觉信息。现有的图像语义分割网络在面对此类需求时,往往难以同时满足高准确性和高实时性的要求,且网络结构复杂,移植性较差。论文主要完成了以下工作:

1.第一章阐述了卷积神经网络的研究现状,并从三个方面阐述了城市街景图像语义分割的研究现状。(1)基于阈值、边缘、聚类及图论的方法;(2)基于候选区域、基于概率图模型和基于分割掩膜的方法;(3)基于深度学习的方法。

2.第二章对卷积神经网络和图像语义分割网络进行研究。对于卷积神经网络,研究了其组成结构。对于图像语义分割网络,研究了 SegNet、U-Net 和 DeepLab 系列网络,分析了各个网络的原理。在此基础上学习并研究了网络模型复杂度、迁移学习和注意力机制的原理。

3.第三章对 DeepLabv3+网络中的各个模块进行了设计优化。首先,本文将 DeepLabv3+的主干网络更换为具有高分辨率表示的 HRNetV2 网络,分析第三章的实验二的结果可知,当主干网络为 HRNetV2 时,能够使网络的参数量和 GFLOPs 显著降低,同时也较为明显的提高分割精度。其次,为了更大程度的扩大网络的感受野,将原始 DeepLabv3+网络中的 ASPP 模块进行了改进,在原始基础上又额外增加了 3 个 atrous 卷积,实验结果表明,该改进可以捕获更多的高级语义信息和低级上下文信息,提高网络的分割精度。此外,在编码器和解码器阶段分别引入 CBAM 和 SE 注意力机制,这两个模块可以充分使用特征图的空间信息和通道信息,从而提高网络的分割精度。然后,为了解决数据集中类别不平衡等问题,引入重构权重损失函数,优化 DeepLabv3+的交叉熵损失函数,提升网络对困难样本的分割能力和精度,实验结果表明优化后的交叉熵损失函数加快了网络的收敛速度和提高了网络的分割精度。最后,将 HRDLNet 与先进的分割网络在 Cityscapes 数据集上进行性能对比,

由实验结果可知, 本文的 HRDLNet 的参数量为 33.9M, GFLOPs 为 115.2G, 相比于其他先进分割网络, 本文所提出的改进网络降低了模型复杂度, 同时也取得了较为理想的分割性能。此外, 对本文所提出的改进网络在 PASCAL VOC 2012 Augmented 数据集上进行了跨数据集性能验证, 由表 3.9 可知, 在该实验中, 不仅在分割精度上占据明显的优势, 同时在网络效率方面, 第三章所提出的网络也表现出了明显的优势性能。综合第三章的五个实验, HRDLNet 在完成城市街景图像分割任务时表现优秀。

4.第四章基于 HRDLNet 及当前主流分割网络, 进行了一系列优化设计。首先, 第四章设计了一种 HCSA, 通过将 HCSA 集成在 DeepLabv3+网络中, 使得该网络可以自适应的对不同特征进行加权。通道注意力机制通过对每一个通道进行加权, 增强了图像中的重要特征; 空间注意力机制则对不同空间位置的特征进行加权, 使网络能够更好的关注重要的空间区域, 这种结合有助于捕捉全局和局部特征, 提升语义分割的性能。其次, 还设计了一种 MSGA, 通过将 MSGA 集成在该网络中, 使得该网络能够通过自适应平均池化提取全局上下文信息, 利用多个不同膨胀率的卷积层提取多尺度特征, 并结合全局上下文信息进行加权。此外, 本章在 ASPP 模块中新增了 4 个 atrous 卷积, ASPP 模块通过使用不同膨胀率的卷积来捕获多尺度信息, 新增 4 个 atrous 卷积进一步增强了信息捕获能力, 使网络能够捕捉更丰富的多尺度特征。最后, 由表 4.5, 将 HHMENet 与先进的分割网络在 Cityscapes 数据集上进行性能对比, 由实验结果可知, HHMENet 的参数量为 32.7M, GFLOPs 为 107.8G, 相比于其他先进分割网络, 该网络降低了模型复杂度, 同时也取得了较为理想的分割性能。此外, 对本文所提出的 HHMENet 在 PASCAL VOC 2012 Augmented 数据集上进行了跨数据集性能验证, 在该实验中, 不仅在分割精度上占据明显的优势, 同时在模型效率方面, 第四章所提出的网络也表现出了明显的优势性能。综合第四章实验, HHMENet 在完成城市街景图像分割任务时表现优秀。

5.2 展望

虽然本文提出的两个语义分割方法相比于当下较为先进的分割方法在 Cityscapes 数据集上都取得了不错的分割结果, 特别是对于分割精度以及模型效率等方面, 本文方法都较为明显的优于其他方法。但是本文方法仍然存在一些需要优化改进的地方。

(1) 为了实现精度高的语义分割效果, 通常需要庞大的数据集来训练语义分割网络, 而在真实的城市街景中, 拥有数据量大、均匀分布及优良的数据集少之又少,

则会导致当前图像分割精度难以有较大的突破，故制作质量高的数据集有利于提升图像分割的精度。

（2）在自动驾驶系统应用中，仅仅依靠优化图像语义分割算法是远远不够的，还需结合其他计算机视觉技术来改进分割，并将该复杂问题用在移动设备上达到实用价值的目的。

（3）本文网络的分割精度在某些类别上的分割精度较低，比如：自行车，这些都是将自动驾驶技术应用到实际生活中的挑战，因此还需对算法进行优化。

（4）本文的研究内容是城市街景的语义分割，其实本文方法同样适用于其他场景的语义分割工作，这也是后续研究的重点。

参考文献

- [1]Asgari T S, Abhishek K, Cohen J P, et al. Deep semantic segmentation of natural and medical images: a review[J]. Artificial Intelligence Review, 2021, 54(1): 137-178.
- [2]黄鹏, 郑淇, 梁超. 图像分割方法综述[J]. 武汉大学学报(理学版), 2020, 66(6): 519-531.
- [3]Hubel D H, Wiesel T N. Receptive fields and functional architecture of monkey striate cortex[J]. The Journal of physiology, 1968, 195(1): 215-243.
- [4]LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [5]Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [6]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv: 1409. 1556, 2014.
- [7]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[J]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 1-9.
- [8]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[J]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [9]Li C, Xia W, Yan Y, et al. Segmenting objects in day and night: Edge-conditioned cnn for thermal image semantic segmentation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(7): 3069-3082.
- [10]王嫣然, 陈清亮, 吴俊君. 面向复杂环境的图像语义分割方法综述[J]. 计算机科学, 2019, 46(09): 36-46.
- [11]Kwak N, Dong K, Kim Y, et al. Color image segmentation using edge and adaptive threshold value based on the image characteristics[J]. Proceedings of the IEEE, 2004, 87(12): 555-558.
- [12]Xiang Z, Bao A, Su J, et al. Hybrid birds-eye edge based semantic visual slam for automated valet parking[J]. 2021 IEEE International Conference on Robotics and Automation (ICRA), 2021, 56(29): 11546-11552.
- [13]Subudhi S, Patro R, Biswal P, et al. Superpixel clustering based segmentation algorithm for Hyperspectral Image classification[J]. 2019 International Conference on

- Information Technology, Bhubaneswar, 2019, 42(16): 371-375.
- [14] Brito A and Cruvinel P, Tomographic image segmentation model for features extraction of oilseeds based on graph theory[J]. 2020 IEEE 14th International Conference on Semantic Computing, 2020, 30(40): 341-346.
- [15] 田萱, 王亮, 丁琪. 基于深度学习的图像语义分割方法综述[J]. 软件学报, 2019, 30(2): 440-468.
- [16] Chen H, LU F, Fan K, et al, Image semantic segmentation based on region and deep residual network[J]. 电子与信息学报. 2019, 41(11): 2777-2786.
- [17] Van R, Lin H, Qiao Y, et al, Development of a 3D semantic segmentation camera based on mask regional convolutional neural network[J]. 2019 International Conference on System Science and Engineering, 2019, 21(30): 98-102.
- [18] Zheng S, Jayasumana S, Romera B, et al. Conditional random fields as recurrent neural networks[J]. 17th IEEE International Conference on Computer Vision, 2017, 29(21): 1529–1537.
- [19] FVisin F, Ciccone M, Romero A, et al. A recurrent neural network- based model for semantic segmentation[C]. 29th IEEE Conference on Computer Vision and Pattern Recognition Workshops. IEEE, 2016: 426-433.
- [20] Su C, Huang R, Liu C. Prostate MR image segmentation with self-attention adversarial training based on wasserstein distance[J]. Proceedings of the IEEE, 2019, 30(18): 184276-184284.
- [21] Xia Y, Zheng D, Li Q. Based on the improved Deeplabv3+ remote sensing image semantic segmentation algorithm[J]. 2019 4th International Conference on Advanced Electronic Materials, 2019, 28(24): 717-720.
- [22] Yang Z, Zou Y. U-GAN: Generative adversarial networks with U-Net for retinal vessel segmentation[J]. 2019 14th International Conference on Computer Science & Education, 2019, 57(19): 642-646.
- [23] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 3431-3440.
- [24] Li K, Ding G, Wang H. L-FCN: A lightweight fully convolutional network for biomedical semantic segmentation[C]. 2018 IEEE International Conference on Bioinformatics and Biomedicine. IEEE, 2018: 2363-2367.
- [25] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions. arXiv preprint

- arXiv:1511.07122, 2015.
- [26]梁格颖, 王文琪, 霍智勇. 基于空洞卷积的语义图像分割算法研究[J]. 信息通信, 2019(06): 33-36.
- [27]Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]. 18th International Conference on Medical Image Computing and Computer-Assisted Intervention. IEEE, 2015: 234–241.
- [28]Li P, Zhang L, Qiao Jan, et al. A semantic segmentation method based on improved u-net network[C]. 2021 4th International Conference on Advanced Electronic Materials. IEEE, 2021: 600-603.
- [29]Badrinarayanan V, Kendall A, Cipolla R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(12): 2481–2495.
- [30]Dong Y, Li F, Hong W, Ren H. Land cover semantic segmentation of port area with high resolution SAR images based on SegNet[J]. 2021 SAR in Big Data Era, 2021, 40(21): 1-4.
- [31]Paszke A, Chaurasia A, Kim S. Enet: A deep neural network architecture for real-time semantic segmentation. Ar Xiv preprint ar Xiv: 1606.02147, 2016.
- [32]Chen L, Yang Y, Wang J. Attention to scale: Scale-aware semantic image segmentation[C]. 29th IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 3640–3649.
- [33]Zhao H, Shi J, Qi X. Pyramid scene parsing network[C]. 30th IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 6230–6239.
- [34]Li H, Chou H, Qin J. AttentionNet: Learning where to focus via attention mechanism for anatomical segmentation of whole breast ultrasound images[C]. 2019 IEEE 16th International Symposium on Biomedical Imaging. IEEE, 2019:1078-1081.
- [35]Xiong Z, Wang Z, Li R. Using Features Specifically: An efficient network for scene segmentation based on dedicated attention mechanisms[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 39(43): 217947-217956.
- [36]Zhang Y, Chen Y, Ma Q. Dual Lightweight network with attention and feature fusion for semantic segmentation of high-resolution remote sensing images[J]. 2021 IEEE International Geoscience and Remote Sensing Symposium, 2021, 50(24): 2755-2758.
- [37]Liang-Chieh C, Papandreou G, Kokkinos I, et al. Semantic image segmentation with deep convolutional nets and fully connected crfs[C]. International conference on

- learning representations. 2015.
- [38]Chen L C, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.
- [39]Kamal K C, Yin Z, Wu M, et al. Depthwise separable convolution architectures for plant disease classification[J]. Computers and Electronics in Agriculture, 2019, 165: 1049-1054.
- [40]Guo J, Li Y, Lin W, et al. Network decoupling: From regular to depthwise separable convolutions[J]. arXiv preprint arXiv:1808.05517, 2018.
- [41]Liu B, Zou D, Feng L, et al. An fpga-based cnn accelerator integrating depthwise separable convolution[J]. Electronics, 2019, 8(3): 281-285.
- [42]Zhou Q, Wang Y, Liu J, et al. An open-source project for real-time image semantic segmentation[J]. Sci. China Inf. Sci., 2019, 62(12): 227101.
- [43]Asgari Taghanaki S, Abhishek K, Cohen J P, et al. Deep semantic segmentation of natural and medical images: a review[J]. Artificial Intelligence Review, 2021, 54(1): 137-178.
- [44]Guo Y, Liu Y, Georgiou T, et al. A review of semantic segmentation using deep neural networks[J]. International journal of multimedia information retrieval, 2018, 7(2): 87-93.
- [45]Li Y, Shi T, Zhang Y, et al. Learning deep semantic segmentation network under multiple weakly-supervised constraints for cross-domain remote sensing image semantic segmentation[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 175: 20-33.
- [46]Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
- [47]Li L, Qian B, Lian J. et al. Traffic scene segmentation based on RGB-D Image and deep learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(5): 1664-1669.
- [48]Marreiros A, Daunizeau J, Kiebel S J, et al. Population dynamics: variance and the sigmoid activation function[J]. 2008 International Conference on System Science and Engineering, 2008, 42(1): 147-157.
- [49]Leshno M, Lin V, Pinkus A, et al. Original Contribution: Multilayer feedforward

- networks with a nonpolynomial activation function can approximate any function [J]. Neural Networks, 1991, 6(6): 861-867.
- [50]Baheti B, Innani S, Gajre S, et al. Semantic scene segmentation in unstructured environment with modified DeepLabV3+[J]. Pattern Recognition Letters, 2020, 138: 223-229.
- [51]Liu X, Yan W Q, Kasabov N. Vehicle-related scene segmentation using CapsNets[C]. 2020 35th International Conference on Image and Vision Computing, 2020: 1-6.
- [52]李琳辉, 钱波, 连静. 基于卷积神经网络的交通场景语义分割方法研究[J]. 通信学报, 2018, 39(4): 8-15.
- [53]何淼楹, 崔宇超. 面向自动驾驶的交通场景语义分割[J]. 计算机应用, 2021, 41(S01): 6-12.
- [54]Zhao H, Qi X, Shen X, et al. Icnnet for real-time semantic segmentation on high-resolution images[C]. Proceedings of the European conference on computer vision, 2018: 405-420.
- [55]Kamal K C, Yin Z, Wu M, et al. Depthwise separable convolution architectures for plant disease classification[J]. Computers and Electronics in Agriculture, 2019, 165: 1049-1054.
- [56]Guo J, Li Y, Lin W, et al. Network decoupling: From regular to depthwise separable convolutions[J]. arXiv preprint arXiv:1808.05517, 2018.
- [57]Liu B, Zou D, Feng L, et al. An fpga-based cnn accelerator integrating depthwise separable convolution[J]. Electronics, 2019, 8(3): 281-285.
- [58]Cao B, Pan S J, Zhang Y, et al. Adaptive transfer learning[C]. proceedings of the AAAI Conference on Artificial Intelligence, 2010: 407-412.
- [59]Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [60]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [61]Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 3146-3154.
- [62]Chen L C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation. arXiv[J]. arXiv preprint arXiv:1706.05587, 2017, 5.
- [63]Daliparthi V S S A. The Ikshana Hypothesis of Human Scene Understanding[C].

- Proceedings of the Satellite Workshops of ICVGIP 2021. Singapore: Springer Nature Singapore, 2022: 161-181.
- [64]Wang Y, Qi L, Chen Y C, et al. Image synthesis via semantic composition[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 13749-13758.
- [65]Tan Z, Chen D, Chu Q, et al. Efficient semantic image synthesis via class-adaptive normalization[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(9): 4852-4866.
- [66]Tan Z, Chai M, Chen D, et al. Diverse semantic image synthesis via probability distribution modeling[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 7962-7971.
- [67]Sushko V, Schönfeld E, Zhang D, et al. You only need adversarial supervision for semantic image synthesis[J]. arXiv preprint arXiv:2012.04781, 2020.
- [68]Zbinden L, Doorenbos L, Pissas T, et al. Stochastic segmentation with conditional categorical diffusion models[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 1119-1129.
- [69]Xu J, Xiong Z, Bhattacharyya S P. PIDNet: A real-time semantic segmentation network inspired by PID controllers[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 19529-19539.
- [70]Zhou Q, Qiang Y, Mo Y, et al. Banet: Boundary-assistant encoder-decoder network for semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 25259-25270.