

学校代号 10532

学 号 S180200310

分 类 号 U461.91

密 级 公开



湖南大学
HUNAN UNIVERSITY

硕士学位论文

基于核相关滤波和DeepSORT级联的 驾驶员人脸跟踪算法研究

学位申请人姓名 王秋丽

培 养 单 位 机械与运载工程学院

导师姓名及职称 曹立波教授

学 科 专 业 机械工程

研 究 方 向 汽车安全

论 文 提 交 日 期 2021年4月9日

学校代号：10532

学 号：S180200310

密 级：公开

湖南大学硕士学位论文

基于核相关滤波和 DeepSORT 级联的 驾驶员人脸跟踪算法研究

学位申请人姓名：王秋丽

导师姓名及职称：曹立波教授

培 养 单 位：机械与运载工程学院

专 业 名 称：机械工程

论 文 提 交 日 期：2021 年 4 月 9 日

论 文 答 辩 日 期：2021 年 5 月 20 日

答辩委员会主席：刘敬平教授

Research on Driver's Face Tracking Algorithm Based on cascading Kernel
Correlation Filtering and DeepSORT Tracking Algorithm

by

WANG Qiuli

B.E.(Jilin University) 2018

A thesis submitted in partial satisfaction of the

Requirements for the degree of

Master of Engineering

in

Mechanical Engineering

in the

Graduate School

of

Hunan University

Supervisor

Professor CAO Libo

April, 2021

摘要

近年来,由于驾驶员不当操作引起交通事故问题越来越多,这促使我们思考如何使用驾驶辅助技术来提高驾驶安全性。一些学者提出了驾驶员疲劳检测、分心驾驶检测等,这些基于图像的驾驶员检测技术需要依赖人脸检测,使人脸检测和跟踪成为人们关注的焦点。目前,针对人脸的跟踪主要使用基于检测的跟踪算法,但是此方法具有高度依赖检测的缺点,跟踪会随着检测的失败而停止。改进方法都是针对检测算法的优化,没有考虑检测失败情况下如何进行人脸跟踪的情况。

针对以上问题,本文提出一种级联跟踪算法,将融合多任务卷积神经网络(Multi-task Convolutional Neural Network, MTCNN)人脸检测算法的具有深度关联指标的简单在线跟踪算法(Simple Online and Real-time Tracking with a Deep Association Metric, DeepSORT)级联了传统的不完全依赖检测的核相关滤波(Kernel Correlation Filter, KCF)算法,用于减少驾驶员人脸跟踪过程漏检情况。

DeepSORT 算法中应用了行人重识别网络,将提取的特征用于数据关联,减少身份跳变问题。在本文中,重新设计了基于宽残差网络的深层应用于人脸的特征提取网络。并清洗一些人脸识别数据集,制作用于本文人脸特征提取网络的训练和检测数据集。通过网络训练和测试,得到 90.58% 的人脸识别准确度。在跟踪实验中,本文提出的跟踪算法身份跳变次数较 DeepSORT 算法有所减少。

设计了级联跟踪架构。驾驶员的面部检测和跟踪将通过 MTCNN 和 DeepSORT 算法完成。MTCNN 将完成驾驶员的面部检测,并将检测到的面部边界框传输到 DeepSORT 跟踪算法中。在此步骤中,我们将获得驾驶员的面部检测和跟踪边界框。随后,将检测的边界框传输到 KCF 跟踪算法。当未检测到驾驶员面部时,KCF 跟踪器将使用最后一帧检测信息来跟踪当前帧的驾驶员面部,将跟踪信息传输到 DeepSORT 算法,并在当前帧中重新识别驾驶员面部。如果检测没有丢失,我们仅将检测信息记录在 KCF 跟踪器中,而不启动跟踪器。

建立了针对驾驶员这一特定群体的数据集。利用驾驶模拟器,采集实时驾驶视频数据,并应用于本文提出的级联跟踪算法和 DeepSORT 跟踪算法,通过实验数据计算,本文提出的级联跟踪算法具有实时性,且跟踪准确度高于 DeepSORT 跟踪算法,能实现更稳定的驾驶员面部跟踪效果。

另外，在本文数据采集中，摄像头的具有不同的安装角度，可以为研究不同角度下驾驶员面部研究提供数据支持。

对比实验结果证明，本文提出的核相关滤波与深度关联在线跟踪方法的级联跟踪结构获得了最高 94.3%准确度的效果，在同一角度摄像头下，驾驶员人脸跟踪准确度较原来 DeepSORT 跟踪算法提高了 4%，驾驶员人脸漏检数量三个角度漏检总数减少了 60%。

关键词：驾驶员人脸跟踪；MTCNN;人脸特征提取；核相关滤波器；DeepSORT;级联跟踪算法

Abstract

In recent years, there have been more and more traffic accidents caused by improper operation by drivers, which makes us think about how to use Driver Assistance technology to improve driving safety. Some scholars have proposed driver fatigue detection and distracted driving detection. Image-based driver detection technology needs to rely on face detection. These methods make face detection and tracking become the focus of attention. At present, tracking of human faces mainly uses a tracking by detection algorithm, but this method has the disadvantage of being highly dependent on detection, and tracking will stop when the detection is failed. The basic improvement methods are optimized for the detection algorithm, without considering how to track the face in the case of a detection failure.

In response to the above problems, a cascaded tracking algorithm was proposed in the thesis, which combines the Multi-task Convolutional Neural Network (MTCNN) detection algorithm and applies it to the Simple Online and Real-time Tracking with a Deep Association Metric tracking algorithm (DeepSORT) cascading the traditional Kernel Correlation Filter (KCF) which does not rely entirely on detection algorithm, used to reduce the missed face detection in the drivers' face tracking process.

The Pedestrian re-identification network was applied in the DeepSORT algorithm, and the extracted features were used for data association to reduce the identity switch. In this thesis, the deep-layer feature extraction network based on wide residual network is redesigned. In addition, the existing face recognition datasets are cleaned, and the new training and detection datasets for the face feature extraction network are made in this thesis. Through network training and testing, a face recognition accuracy of 90.58% is obtained. In the tracking experiment, the number of identity switches of the cascaded tracking algorithm proposed in this thesis is less than that of the DeepSORT algorithm.

A cascaded tracking architecture is designed. The driver's face detection and tracking will be completed by the MTCNN and DeepSORT algorithm. The MTCNN will complete the driver's face detection and transfer the detected face's bounding boxes to the DeepSORT tracking

algorithm. In this step, the driver's face detection and tracking bounding boxes will be obtained. Subsequently, the detection of the bounding box is transmitted to the KCF tracking algorithm. When the driver's face is not detected, the KCF tracker will use the last frame of detection information to track the driver's face at the current frame, convert the tracking information into a deep SORT algorithm, and re-identify the driver's face in the current frame. If the detection is not lost, the detection information is only recorded in the KCF tracker without starting the tracker.

A dataset is collected for the specific group of drivers. The real-time driving video data is collected by using the Vehicle Driving simulator. The dataset is used to test the cascaded tracking algorithm designed in this article, and the comparison test with the original algorithm proves that the cascade tracking algorithm proposed in this article has better tracking effect and can realize a more stable driver's face tracking effect. In addition, in the process of data collection in this thesis, the cameras have different installation angles, which can provide data support for the study of the driver's face under different angles.

The comparative experiment results prove that the cascaded tracking structure of KCF and DeepSORT tracking algorithms proposed in this thesis achieves the highest accuracy of 94.3%. Under the same angle camera, the driver's face tracking accuracy is 4% higher than the original DeepSORT tracking algorithm, and the total number of missed detections on the three angles of the driver's face has been reduced by 60%.

Keywords: Driver's Face Tracking; MTCNN; Face Feature Extraction;
KCF; DeepSORT; Cascaded Tracking

目录

学位论文原创性声明	I
学位论文版权使用授权书	I
摘要	II
Abstract	IV
第 1 章 绪论	1
1.1 课题研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 人脸检测研究现状	3
1.2.2 跟踪算法研究现状	5
1.3 本文研究内容章节安排	8
1.4 小结	9
第 2 章 人脸检测算法实现	10
2.1 人脸检测方法	10
2.2 神经网络	10
2.2.1 神经网络概述	10
2.2.2 卷积神经网络	11
2.3 人脸检测理论	12
2.3.1 候选框	12
2.3.2 边框回归	14
2.3.3 非极大值抑制	15
2.3.4 人脸检测算法评价指标	16
2.4 基于三层级联网络的人脸检测算法 MTCNN	17
2.4.1 MTCNN 网络结构	17
2.4.2 人脸检测损失函数	19
2.4.3 检测效果	20
2.5 小结	21
第 3 章 人脸跟踪算法实现	22
3.1 人脸跟踪算法概述及框架	22
3.1.1 人脸跟踪概述	22
3.1.2 人脸跟踪架构	23
3.1.3 人脸跟踪实现难点	24
3.2 KCF 跟踪算法	24

3.2.1 KCF 理论概述	24
3.2.2 KCF 跟踪方法优缺点	25
3.3 DeepSORT 跟踪算法实现	26
3.3.1 DeepSORT 概述	26
3.3.2 DeepSORT 实现跟踪流程	28
3.3.3 DeepSORT 实现关键技术	29
3.4 小结	34
第 4 章 级联人脸跟踪架构设计	35
4.1 级联人脸跟踪架构设计	35
4.2 人脸重识别网络结构设计	37
4.2.1 残差神经网络	37
4.2.2 宽残差网络	38
4.2.3 人脸重识别网络结构	40
4.2.4 人脸重识别网络损失函数	40
4.3 KCF 跟踪算法和数据关联	42
4.4 人脸重识别网络数据集制作	43
4.4.1 数据集来源	43
4.4.2 人脸对齐	45
4.4.3 数据增强	46
4.5 小结	47
第 5 章 实验设计和结果分析	48
5.1 实验环境	48
5.2 人脸重识别网络训练及结果	48
5.2.1 模型训练方法	48
5.2.2 特征图可视化分析	49
5.2.3 训练结果分析	50
5.3 检测和级联跟踪实验	51
5.3.1 驾驶员数据集采集	51
5.3.2 实验结果及分析	53
5.4 小结	57
总结与展望	59
参考文献	61
附录 A 攻读学位期间完成的主要成果	66
致 谢	67

第 1 章 绪论

1.1 课题研究背景及意义

21 世纪以来,汽车作为重要的交通工具,越来越多的人购买和使用。据公安部统计,2020 年全国机动车数量较往年有所增加,汽车数量也包括在里面并有所增加;机动车和汽车驾驶人数也在不断增加,汽车驾驶人数量占我国人口四分之一以上^[1]。每年总体数量和趋势如图 1.1 所统计。




图 1.1 保有量走势图



图 1.2 中国机动车驾驶人数量及增速

但是由汽车带来的相关安全问题也日益凸显。可见,汽车虽然给人们带来方便,但是同时也产生安全问题。作为汽车行业的研究者,我们不仅将车辆安全重心放在被动安全设计上,也倾注努力在主动安全方面,逐渐思考和实现减少交通事故发生。我国每年道路交通事故导致的人员伤亡、财产损失达数十亿,最有效的解决办法是规避事故的发生,驾驶员则是导致事故发生的一个重要因素。因此,对于驾驶员驾驶检测系统的研发也逐渐得到关注。在汽车主动安全设计中,人们逐渐增加了针对驾驶员检测的研究。主要有疲劳检测,分心驾驶,驾驶员身份及年龄判别等。但是驾驶员检测具备实时性和鲁棒性特点,整个系统比较复杂,需要不断提高针对驾驶员检测的准确性。

如图 1.3 为我国在 2014-2019 年期间每年的交通事故统计结果^[2]。其中,有约 96% 的交通事故是由于驾驶员操作不当造成的,疲劳驾驶也是其中一个主要原因。




图 1.3 2014-2019 年中国车祸发生次数及死亡人数和交通事故受伤人数统计

驾驶人如果有睡眠问题、长时间不休息的驾驶车辆、和乘客聊天、注意力不集中和无证驾驶等行为极易发生道路交通事故^[3]。

针对驾驶员疲劳检测主要需要驾驶员人脸检测信息，常用的对驾驶员疲劳驾驶检测判定的依据有头部运动检测、通过关键点检测眼睛闭合频率、打哈欠频率等面部信息等。尹苍穹等人利用深度神经网络模型检测驾驶员眼睛和嘴巴位置关系和关键点，开发了疲劳状态分级警告系统^[4]。

年龄信息作为人体的一种重要生物特征，也可用于检测驾驶员是否不满足年龄要求违规驾驶^[5]，人脸信息还被应用于驾驶员身份判别，利用深度学习方法，对人群按照年龄段进行划分，再针对性的学习面部特征，对输入图像进行年龄评估，同时还可以保存识别到的人脸身份信息，在驾驶员进入驾驶环境的时候用于验证驾驶员身份，能够有效监测换人驾驶等违规行为。

驾驶员注意力不集中，或许会产生踩错刹车油门、不打转向、弯道不减速等行为，也即分心驾驶。而这些行为有可能会引起交通事故，比如在行驶过程中不观察路况信息，在路口、弯道、变道不观察车辆周围信息，还有诸如喝水，扭头和乘客聊天等非常危险的驾驶行为。通过对驾驶员注意力检测与判别，对驾驶员人脸进行检测，比如长时间侧脸，嘴动等，可以判断是否处在正常驾驶状态，如果没有，展开对分心驾驶行为的细致判别。电子科技大学唐诗超^[6]使用车载相机实时保存驾驶员图像，并且设计

了一套检测程序。将驾驶员图像输入该系统，可以实时判断驾驶员是否在分心驾驶。这些关键的辅助驾驶技术都是基于稳定可靠的驾驶员人脸检测信息，基于人脸检测跟踪信息进一步的进行人脸关键点检测、性别、年龄的判断。

在针对驾驶员人脸检测过程中，车内的环境下，天气、光照、逆光、驾驶员头部姿态变化等都会导致的驾驶员人脸检测准确性不够，实时性不高。视觉目标跟踪的目的是，如果给定目标在一定时间序列的视频的初始帧中的位置，便能定位到目标在后续帧中的准确位置。在驾驶员检测系统需要对驾驶员面部有实时性和准确性的检测要求，单纯的面部检测不能满足对准确性和实时性的高要求，因此需要对面部检测结果进行实时性的跟踪。

1.2 国内外研究现状

1.2.1 人脸检测研究现状

人脸检测作为目标检测的一个具体类别，旨在通过检测算法找出图像中是否存在人脸，并且通过算法获得人脸在图像中的位置。随着人工智能技术的发展，在智能门锁、智能车锁、视频监控等领域，人脸检测有很强的应用价值。同时，人脸检测在实际应用中遇到很多问题，比如人脸在图像中位置的任意性，人脸大小不一致性，人脸被遮挡，或者在图像中视角和姿态有所不同等，解决这些问题同时，人脸检测方法也在不断改进。

(1) 模板匹配算法

在人脸检测发展初期，人们采用比对的方式，也即模板匹配的方法。给定一个人脸模板图像，匹配被检图像中每一个位置，用类比的方法判断图像中是否有人脸，且要能够知道人脸在图像中的位置。目标检测按照对目标检测框的处理方式分为一阶段(One-stage)和两阶段(Two-stage)两种方法。一阶段方法速度快，直接使用主干网络(Backbone)回归物体的类别和位置信息。两阶段的方法是经过卷积神经网络(Convolutional Neural Networks, 简称 CNN)提取的卷积特征生成一系列样本候选框，再通过卷积神经网络进行训练，根据卷积特征完成样本分类，这样的网络结构使得检测准确度比较高。Rowley^[7]提出了一种具有代表性的两阶段的方法，在系统输入固定尺寸的图像，用一个基于神经网络的滤波器，得到系统二值化输出，1 代表人脸存在，-1 代表人脸不存在，可以解决近似正面人脸检测相关问题。Bo Wu 等人^[8]使用了两个神经网络解决了多角度人脸检测问题，第一个网络用于估计人脸的角度，然后把检测窗旋转该角度，第二

个网络主要用于判断对旋转后的图像，从而确定该图像是不是人脸。梁路宏等人^[9]通过关联多个模板匹配算法，一定程度上解决了正脸和多角度人脸检测问题。

(2) AdaBoost 框架

Boosting 是一种将多个中等准确度的“弱”假设通过组合从而寻找一个高准确度假设的方法。AdaBoost 算法基于组合的想法，将弱分类器逐层叠加得到分类效果强的分类器，是具有自适应性 Boosting 算法。Freund Y 等人考虑了在最坏情况下的动态分配问题，提出了一种解决动态分配问题的算法，同时应用乘法权值更新技术，提出的新的 Boosting 算法^[10]。Schapire R E 等人^[11]在一个扩展的框架中研究了 Boosting，在这个框架中，每个弱假设不仅产生预测的分类，而且还产生自评的置信分数，估计每个预测的可信度。微软研究院等研究的方法被称之为 VJ 框架^[12]，通过组合基于特征的检测器（Haar-like 特征）和分类器（级联 AdaBoost 算法）构建了新的检测器。VJ 框架检测速度比以前的算法提高了两个数量级，且精度非常高，但是该方法具有计算复杂度高的缺点。江伟坚^[13]等人在 VJ 框架基础上使用两组扩展 Haar-like 特征，并且用积分图给出特征组的计算方法，有效解决了该问题。但是，当在人脸姿态发生变化、图像中存在与人脸的灰度分布情况类似的区域时、光照变化等因素会导致 Adaboost 检测算法误检和漏检的情况。此后，衍生了很多基于 VJ 框架改进的人脸检测方法，比如基于 ACF 特征的人脸检测方法等^[14]。相比于基础的 Haar-like 特征，改进的方法效果更好。

(3) 深度学习框架

卷积神经网络最核心的思想是卷积运算。CNN 在图像领域应用非常多，通过卷积运算可以获取图像各个位置的浅层和深层特征，在获取图像各种特征之后，可以对图像进行检索、分类、语义分割、物体检测等。

卷积神经网络 Alex-Net 在 2012 年被 Hinton 等人提出，而且在当年的 ImageNet^[15]图像分类竞赛中获得巨大成功。人们越来越多的将 CNN 用于人脸检测问题，在精度上远高于 AdaBoost 框架。

在卷积网络在图像分类的成功后，跟随其快速发展，由于其在人脸检测性能上表现优异，在人脸研究领域，深度卷积神经网络成为主流方法，有基于区域的 CNN 方法^[16,17]和一些经过改进 CNN 的目标检测方法^[18,19]等。通用目标检测和分类的方法具有一定的高性能，但是在针对人面部检测领域无法达到令人满意的效果。在 Faster-RCNN 的基础上，Face-RCNN 的方法提出了一种具有鲁棒性的深度人脸检测方法^[20]，该方法首次集成在线样本硬挖掘(Online Hard Example Mining)、中心损失(Center Loss，

CL)和多尺度训练(Multi-Scale Training)三种技术。中心损失函数可最大程度地减少样本与学习的类中心之间的距离,作者将一个批处理中通过设置 1:1 的正负样本比例,在一定程度上解决了 Faster-RCNN 中 Softmax 函数的样本不均衡问题^[21]。在线样本硬挖掘技术主要选出 N 个正负样本,被选的样本在每次训练中损失最大。多尺度训练可以在训练阶段通过尺度缩放,弱化图片尺度对网络的影响,有利于检测小目标。因此 Face-RCNN 获得了良好的人脸检测性能。考虑到严重的遮挡和大的姿势变化, FacenessNet^[22]设计了一种使用 CNN 和属性监督来发现面部部位反应的新颖的方法。FacenessNet 在这些属性感知网络之间共享特征并从中生成建议区域,从而成功实现了从部分面部特征到整个面部的推理。但是论文^[23,24]提出的方法则需要独立的卷积网络来学习不同的面部反应。与 FacenessNet 相同, SSH^[25]和 S³FD^[26]是一阶段的方法,能够减少了网络运行时间并提高检测效率。两阶段的方法首先在第一阶段产生边界框,然后在第二阶段利用剩余的网络层来实现分类。吴素霞^[27]等人针对人脸检测提出一种两阶段的检测算法,首先使用选择性搜索策略判断哪些目标候选框可能存在人脸,其次将候选窗口输入到基于 Gabor 优化的 CNN 算法,进行特征信息提取并对其进行分类。此外,虽然 SSH 和 S³FD 方法的输入图像是尺度不变的,但是它们可以在网络的一次正向传递中同时从不同层检测具有不同比例的面部。一些文章也使用了在不使用图像金字塔的情况下处理多尺度图像的方法^[28,29]。Ranjan R 等人^[30]提出了 HyperFace 方法,不仅能够进行人脸检测,同时可以人脸关键点定位和性别检测等多种功能,但是该方法不能完成人脸识别任务。Li H 等人提出了一个三级级联的 CNN 网络用于快速人脸检测,但是该网络首先使用密集滑动窗口在整个图片上进行采样,这种方法效率低下,限制了网络的性能^[31]。MTCNN 由精心设计的三级 CNN 组成,是基于两阶段的人脸检测多任务级联算法,它联合了面部检测和对齐功能,并同时预测了面部和标记点的位置^[32]。相比之下, MTCNN 的第一级是一个完全卷积的网络,它可以接受任意尺度的输入图像,并使用卷积运算代替滑动窗口,从而大大提高了运行效率。2019 年 5 月, J Deng 等人^[33]提出了 RetinaFace 人脸检测算法, RetinaFace 是基于单阶段的人脸检测网络,最大的优点就是检测的速度不受人脸数量的限制。

1.2.2 跟踪算法研究现状

目标跟踪是一个过程,要在一定时间序列的视频中识别感兴趣区域。通过给定目标在视频中某一帧的位置、尺寸等状态,用跟踪方法估计该目

标在后续帧中的状态，并且能获取目标空间位置。

尽管人脸检测已经得到了很好的发展并解决了一些实际应用问题，但在实际应用中，在光照、遮挡等复杂环境中和相机抖动情况下，仅依赖检测的结果，检测框具有非常高的不稳定性。但是加入跟踪后的检测框却非常稳定，目标框平滑且不抖动，通过给出目标物体的标签对不同物体做了区分，同时能够通过赋予同一类型物体的不同的身份(Identity, ID)信息对同一类型物体做了区分^[34]。

同时用于驾驶员驾驶过程中人脸检测需要具备实时性，只有人脸检测不能满足实时性的高要求。因此人们引入了面部跟踪任务，旨在得到人脸特征在每个视频序列中位置的准确估计。通过分析面部特征的几何相关性，获得独立面部检测器，在获取人脸候选框的任务上具有非常高的鲁棒性。检测和跟踪的结合在面部检测方面取得了巨大的成就。

由于观测模型不同，目标跟踪算法又被分为生成式方法和判别式方法。根据其应用效果，常用的判别式跟踪方法有相关滤波和基于深度学习的方法。

生成式方法非常重要的理论是计算跟踪过程中目标的相似度。通过基于前一帧预测得到的目标与当前帧候选框的相似度对比，选择最相似的候选框标记为当前帧跟踪结果。

生成式模型出现最早，常见的有 L-K 光流法，粒子滤波和均值漂移(Mean Shift)等。L-K 光流法^[35]主要在目标跟踪中用于求解序列或帧与帧之间的光流关系和运动关系。粒子滤波算法^[36]是属于目标空间建模的方法，主要通过对目标的抽样粒子空间分布进行统计，缺点是需要大量的样本，计算量比较大。Mean Shift^[37]算法通过对目标颜色三通道数据进行分析，利用颜色直方图进行目标建模，然后经过迭代，得到目标的概率位置分布，缺点是对颜色的要求比较高，背景颜色非常影响算法的准确性，使用场景有限。张涛等人^[38]提出了基于多特征的 Mean Shift 人脸跟踪算法，该方法融合了局部三值模式(Local Ternary Patterns, LTP) 纹理特征，使用卡尔曼滤波器对目标进行检测，该算法的目标定位的准确性和跟踪性得到明显提高。

判别式方法是基于分类的目标跟踪算法，将目标视为前景，将不包含目标的区域视为背景，从而将匹配问题转换成了将目标从背景中分离的问题。

基于相关滤波器(Correlation Filter, CF)的跟踪器可以通过旋转，遮挡和其他干扰来跟踪复杂的对象，在基准数据集上有出色表现，同时又保持了较高的帧率。Ds Blome^[39]在论文中提出了合成平均滤波器(Average of

Synthetic Exact Filters, ASEF), 可以完全指定每个训练图像相关输出, 而在当时其他现有方法仅对每个训练图像指定一个输出值。尽管如此, ASEF 方法的训练方式不适用于跟踪。2010 年, Bolme 等又提出了最小输出平方误差和滤波器 (Minimum Output Sum of Squared Error Filter, MOSSE), 对单帧目标进行初始化具有稳定性^[40]。由相关滤波器衍生出来的判别式跟踪方法具有一个特点, 为了区分目标和周围环境, 这需要大量的训练样本。而且图像存在自然变化特性, 需要将训练样本进行平移和尺度变换, 经过变换后的样本再用来训练分类器, 但是存在将重叠像素判定为一样, 导致变换后的样本集比较冗余。JF Henriques 等人^[41]发现数据矩阵具有循环特性, 离散傅里叶变换是一种数学运算, 可以对角化该循环矩阵, 能够极大的减少存储量和计算量。提出了核相关滤波器 (KCF), 使用创新的循环矩阵来生成训练样本, 扩大了样本量。但是 KCF 中的目标边界框在跟踪过程中是固定的, 跟踪序列中对象大小的变化将导致跟踪失败。西安科技大学李睿^[42]使用了深度学习和相关滤波融合进行行人跟踪算法研究, 使用分组训练方法, 改进 KCF 算法在目标跟踪中的不足。

传统的判别式跟踪方法不依赖于检测信息, 人们对跟踪的要求越来越高, 对视频流的跟踪, 实时的跟踪, 深度学习的方法越来越多应用于跟踪问题。

Feichtenhofer C 等人^[43]提出了一种 ConvNet 架构, 引入相关特征关联跨帧的目标, 检测和跟踪相辅相成, 既可以完成基于目标帧的对象检测, 同时又完成跨帧的轨迹回归。由于输入图像的分辨率高, 因此需要在多个输入帧和检测之间进行权衡, 这将限制运行速度。

Bewley A 等人^[44]提出了 SORT (Simple Online and Realtime Tracking) 多目标跟踪方法, 该方法具有实时性, 首先使用 Faster RCNN 进行检测, 利用卡尔曼滤波器和匈牙利方法, 分别用于处理跟踪问题的运动预测和数据关联问题, 它使用边界框交并比距离来解决遮挡问题, 只是将前一帧和当前帧的检测结果提供给跟踪器, 检测失败会导致 ID 切换。SORT 跟踪算法旨在有效地关联对象, 并且让跟踪具有实时性特点。目标检测质量非常影响 SORT 算法跟踪性能, 论文指出在替换了检测器的情况下, SORT 算法跟踪质量有 18.9% 的提高。

在此基础上, 该团队提出了具有深度关联信息的实时在线跟踪算法 (DeepSORT), 该方法增加了外观信息以提高 SORT 的性能, 将许多计算复杂度置于离线预训练阶段, 在此阶段中, 我们在大规模人员重新识别数据集上学习深度关联指标。SORT 使用余弦距离衡量预测轨迹和检测框之间的相似性, 还提出了一种匹配的级联架构来解决检测与预测轨迹的关

联，身份 ID 变换减少了 45%，从而提高了目标丢失和遮挡的鲁棒性^[45]。

2016 年 Bertinetto 等人^[46]提出了用于目标跟踪的全卷积孪生神经网络 (Fully-Convolutional Siamese Networks，简称 SiamFC)。该方法用 SiamFC 作为基本的跟踪算法，并且使用端到端的形式进行训练，而且在实际应用中实时帧率很高，但是，该跟踪网络骨干网络是用的比较浅层的网络，没有充分利用深度神经网络的功能。

新疆大学的刘鹏^[47]研究了基于视频序列的目标人脸跟踪技术的研究，主要针对人脸跟踪中特征融合阶段，他在人脸检测问题上考虑了肤色问题，并且对自适应人脸特征跟踪方法进行改进，改进的 Staple 跟踪方法能够在一定程度上克服目标人脸移动、消失等问题。

由于智能检测算法还在发展过程中，存在未充分考虑人脸检测算法可能出现漏检等情况，针对人脸检测的跟踪应用发展还不完善。本文根据驾驶员实时检测特点，选择 MTCNN 检测和 DeepSORT 跟踪方法，但是该跟踪算法太依赖检测，没有考虑检测丢失情况下的跟踪问题，所以考虑级联传统判别式 KCF 跟踪器解决检测丢失情况下的跟踪问题。

1.3 本文研究内容章节安排

本文主要研究目的是以驾驶员疲劳检测、驾驶员分心驾驶检测为背景，将人脸检测和人脸跟踪应用于驾驶员实际驾驶过程中，通过对人脸检测和跟踪的国内外研究现状分析得出，驾驶员跟踪具有非常重要的意义，目前还没有考虑检测丢失情况下如何对驾驶员进行的一系列基于人脸图像的研究。本文研究目的是减少驾驶员人脸检测和跟踪过程中的漏检。

具体研究内容总结如下：

第一章：绪论。查阅大量国内外文献，了解现有的人脸检测和跟踪技术的出发点和原理，学习精华，发现研究中的缺点和不足，总结现有的检测和跟踪研究方法，结合到本文的研究中。

第二章：人脸检测算法实现。介绍目标检测算法的发展过程以及其在人脸检测领域的应用，对现实生活中重要的应用。通过对人脸检测算法国内外文献研究，对级联 CNN 的 MTCNN 算法进行研究，介绍 CNN 发展过程和工作原理，系统介绍该级联神经网络在人脸检测方面的技术和关键理论。最后详细分析 MTCNN 网络结构、检测过程并展示该算法人脸检测效果。

第三章：人脸跟踪算法实现。通过对人脸跟踪算法进行概述，引出人脸跟踪实现难点和多目标跟踪算法的广泛应用。详细介绍基于相关滤波的核相关滤波器原理和实现方法。同时详细分析深度学习在跟踪方面的

应用 DeepSORT 算法，详细分析实现数据关联和匹配的架构。为提取深度人脸特征做准备。

第四章：级联人脸跟踪架构设计。基于我国现在人脸跟踪的分析和研究，提出 KCF 和 DeepSORT 级联的跟踪算法。并对 DeepSORT 跟踪算法中重识别网络进行改进，适用于人脸深度特征提取的深度学习网络，并且进行人脸识别数据集制作。本章还着重展示本文设计的融合检测的级联人脸跟踪架构：DeepSORT 的跟踪取决于检测结果，它的输入必须是已经检测到的目标框，和它进行匹配的也是已经检测到的目标，如果这个目标下一帧没有检测到，DeepSORT 无法主动去搜索这个目标的框，当人脸检测丢失时，DeepSORT 也跟踪失败。而 KCF 是带有检测和跟踪的功能，能够使用上一帧的检测信息在下一帧中主动搜索目标的框，能够脱离检测信息进行一段时间的跟踪。本文设计该级联架构用于减少基于检测的人脸跟踪问题。

第五章：实验设计和结果分析。本章主要介绍实验平台，并进行人脸识别网络的训练，并对训练过程网络特征图进行可视化及分析。根据驾驶员人脸检测和跟踪特点，介绍驾驶员实验数据收集平台驾驶模拟器，并且进行志愿者视频采集工作，将采集视频用于检测级联跟踪架构的跟踪效果，并且和改进之前的模型进行对比分析，最后对跟踪结果做出评价。

1.4 小结

本章主要介绍人脸检测和跟踪算法对展开驾驶员相关研究的重要意义。简要阐述了目前国内外人脸检测和人脸跟踪的研究现状，通过分析跟踪的几种方法及优缺点决定选用如何减少基于检测的跟踪算法在跟踪过程中漏检问题为研究目标，提出级联跟踪架构作为本文的研究方向。总结目前人脸跟踪的方法，结合应用场景，决定采用级联跟踪算法进行驾驶员人脸检测和跟踪。最后介绍了本文的章节安排。

第 2 章 人脸检测算法实现

2.1 人脸检测方法

人脸检测主要由两部分工作构成：一个是需要判断图片中是否含有人脸区域，另一个是找到图片中人脸位置。人脸检测常见的方法有基于特征和知识、外观的方法、模板匹配和深度学习的方法。基于知识的方法指对于某种事物认知的先验知识，先验知识指是人们基于经验所知道内容，对于人脸的通常认识是五官，所以经过判断特征间的位置分布和距离可以完成对人脸的学习；模板匹配顾名思义就是建立人脸模板，通常拿需要检测的人脸特征和轮廓和模板进行对比；基于外观的方法使用分类器，完成对是否是人脸的判断并分类；基于深度学习的方法，在深度学习初期，人们将传统的计算机视觉方法应用于人脸检测，传统的计算机视觉方法依赖手工标注人脸特征，根据人脸特征训练一个分类器，因此也将人脸检测视为一个二分类问题。后来，卷积神经网络被用于人脸检测，并且得到良好的效果，成为了主流的应用方法。

2.2 神经网络

2.2.1 神经网络概述

科学家从很久之前就开始研究神经元，随着对生物神经元组织结构认识的进步，参考其结构模型，Pitts 和 Mc Culloch 两人将 MP 神经元模型提出并获得了巨大成功^[48]。

MP 模型模拟了生物神经元接受信号到输出结果的过程，神经网络在其基础上得到发展。人工神经网络主要由大量的神经元以及神经元之间的有向连接构成。科学家 Rosenblatt 提出感知器(Perceptron)，也叫做单层感知网络，由输入层和计算层组成^[49]。因为是单向传播，也叫做前馈神经网络。该网络使用线性激活函数，只能对线性问题进行分类。可以修改激活函数或者增加神经网络层数来改善这个问题。一般情况都会增加网络层数，在网络中间部分增加隐含层，而且在训练样本中不能观察到它们的值，也就是我们熟知的多层感知器(Multilayer Perceptron, MLP)。

MLP 带来了庞大的神经元数量，所以这种网络的计算量很大。Rumelhart 等人^[50]提出了反向传播算法解决在训练时 MLP 的计算量过大的问题。通常在神经网络训练过程中，将网络输出的真实值与目标值的

差值函数称为代价函数。反向传播算法就是将误差函数的值向后传播得到输出权重的梯度，将误差值在网络层中向前传播，并且通过误差得到当前网络层的权重梯度，依照梯度大小优化当前网络层的神经元参数，通过不断迭代，得到误差最小的模型参数。

2.2.2 卷积神经网络

卷积是通过积分变换使两个不同的函数生成第三个函数的操作。卷积神经网络(Convolution Neural Network, CNN)是具有卷积计算和前馈神经深度结构的典型深度学习算法。图 2.1 为卷积网络主要组成结构示意图。




图 2.1 CNN 组成结构示意图

卷积层是通过设定一定的卷积核滑动方式，对感受野进行卷积运算，从而获取各区域特征值的网络层。卷积层是 CNN 的核心层，在这一层要进行大量的卷积计算。一般来说，用于分类目标检测的卷积神经网络最后都会获得图像的高纬度特征输出，该高纬度特征包含网络的分类和评分情况，通常用一个向量表示，如图 2.2 所示，网络最后获得在深度方向排列的向量。卷积具有权值共享特性，所以能有效降低参数数量，可以防止参数过多模型产生过拟合问题。




图 2.2 卷积神经网络

池化层(Pooling)不学习权重系数，只是定义了一种从感受野获得值的运算方式，如最大值，均值等。池化层能够有效减少数据尺寸，从而减少网络中参数量和计算量。如图 2.3 所示。此外，池化注重是否存在某些特征具有平移、旋转、尺度特征不变性，而不强调特征所在的位置，而且池化在一定程度上具有防止过拟合的作用。




图 2.3 池化操作

全连接层(Fully Connected Layer, FCN)通过矩阵变换获得分布式特征，这些特征具有分类作用，再映射到样本标记空间。图 2.4 展示了全连接层网络结构。




图 2.4 全连接网络

2.3 人脸检测理论

2.3.1 候选框

候选框(Bounding box, Bbox)的生成是人脸检测过程中非常重要的一个步骤，候选框提供了人脸可能存在的位置，候选框的生成方式会直接影响人脸检测的速度和检测效率。随着目标检测技术的不断发展，常用的生

成候选框方法有滑动窗口和选择性搜索法。

滑窗法(Sliding window)通过给不同大小的滑窗设定滑动规律,并且滑动到每个位置都进行运算得到运算结果。最后结合训练过的分类器得到物体存在的概率。滑窗按照滑动规律运行到图像中各个位置,获得不同窗口检测到的物体标记,经过判别所有重复较高的部分窗口,再筛选获得检测人脸,滑窗法原理图如图 2.5 所示。虽然滑窗法容易理解,但是窗口过多导致全局搜索效率低下,不适用于实时性要求较高的分类器。




图 2.5 滑窗法示意图

选择搜索方法^[51] (Selective Search)是对图像中包含可能性最高的目标区域进行搜索方法,如果图像中存在某物体,那在图像中的物体所在区域某些像素点应该是连续且具有相似性。




图 2.6 选择性搜索方法

如图 2.6 所示,根据其定义,可以将图像分割为多个子区域。其次考

考虑图像中物体纹理、大小、颜色等特征的相似性，进行区域合并。最后经过不断的对子区域迭代和合并，每次迭代都有进行合并操作，合并后的子区域也要不断裁剪，一般用外切矩形进行裁剪，剪裁后的矩形就是候选框。

由以上的介绍可知，滑窗法遵循全局搜索特性，不放过任何一个部分，选择性搜索相较于滑窗法更具有针对性，所以计算效率高。而且通过子区域相似性合并，不放过任何一个可能存在某种物体存在的可能性，提供了各种疑似物体的框，这就使物体被检测到的概率大大提高。

2.3.2 边框回归

在论文 Faster R-CNN 中提出了边框回归^[19](Bounding box regression)的概念，利用平移变换和尺度变换实现映射。在应用中边框回归是将目标检测过程中产生的候选框逐渐逼近真实标注框的过程，将这个过程建模为回归问题，使得最终检测到的目标定位更加接近真实值，提高定位准确率。在候选框逐渐接近真实标注框的过程中，引入了重合度交并比(Intersection Over Union, IOU)的概念，指目标检测过程中产生的候选框与真实标注边界框之间的交集面积与两边界框组成的形状单元并集面积和的比值。如图所示 2.7 所示，比值越高，重合度 IOU 值越大，预测边界框位置越准确。




图 2.7 IOU 定义展示图

R-CNN 检测算法加入了边框回归的任务，边框回归方法可以调整候选框人脸窗口的大小和位置，从而使候选框更清楚的框住人脸目标^[52]。窗口一般用边界框中心点坐标、边界框宽和高四维向量 (x, y, w, h) 表示，代表边界框中心点坐标， w 和 h 分别代表。如图 2.8 所示， P 代表检测器给出的候选框(Proposal)， G 为处理数据集时候标记的真实标注框(Ground Truth)。




图 2.8 边框回归方法

边框回归是通过寻找一种关系 f ，该关系使建议目标可能存在的候选框 P 经过映射得到和标记的窗口更接近的回归框 $\hat{G}$ ，如式(2.1)和(2.2)。

$$f(P_x, P_y, P_w, P_h) = (\hat{G}_x, \hat{G}_y, \hat{G}_w, \hat{G}_h) \quad (2.1)$$

且

$$(G_x, G_y, G_w, G_h) = (\hat{G}_x, \hat{G}_y, \hat{G}_w, \hat{G}_h) \quad (2.2)$$

边框回归也主要通过平移变换和尺度变换操作完成。如式(2.3)和(2.4)，首先 P 完成平移操作：中心坐标平移量为分别为 Δx 和 Δy ，其中 $\Delta x = P_w d_x(P)$, $\Delta y = P_h d_y(P)$ 。

$$\hat{G}_x = P_w d_x(P) + P_x \quad (2.3)$$

$$\hat{G}_y = P_h d_y(P) + P_y \quad (2.4)$$

然后 P 完成尺度缩放操作，如式(2.5)和(2.6)：宽 w 和高 h 的缩放分别表示为 S_w 和 S_h ，其中 $S_w = \exp(d_w(P))$, $S_h = \exp(d_h(P))$ ，

$$\hat{G}_w = P_w \exp(d_w(P)) \quad (2.5)$$

$$\hat{G}_h = P_h \exp(d_h(P)) \quad (2.6)$$

边框回归实现 $d_x(P)$, $d_y(P)$, $d_w(P)$, $d_h(P)$ 四个变换。在网络模型中，真实输入特征向量 $X(P_x, P_y, P_w, P_h)$ ，经过变换 Δx , Δy , S_w , S_h 得到预测边框 $\hat{G}$ ，预测边框 $\hat{G}$ 是无限接近真实边框 G 。

2.3.3 非极大值抑制

非极大值抑制(Non-Maximum Suppression, NMS)是从检测过程中产生诸多候选框种筛选出最合适的候选框，合适是指保留的候选框与真实标注框重叠度最高。

在真实人脸检测过程中，对于同一个人脸会预测出多个候选框，分类器给每个候选框打分，分值代表候选框属于某一类的概率，同时设定 IOU 阈值，通过遍历所有的候选框，保留分值最高的候选框。NMS 的作用就

是通过去除多余的 Bbox，只保留和真实标注框重叠度最高的 Bbox。图 2.9 为非极大值抑制在人脸检测中的处理效果。




图 2.9 NMS 作用效果示意图

2.3.4 人脸检测算法评价指标

召回率(Recall):在目标检测中，会通过设定 IOU 阈值判断检测器是否检测出目标，大于该阈值则认为检测成功，召回率就代表检测出来的目标与标记总目标数量的比值。

$$Recall = \frac{\text{检测出来的人脸数量}}{\text{图像中总人脸数量}}$$

误检数(False Positives):通常是指非目标物体在检测过程中被误标记为目标，这个目标与真实标注框的 IOU 值小于设定的阈值，其个数就是误检数，表明检测器存在一定的错误风险，该数量越少越好。

检测速度(Speed):通常用每秒检测多少帧表示检测速度，称为帧率(Frame-Per-Second, FPS)。检测器检测一幅图像种是否存在目标需要花费一定的时间，该时间越少越好。




图 2.10 人脸检测算法性能判断

2.4 基于三层级联网络的人脸检测算法 MTCNN

2.4.1 MTCNN 网络结构

MTCNN 算法是级联三个 CNN 子网络的人脸检测算法,而且具备多任务级联的特性,不仅可以人脸检测,还能获得人脸特征点位置。相比较于 R-CNN 系列通用目标检测算法,在检测速度和精度上具有一定的提升^[32]。

该级联检测算法主要包括建议网络(Proposal Network, P-Net),细化网络(Refine Network, R-Net)和输出网络(Output Network, O-Net)三个子网络构成。首先采用对金字塔模型对图像进行不同尺度缩放, P-Net 是级联结构的第一级,主要是一个全卷积神经网络(FCN), FCN 网络没有全连接层,所以输入图像尺寸大小不受限制^[28]。如果网络中有全连接层,则输入的图片尺度一般需要固定。

怎么才能提高人脸检测的卷积神经网络的性能?经过总结,作者提出了两个主要影响因素:首先是样本的多样性,会影响模型泛化能力;其次是人脸检测相对复杂的分类任务会比较简单。所以不需要仿照别的卷积网络设置过多的过滤器(Filter),而且每层网络的特征图(Feature maps)个数不需要太多。于是作者在网络每层设计有限个数的过滤器,但是整个网络的深度有所增加,这种操作显著减少了网络计算量,有助于提高网络性能。同时全部改用 3×3 的过滤器,卷积核的大小直接影响计算量,小卷积核使得计算量更小,并且采用了非线性激活函数 ReLU 函数。MTCNN 结构设计如图 2.11 所示。

在 P-Net 中,将每一个 12×12 区域作为第一级人脸检测网络输入。一般输入 $12 \times 12 \times 3$ 的 RGB 图像,经历过卷积操作和最大池化操作,得到三个输出向量:

第一个输出向量大小为 $1 \times 1 \times 2$ 。该向量主要代表两个概率值,用于判断图像中有没有人脸存在。

第二个输出向量大小为 $1 \times 1 \times 4$ 。候选框左上角的坐标值和宽度高度值,用于描述候选框的精确位置。为了得到较好的人脸输出效果,也采用了边框回归,所以该向量是经过边框回归的候选框坐标值的偏移量和宽高偏差值。

第三个输出向量大小为 $1 \times 1 \times 10$ 。级联 MTCNN 算法具有人脸特征点坐标(facial landmark localization)检测功能,该向量代表了人脸 5 个关键点坐标,如图 2.12 所示。




图 2.11 MTCNN 三层子网络示意图



图 2.12 关键点位置示意图

P-Net 网络是对人脸进行比较粗略的检测，将生成的边界框输入到下一级网络 R-Net 进行细化，在进入第二级网络之前，将图像尺寸放大到

$24 \times 24 \times 3$ ，相比于 P-Net，R-Net 增加了一个全连接层，内部卷积层数增多，参数更多，更精确的选取候选框，这一操作排除了大量的非人脸框，剩余比较少的候选框，减少了下一层网络的计算量。

O-Net 网络进一步将 R-Net 的所得到的图像尺寸放大到 $48 \times 48 \times 3$ ，且比 R-Net 多了一层卷积层，参数数量进一步增加，精度大幅提升，得到置信度更高，边界坐标更精确的边界框。相较前两级网络，O-Net 显示人脸特征点定位，前两级只进行是否为人脸的分类，不显示人脸定点结果。

2.4.2 人脸检测损失函数

损失函数指的是预测的结果与真实结果之间的差距。由于 MTCNN 人脸检测算法网络具有三种任务输出，损失函数也由三部分组成，分别是人脸识别损失函数，候选框回归损失函数和关键点损失函数，网络总损失由三个损失函数按照不同权重组成。

针对是否是人脸的任务损失，针对输入样本 x_i ，使用比较平滑的交叉熵损失函数，用于人脸二分类问题。

相对熵又被称为 KL 散度，KL 散度的值越大代表两个分布概率之间的差异越大。对于同一个随机变量 X ，又两个单独的概率分布 $P(x)$ 和 $Q(x)$ ，两个概率分布之间的 KL 散度定义如公式(2.7)：

$$KL(P||Q) = \sum P(x) \log \frac{P(x)}{Q(x)} = \sum_{i=1}^n p_i \log(p_i) - \sum_{i=1}^n q_i \log(q) \quad (2.7)$$

$$L(P||Q) = -H(p(x)) + \left[- \sum_{i=1}^n p(x_i) q_i \log(q(x_i)) \right] \quad (2.8)$$

公式(2.8)是 KL 散度公式的变形，其中 $H(p(x))$ 代表事件 X 概率分布为 $P_{(X=x)} = p$ 时的信息熵，公式中另一项则为交叉熵，表示为公式(2.9)：

$$H(p, q) = - \sum_{i=1}^n p(x_i) q_i \log(q(x_i)) \quad (2.9)$$

在深度学习中，假设事件 $P(x)$ 为样本数据得到的真实分布， $Q(x)$ 为模型计算得出来的预测分布，在已知样本数据和标签的情况下， $P(x)$ 的信息熵 $H(p(x))$ 就是一个常量。在模型训练过程中我们希望预测值与真实值之间的差异尽量小，如何使交叉熵的值最小？可以使相对熵最小作为出发点，得到观测值和估计值最小值，由公式(2.8)可知，使 KL 散度值最小即可。

交叉熵损失函数被广泛应用于分类问题，比如人工神经网络和支持向量机等。如式(2.10)所示，真实样本标签用 y_i^{det} 表示，判断网络输出是不是人脸的概率用 p_i 表示。

$$L_i^{det} = -(y_i^{det} \log(p_i)) + (1 - y_i^{det})(1 - \log(p_i)) \quad (2.10)$$

针对框回归任务，使用欧氏距离(Euclid Distance)作为学习目标，欧氏距离变换主要通过对二值图像前景和背景色的区分，将前景中像素点的值转化为该点到达最近的背景点的距离，计算方式如式(2.11)所示。

$$L_i^{box} = \|\hat{y}_i^{box} - y_i^{box}\| \quad (2.11)$$

其中 $\hat{y}_i^{box}$ 代表网络输出之后校正得到的边界框坐标， y_i^{box} 是真实标注的边界框。

人脸关键点坐标定位任务的目标函数旨在最小化网络输出值与真实标注值的误差，通过前面对欧氏距离的介绍，也在此处进行应用。网络损失计算方式如式(2.12)：

$$L_i^{landmark} = \|\hat{y}_i^{landmark} - y_i^{landmark}\| \quad (2.12)$$

网络总损失为各个子任务损失与其权重乘积的总和，如式(2.13)：

$$\min \sum_{i=1}^N \sum_{j \in \{det, box, landmark\}} \alpha_j \beta_j^i L_j^i \quad (2.13)$$

N 代表训练样本总数， α_j 代表各个损失所占的权重。在 P-Net 和 R-Net 中，设置 $\alpha_{det} = 1, \alpha_{box} = 0.5, \alpha_{landmark} = 0.5$ ，在 O-Net 中 $\alpha_{det} = 1, \alpha_{box} = 0.5, \alpha_{landmark} = 1, \beta_j^i \in \{0, 1\}$ 表示样本类型指示符。

2.4.3 检测效果

MTCNN 在不同的数据集上训练人脸检测任务，也对人脸对齐任务进行了训练，有 Benchmark(FDDB)^[53]，FaceScrub^[54]，WIDER FACE^[55] 数据集等。总训练数据由 3:3:1:2(Negative/Positive/PartFace/LandmarkFace) 数据组成，Negative 代表负样本，IOU 值小于 0.3，图像中不包括人脸；Positive 代表正样本，IOU 值大于 0.65 图像中有人脸；PartFace 代表图像中部分有人脸，IOU 值介于 0.4 和 0.65 中间；LandmarkFace 代表有人脸关键点位置标记的图像，MTCNN 的输出验证准确性为 95%。

本文中使用 MTCNN 输出检测框作为 DeepSORT 跟踪算法的输入，由于不使用关键点坐标进行其他任务，所以在本文检测中不显示关键点。尽管这不是一个准确度非常高的面部检测模型，但 MTCNN 可以同时完成面部检测和对齐任务，这对于驾驶员人脸检测非常重要，MTCNN 算法检测效果如图 2.13 所示。




图 2.13 MTCNN 检测效果

2.5 小结

本章首先介绍了人脸检测相关方法，其次介绍了神经网络从生物神经元发展到单层感知器的过程，以及单层感知器过渡到多层感知器的研究以及反向传播算法在多层感知器中的应用。其次，本文介绍了卷积神经网络的网络架构以及在人脸检测中的应用和关键技术。最后，本章重点介绍了实现人脸检测的关键理论和详细分析基于级联 CNN 的人脸检测 MTCNN 算法，并展示了该算法在驾驶员驾驶过程中检测效果，为本文中使用 MTCNN 检测算法奠定理论基础。

第 3 章 人脸跟踪算法实现

3.1 人脸跟踪算法概述及框架

3.1.1 人脸跟踪概述

人脸跟踪可以获得目标在特定区域内的轨迹，根据目标数量的多少被分为单目标和多目标跟踪，根据跟踪条件又不同被分为静态和动态背景下的跟踪。

在静态背景中，相机会被固定在某一位置，其观察范围是固定且静止的。在这种情况下，针对单目标跟踪一般会采用建模方法，将背景固定，通过视频帧获取前景信息，从而将获取跟踪目标变为一个二分类问题，即经过前景背景分离，获取图像目标。然而面对多目标跟踪，因为每个目标的跟踪都需要很多信息，比如运动速度、方向、所在位置和特殊特征等。此时，图像帧的质量会大大影响跟踪效果，通常需要均值滤波、高斯平滑等预处理工作降低图像噪声，还能通过图像增强方法使跟踪算法更具泛化性能。

在动态背景中，摄像机会不是一成不变的，会被控制进行一些旋转，移动操作。因此，在这种情况下获得的图像是随着时间的不同而变化的，从而导致背景一直在改变，这使得目标跟踪变得非常困难。

多目标跟踪要在一定时间顺序的图像序列中找到每一帧图像中的运动物体，并识别。也就是给定一个确定的身份(ID)，无需事先了解目标的外观和数量。由于人是一个非刚体的目标，随着目标跟踪技术的发展，逐渐将其应用于行人跟踪，比如监控环境，行为分析等。基于人脸识别的商场引导机器人、家庭智能家居等越来越多商业化的产品应运而生，使得人脸检测和跟踪具有更多的商业化可能性，实现更好的应用。

多目标跟踪多被视为数据关联问题，在视频帧序列中进行跨检测结果的关联，为了解决数据相关的问题，跟踪器使用了多种方法对运动过程和运动目标的外观特征进行建模。与目标检测算法不同，目标检测算法的输出是一个由其坐标，高度和宽度标识的矩形边界框的集合，多目标跟踪算法也将目标 ID 关联到每个框，以便区分类内对象。

在多目标跟踪过程中，按照检测器的有无分为两种跟踪情况。一是需要检测器，要基于检测目标进行跟踪，简称为 TBD(Tracking By Detection)。二是不需要检测器，跟踪系统基于初始框进行目标跟踪，简称为 DFT(Detection Free Tracking)。现在多使用 TBD 目标跟踪算法，利用检

测得到的边界框进行数据关联实现跟踪。梁路宏^[56]等人使用人脸检测器得到人脸初始位置,然后利用先后两帧图像信息,将前一帧的检测信息,利用算法预测出目标在下一帧的位置和尺度大小,经过证明,该 DBT 的方法在图像序列复杂且背景有动态变化时产生了作用,可用于实时性系统。

另外,根据数据关联方式不同,多目标跟踪算法又被分为在线(On-Line)和离线(Off-Line)两种方法。

离线学习方法,即需要一段视频完全通过检测器检测之后,利用所生成的边界框做数据关联。数据关联方法有最大流最小割(Max Flow Mini Cut)、条件随机场(CRF)、K-Partite Graph、Multicut、马尔可夫随机场(MRF)等,主要是涉及组合、图论或者是概率图模型中的一些方法。离线学习方法,通过比较相邻帧之间的相似度生成短的轨迹,之后再将短的轨迹合成成长的轨迹,缺点在于无法实时处理视频。

在线学习方法,只能使用当前帧及之前帧的信息来进行当前帧的跟踪。主要数据关联方法有匈牙利算法(Hungarian Algorithm)和马尔可夫决策过程(MDP)算法。MDP 算法把多目标跟踪当作强化学习,该方法第一次将强化学习加入到跟踪这个领域,将目标的跟踪周期建模成马尔可夫过程进行优化^[57]。

在计算机视觉技术中,多目标跟踪技术至关重要,尤其在汽车应用行业,现在逐渐发展的自动驾驶技术,目标跟踪将会是推动其发展的重要环节,不仅可以对车内驾驶员和乘员进行跟踪,也能对车外行人、车辆和其他运动物体进行跟踪,从而提高自动驾驶技术的安全性。

3.1.2 人脸跟踪架构

视觉目标跟踪是通过在时间序列连续的视频帧中,在最后一帧图像中找的前一帧目标的过程。将目标跟踪的对象确定为人脸,也即跟踪目标为人脸。人脸跟踪有三个关键步骤:

(1)初始位置的确定:检测到的人脸目标,用于预判下一帧位置,即候选框生成;

(2)特征表达和提取:提取人脸特征、目标运动信息以及其他特征;

(3)决策:根据前两步输出结果,利用前一帧中的信息在当前帧中鉴别目标。




图 3.1 人脸跟踪示意图

根据图 3.1，可以看出，在人脸跟踪过程中，有三个模型，分别是运动模型、特征模型和观测模型。运动模型指随着人脸移动，人脸检测框位置的移动，其输入为上一帧图像和当前帧图像，通过两帧图像关联，输出为人脸检测框信息；特征模型指对人脸检测框进行各种特征分析，输入为人脸检测框，通过分析人脸检测框信息，输出为候选框和图像特征；观测模型指对特征模型进行甄别，输入为候选框和特征，通过算法进行决策，输出为当前帧图像预测的人脸位置。

3.1.3 人脸跟踪实现难点

在人脸跟踪具有非常大的难点，人所在区域的背景有变化，比如背景相似和人员移动、检测人脸具有不同的表情、戴口罩和墨镜、光照强度的变化、低头、仰头、转一定角度、不完全在相机视野内等多种情况。通用的基于检测跟踪算法会随着检测的丢失而停止跟踪。多目标跟踪也具有非常大的一个问题，就是产生 ID 跳变，检测目标没有被检测到或者被遮挡，当它在此次出现的时候会被识别为新的目标，赋予新的 ID，也就产生了 ID 跳变。

3.2 KCF 跟踪算法

3.2.1 KCF 理论概述

相关滤波器的概念起源于信号处理，然后逐渐被应用到图像处理方面。基于 CF 的目标跟踪算法主要进行待跟踪目标信号和滤波器之间的相似性检测，主要是通过训练和更新得到滤波器模板，使得滤波器与待跟踪目标之间的相似性最强，也因此获得最大响应以完成对感兴趣目标的准确跟踪。

KCF 算法^[41]需要训练给定的样本得到分类器，该分类器可判断出目标和背景信息。与 MOSSE 算法不同的是，KCF 算法采用具有更好性能的 HOG 特征代替原有的单通道灰度特征，不仅保证了较高的跟踪速率，也进一步提高了跟踪算法精确度。KCF 跟踪算法的原理图如下：




图 3.2 KCF 目标跟踪算法原理框图

KCF 目标跟踪算法属于经典的判别式目标跟踪方法，主要流程是训练、检测和跟踪。在第 t 帧中，在当前位置 p_t 附近进行采样，对图像中目标特征进行训练，从而得到初始滤波器。该滤波器通过采样计算，可以给出一个小窗口的响应。然后使用滤波器对后一帧的图像进行目标搜索和定位，也要及时更新滤波器参数。在跟踪过程，为了判断下一帧的位置，要在上一帧 p_t 位置附近采样，用上一帧更新的滤波器判断每个采样的响应。根据信号响应原理，则最大响应的位置 p_{t+1} ，就是目标在 $t+1$ 帧的位置。最后根据跟踪目标位置提取图像特征信息进行训练和更新目标外观模型和滤波器参数。

3.2.2 KCF 跟踪方法优缺点

KCF 算法针对训练过程中负样本比较少的问题，提出跟踪目标所在区域的循环矩阵可以作为大量正负样本的方法。岭回归方法比较适用处理矩阵元素变动问题，所以在 KCF 训练的时候采用了该方法，从而将矩阵的运算转化为向量的点积。该训练方法有效减少了运算量，运算速度也得到了提高，满足实时跟踪算法要求^[58]。

但是核相关滤波方法在跟踪过程中，在训练和更新检测器的时候过于依赖循环矩阵。而且该目标框是已经设定好的，初始化矩阵不具有自适应

应改变性。在面对尺度较多的目标时候，目标框的漂移会使跟踪失败。最后，KCF 跟踪算法不能解决跟踪过程中目标被遮挡问题。

3.3 DeepSORT 跟踪算法实现

3.3.1 DeepSORT 概述

DeepSORT 是多目标跟踪中常用的基于检测的跟踪方法。该跟踪方法主要分为四步：一是要给定原始帧视频。二是要使用目标检测器检测目标，获取目标检测框。常用的通用目标检测器有 Faster R-CNN、YOLOv3 等，在本文中使用用于人脸检测的 MTCNN 算法。三是处理检测得到目标框，对里面的目标进行特征提取，常见表观特征（如颜色、形状等）和运动特征（速度、方向等）。然后要对前后帧目标进行相似度计算，一边完成匹配。四是通过数据关联算法，给每个跟踪对象分配身份(ID)，完成数据关联工作。基于检测的跟踪算法表现关键在于检测器性能。

SORT^[44]是一种多目标跟踪方法，具有简单和实时性在线跟踪的特点。该算法以检测作为关键组件，使用 Faster RCNN 检测器，检测出每一帧物体。然后通过卡尔曼滤波对目标在下一帧位置进行预测，并传播目标状态到下一帧中。将当前检测与现有目标相关联，主要使用卡尔曼预测位置 and 实际检测位置做 IOU 计算，进行相邻两帧目标相似度判断，通过使用匈牙利算法进行数据关联，匹配目标得到相邻帧对应的 ID 信息，并对跟踪目标的生命周期进行管理^[44]。




图 3.3 SORT 实现跟踪流程图

如图 3.3 所示，人脸检测器得到目标检测框作为跟踪系统输入，同时卡尔曼滤波器通过运动趋势预测当前的帧的轨迹，然后将检测框和预测

轨迹进行 IOU 匹配，最终得到三种匹配结果：未匹配的轨迹、未匹配的检测框和匹配的轨迹。

（1）未匹配的轨迹：代表匹配失败，检测框和预测轨迹无法进行匹配，设定匹配失败持续次数，超过则将目标 ID 删除。

（2）未匹配的检测框：代表没有预测的轨迹能够匹配的上检测框，需要为检测框分配新的轨迹。

（3）匹配的轨迹：说明目标检测器与预测的轨迹得到了良好的匹配结果。

但是 SORT 具有非常明显的缺点，只用了 IOU 方法进行轨迹匹配，IOU 只是对两个计算框的重叠面积进行计算，当目标发生遮挡情况，跟踪过程会产生 ID 跳变。

因此，具有深度关联指标的简单在线和实时跟踪方法^[45]在 SORT 的基础上，加入了外观信息度量进行改进。在实时目标追踪过程中，为了解决遮挡问题，使用一个神经网络提取目标的表观特征，在使用匹配算法完成最近邻匹配，遮挡情况下 ID 跳变得到改善。

该最邻近匹配方法即级联匹配(Matching Cascade)和新轨迹的确认^[45]。作者在 SORT 基础上它将基于 IOU 的面积匹配修改为了特征匹配，因为一般情况下很少遇到外观特征完全相同的物体，如图 3.4 所示，利用 resnet50 网络先将目标特征提取出来，这种改进是有效的，把 ID 跳变降低了 45%。




图 3.4 DeepSORT 基于 CNN 的特征提取器

DeepSORT 用于行人跟踪，所以借用了行人重识别(Pedestrian Re-Identification, ReID)网络模型来提取跟踪目标表观特征，有效减少了 ID 跳变的次数。特征提取网络层如表 3.1 所示。

表 3.1 DeepSORT 卷积神经网络架构

名称	卷积核/步长	输出
Conv1	3×3/1	32×128×64
Conv2	3×3/1	32×128×64
Max Pool 3	3×3/2	32×64×32
Residual 4	3×3/1	32×64×32
Residual 5	3×3/1	32×64×32
Residual 6	3×3/2	64×32×16
Residual 7	3×3/1	64×32×16
Residual 8	3×3/2	128×16×8
Residual 9	3×3/1	128×16×8
Dense 10		128
Batch and l_2		128
normalization		

3.3.2 DeepSORT 实现跟踪流程

根据对 DeepSORT 算法进行分析, 该跟踪方法不仅使用目标运动信息, 还加入表观信息进行级联匹配。DeepSORT 流程图如图 3.5 所示。

匹配过程主要有四个步骤:

(1) 跟踪系统输入: 将检测器输出的边界框转化为检测目标检测框(Detections)。

(2) 轨迹(tracks)预测: 使用卡尔曼滤波的预测方法, 基于上一时刻的目标状态对当前时刻的状态和不确定性, 对每条轨迹进行状态预测。同时更新每条轨迹的计数器, 计数器代表每条轨迹的匹配次数。记录更新轨迹的次数, 用于判断此条轨迹是否离开了画面。每预测一次轨迹, 该计数器加 1, 如果后续该轨迹成功匹配上了检测框, 该计数器清零。因此计数器代表这条轨迹连续多少次未和检测框匹配。

(3) 一段轨迹(trackers)更新: 一段轨迹中会保存所有的轨迹, 每一次检测器的检测结果得到的检测框都需要和一段轨迹中的预测轨迹进行匹配, 完成检测框的分配问题。主要包括轨迹的匹配(包括级联匹配和 IOU 匹配)、轨迹更新、标记的轨迹丢失、初始化新的轨迹、删除轨迹、更新在级联匹配中用于和新的检测框的外观特征向量计算余弦距离的轨迹的外观特征向量。

(4) 输出匹配上检测的轨迹。




图 3.5 DeepSORT 实现跟踪流程图

3.3.3 DeepSORT 实现关键技术

3.3.3.1 运动轨迹和运动状态估计

卡尔曼滤波器(Kalman filter)是一种使用线性状态方程优化估计具有不确定信息的动态系统状态的算法。在 DeepSORT 中, 卡尔曼滤波主要实现预测轨迹在下一时刻的位置和基于目标检测框更新预测位置的功能。

使用卡尔曼滤波算法前提, 认为边界框的移动和尺寸变化是线性匀速变化的, 基于之前的轨迹预测当前时刻的轨迹如公式(3.1):

$$x' = Fx \quad (3.1)$$

$$\begin{matrix} \begin{bmatrix} u \\ v \\ r \\ h \\ x' \\ y' \\ r' \\ h' \end{bmatrix} \\ \text{t 时刻} \end{matrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & dt & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & dt & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & dt & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & dt \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{matrix} \begin{bmatrix} u \\ v \\ r \\ h \\ x' \\ y' \\ r' \\ h' \end{bmatrix} \\ \text{(t-1)时刻} \end{matrix}$$

向量 x 是轨迹在 $t-1$ 时刻的状态，状态转移矩阵记为 F ，公式(3.1)用来预测时刻 t 的目标状态向量 x' 。




图 3.6 边界框坐标示意图

x 为输入向量， $x = (u, v, r, h, x', y', r', h')^T$ ，每个目标在每帧都具有一个状态，用八维空间坐标 x 来表示目标 t 时刻所处轨迹状态，如图 3.6， (u, v, r, h) 中 (u, v) 表示目标边界框的中心点位置， r 代表长宽比， h 代表边界框的高。 (x', y', r', h') 四个参数为前四个参数的导数，代表目标边界框位置坐标在图像坐标系下的相对运动速度。跟踪目标的直接观测模型即是该八维空间坐标状态，卡尔曼滤波器的观测变量为 (u, v, r, h) 四个参数，默认观测模型做匀速且线性运动。

3.3.3.2 数据关联

在多目标跟踪过程，为了进行帧与帧之间多个目标进行匹配，必须进行数据关联，传统得的数据观关联方法多为运筹学方法，经典的数据关联算法包括匈牙利算法和 KM(Kuhn-Munkras)算法。

余弦距离代表两个向量夹角的余弦值，主要度量两个向量差异大小。在 DeepSORT 中，用于衡量外观特征之间的距离。计算每一个检测框经过行人重识别 ReID 网络得到的特征向量和预测轨迹中已经存储的特征

向量（默认 100，可自行设置）计算余弦距离，每个检测器目标检测框和每个预测轨迹会有 100 个余弦距离，取其中的最小值为该预测轨迹和检测框的余弦距离。

如图 3.7 所示，马氏距离是点与一个分布之间的距离，主要用于相似度计算。且具有尺度无关特性，能够表示不同特征之间的联系。 μ 是样本均值， Σ 是协方差矩阵（多个变量向量）。




图 3.7 马氏距离分布示意图

单个数据点的马氏距离如公式(3.2):

$$D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)} \quad (3.2)$$

数据点 x , y 之间的马氏距离如公式(3.3):

$$D_M(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)} \quad (3.3)$$

在 DeepSORT 中，马氏距离用于过滤外观特征匹配上检测器目标和预测轨迹在图像中的位置相差很大的配对。计算每个检测目标框到每个预测轨迹的马氏距离，根据马氏距离的阈值（3 倍的标准差），去除离群点。

当检测框和预测轨迹都满足余弦距离和马氏距离，那么将使用匈牙利算法进行匹配。

匈牙利算法通过寻找增广路径求二分图最大匹配。简单来说，匈牙利算法就是一个递归过程，在目标跟踪中用于寻找前后相邻两帧的目标匹配最优解，尽可能找到让上一帧与当前帧目标一对一的匹配，对运动模型和表观模型要求较高。

匈牙利算法存在一个很大的问题，就是该算法将每个目标的匹配对象视为评级，然而在实际的跟踪任务中，肯定有些匹配的框比较接近目标，有些框与目标相差较大，这时候如果将其视为同级会影响匹配准确度，所以在匈牙利算法的基础上又提出了 KM 算法，这也是实际任务中比较常用的算法，KM 算法引入了权值的概念，解决了带权二分图的最优

匹配问题。

DeepSORT 算法不仅关联了运动信息，又加入了跟踪目标表观信息。卡尔曼滤波预测出目标位置，和检测器输出的检测框之间的马氏距离进行信息关联，就是运动信息关联。

使用马氏距离来度量预测轨迹的卡尔曼状态（边界框的几何位置）和新到来检测框之间的距离。

$$d^{(1)}(i, j) = (d_j - y_i)^T S_i^{-1} (d_j - y_i)^T \quad (3.4)$$

$$b_{i,j}^{(1)} = 1[d^{(1)}(i, j) \leq t^{(1)}] \quad (3.5)$$

在公式(3.4)中， d_j 代表第 j 个检测框， y_i 代表第 i 个预测轨迹， S_i^{-1} 代表 d 和 y 的协方差。公式(3.5)是一个指示器，比较的马氏距离和卡方分布的阈值， $t^{(1)} = 9.4877$ ，如果马氏距离小于该阈值，代表成功匹配。

余弦距离被用于度量跟踪目标表观特征之间的距离，各个轨迹的 128 维的表观特征(appearance feature)和检测特征(detection feature)之间的距离，用来更准确地预测 ID。

$$d^{(2)}(i, j) = \min \{1 - r_j^T r_k^{(i)} | r_k^{(i)} \in R_i\} \quad (3.6)$$

$$b_{i,j}^{(2)} = 1[d^{(2)}(i, j) \leq t^{(2)}] \quad (3.7)$$

在公式(3.6)中， $r_j^T r_k^{(i)}$ 计算余弦相似度，余弦距离值为 $1 - r_j^T r_k^{(i)}$ ，通过余弦距离来度量预测轨迹的表观特征和检测框对应的表观特征，来更加准确地预测 ID。SORT 中仅仅用运动信息进行匹配会导致 ID Switch 比较严重，所以引入外观模型和级联匹配可以缓解 ID 跳变问题。

如公式(3.7)，两个二值函数分别比较平方马氏距离、余弦距离和阈值的大小，并结合两个函数限制矩阵；如果余弦距离小于 $t^{(2)}$ ，则认为匹配上。这个阈值在代码中被设置为 0.2（由参数 max_dist 控制），这个属于超参数，在人脸识别中一般设置为 0.6。

如公式(3.8)，综合匹配度是运动模型匹配度和外观模型匹配度加权重。

$$c_{i,j} = \lambda d^{(1)}(i, j) + (1 - \lambda) d^{(2)}(i, j) \quad (3.8)$$

λ 是一个超参数，在代码中默认为 0，在摄像头有实质性移动的时候这样设置比较合适，也就是在关联矩阵中只使用外观模型进行计算。在 DeepSORT 中，马氏距离会对外观模型得到的距离矩阵进行限制，忽视掉明显不可行的分配。

$$b_{i,j} = \prod_{m=1}^2 b_{i,j}^{(m)} \quad (3.9)$$

在公式(3.9)中， $b_{i,j}$ 是指示器，只有 $b_{i,j} = 1$ 的时候才认为初步匹配成功。

3.3.3.3 级联匹配

级联匹配算法是 DeepSORT 算法区别于 SORT 算法的一个核心内容，主要用于解决目标被长时间遮挡的情况，让当前的检测框匹配上当前时刻较近的轨迹，匹配的时候检测框优先匹配消失时间较短的轨迹。

当目标被长时间遮挡会增加卡尔曼滤波预测结果的不确定性，因为在被遮挡这段时间没有观测对象来调整运动轨迹，因此极大地降低了状态空间内的可观察性。

在两个预测轨迹竞争同一个检测器目标的时候，消失比较久的轨迹匹配运算得到更小的马氏距离，使得检测框和遮挡时间较长的轨迹相关联的可能性增大，从而破坏一个轨迹的持续性，这也就是 SORT 中 ID Switch 太高的原因之一。级联匹配流程如图 3.8 所示。




图 3.8 DeepSort 级联匹配示意图 [45]

级联匹配示意图匈牙利算法部分代表了级联匹配中的数据关联。将检测框 (Detections) 和轨迹 (Tracks) 进行匹配，会出现几种情况：

(1) 检测框和轨迹匹配，也就是匹配的轨迹 (Matched Tracks)。检测框和预测目标很好的匹配上，没有断开。

(2) 检测框没有找到匹配的轨迹，也就是未匹配检测 (Unmatched Detections)。图像中突然出现新的目标的时候，检测框无法在之前的轨迹中找到匹配的目标。

(3) 轨迹没有找到能够匹配上的检测框，也就是未匹配轨迹

(Unmatched Tracks)。有可能是目标消失，或者超出画面导致轨迹无法匹配上现有的检测框。

(4)存在两个目标被遮挡的情况，就是两个目标遮挡的情况。他们的预测轨迹无法匹配到当前检测框，记为目标消失，如果后面那两个目标再次出现，还要保证他们被分配的 ID 和之前一样，即减少 ID 跳变，级联匹配就用于这种情况。

级联匹配是个循环过程，要迭代 `max_age` 次，在每一次迭代预测轨迹都和检测框进行匹配。优先匹配没有丢失过的轨迹，通过级联匹配，如果目标被遮挡了，在迭代未结束之前再出现，就会被识别为同一个目标，所以能够大大减少 ID 跳变次数，在本文中将 `max_age` 设置为 30，控制匹配条件更为严格。

3.4 小结

本章首先介绍了人脸跟踪相关方法，其次介绍了 KCF 跟踪算法实现原理和过程，分析了优缺点。最后介绍了 DeepSORT 在线实时检测跟踪算法，深入研究了 DeepSORT 实现的详细流程和关键技术，重点介绍了数据关联和级联匹配技术。KCF 算法具有训练滤波器的功能，DeepSORT 跟踪方法能有效解决遮挡问题，两者相互辅助，为下一章级联跟踪算法的创建提供了创新点和理论基础。

第 4 章 级联人脸跟踪架构设计

4.1 级联人脸跟踪架构设计

检测和跟踪相辅相成，越来越多的人探索人脸检测与跟踪之间的联系，考虑如何将两者合并到一起，在同一个框架下解决问题。

尽管人们将 MTCNN 检测算法和行人跟踪算法 DeepSORT 结合起来完成检测和跟踪，并且具有一定的实时性，但是该方法高度依赖检测信息实现跟踪，如果检测丢失，则跟踪停止。

DeepSORT 算法是用于行人检测和跟踪的方法，在本文中，想要对驾驶员进行人脸检测和跟踪，所以要在 DeepSORT 基础上，将进行表观特征提取的行人重识别网络更改为适合人脸特征提取的网络结构。在人脸重识别网络结构设计中，采用了宽残差网络结构的形式，能够在保证网络深度的情况下，提高识别精度。

现有的 DBT 跟踪算法都没有考虑在检测丢失的情况下的跟踪。所以本文基于这个考虑，创建了一种功能强大的在线跟踪方法，用于驾驶员面部检测和跟踪。在本文中，将传统 KCF 算法与 MTCNN-DeepSORT 算法进行了级联，并且重新设计了 DeepSORT 网络中人脸重识别深层网络，采用了宽残差网络结构的形式，能够在保证网络深度的情况下，提高精度。并且从深层网络中提取脸部特征，用于跟踪算法的数据关联和匹配工作。

DeepSORT 集成了运动模型，IOU 距离和用于跟踪的外观信息，应用经过训练的卷积神经网络去识别大规模的人脸重识别数据集上的人脸，从而在人脸跟踪环境中创建深度度量学习。该方法主要依赖检测提供的目标的检测框来预测下一帧目标，该目标的检测框可能是跟踪数据集中每一帧标注信息，也可以是实际应用中每一帧的检测信息，在本文中，我们使用的是每一帧的检测信息。

KCF 是一种传统的跟踪算法，首先利用给定初始帧的特征经过训练得到滤波器，即使未能检测到当前帧中的跟踪目标，也可以使用初始帧信息主动搜索当前帧中以及后续帧中的跟踪目标。

基于两种跟踪方法的跟踪特点，KCF 在本文中扮演着连接检测和跟踪信息的角色，弥补 DeepSORT 算法在检测丢失后的跟踪问题。即如果 DeepSORT 检测算法检测信息丢失，驾驶员的面部检测失败，KCF 跟踪器将使用最后一帧面部检测信息去搜索和跟踪当前帧，然后 KCF 跟踪框将

再次发送到 DeepSORT 人脸重识别网络,这可以弥补 DeepSORT 的不足。

首先,驾驶员的面部检测和跟踪将通过 MTCNN 和 DeepSORT 算法完成。MTCNN 将完成驾驶员的面部检测,并将检测到的面部边界框传输到 DeepSORT 跟踪算法中,在此步骤中,我们将获得驾驶员的面部检测框和跟踪边界框。然后,将边界框的检测传输到核相关滤波器(KCF)跟踪算法。当未检测到驾驶员面部时,KCF 跟踪器将使用最后一帧检测信息来搜索和跟踪当前帧的驾驶员面部,将跟踪信息转换为 DeepSORT 算法,并在当前帧中重新识别驾驶员面部。如果检测没有丢失,我们仅将检测信息记录在 KCF 跟踪器中,而不启动跟踪器。并且本文整体检测和级联跟踪详细网络架构图 4.1 所示。




图 4.1 检测和级联跟踪详细网络架构

4.2 人脸重识别网络结构设计

4.2.1 残差神经网络

何恺明^[59]等人提出了残差神经网络(Residual Network), 在图像分类和物体识别表现出优良的性能, 主要用于解决网络退化问题, 而且容易优化, 能够通过增加一定的深度提高准确率, 能够提高更深的网络训练可能性。

在深度学习过程中, 一般认为经过训练的深度神经网络能够将数据特征逐层抽象, 最终提取出完成任务所需要的特征表示, 最终使用一个简单的分类器(或其他学习器), 就可以完成最终任务。但是深度神经网络在训练过程中会产生两大问题: 梯度弥散/爆炸和网络退化问题。

梯度问题的出现主要是因为现代神经网络一般通过基于梯度的 BP 算法进行优化, 前向传播时候输入信号, 然后反向传播误差并且使用梯度方法更新参数, 反向传播过程中会产生梯度消失问题, 即底层的参数不能有效更新, 这也就是梯度弥散(或梯度消失), 也会产生梯度以指数级速度增大, 造成系统不稳定, 也即梯度爆炸问题。通常梯度问题很大程度上使用标准初始化和中间层正则化方法得到有效控制, 这些方法使得神经网络可以收敛。

网络退化问题主要是在神经网络收敛的条件下, 网络深度增加, 网络效果表现为逐渐增加至一定程度, 之后会快速下降^[51]。在训练网络模型过程中, 存在一种不符合常理的现象, 在训练次数相同的情况下, 相比于稍微浅层的网络训练, 退化的网络有竟然更高的训练错误。

如果存在某个 K 层的网络 f 是当前最优的网络, 那么可以构造一个更深的网络。让该网络的最后几层输出结果与第 K 层输出的恒等, 就可以取得与 f 一致的结果; 可能 K 还不是理想的最佳层数, 那么就可以加深网络, 获得更好的结果。总而言之, 深层网络应该比浅层网络表现好。因此, 残差网络的作者提出了一个合理的猜测, 在神经网络中, 不容易拟合恒等映射。于是出现了通过对网络单元进行改造用于改善网络退化的方法, 也即提出的残差神经网络。

在统计学中, 残差代表预测值和观测值之间的差异。残差块的堆叠可以组成残差神经网络。在残差块中, 分为直接映射和残差部分, 后者通常有两、三个卷积构成。

直接拟合潜在的恒等映射 $H(x) = x$ 比较困难, 于是构造一个恒等映射, 如式(4.1):

$$H(x) = F(x) + x \quad (4.1)$$

残差单元在神经网络中可以以跳跃式连接的形式出现，将单元的输入与单元输出相加之后再激活，其中跳跃式连接可以将残差很好的传递过去，从而避免梯度消失的现象如图 4.2 所示。




图 4.2 残差学习模块

$F(x)$ 代表残差， $F(x) = H(x) - x$ ，只要令 $F(x) = 0$ ，就构成了恒等映射。所以用深度学习框架实现残差网络成为可能，在深度残差网络中可以使用反向传播算法更新参数。

残差神经网络作者主要提出了两种残差块如图 4.3 所示。




图 4.3 两种残差模块结构

basic: 由图 4.3(a)可知，该结构具有两个连续的 3×3 卷积。

bottleneck: 由图 4.3(b)可知，该结构有三个卷积核，在经过第一个 1×1 的卷积核后，输入目标尺寸会被减小，使 3×3 的卷积得到低维度输入，使网络快速运行，在第三个 1×1 卷积核运算后，尺寸得到恢复，在非常深的网络结构中，可有效减少计算代价。

4.2.2 宽残差网络

深度残差网络过于追求网络深度，而忽略了模块自身的问题。随着模

块的增加，模型的表现并没有明显提升，在此基础上，Sergey Zagoruyko 和 Nikos Komodakis 考虑宽度对残差网络的影响，在 basic 残差块基础上提出了宽残差网络(Wide Residual Network, WRN)^[60]，WRN 在原始残差模块的基础上加了一个系数 K，从而拓宽卷积核的个数。宽残差网络提出通过增加残余块的三种途径：一是增加卷积层数，二是特征平面增加，三是增大卷积层卷积核。WRN 文章原始结构如表 4.1 所示。k 代表了原始模块中卷积核数量的 k 倍（也就是通道数量更大），B(3,3) 代表每一个残差模块内由两个 3×3 的卷积层组成，N 代表组中有多少个残差块。宽残差网络第一层是一个基础 3×3 卷积，然后是 3 组（每组为 N 个）残差块 conv2，conv3 和 conv4，最后经过平均池化层和分类层。经过实验证明该方法有效降低了网络层数且并不减少模型参数，同时加快了计算速度。

表 4.1 宽残差网络层示意图

网络层名称	输出大小	块类型，B(3,3)
Conv1	32×32	[3×3, 16]
Conv2	32×32	$\begin{bmatrix} 3 \times 3, 16 \times k \\ 3 \times 3, 16 \times k \end{bmatrix} \times N$
Conv3	16×16	$\begin{bmatrix} 3 \times 3, 32 \times k \\ 3 \times 3, 32 \times k \end{bmatrix} \times N$
Conv4	8×8	$\begin{bmatrix} 3 \times 3, 64 \times k \\ 3 \times 3, 64 \times k \end{bmatrix} \times N$
Avg-pool	1×1	[8×8]

所以本文参考宽残差结构，用于构建深层人脸识别网络，设计的残差块及其参数如表 4.2 所示。

表 4.2 本文设计的宽残差块

网络层名称	输出大小	块类型 B(3,3)
Layer3	32×32	$\begin{bmatrix} 3 \times 3, 32 \times 2 \\ 3 \times 3, 32 \times 2 \end{bmatrix} \times 1$
Layer4	16×16	$\begin{bmatrix} 3 \times 3, 64 \times 2 \\ 3 \times 3, 64 \times 2 \end{bmatrix} \times 1$
Layer5	8×8	$\begin{bmatrix} 3 \times 3, 128 \times 2 \\ 3 \times 3, 128 \times 2 \end{bmatrix} \times 1$
Layer6	4×4	$\begin{bmatrix} 3 \times 3, 256 \times 2 \\ 3 \times 3, 256 \times 2 \end{bmatrix} \times 1$

4.2.3 人脸重识别网络结构

DeepSORT 被首先应用在行人跟踪网络中，通过深层卷积网络获得 128 维深度表观特征，这些特征用于行人目标匹配。DeepSORT 用于人脸跟踪时，主要提取人脸特征用于深度指标关联(Deep Association Metric)，进行帧与帧之间多个目标进行匹配，确保未跟踪人脸的可能性越来越小。基于这个想法，本文设计了人脸重识别深度网络用于人脸特征提取，进行数据关联和减少 ID 跳变。

在本文中，参考宽残差结构，使用小卷积核组成的网络结构，与大卷积核相比，前者不仅能够增强网络容量，还能提高模型复杂度，同时由于减小了计算量，也使得网络层参数大大减少。人脸重识别网络结构参数如表 4.3 所示。在表 4.3 中，Kernel 表示卷积核大小，Stride 表示步幅，Padding 表示填充大小。

表 4.3 人脸重识别网络层及其参数

网络层名称	网络类型	卷积核大小	步长	填充	输出大小
Conv1	Conv2d	3×3	1	1	[64,64,64]
BN2	BatchNorm2d				[64,64,64]
ReLU3	ReLU				[64,64,64]
MP4	MaxPool2d	3×3	2	1	[64,32,32]
Layer3	BasicBlock	3×3,3×3	1,1	1,1	[64,32,32]
Layer4	BasicBlock	3×3,3×3	2,1	1,1	[128,16,16]
Layer5	BasicBlock	3×3,3×3	2,1	1,1	[256,8,8]
Layer6	BasicBlock	3×3,3×3	2,1	1,1	[512,4,4]
AP7	AvgPool2d	4×4	1	0	[512,1,1]
Linear8	Linear				[256]
BN9	BatchNorm1d				[256]
ReLU10	ReLU				[256]
Linear11	Linear				[11231]

在本文中将网络输入图像尺寸设计为 64×64，第一个卷积层采用 3×3 的卷积核，步长设计为 1，填充也设置为(1, 1)，可以充分利用和处理图像的边缘信息，保持输出与输入同等大小。因为网络具有一定的深度，防止随着网络深度增加，输入尺寸减小太快。然后进行正则化和激活函数操作，进行最大池化，将图片尺寸缩减为 32×32。然后设计了四层宽残差网

络，增加网络深度。经过残差网络层后输出大小为 4×4 ，进行均值池化，将输出变为 1×1 ，然后经过全连接层 **Linear8**，将特征映射到一维空间，而 **ReLU 10** 和线性 **11** 仅用于网络训练和测试过程。

4.2.4 人脸重识别网络损失函数

为了将 DeepSORT 用于人脸跟踪，本文重新设计了 DeepSORT 中的重识别深层网络结构，并从这些网络中提取了深层脸部特征，从而能够将数据关联和匹配用于跟踪过程。本文重新设计了深层 CNN 网络，并使用焦点损失对其进行训练。

何凯明^[60]在 2017 年提出了焦点损失函数(Focal Loss, FL)，焦点损失函数被用于检测任务，通常图像中包含密集物体。焦点损失相比于旧的损失函数，它比以前的解决阶级失衡的方法更为有效。在目标检测中，可能待检物体有 1000 个类别，如果想要识别其中某一个类别，这就产生了样本不均衡的分类问题。焦点损失函数就是设计用于解决样本数量极度不平衡问题的。

本文的训练图像来自具有不同条件的不同公众面部数据集，因此某些样本没有足够的数据进行训练和测试，在所有训练数据中，男性数据多于女性数据，而且每一个人的图像数量都不等。因此，在训练过程中会使用焦点损失函数作为目标函数。

用于二元分类的交叉熵(Cross Entropy, CE)损失函数如公式(4.2)。 $y \in \{\pm 1\}$ 代表标注框的类， $p \in [0,1]$ 是估计概率，用于判断模型是不是标签 $y = 1$ 的类。概率 p 的定义如公式(4.3)。

$$CE(p, y) = \begin{cases} -\log(p), & \text{if } y = 1 \\ -\log(1 - p), & \text{otherwise} \end{cases} \quad (4.2)$$

$$p_t = \begin{cases} p, & \text{if } y = 1 \\ 1 - p, & \text{otherwise} \end{cases} \quad (4.3)$$

在此基础上，经过改进定义了焦点损失函数(FL)，如式(4.4)， $\gamma \geq 0$ 是聚焦参数，在我们训练过程中，损失函数值设置为 2。实际过程中，使用了添加了参数 α_t 的焦点损失函数如公式(4.5)，损失函数示意图^[60]如图(4.4)所示。

$$FL(p_t) = (1 - p_t)^\gamma \log(p_t), \gamma \in [0,5] \quad (4.4)$$

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t), \gamma \in [0,5] \quad (4.5)$$




图 4.4 焦点损失函数

在公式(4.5)中, $\alpha_t > 0$ 能够减少容易分类样本损失, 从而更注重困难的、错分的样本, 减少了简单样本的影响。用于降低正样本或者负样本的权重, 来解决样本不均衡的问题。 $-(1 - p_t)^\gamma$ 的权重代表着, 如果给出的正确类别的概率越大, 那么 $-(1 - p_t)^\gamma$ 的概率值就越小, 代表分类正确的样本权重损失小。

4.3 KCF 跟踪算法和数据关联

核相关滤波器(KCF)是一种遵循训练、检测和跟踪流程的算法, 具有跟踪快速, 效果良好的优点。在普通的 KCF 跟踪方法中, 与目标相关的框被推入跟踪器, 并将一直跟踪该对象, 并且可以主动搜索目标信息, 直到它在图像中消失为止, 而在本文的方法中, 对 KCF 进行了一些更改。

首先, 通过 MTCNN 人脸检测器模型获得人脸检测框, 赋予该检测到的人脸特殊的跟踪身份(ID), 该 ID 将被保存在 DeepSORT 中, 在人脸跟踪过程中身份信息不会改变, 直到该人脸检测框消失或连续 30 次检测丢失。在连续帧中丢失驾驶员面部检测的情况下, 将使用 KCF 跟踪算法管理驾驶员面部。

为了方便管理跟踪轨迹, 本文在级联跟踪算法中将轨迹的状态分为四类: 丢失, 失效, 新增的轨迹和跟踪:

(1) 丢失: 如果驾驶员的面部检测在当前帧中失败, 则驾驶员的面部将被标记为丢失, 相反, 如果驾驶员的面部跟踪在此帧中成功, 则此目标的状态将更新为跟踪。

(2) 死亡: 当跟踪脸丢失 20 帧以上时, 其状态将转换为死亡, 并删除其跟踪信息。由于丢失了驾驶员面部检测, 因此我们的 DeepSORT 将使驾驶员的面部信息保持 30 帧; 在这 30 帧期间, 在本文中 KCF 将会利

用保存的上一帧信息，主动搜索并跟踪丢失的面部，一旦 KCF 跟踪成功或 MTCNN 检测成功，DeepSORT 中的驾驶员面部信息将被更新，否则检测到的丢失面部将被视为死亡。

（3）新增：如果出现新的驾驶员面部 ID，则面部信息将添加到 DeepSORT 特征容器中。对于同一驾驶员，当 DeepSORT 将驾驶员的面部识别为另一个人时，将显示新 ID。

（4）跟踪：此状态表明已稳定跟踪驾驶员的脸部。如果跟踪目标与检测目标成功匹配，则将跟踪目标的框替换为检测框，否则，跟踪器将保留其检测框信息。

关于跟踪人脸的状态管理主要在 DeepSORT 中完成。KCF 算法主要在检测丢失情况下，协助 DeepSORT 捕获无法检测到的面部信息。在 DeepSORT 算法中，数据关联和人脸匹配是通过卡尔曼滤波器，马氏距离和 IOU 距离方法完成的。

使用 DeepSORT 实现驾驶员面部数据的关联和匹配的最大优势在于，我们可以在完成驾驶员面部跟踪的同时实现驾驶员面部的重新识别。实际上，KCF 算法是对数据关联方法的补充。

4.4 人脸重识别网络数据集制作

4.4.1 数据集来源

在人脸重识别网络训练和测试中，分别下载了 FaceScrub^[54]、CASIA-WebFace^[61] 和 AR Face Database^[62]数据集。

AR Face Database: 这个面部数据库是由 U.A.B 的计算机视觉中心的 Aleix Martinez 和 Robert Benavente 创建的。它包含 4,000 多种彩色图像，分别对应 126 人的面孔（男性/70，女/56）。图像都包含正面表情，他们录入不同的面部表情，同时加上一部分伪装，包括戴墨镜、近视镜、化妆、围巾遮住一部分面部等。同时还给予不同的光照条件。





图 4.5 ARface 数据集



FaceScrub: 数据集使用可检测网络搜索公共人物返回的图像中的面部的方 法，然后自动丢弃不属于该被查询者的面部。然后手动检查并清除结果。它总共包含 106863 张名人图像，包括男性 265 人共 51557 张图像，和女性 265 人共 41557 张图像，是最大的公开面孔数据库之一。如图 4.7 所示。




表 4.3 训练数据集

数 据 集	人 数	图 片 个 数	男 性 人 数	女 性 人 数
AR Face Database	126	4000+	70	56
CASIA-WebFace	10575	494414	—	—
FaceScrub	530	106863	265	265

4.4.2 人脸对齐

在 Pytorch 深度学习平台，进行人脸识别网络训练。人脸预处理对于人脸识别任务来说非常重要。通常需要检测出图像中的人脸，然后根据图像中人脸的几何结构对图像进行仿射变换（旋转、缩放、平移等），将人脸变换到一个统一的状态，可以提升人脸识别的精度。人脸对齐(Face Alignment)主要指人脸特征对齐，即根据输入的人脸图像，自动定位出人类面部关键特征点，包括眼睛、鼻子、眉毛和嘴角等代表人面部最明显的特征。

在本文中，下载的人脸数据集包含有不同姿态，不同光照、化妆、戴眼镜（包括墨镜）、遮挡等各种情况下的人脸姿态，非常充足。首先对原始图像进行预处理，通过人脸关键点检测完成人脸对齐处理，主要应用剪裁对齐，只保留人脸区域，用于制作数据集。然后对制作的数据集进行分类，共有 11231 个身份，每个身份具有不同数量的图像。通过编写一个小的程序，将每个人每幅图像都顺序编号，将编号除以三为整数的图像存为测试集，即每个目标图像总数的三分之一，剩余三分之二就是制作训练数据集，人脸对齐后的数据集如图 4.8，4.9，4.10 所示。



图 4.8 ARface 数据集人脸对齐示意图



图 4.9 CASIA-WebFace 数据集人脸对齐示意图



图 4.10 FaceScrub 数据集人脸对齐示意图

4.4.3 数据增强

数据增强是扩充数据的一种方法，是卷积神经网络训练过程中非常重要的数据处理手段，通过数据增强，能将有限的的数据生成更多等价的数据。扩增可以丰富训练数据的多样性，有助于增强模型的泛化能力。数据增强包括了离线和在线增强两种方法，前者适用于小数据的数据集，直接让数据集以倍数扩增。在线方法适合被用于数据集比较大的情况，通常的操作方法是在得到一批数据之后，对这一批次的数据进行处理得到增强数据，通常包括旋转(rotation)、平移(translation)、翻转(flap)、剪裁(clip)等增强方法。

本文采用在线增强数据处理方式，本文将所有用于训练的面部图像的分辨率大小统一调整为 $\text{width} = 64$, $\text{height} = 64$ ，并在 Pytorch 深度学习框架下完成训练，以下是本文训练时采用的数据处理和扩增方式：

(1) 对图像进行变换：采取 `resize` 操作，像素设置为 64×64 。

(2) 随机裁剪：`transforms.RandomCrop`，输入图像大小 64×64 ，padding 设置为 4，上下左右均填充 4 个像素， 68×68 进行随机剪裁，剪裁前图像为图 4.11 所示，随机剪裁效果如图 4.12 所示。

(3) 将图像根据概率值水平翻转：函数为 `RandomHorizontalFlip`，默认概率 P 为 0.5 的水平翻转，如图 4.13 所示。

(4) 归一化 `transforms.Normalize`：对数据进行标准化操作，有助于根据数据的分布特性完成分类，也有利于数据处理和加快程序运行时的收敛过程。



图 4.11 数据增强前图像




图 4.12 随机裁剪示意图




图 4.13 水平方向翻转示意图

4.5 小结

本章首先为了降低了人脸检测和跟踪过程中图像漏检，提出了级联跟踪架构设计，将 KCF 跟踪器级联 DeepSORT 跟踪算法，展示了级联架构示意图，优点在于解决基于检测的 DeepSORT 跟踪算法在丢失检测信息、跟踪失败的时候，启动 KCF 滤波器的跟踪，并将跟踪信息及时传输到 DeepSORT 网络中，完成连续的跟踪过程。其次将 DeepSORT 中用于外观信息提取的行人重识别网络重新设计，用宽残差块构建了人脸重识别深层卷积神经网络，并通过网络训练成功提取人脸特征。然后定义了 KCF 跟踪器在级联跟踪结构中的工作状态，能够在 MTCNN 检测丢失情况下，保证跟踪系统正常运行。最后，本章还制作了用于人脸深度特征提取的训练数据集和测试数据集，并且对数据处理方法和结果进行了展示。

第 5 章 实验设计和结果分析

5.1 实验环境

本文进行实验的硬件配置参数如表 5.1 所示。

表 5.1 实验硬件配置

名称	参数
显卡 (GPU)	NVIDIA GeForce GTX 1660Ti
CPU	Intel core i7-9750H
内存	8GBDDR4
显存	6GB 独显

本文进行实验的软件配置参数如表 5.2 所示。

表 5.2 实验软件配置

名称	参数
操作系统	Windows10
深度学习框架	Pytorch
Anaconda	4.5.4
CUDA	10.0
Python	3.6

5.2 人脸重识别网络训练及结果

5.2.1 模型训练方法

(1) 训练模型优化:

梯度下降 (Gradient Descent, 简称 GD) 是使函数最小化的算法, 在神经网络种用于更新权重, 使用微积分的方法在函数梯度下降方向上逐步迭代以实现损失函数最小化。该方法每次迭代过程都需要计算所有训练集样本的梯度, 如果数据集非常大, 极其影响效率^[63]。

为了解决以上问题, 提出了随机梯度下降法^[64] (Stochastic Gradient Descent, 简称 SGD), SGD 在每个训练样本上执行参数更新。但是该算法也存在一定的缺点, 频繁地更新参数和梯度的波动, 使得损失收敛到最小值过程变得复杂。为了优化 SGD 算法, 在一轮 (epoch) 训练过程中选取一批 (Batch) 样本并全部遍历, 并利用该批样本的梯度信息完成一次模型更新^[65]。也就是小批量梯度下降法 (Mini-Batch based SGD), 小批量梯度下

降在参数更新过程中降低了方差，使收敛过程更稳定^[66]。

在本文人脸识别网络训练过程中 Batch 设置为 32, epoch 设置为 40。

(2) 学习率设置(Learning rate):

在网络训练过程中需要设置学习率控制参数更新速度。学习率决定了参数更新的幅度，学习率过大可能导致不收敛，过小又会降低优化速度。我们在设置学习率的时候，要考虑在开始训练时候稍大的学习率加快收敛速度，但是要逐渐随着训练轮数衰减，要不然迭代后期学习率太大可能会错过收敛点。在本文中，学习率设置为 0.1，并随着轮数以 0.1 的倍数衰减。

(3) 批规范化操作:

人们常依赖网络训练提高模型性能，批规范化操作可以加快模型收敛速度，能缓解梯度弥散问题。因此，可以使深层网络在训练过程中更稳定，训练更容易^[67]。

在本文中：训练参数设置如表 5.3:

表 5.3 人脸识别网络训练参数

参数	数值
批尺寸(Batch_size)	32
训练轮次(epoch)	40
学习率(Learning rate)	0.1
动量(momentum)	0.9

5.2.2 特征图可视化分析

本文对人脸识别网络的卷积层和残差层的特征图进行了可视化，并对其进行分析，图 5.1 为某一张系统输入图片。



图 5.1 系统输入原图

图 5.2 和图 5.3 为图像经过第一层卷积和第一层残差模块之后输出的特征，此时的网络层比较浅。由图片显示可以看到面部纹理和细节特征，包含了更多像素点的信息，同时也能看出人脸轮廓，颜色分布和边缘信息。




图 5.2 经过 Conv1 卷积后的特征图




图 5.3 经过残差层 layer3 特征图

图 5.4 和图 5.5 为经过第二层和第三层残差网络模块输出的特征，随着网络层的逐渐加深，图像的分辨率越来越低，底层特征逐渐减少，高层语义信息逐渐增加，提取特征也越来越抽象。




图 5.4 经过残差层 layer4 的特征图




图 5.5 经过残差层 layer5 的特征图

5.2.3 训练结果分析

人脸识别网络训练和测试的网络损失如图 5.7，网络测试准确度如图 5.8 所示。在我们的评估数据集中，测试准确性为 90.58%，达到了我们的面部识别要求。




图 5.7 网络训练和测试损失




图 5.8 人脸识别网络测试精度

5.3 检测和级联跟踪实验

5.3.1 驾驶员数据集采集

本文提出基于 DeepSORT 和 KCF 级联跟踪算法，旨在减少跟踪过程漏检，在本章中进行仿真实验，对比级联跟踪结构和原始 DeepSORT 跟踪性能。

据了解，没有专门针对驾驶员的面部跟踪数据集。本文根据实验室现

有实验设备，从科学车辆驾驶模拟器(Scientific Vehicle Driving simulator)中收集跟踪数据，驾驶模拟器如图 5.9 所示，搭建了一个虚拟驾驶环境，可以让志愿者模拟驾驶过程中的操作，具有安全和便捷性。




图 5.9 驾驶模拟器

因此，我们征集志愿者，并且使用驾驶模拟器从不同角度收集驾驶员的面部跟踪数据集。驾驶模拟器上前面安装有 3 个视角的摄像机，驾驶员的前方作为参考方向，照相机 1 放置在驾驶员的左上侧，与驾驶员的正前方大约 60° 的角度，垂直角度为 30° ，照相机 2 放置在驾驶员正前方的仪表板上，与驾驶员正前方成 0° 角，垂直角为 -10° ，摄像机 3 放置在驾驶员的右上角，与驾驶员的正前方大约 30° 的角度垂直于驾驶员前方，垂直角度约为 10° 。收集了 20 名驾驶视频的志愿者，其中包括 14 名男性志愿者和 6 名女性志愿者。图 5.10 展示了每个角度摄像机志愿者分配数据。




图 5.10 三个角度摄像机志愿者人数

最终，我们获得了 20 个在 3 个角度的科学车辆驾驶模拟器上行驶的志愿者的视频数据，每个视频均以 1200 帧剪切 1 分钟，每个角度志愿者收集视频数据如图 5.11 所示。




图 5.11 三个摄像机角度志愿者驾驶姿态

5.3.2 实验结果及分析

对于同一驾驶员，本文绘制包括融合了 MTCNN 和 DeepSORT 检测跟踪结果，以及本文设计的级联跟踪结果。实验期间，志愿者将摇头和低头，并操作方向盘、油门、手刹和制动器。

在实验中，MTCNN 检测结果使用白色边界框绘制，DeepSORT 跟踪结果使用蓝色边界框绘制，而本文级联跟踪结果使用绿色边界框绘制。

本文的实验结果与原始 MTCNN 检测算法连接的 SORT 跟踪算法进行了比较。驾驶员面部检测和跟踪的实验结果 5.12 所示。




图 5.12 比较实验

在持续跟踪过程中，产生检测失败、跟踪框消失、ID 切换几种现象。

当驾驶员的面部检测失败时，原始的 DeepSORT 算法只能保留检测信息以进行匹配。它是一种依赖于检测的跟踪算法，当检测算法实现失败时，它将丢失驾驶员面部信息。我们的级联算法可以解决这个问题。当人脸检测失败时（没有白色和蓝色边界框，只有绿色边界框），我们的跟踪算法的结果如图 5.13 所示。



图 5.13 只有绿色边界框

原始的 DeepSORT 程序在连续的视频跟踪中将同一个驾驶员识别为多个驾驶员，如图 5.14 和 5.15 所示。在蓝色框连续几帧丢失之后，图 5.14 蓝色框的 ID 从 1 变到了 4，3 次将该驾驶员的面部识别为另一驾驶员的面部。图 5.15 蓝色框 ID 从 1 变成了 7，6 次将该驾驶员的面部识别为另一驾驶员的面部。

然而本文设计的级联跟踪算法绿色跟踪框一直保持 ID 是 1。与之相比，我们的跟踪算法更加稳定，在跟踪期间 ID 信息没有发生切换，身份信息没有更改。



图 5.14 ID 切换



图 5.15 ID 切换

本文提出的方法主要是解决检测问题和跟踪丢失情况，因此我们比较丢失跟踪的次数来验证算法的性能。

图 5.16 记录了用于在不同角度进行驾驶员面部检测和跟踪的丢失帧的数量。相机 1 中，本文漏检数量为 1248 帧，相比原来的结构减少了 2400 帧，减少了 65.8%；相机 2 中，本文漏检数量为 481 帧，相比原来的结构减少了 328 帧，减少了 40.5%；相机 3 中，本文漏检数量为 230 帧，相比原来的结构减少了 204 帧，减少了 47%。

本文级联算法在三个相机漏检总数为 1959 帧，原来的 MTCNN-DeepSORT 跟踪算法漏检总数为 4891 帧，本文算法漏检总数减少了 60%。




图 5.16 驾驶员人脸漏检数据统计

多目标跟踪准确度(Multiple Object Tracking Accuracy, MOTA)是一个非常重要的跟踪指标,这个指标综合了漏报率(False Positive, FP)、误报率(FALSE Negative, FN)、误配率(ID switch)三点因素, MOTA 越接近于 1 表示跟踪器性能越好,公示表示如下:

$$MOTA = 1 - \frac{FN + FP + \emptyset}{T} \quad (5.1)$$

(1) 漏报率: 在本文跟踪过程中, 图像帧具有人脸部分, 但是跟踪器没有检测出来。

(2) 误报率: 在本文跟踪过程中, 图像帧中非人脸部分被标记为人脸, 称为误报率。

(3) $\emptyset$: 指所有帧目标发生跳变数(ID Switch), $\emptyset_t$ 为第 t 帧目标跳变数, 则 $\emptyset = \sum_t \emptyset_t$ 。

(4) T : 指所有帧真正目标数的总和, 假设第 t 帧有 g_t 个目标, 那么 $T = \sum_t g_t$ 。

在我们的实验中: 摄像机 1 共有 12000 帧图像、摄像机 2 共有 8400 帧图像、摄像机 3 共有 3600 帧图像: 分别统计了原始的 MTCNN+DeepSORT 跟踪架构和本文提出的级联跟踪的 MTCNN+KCF-DeepSORT 跟踪架构中漏报帧数、误报帧数和所有帧目标发生跳变数如表 5.4 所示。

表 5.4 实验数据

摄像机	模型	FP/帧	FN/帧	Ø/次	MOTA
Camer1	MTCNN+DeepSORT	3648	354	141	0.655
	MTCNN+KCF-DeepSORT	1248	241	54	0.871
Camer2	MTCNN+DeepSORT	809	0	0	0.904
	MTCNN+KCF-DeepSORT	481	0	0	0.943
Camer3	MTCNN+DeepSORT	434	278	113	0.771
	MTCNN+KCF-DeepSORT	230	117	17	0.898

根据实验数据和公式(5.1)计算 MOTA 数值, 由表 5.4 可以看出, 在同一个摄像机采集的视频中进行对比跟踪实验, 本文提出的级联跟踪算法跟踪准确度都高于原始的 DeepSORT 结构, 跟踪准确度最高达到 0.943, 并且 ID 跳变次数也减少, 说明本文设计的人脸重识别网络结构在跟踪过程中发挥了重要作用, 并且在 DeepSORT 中发挥了特征提取和匹配的作用。而且本文提出的结构在三个角度跟踪准确度最低为 0.871。针对漏检问题, 本文提出的方案在原来基础上减少 60%的漏检数量。

因此, 经过验证, 本文提出的级联跟踪算法是有效的, 且可以实现更稳定的驾驶员面部匹配和跟踪, 相较 DeepSORT 算法具有更好的跟踪效果。

同时注意到一个问题, 由于摄像头具有不同角度安装, 正对驾驶员的摄像机 Camera2 跟踪效果最好, 几乎没有产生误报和 ID 切换, 在 Camera1 和 Camera3, 都有不同程度的误报和 ID 跳变, 原因是因为在训练人脸识别深度网络时候, 准备的人脸数据集正脸偏多, 所以训练出来的数据对正脸的跟踪效果比较好, 也间接引发了对车内驾驶员检测摄像头安装角度问题或者训练数据丰富性的思考。

5.4 小结

本章首先介绍了实验平台软硬件环境配置以及人脸重识别网络的训练方法和训练结果, 并且得到了 90.58%的人脸特征提取检测精度。其次本章着重介绍了驾驶员人脸数据集采集的平台, 以及视频帧数据处理方法。最后对 MTCNN 和级联人脸跟踪的融合算法进行测试, 并且与原来的 MTCNN+DeepSORT 跟踪算法进行对比试验, 得到本文提出的方法跟踪过程中人脸漏检总数量减少了 60%, 级联人脸跟踪准确度最高达到了 0.943。

在同一相机角度下，原来的跟踪算法的跟踪准确度最高只有 0.904，提高了 4%。而且每个相机角度的跟踪实验结果都表明本文的级联跟踪准确度高于原来的跟踪算法的跟踪准确度。

总结与展望

针对驾驶员在驾驶过程中产生的诸如疲劳驾驶等各种情况，人们开展了各种研究，基于驾驶员人脸图像的研究方法需要使用人脸检测技术，但是只用检测方法具有极大的不稳定性，人们逐渐将检测和跟踪算法结合起来，但是也产生了一些问题。常用的基于检测的跟踪算法过于依赖检测器，在检测信息丢失的情况下无法进行跟踪，这就给驾驶员的检测技术带来缺点。本文提出的基于级联跟踪的人脸检测和跟踪方法，使得检测信息丢失的情况下能够使用上一帧信息继续跟踪，有效改善人脸跟踪过程中漏检，为在此基础上展开的各种研究提供了更可靠的选择。本文主要的工作总结如下：

（1）研究人脸检测和跟踪算法的应用领域以及进行研究痛点和盲点分析，结合国内外人脸检测和跟踪的研究现状，提出本文针对驾驶员人脸检测和跟踪研究，再根据对基于检测的跟踪方法的缺点分析，提出级联人脸跟踪算法研究目标。

（2）展开基于 CNN 的人脸检测算法分析，详细介绍了人脸检测算法 MTCNN 工作原理及检测过程。同时介绍了基于检测的跟踪方法 DeepSORT，分析了其跟踪原理和优缺点。又详细介绍了传统判别式跟踪算法 KCF，为级联架构设计奠定了理论基础。

（3）提出针对驾驶员人脸跟踪的改进 DeepSORT 算法，基于宽残差结构原理，设计深层人脸特征提取网络，用于数据关联和轨迹匹配，并有效减少 ID 跳变，还设计级联跟踪架构中跟踪轨迹管理办法。

（4）通过常用的人脸数据集进行数据处理，制作用于人脸特征提取网络训练和测试的数据集，并对人脸重识别网络层进行特征可视化分析，人脸识别准确度达到 90.58%，而且在级联跟踪算法测试过程中，ID 跳变减少，证明了人脸特征提取网络的有效性。

（5）采集驾驶员驾驶视频数据集。利用驾驶模拟器，进行志愿者实验，收集驾驶员驾驶过程中人脸数据，并且对本文设计的级联跟踪算法进行视频流测试并进行结果分析，漏检总数减少了 60%，跟踪准确度最高达到 94.3%，证明级联跟踪算法是有效的，可以应用于驾驶员人脸跟踪，并且效果优于 DeepSORT 跟踪算法。

综合考虑本文所做的工作，本文主要的创新点有三点：其一，针对基于检测的跟踪方法在跟踪过程中漏检问题，提出级联跟踪算法，在检测信息丢失时，DeepSORT 跟踪算法失败，从而启动 KCF 跟踪器，能够使用

保存的上一帧信息主动完成人脸搜索和跟踪，完成级联跟踪算法数据关联设计。并且通过级联跟踪架构设计和驾驶员人脸跟踪实验证明级联算法的有效性。其二，设计人脸识别深层网络，并成功进行人脸特征提取并成功应用于跟踪过程中的数据匹配部分，减少 ID 跳变。其三，采集多角度驾驶员驾驶视频数据并用于测试跟踪算法的性能。

虽然本文研究的级联驾驶员人脸跟踪算法较原来的算法跟踪性能得到提高，但是还有以下几个方面不足，可以展开研究：

（1）基于 MTCNN 人脸检测算法的利用不够充分，该算法还具有关键点标记任务，可以扩展此想法，应用多关键点检测，并且可以考虑基于检测关键点的跟踪，可以用于疲劳驾驶检测。

（2）本文采集的驾驶员数据集有限，且男女比例不均衡，并且具有不同角度摄像机的安装，经过实验发现，因为人脸识别网络数据集正脸姿态偏多，不同位置摄像头对人脸识别有影响。在今后可以根据车内摄像头安装位置，或者扩充侧脸数据，有针对性的完成人脸模型训练。

（3）没有考虑车夜间行车情况下驾驶员的人脸跟踪，可以基于这个考虑，加强对夜间图像的处理，优化人脸检测和人脸重识别网络对夜间图像人脸检测。

参考文献

- [1] 公安部交通管理局.全国道路交通统计年报[J].2020 年.
- [2] 公安部.中华人民共和国道路交通事故统计年报[J].北京:公安部交通管理局, 2019.
- [3] 李都厚, 刘群, 袁伟, 等. 疲劳驾驶与交通事故关系[J]. 交通运输工程
- [4] 尹苍穹, 王玉龙, 裴锋, 等. 基于深度学习的嵌入式驾驶员疲劳检测系统[C]. 2020 中国汽车工程学会年会暨展览会.
- [5] 王先梅, 梁玲燕, 王志良, 等. 人脸图像的年龄估计技术研究[J]. 中国图像图形学报, 2012(06):603-618.
- [6] 唐诗超. 基于视频监控的驾驶员分心状态检测方法的研究与实现[D]. 电子科技大学, 2020.
- [7] Rowley H A, Baluja S, Kanade T. Neural Network-Based Face Detection[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 1996.
- [8] Bo W, Ai H, Chang H, et al. Fast rotation invariant multi-view face detection based on real Adaboost[C]. IEEE International Conference on Automatic Face & Gesture Recognition. IEEE, 2004.
- [9] 梁路宏, 艾海舟, 何克忠, 等. 基于多关联模板匹配的人脸检测[J]. 软件学报, 2001(01): 94-102.
- [10] Freund Y, Schapire R E. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting[C]. Proceedings of the Second European Conference on Computational Learning Theory. Springer-Verlag, 1995.
- [11] Schapire R E, Singer Y. Improved Boosting Algorithms Using Confidence-rated Predictions[J]. Machine Learning, 1999, 37(3):297-336.
- [12] Li S Z, Long Z, Zhang Z Q, et al. Statistical learning of multi-view face detection[C]. European Conference on Computer Vision. Springer, Berlin, Heidelberg, 2002.
- [13] 江伟坚, 郭躬德, 赖智铭. 基于新 Haar-like 特征的 Adaboost 人脸检测算法[J]. 山东大学学报: 工学版, 2014(2 期):43-48.

- [14] Yang B, Yan J, Zhen L, et al. Aggregate channel features for multi-view face detection[C]. IEEE International Joint Conference on Biometrics. IEEE, 2014.
- [15] Jia D, Wei D, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2009.
- [16] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2013.
- [17] Krizhevsky A, Sutskever I, Hinton G. ImageNet Classification with Deep Convolutional Neural Networks[C]. NIPS. Curran Associates Inc. 2012.
- [18] Girshick R. Fast R-CNN[J]. Computer Science, 2015.
- [19] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.
- [20] Wang H, Li Z, Ji X, et al. Face R-CNN. 2017.
- [21] Wen Y, Zhang K, Li Z, et al. A Discriminative Feature Learning Approach for Deep Face Recognition[J]. European Conference on Computer Vision, 2016.
- [22] Yang S, Luo P, Loy C C, et al. Faceness-Net: Face Detection through Deep Facial Part Responses[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017:1-1.
- [23] Yang S, Ping L, Loy C C, et al. From Facial Parts Responses to Face Detection: A Deep Learning Approach[C]. IEEE International Conference on Computer Vision. IEEE, 2016.
- [24] Chen C L, Ping L, Chen H. Deep Learning Face Attributes for Detection and Alignment[M]. Springer International Publishing, 2017.
- [25] Najibi M, Samangouei P, Chellappa R, et al. SSH: Single Stage Headless Face Detector[C]. IEEE International Conference on Computer Vision. IEEE, 2017.
- [26] Zhang S, Zhu X, Zhen L, et al. S³FD: Single Shot Scale-Invariant Face Detector[C]. IEEE International Conference on Computer Vision. IEEE, IEEE, 2017.

- [27] 吴素雯, 战荫伟. 基于选择性搜索和卷积神经网络的人脸检测[J]. 计算机应用研究, 2017, 34(009):2854-2857.
- [28] Bai Y, Ghanem B. Multi-Branch Fully Convolutional Network for Face Detection[J]. 2017.
- [29] Yang S, Xiong Y, Chen C L, et al. Face Detection through Scale-Friendly Deep Convolutional Networks[J]. 2017.
- [30] Ranjan R, Patel V M, Chellappa R. HyperFace: A Deep Multi-task Learning Framework for Face Detection, Landmark Localization, Pose Estimation, and Gender Recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2018:1-1.
- [31] Li H, Zhe L, Shen X, et al. A convolutional neural network cascade for face detection[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2015.
- [32] Zhang K, Zhang Z, Li Z, et al. Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks[J]. IEEE Signal Processing Letters, 2016, 23(10):1499-1503.
- [33] Deng J, Guo J, Zhou Y, et al. RetinaFace: Single-stage Dense Face Localization in the Wild[J]. 2019.
- [34] Ciaparrone G, FL Sánchez, Tabik S, et al. Deep Learning in Video Multi-Object Tracking: A Survey[J]. Neurocomputing, 2019, 381.
- [35] Lucas D. An iterative image registration technique with an application to stereo vision[C]. Proc. DARPA Image Understanding Workshop, 1981.
- [36] Bair W, Cavanaugh J R, Movshon J A. Advances in Neural Information Processing Systems[M]. Morgan Kaufmann Publishers, 2001.
- [37] D Comaniciu, Meer P. Mean shift: a robust approach toward feature space analysis[J]. IEEE Trans Pattern Analysis & Machine Intelligence, 2002, 24(5):603-619.
- [38] 张涛, 蔡灿辉. 基于多特征 Mean Shift 的人脸跟踪算法[J]. 电子与信息学报, 2009, 31(008):1816-1820.
- [39] Bolme D S, BA Draper, Beveridge J R. Average of Synthetic Exact Filters[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2009.
- [40] Bolme D S, Beveridge J R, Draper B A, et al. Visual object tracking using adaptive correlation filters[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2010.

- [41] Henriques J F, Caseiro R, Martins P, et al. High-Speed Tracking with Kernelized Correlation Filters[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2015, 37(3):583-596.
- [42] 李睿. 深度学习与相关滤波融合的行人跟踪算法研究[D].西安科技大学, 2020.
- [43] Feichtenhofer C, Pinz A, Zisserman A. Detect to Track and Track to Detect[J]. IEEE, 2017.
- [44] Bewley A, Ge Z, Ott L, et al. Simple Online and Realtime Tracking[C]. IEEE International Conference on Image Processing. IEEE, 2016.
- [45] Wojke N, Bewley A, Paulus D. Simple Online and Realtime Tracking with a Deep Association Metric. IEEE, 2017:3645-3649.
- [46] Bertinetto L, Valmadre J, Henriques J F, et al. Fully-Convolutional Siamese Networks for Object Tracking[C]. European Conference on Computer Vision. Springer, Cham, 2016.
- [47] 刘鹏. 基于视频序列的目标人脸跟踪技术的研究[D]. 新疆大学, 2019.
- [48] Mcculloch W S, Pitts W H. A logical Calculus of Ideas Immanent in Nervous Activity[J]. The Bulletin of Mathematical Biophysics, 1942, 5:115-133.
- [49] Minsky, Marvin and Papert, Seymour. Perceptrons: An Introduction to Computational Geometry. The MIT Press, 1969.
- [50] Buscema M. Back Propagation Neural Networks[J]. International Journal of the Addictions, 1998, 33(2):233-270.
- [51] Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104(2):154-171.
- [52] 高俊艳. 基于视频流的实时人脸检测与跟踪[D].广东工业大学, 2019
- [53] Jain V, Learned-Miller E. Fddb: A benchmark for face detection in unconstrained settings. 2010.
- [54] Hong-Wei, N., and Stefan, W. "A Data-Driven Approach To Cleaning Large Face Datasets Advanced Digital Sciences Center (ADSC)," in International Conference on Image Processing (ICIP), in University of Illinois at Urbana.
- [55] Yang S, Luo P, Loy C C, et al. WIDER FACE: A Face Detection Benchmark[J]. IEEE Conference on Computer Vision & Pattern Recognition, 2016:5525-5533.

- [56] 梁路宏, 艾海舟. 基于人脸检测的人脸跟踪算法[J]. 计算机工程与应用, 2001(17):42-45.
- [57] Xiang Y, Alahi A, Savarese S. Learning to Track: Online Multi-object Tracking by Decision Making[C]. IEEE International Conference on Computer Vision. IEEE, 2015.
- [58] 苏祺翔. 基于 KCF 跟踪算法的行人数量统计[D]. 哈尔滨工程大学.2018.
- [59] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2016.
- [60] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, PP(99):2999-3007.
- [61] Dong Y, Zhen L, Liao S, et al. Learning Face Representation from Scratch[J]. Computer Science, 2014.
- [62] A Martínez, Benavente R. The AR Face Database[J]. Cvc Technical Report, 1998, 24.
- [63] Ruder S. An overview of gradient descent optimization algorithms. 2016.
- [64] Paras. Stochastic Gradient Descent[J]. Optimization, 2014.
- [65] Mu L. Efficient mini-batch training for stochastic optimization[C]. Acm Sigkdd International Conference on Knowledge Discovery & Data Mining. ACM, 2014.
- [66] Mu L. Efficient mini-batch training for stochastic optimization[C]. Acm Sigkdd International Conference on Knowledge Discovery & Data Mining. ACM, 2014.
- [67] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. JMLR.org, 2015.

附录 A 攻读学位期间完成的主要成果

- [1] Liao J, Wang Q, Cao L, et al. MTCNN-KCF-deepSORT: Driver Face Detection and Tracking Algorithm Based on Cascaded Kernel Correlation Filtering and Deep SORT[C]. WCX SAE World Congress Experience. 2020.
- [2] 曹立波, 向国梁, 张乐祺, 等. 一种融合 UWB 和视觉信息的行人预警方法[J]. 汽车工程学报, 2020(4).

致 谢

麓山巍巍，湘水泱泱。宏开学府，济济沧沧。

时光荏苒，在湖南大学已经度过了三年的时光。我对这片土地以及这里的朋友产生了深厚的感情。在研究生就读期间，我延续了对汽车的热爱，并确立了研究方向，以严谨的科研态度，踏实的作风完成自己每一项任务，更对智能驾驶领域有了充分的了解，对未来职业有了清晰的规划。

首先，我要感谢导师曹立波教授，曹老师带领的科研团队具有的不断探索求新的科研态度，勤恳踏实的工作作风，更是提供了非常多的科研项目，结合每位同学的兴趣和特点制定了科研方向。感谢曹老师在日常的悉心教导和答疑，在学术上的引领和对学生生活的关心。同时特别感谢同时曹老师耐心指导毕业论文的研究方向和解答论文写作中出现的问题。

其次，特别感谢廖家才博士，廖家才师兄在科研中的认真努力给我树立了良好的榜样，在科研项目中起到领头羊作用，更是关照到每一个人，耐心解答学习中产生的疑问。在师兄的帮助下，我顺利展开科研任务，并且师兄在我撰写论文期间给予非常大的帮助。在生活中师兄更是非常温和宽厚，经常组织小组成员小聚，给了我们家一样的温暖。我还特别感谢李伟博士、冯谢星博士、吴强、张乐祺、向国梁、罗荣华等师兄师姐对我的帮助。感谢同届李修远、罗景、宁东宇、徐晗、王桢、徐梓皓、洪班豪、李超辉等人在学习和求职中对我的陪伴和帮助，感谢我的室友张怡婷、左雯、阳琴在学习生活中的陪伴和关心。感谢人美心善的何珂言，在我实习期间给予我非常大的关心和帮助。

最后，感谢我的父母、哥哥姐姐等家人们和男朋友张国庆，是他们对我无条件的支持和鼓励，让我能够一直充满爱和自信的面对生活的困难和挑战，在学习上追求进步，在生活中追求美好，让我坚定的相信自己努力就会有收获。

谢谢母校湖南大学，她以开放包容的姿态为大家提供了学习的平台和学习资源，祝福学校越来越好。十分感谢审阅我的论文并提出修改意见的各位老师和专家们，非常感谢！

今后，我将谨遵父母师长教诲，让自己学有所长、学有所用。

王秋丽

2021年4月写于湖南大学